

2020 年度 卒業論文

複数の Coaxial-UAV による協調搬送 に向けた姿勢制御

Attitude Control for Cooperative Transportation
by Multiple Coaxial-UAVs

東京電機大学工学部第二部 電気電子工学科

指導教員： 教授 五十嵐 洋

研究室名： 協調ロボティクス研究室

16NE008 井上 温

2021 年 1 月 31 日 提出

研究概要

UAV は様々な場面で活用されており、荷物搬送に利用することで既存の搬送手段の代替とすることが可能となる。これまでの UAV による搬送では、搬送可能な重量に制限がある。そのため、複数機を用いた搬送について研究が行われてきた。従来の複数機を用いた研究では、UAV どうしの位置関係の把握や、タスク全体の厳密なシステムモデリングが必要であった。そこで、本研究では Coaxial-UAV を複数用いた協調搬送システムを提案する。本稿では、STA アーキテクチャを用いて Coaxial-UAV の制御を行う。結果として、STA アーキテクチャによる UAV 制御法を構築し、2 台を用いた 1DoF での制御可能性を示唆した。

目次

第1章	序論	1
1.1	背景	2
1.2	本研究の目的	4
第2章	提案手法	5
2.1	STA アーキテクチャ	6
2.1.1	概要	6
2.1.2	UAV への適用	7
2.2	Neural Network	9
第3章	システム	10
3.1	UAV の概要	11
3.2	Contra-Rotating Motor	14
3.3	センシング	15
3.4	コントローラ	16
3.5	Neural Network	18
第4章	実験と結果	20
4.1	単機によるホバリング制御	21
4.1.1	実験手法	21
4.1.2	事前実験	23
4.1.3	実験結果	25
4.2	複数機による姿勢制御	27
4.2.1	実験手法	27
4.2.2	事前実験	29
4.2.3	実験結果	31

第5章 結論	34
第6章 今後の展望	35

第1章 序論

本研究では，UAV を用いた搬送において，複数の Coaxial-UAV を用いることができる制御手法を提案する．本章では，以下の項目を述べる．

- 研究背景
- 本研究の目的

1.1 背景

Unmanned Aerial Vehicle(UAV)を活用するシステムは、農薬散布用 UAV や空撮用 UAV などの専用デバイスを搭載するもののほか、建造物の老朽化を検査するための UAV などがある。さらに、UAV を荷物搬送に活用することで、新しい搬送手段として利用できることが期待されている [1]。インプレス社による試算では、UAV に関する市場規模は図のように拡大すると予測されている。しかしながら、UAV を用いた運搬市場は多分野に比べ規模が小さい。この要因として、従来の UAV を用いた活用法ではマルチコプタによって行われており、搬送作業においては、積載物の重量に応じてよりペイロードの大きい UAV を導入する必要がある。ペイロードを得る手法として、UAV の機体数を増やし、協調搬送を行うことによって負荷を分散することが考えられる。この手法は多くの研究が行われている [2][3]。これらの研究では、ケーブルを用いて一つの荷物を複数の UAV で協調搬送を行う。しかしながら、協調搬送のために各 UAV の相対的な位置関係を把握する必要があり、多くのセンサを必要とする。

これに対し筆者らは、Coaxial-UAV を複数機用いることで、搬送作業が可能であると考案した。積載物に対して複数の UAV が直接装着することで搬送を可能とする。このとき、UAV を装着する箇所自由度を持たせることで、汎用的な利用が可能となると考える。

同軸二重反転式 UAV に関する研究は複数行われている [4][5][6]。これらは二重反転モータを用いることで、単機での飛行を実現している。しかしながら、複数機を用いた運搬作業に関する研究は行われておらず、更に、UAV の配置を考慮しないシステムは確認されていない。




図 1.1: Market size of UAVs by segment

1.2 本研究の目的

本研究では，複数機による協調搬送を可能とする UAV とそのシステムの開発における初期研究として，「空気を読める」 (Sense The Atmosphere: STA) アーキテクチャ[7] による，ニューラルネットワーク (Neural Network: NN) を用いた制御手法を提案し，その制御性の検証を行う．

第2章 提案手法

本研究で提案する Coaxial-UAV の制御手法について，本章では，以下の項目を述べる．

- STA アーキテクチャ
- Neural Network

2.1 STA アーキテクチャ

2.1.1 概要

本研究の想定する環境では，搬送する物体，UAV の台数，配置された位置によって，ある一つの UAV に対する状況は容易に変化する．そのため，画一的に設計されたシステムに対する評価関数は，想定通りに動作しない可能性がある．そこで本研究では，STA アーキテクチャを用いる．STA アーキテクチャでは，NN を常に更新することで，環境の変化を考慮したモデルを構築する．構築されたモデルを用いて，動作指令を実行した際に発生する状態の変化を予測する．この変化を予測値に依存する評価関数に入力し，最小二乗法によりこの関数を最小化する指令値を決定する．これを繰り返すことにより，目標とする状態に近づけることを可能とする．

2.1.2 UAV への適用

UAV に STA アーキテクチャを適用させるには、目標の姿勢角との角度誤差を最小化するフィードバック情報を算出すれば良い．図 2.1 に STA アーキテクチャと NN を利用した時のブロック図を示す．

本稿では、同一の NN を 2 つ構築し、UAV へ入力された回転数 τ から $\pm\Delta_\tau$ だけ変化させた回転数とその他の共通の要素をそれぞれの NN に入力する．これにより予測される姿勢角 $\hat{\eta}$ を用いて誤差を最小化する STA アーキテクチャを構築する．その時の NN への入力要素である回転数 τ は、

$$\tau^\pm[k] = \tau[k] \pm \Delta_\tau, \quad (2.1)$$

と表される．ここで、 k は予測の元となるステップである．姿勢角の予測値 $\hat{\eta}$ に依存する評価関数は、回転数 τ から $\pm\Delta_\tau$ だけ変化させた時、

$$J^\pm = \mu_p (\eta_{ref} - \hat{\eta}^\pm)^2 + \mu_d (\dot{\eta}_{ref} - \dot{\hat{\eta}}^\pm)^2, \quad (2.2)$$

と表される．ここで、 η_{ref} は目標角度、 $\dot{\eta}_{ref}$ は目標角速度、 $\hat{\eta}$ は NN によって予測した角度、 $\dot{\hat{\eta}}$ は角速度、 μ_p は角度誤差の重み係数、 μ_d は角速度誤差の重み係数である．また、UAV の姿勢角は Euler 角 $\eta = [\phi \ \theta \ \psi]$ で表現される．この評価関数によって得られた誤差を最小化するための $\tau[k+T]$ を次式によって決定する．

$$\tau[k+T] = \tau[k] - \mu_\tau \left(\frac{\partial J}{\partial \tau} \right). \quad (2.3)$$

$$\frac{\partial J}{\partial \tau} = \frac{J^+[k+T] - J^-[k+T]}{2\Delta_\tau}. \quad (2.4)$$

ここで、 μ_τ はタスクに依存する正の重み係数である．




图 2.1: Block diagrams of the UAV control model for feedback and learning mode.

2.2 Neural Network

STA アーキテクチャを用いて UAV を設定された目標の姿勢角 η_{ref} に向けて制御を行うためには、現在の姿勢角 η において、モータ回転数 τ を変化させた時における未来の姿勢角 $\hat{\eta}$ を予測する必要がある。また、環境の変化を考慮した予測モデルを構築するためには、時系列において過去の情報を関連づける必要がある。そのため、本研究では時系列を考慮することが可能である Recurrent Neural Network(RNN) の勾配消失問題を解決した、Long Short-Term Memory(LSTM) を用いて NN を構築し、時系列を考慮した学習および予測を行う [8]。この時の NN による予測値 $\hat{\eta}$ は、

$$\hat{\eta} = f_{NN}(X) \quad (2.5)$$

となる。ここで、 $f_{NN}(\cdot)$ は一般化した非線形関数、 $X \in R_t^n$ は NN の予測に必要な N 個の入力変数、時系列長 t であり、出力と教示の平均二乗誤差が最小となるように学習を行う。

第3章 システム

本研究で用いる Coaxial-UAV と使用する Neural Network について、本章では、以下の項目を述べる．

- UAV の概要
- センシング
- コントローラ
- Neural Network

3.1 UAV の概要

本研究では、Contra-rotating Motor と 9 軸慣性測定装置によって構成される Coaxial-UAV を利用した。

本研究において、1 機による制御検証に用いた Coaxial-UAV の仕様を表 3.1 に示す。Coaxial-UAV の外観を図 3.1 に示す。

単機による制御検証後、Contra-rotating Motor の仕様上、滑りが発生していることが確認された。そのため、使用するモータの変更を行った。複数機による制御検証に用いた Coaxial-UAV の仕様を表 3.2 に示す。Coaxial-UAV の外観を図 3.2 に示す。

また、システム全体のブロックダイアグラムを図 3.3 に示す。

表 3.1: UAV specifications used for 1DoF task on a single unit

Parts	Ratings
Coaxial Motor	AEO, CRM2405-1500KV
2 Propellers	GWS, DD-8040
2 Motor Drivers	STMicroelectronics STEVAL-ESC001V1
Micro Controller	STMicroelectronics NUCLEO-F767ZI
9-Axis IMU	TDK InvenSense, MPU9250

表 3.2: UAV specifications used for 1DoF task on multiple units

Parts	Ratings
Coaxial Motor	Himax, CR2805-1430
2 Propellers	APC, A0705E
2 Motor Drivers	STMicroelectronics STEVAL-ESC001V1
Micro Controller	STMicroelectronics NUCLEO-F767ZI
9-Axis IMU	TDK InvenSense, MPU9250



图 3.1: Coaxial-UAV 用于单单元实验





图 3.2: Coaxial-UAV 用于多单元实验



☒ 3.3: System diagrams

3.2 Contra-Rotating Motor

本研究では、二重反転モータを用いている。これは、同軸上に2つの回転軸をもうけ、互いに逆方向へ回転させることによって、回転運動により発生するカウンタートルクの相殺を行う。また、互いの回転速度を変化させるとこにより、Yaw 軸の制御を単体で行うことが可能となる。さらには、省スペースで推力を増加させることが可能となる推進装置である。

二重反転モータは、単機による実験では、最大 334 W / 11400 RPM である AEO 社のモータを使用した。また、複数機による実験では、最大 120 W / 20000 RPM である Himax 社のモータを使用した。

3.3 センシング

姿勢角は，UAV に搭載された 9 軸慣性計測装置 (Inertial Measurement Unit: IMU) によって測定された加速度，角速度および地磁気から Madgwick Filter を通し，Euler 角に変換することで推定を行う [9]. 9 軸 IMU には，図 3.4 に示す TDK InvenSense 社の MPU9250 を使用し，後述するマイコンボードと SPI 通信を用いて測定データを取得した.



図 3.4: MPU9250

3.4 コントローラ

センシングの結果から推定された姿勢角，コンピュータにより出力されるモータ指令回転数は，マイクロコントローラを通じてPCと双方向通信を行う．本研究では，図 3.5 に示す STMicroelectronics 社の Nucleo-F767ZI を利用した．モータドライバは図 3.6 に示す STMicroelectronics 社の STEVAL-ESC001V1 を利用した．マイコンボードとモータドライバ間はPWMを用いて指令値を送信し，コンピュータとマイコンボードはUDP/IP 通信を用いる．なお，UDP/IP 通信は 100 Hz で行う．




图 3.5: NUCLEO-F767ZI




图 3.6: STEVAL-ESC001V1

3.5 Neural Network

本研究で用いるプログラミング言語はC++17であり，リアルタイムに実験タスクと並行して行う必要があることから，本研究では機械学習フレームワークとしてPytorch C++を利用した．単機による実験時におけるNNについて詳細を表3.3に示す．

単機による制御検証後，NNの予測精度を向上するため，入力変数に目標姿勢角と実際の姿勢角との誤差を追加した．また，中間層の数を変更した．この時のNNの詳細を表3.4に示す．どちらのNNにも，最適化アルゴリズムにはAdamを利用し，活性化関数にはtanh関数を利用した[10]．

表 3.3: NN settings used for 1DoF task on a single unit

Settings	Values
Input Layer	4
Input Steps	10
Middle Layer	160
Output Layer	1
Output Steps	10
Optimizer	Adam
Learning Coefficient	0.001
Batch size	1
Step Gain	1
Input Signal	Past roll angle, Past roll angular velocity Past roll angular acceleration, Past rotational speed
Output Signal	Roll angle

表 3.4: NN settings used for 1DoF task on multiple units

Settings	Values
Input Layer	5
Input Steps	10
Middle Layer	33
Output Layer	1
Optimizer	Adam
Learning Coefficient	0.001
Batch size	1
Step Gain	1
Input Signal	past angle, past angle error with the target, past angular velocity, past angular acceleration and past rotational speed
Output Signal	Roll angle

第4章 実験と結果

本研究で提案する制御システムによって Coaxial-UAV の制御が可能であるか検証した。本章では，以下の項目を述べる．

- 単機による姿勢制御
- 複数機による姿勢制御

4.1 単機によるホバリング制御

本実験では，単機による姿勢制御が可能であるか検証を行った．本節では，実験の手法と結果について述べる．

4.1.1 実験手法

目標とする姿勢角へ達成するようにタスクを行う．図 4.1 にタスク全体像を示す．UAV は 1DoF に拘束され， $\pm 0.7 \text{ rad}$ の可動範囲に制限される．

本実験の時間は設定せず，はじめの 10 秒間にモータを浮上しはじめない程度である 3000 rpm で回転させる．10 秒から NN の学習を始め，同時に任意の回転数を連続的に与えることで上下の動作を行う．その後の 20 秒から STA アーキテクチャを適応し，バックグラウンドで学習を行いながら STA アーキテクチャによって回転数を変化させる．各実験の目標角度 η_{ref} はホバリングを目的とし， 0 rad とした．また，目標角速度 $\dot{\eta}_{ref}$ は目標角で静止することを目標とすれば良いため， 0 rad/s とした．なお，モータの回転数が 8000 rpm 以上となるとテストベンチの天板に接触し，正常な実験が行えないことから，エラーとして実験を終了する．本実験における各パラメータは， $\mu_p = 500$ ， $\mu_d = 0.0001$ ， $\mu_\tau = 600$ ， $\Delta_\tau = 500$ とした．




图 4.1: Test bench used for experiments with a single unit

4.1.2 事前実験

事前実験として，NNによって姿勢角の予測が可能か検証を行った．はじめの10秒間にモータを浮上し始めない程度である3000 rpmで回転させる．10秒から60秒までを学習時間とし，その後の20秒で学習の確認を行う．学習時間中のモータへの回転数指令は手動にて行う．回転数は3000 rpmから8000 rpmの間で任意に変化させた．実験結果を図4.2に示す．結果より，実際の値に対して予測した値が追従していることがわかる．また，NNによる予測された値と実際の値の誤差をヒストグラムにしたものを図4.3に示す．これより，0を中心に正規分布していることがわかる．これらの結果より，今回用いるNNによって，姿勢角の予測が可能であるといえる．




图 4.2: Confirmation of UAV attitude angle prediction with a single unit




图 4.3: Histogram of UAV attitude angle prediction with a single unit

4.1.3 実験結果

前述した実験手法による実験結果を図 4.4 に示す．姿勢角の変化より，制御は安定せず，目標角に収束しないことが確認できる．また，20 秒以降に式 (2.4) によって得られた値を図 4.5 に示す．これは，次ステップの回転数を決定する値であり，特定の姿勢角において正または負の値を出力することによって回転数が増減する．これらの結果より，制御は安定せず，発振していることが確認できる．しかしながら，図 4.5 より，目標角である 0 deg に対して回復を試みることが確認できる．ホバリングを実現するには，図 4.5 における動作範囲を小さくするように各パラメータを可変させることで制御が可能であると考えられる．




图 4.4: Trajectory of the angle and rotational speed with a single unit




图 4.5: Value of partial derivative for least-squares method with a single unit

4.2 複数機による姿勢制御

複数機による姿勢制御が可能であるか検証を行った．本節では，実験の手法と結果について述べる．

4.2.1 実験手法

本実験では，目標とする姿勢角へ達成することを目標としたタスクを行う．図 4.6 にタスク全体像を示す．UAV は 1DoF に拘束され， ± 0.5 rad の可動範囲に制限される．中心に配置されたパンチングメタルの穴を用いて，UAV を任意の箇所に配置することを可能とした．


実験は 140 秒間に設定し，はじめの 20 秒間で UAV を起動する．20 秒から 10 秒間，NN の事前学習として，UAV に回転数を sin 波形のように入力し，動作を学習する．その後，110 秒間のタスクを行う．目標とする姿勢角は 0 rad, ± 0.25 rad とした，UAV 間の距離は中心から 1:1 となるように配置し，ケーブルからの影響をなくすため，ケーブルを設置土台に固定した．本実験における各パラメータは， $\mu_p = 20000$ ， $\mu_d = 0.0001$ ， $\Delta_\tau = 100$ とした．また， μ_τ は前述した実験結果より可変させることが有用であると考えられたことから， $\mu_\tau = \tanh(\eta_{ref} - \eta)$ とした．




图 4.6: Test bench used for experiments with multiple units

4.2.2 事前実験

事前実験として、NNによって姿勢角の予測が可能か検証を行った。検証では、任意の回転数を UAV へ指令値として入力し、42 秒間学習および予測を行い、その後 60 秒までを予測のみで出力した。実験結果を図 4.7 に示す。結果より、実際の値に対して予測した値が追従していることがわかる。また、42 秒以降、NN による予測された値と実際の値の誤差をヒストグラムにしたものを図 4.8 に示す。これより、0 を中心に正規分布していることがわかる。これらの結果より、今回用いる NN によって、姿勢角の予測が可能であるといえる。



⊠ 4.7: Confirmation of UAV attitude angle prediction with multiple units



⊠ 4.8: Histogram of UAV attitude angle prediction with multiple units

4.2.3 実験結果

前述した実験手法により、140 秒間の実験を行った結果を図 4.9 に示す。また、実験開始から 30 秒以降に式 2.4 によって得られた値を図 4.10 に示す。図 4.9 より、50-120 秒間において、目標角への追従が確認できる。これより、複数 UAV 環境において姿勢制御が可能であることが示唆された。また、図 4.10 より、UAV 1 および UAV 2 では姿勢角に対して異なる指令値修正を行っていることから、環境に応じた動作生成が可能であることが示唆された。しかしながら、30-50 秒間および 120-140 秒間においては、追従できてないことが確認できた。図 4.10 では、正常に指令値修正を行っていることから、今後は要因を解析する必要がある。






図 4.9: Trajectory of the angle and rotational speed with multiple units



(a) UAV 1



(b) UAV 2

图 4.10: Value of partial derivative for least-squares method with multiple units

第5章 結論

関連研究で行われている，複数の UAV による協調搬送では，群制御によるフォーメーションコントロールを行うことで，搬送を可能としていた．しかしながら，各 UAV の位置情報を正確に把握することが必要であり，これら UAV 群のネットワークを構築する必要があった．そこで本研究では，それぞれの UAV の位置関係や搬送物の重心に依存しない分散システムとして，STA アーキテクチャを用いた協調搬送システムの提案を行い，姿勢制御の可用性を検証した．実験では，1DoF に拘束することができる実験プラットフォームを構築し，単純化された環境での検証を可能とした．次に，制御アルゴリズムにおける，NN を用いた姿勢予測が可能であることを検証し，予測が可能であることを確認した．そこで，実際に複数の Coaxial-UAV を用いて，目標とする姿勢角へ追従可能か検証を行った．その結果，姿勢制御が可能であり，環境に応じた動作生成が可能であることが示唆された．

しかしながら，本検証では UAV 間の距離は 1:1 に固定しているため，任意の配置で制御可能かどうか検証を行う必要がある．さらに，制御アルゴリズムにおいて，評価関数のゲインパラメータは手動で決定したことから，よりさまざまな環境への適応には自動最適化が必要であるといえる．

第6章 今後の展望

今後は、より複雑な環境への適用のため、制御アルゴリズムの拡張を行っていく。具体的には、複数機を用いた 6DoF での姿勢制御を可能としていく。加えて、外乱への対応を行う。現在のシステムでは、外乱が加わった場合、NN の学習に影響を与えることになるため、アウトーループでの外乱除去を検討している。さらに、Coaxial-UAV のパッケージ化を行い、最終的に任意に配置可能な協調搬送システムの構築を行う。

謝 辞

本研究を進めるにあたって、ご指導ご鞭撻を頂きました五十嵐洋教授に心より深い感謝を申し上げます。また、幅広い知識や提案をいただいた協調ロボティクス研究室の皆様に深く感謝いたします。

参考文献

- [1] 春原 久徳, 青山 祐介: “ドローンビジネス調査報告書 2020,” インプレス総合研究所, 2020.
- [2] Behzad Shirani, Majdeddin Najafi, Iman Izadi: “Cooperative load transportation using multiple UAVs,” *Aerospace Science and Technology*, Volume 84, 158-169, 2019.
- [3] Segun O. Ariyibi, Ozan Tekinalp: “Quaternion-based nonlinear attitude control of quadrotor formations carrying a slung load,” *Aerospace Science and Technology*, Volume 105, 2020.
- [4] Fei Wang, Swee King Phang, Jinqiang Cui, Guowei Cai, B. M. Chen, and T. H. Lee: “Nonlinear modeling of a miniature fixed-pitch coaxial UAV,” in 2012 American Control Conference (ACC), pp. 3863 – 3870, 2012.
- [5] M. R. Mokhtari, B. Cherki, and A. C. Braham: “Disturbance observer based hierarchical control of coaxial-rotor UAV,” *ISA Trans.*, vol. 67, pp. 466 - 475, 2017.
- [6] T. Khamvilai, J. B. Mains, M. Z. Miller, and E. M. Feron: “Trajectory Control of a Swashplate-less Coaxial Helicopter Using Nonlinear Techniques,” *IEEE Aerosp. Conf. Proc.*, vol. 2019-March, pp. 1 - 12, 2019.
- [7] 五十嵐 洋: “「空気を读める」システムアーキテクチャ: ヒューマンセンシングとヒューマンモデリングの融合,” [D] 平成29年電気学会産業応用部門大会講演論文集, pp. 47 - 50, 2017.
- [8] F. A. Gers, J. Schmidhuber, and F. Cummins, “Learning to

- forget: Continual prediction with LSTM, ” Neural Comput., vol. 12, no. 10, pp. 2451 - 2471, 2000.
- [9] Sebastian O. H. Madgwick: “An efficient orientation filter for inertial and inertial/magnetic sensor arrays,” Report x-io and University of Bristol (UK), 2010.
- [10] D. P. Kingma and J. L. Ba: “Adam: A method for stochastic optimization,” in 3rd International Conference on Learning Representations, ICLR 2015 - Conference Track Proceedings, 2015.