

口調から言葉の尺度を推定する会話システム

Development of Verbal Communication System to Estimate Probability Range in Tone

17EH064 馬場 柚貴

指導教員 教授 五十嵐 洋

1 はじめに

近年、音声認識を用いたインタフェースが増えており、ロボットに音声を用いて情報を伝達することが身近になっている^[1]。特に機械翻訳や会話システムを用いて家電やタブレット端末を操作することが多くなり、会話システムへの注目がされている。既存製品では、会話システムに多く用いられている技術として音声認識があり、文字情報から話者の伝えたい意図の推定をしている。しかし文字情報からの意図の推定は重要ではあるが、実際の人間同士の会話では、文字情報以外にも話者の思考や感情などの情報を得ることも重要である。よって、会話システムにおいても音声認識による文字情報以外の情報も得ることが必要である。例えば、ボディーランゲージや表情、音声情報の口調などを用いる手法が考えられる。口調は特に、意図を伝える際の言葉に付与される情報の手法として用いられる。そのため本研究では口調に着目し、口調から得られる話者の意図を推定することを目的とする。

2 関連研究

音声情報から文字以外の情報を推定する研究として、感情の推定をする音声感情認識の研究などが挙げられる。Y.Xie, R.Liang らの研究では、音声感情認識を行う際に学習器として long short-term memory(LSTM)を用いている^[2]。LSTM を用いることで、研究者の学習方法に対する経験則があまり必要ではなくなった。さらに、2-layerLSTM と Attention Mechanical を用いた Attention-Based LSTM により、精度の高い認識率を出すことに成功した。しかし感情は話者の伝えたい意図が感情でない限り、情報の重要度が高くないものになってしまう。そこで本研究では口調から得られる情報の中で、話者の伝えたい情報として会話で利用される物事の尺度に着目する。

3 提案手法

3.1 音声特徴量

関連研究などの音声認識では音声特徴量として INTERSPEECH(2009) 等の特徴量セットが用いられている^[3]。基本周波数やメル周波数ケプストラム(MFCC)、ゼロ交差率(zero crossing rate:ZCR)などが含まれている。特に入力に関わる要因を検討し比較をするために、特徴量セットで重要な特徴量である MFCC のみを使用する傾向がある。しかし MFCC は、情報を削減してしまい関係が見れない可能性がある^[4]と指摘されている。そのため、本実験では MFCC のケプストラムに変換す

る前であるメル周波数スペクトラムを用いる。周波数にメルフィルタバンクを適用したデータをあつかう。一般的にフィルタバンクの個数は 20 から 40 とされている。本実験では音声認識や感情認識のように出力で分類器を使用しない。そのため、今回 40 個のフィルタを使用し、入力 40 次元とする。また本実験では録音時間を固定長としている。

3.2 LSTM

本研究では時系列信号である音声特徴量を扱う。そのため時系列の隣接する入力の相関を取りつつ、かつ長期的に相関の関係を踏まえて学習する必要がある。これは、関連研究^[3]で用いられた LSTM が適している。本研究では、口調から話者の伝えたい尺度を認識するため、LSTM で口調の使い方を学習して尺度を認識可能にする。入力の音声特徴量としてメル周波数スペクトラムを用いる。そのため、時間領域を取り扱うのに対し、出力は尺度であり、時間領域はない。そのため LSTM の出力を最後の終段から全結合層によって出力を 1 つとする。

4 実験方法と評価

4.1 実験方法

本研究では、尺度の一つとして物体の 2 点間の距離に着目し、この距離を伝えたい意図とする。音声情報から口調を抽出し、話者の意図を推定可能か確認するため指示バタスクを提案する。指示バタスクを Fig. 1 に示す。本タスクでは操作バーを目標バーまで移動を行う。人間とロボットにそれぞれ役割を与え、ロボットは操作バーの操作を行い、人間側は移動する距離の指示を行う。ここで、ロボットは目標の座標 x_t が提示していない。そのため、被験者である人間側が目標バーまでの位置を加味して“もうちょっと”と発声する。そして、ロボットがその発声から目標の座標 x_t を推定して移動量 x_m を決定する。

今回の実験タスクの条件として、ロボットが操作バーをランダムに移動させる。そして、その移動距離と残りの移動量 x_m に対して人間側は発声する。人間側が発声する単語として“もうちょっと”の一単語のみとする。この理由としては同条件にすることによって口調に注目して比較を行うようにするためである。

4.2 評価方法

パフォーマンス P を、ランダムに移動する前の操作バーの座標 x_s と目標バーの座標 x_t と移動量 x_m を用いて式 (1) と定義する。




Fig. 1 Cue Bar Task

$$P = \frac{|x_m|}{|x_s - x_t|} \quad (1)$$

5 結果

提案手法によってモデルを学習させた後、同様の条件で実際のテストをした際のパフォーマンスの結果を Fig. 2 に示す。横軸は実行回数 (subject) となっており、縦軸は評価関数の値 (Evaluation Value) となっている。学習器の出力 (output) と正解値 (label) との差の平均値は、0.17 最大の差は 0.39 最小は 0.02 となった。Fig. 2 から正解値との誤差が小さい場合と大きく異なる場合がある。この原因としては今回のタスクでは、人間は指示した後のロボットの移動が見ることができない。人間のロボットへの指示がロボットの移動量にどのように影響されるのか、人間自身が予測できなくなる可能性がある。そのため、人間の指示をする尺度が変化してしまうためだと考える。




Fig. 2 Experiment results

6 おわりに

6.1 まとめ

従来研究では会話から認識する情報として、音声認識や音声感情認識があった。従来の会話システムにおいて、話者の意図を推定するためにこれらの技術が利用されていた。本研究では、話者の伝えたい尺度を認識する

ことで、意図の推定を試みた。話者の伝えたい尺度を認識させるために LSTM を用いて、口調から移動量を推定させるバータスクを考案した。結果として正解値との誤差が大きい場合と小さい場合に大きく分かれた。これは指示をする人間側が原因だと考えられる。人間側は自身の指示がロボットの移動量にどのように反映されるかイメージができなくなるためであると考えた。

6.2 今後の展望

今後の展望としては、より精度を向上させるために、今回入力にはメル対数メルスペクトラムのみを導入した。そのうち一次差分 (Δ) 及び二次差分 ($\Delta\Delta$) またメル対数スペクトラムのケプストラムの MFCC とその一次差分と二次差分 (Δ), ($\Delta\Delta$) を導入することにより精度を向上させることを検討する。また今回は音声の録音時間が固定の長さになっている。ここに音声区間検出 (voice activity detection :VAD) を行うことでより精度を上げたい。タスクの改善点として実験では、結果で挙げられていた人間側のロボットへの影響のイメージができない原因として、指示をしたあとのロボットの移動量を見ることができなかったためであると考えられた。そのため改善案として、学習した結果をタスクに反映させる。その反映させた移動量から指示をさせ、交互に指示と移動を行うようなタスクにすることなどが挙げられる。

参考文献

- [1] 総務省 | 令和元年版 情報通信白書 | レイヤー別にみる市場動向 : <https://www.soumu.go.jp/johotsusintokei/whitepaper/ja/r01/html/nd112130.html>
- [2] Y.Xie,R.Liang,Z.Liang,C.Huang, C.Zou and B.Schuller, "Speech Emotion Classification Using Attention-Based LSTM," in IEEE/ACM Transactions on Audio,Speech,and Language Processing, Vol. 27,No. 11,pp.1675-1685,Nov. 2019
- [3] J.Deng,X.Xu,Z.Zhang, S.Frühholz and B.Schuller, "Semisupervised Autoencoders for Speech Emotion Recognition," in IEEE/ACM Transactions on Audio,Speech,and Language Processing, Vol. 26,No. 1,pp.31-43,Jan. 2018
- [4] H.Purwins,B.Li,T.Virtanen,J.Schlüter, S.Chang and T.Sainath,"Deep Learning for Audio Signal Processing," in IEEE Journal of Selected Topics in Signal Processing,vol. 13,no. 2,pp. 206-219, May 2019