

2021 年度 卒業論文

長・短期記憶ネットワークによる筋電位 の時系列予測

Series Prediction of EMG by Long Short-Term
Memory(LSTM) Network

東京電機大学工学部 電子システム工学科

指導教員： 教授 五十嵐 洋

研究室名： 協調ロボティクス研究室

18EH096 山本 隆人

2022 年 2 月 7 日 提出

研究概要

人間の生体信号のひとつに筋収縮を行う際に発生する筋電という信号がある．この信号は力の入れ具合や運動意図を情報として含んでおり，リハビリテーションや熟達支援の分野において，四肢に何らかの障害を持つ人々へのサポートを行うデバイス類の制御入力として活用されている．しかし筋電信号を入力として利用する際，様々な問題が発生する．本研究ではそれらの問題を解消するための足掛けとして，ニューラルネットワークの1つである長・短期記憶ネットワーク（Long Short-Term Memory:LSTM）を用いた筋電図（Electromyography:EMG）への時系列予測を行ない，その有効性と可能性を示す．

キーワード：機械学習，ニューラルネットワーク，筋電，EMG，時系列予測

目次

第1章	序論	1
第2章	筋電発生機序と生体計測	3
2.1	筋の構造と活動の仕組み	3
2.1.1	筋肉の種類	3
2.1.2	運動単位	5
2.1.3	骨格筋収縮	6
2.2	筋電計測	8
2.2.1	表面筋電図 (sEMG) の計測原理	8
2.2.2	サンプリングと量子化	9
2.3	信号処理	11
2.3.1	周波数フィルタリング	11
2.3.2	振幅情報の解析	11
2.3.3	周波数情報の解析	12
第3章	ニューラルネットワークによる時系列予測	13
3.1	RNN	14
3.1.1	RNN の学習方法	15
3.1.2	RNN の問題点	22
3.2	LSTM	24
第4章	提案手法・実験・結果	29
4.1	筋電計測	29
4.2	信号処理	31
4.3	筋電位の時系列予測	32
4.4	結果	34

第1章 序論

近年，リハビリテーションや熟達支援の分野において，機械が人間をサポートするマンマシンインタフェースの発展がめざましいものとなっている．その制御入力として，生体信号と呼ばれる人間が体内から発する生体现象をセンサによって定量化したものが，インタフェースを通してデバイス類の制御に活用されている．例を挙げると，心拍，脳波，脈拍，筋電，発汗などが存在する．その中でも筋電は筋肉を持つ部位を司り，人間の運動意図を正確に反映する最も重要な生体信号のひとつである．筋電を利用したサポートは，主に手や足といった人間にとって重要な部位へのものが多く，四肢欠損者，麻痺者を対象とした研究が盛んに行われている．その具体的なサポート例として有名なものは筋電義手 [1]，機能的電気刺激 (FES) [2] などが挙げられる．

しかし，筋電をインタフェースへの入力として利用した時に，いくつかの問題点が生じる．1つは比較的単純な動きでも作り出すことが難しい，複雑な筋活動のパターン認識である [3]．その原因は，EMGを取得する際，電極の貼られた周辺一帯の複数の筋活動に関する信号が混ざり合って計測されてしまい，特定が難しくなってしまうためである．また，振幅，周波数のパターンは個人によって変化し，同じ人間でも時間変化で変動することがあり，それもパターン認識の難しさにつながる．もう1つの問題は筋電が発生してから実際に張力が発揮されるまでに存在する電気力学的遅延と呼ばれる遅延時間が挙げられる．上肢における遅延時間は約 50ms ほどと言われており，それはデバイス制御への遅延にそのままつながってしまう [4]．このように，筋

電位をインタフェースへの入力として利用する際にはいまだに様々な課題・問題点がある。

本研究では、筋電をインタフェースへの入力として利用する際に生じる問題点を解決するための足掛けとして、機械学習の1つであるニューラルネットワーク（以下 NN）を用いて、手を動かした際の筋活動のパターン認識を学習させ、その情報から未来の EMG の推定値を予測する「時系列予測」を目的とした。今回使用した NN のモデルは RNN の一種である LSTM である。一般的な順伝搬型 NN は内部に循環を持たず単一方向のみに情報が伝搬するが、LSTM は中間層にループを持ち、この構造は時間方向につながりを持つデータの処理に有効である。また時系列予測とは、過去の情報を活用して未来の出力の予測値の精度を向上させていくような予測方法のことである。そのため LSTM を用いての学習とは相性が良いことがわかる。時系列データである EMG の推定値予測の精度が向上し、正確な未来の出力がわかるようになれば、手や足といった筋活動を行う人間の部位の、今までは分からなかった未来の位置情報が取得でき、それによって筋電を利用したデバイス類の持つ課題の解決につながると考えた。

第2章 筋電発生の機序と生体計測

筋電位とは，筋膜表面に生じる筋放電現象を電圧として計測したものであり，筋活動と関係性の強い電気活動である．本章では，筋電が発生する機序，また筋電計測とデジタル制御のための処理・解析について記述していく．

2.1 筋の構造と活動の仕組み

人体の運動はすべて筋肉の活動の結果であり，筋活動は神経によって支配されている．流れとしては脳からの電気信号が脊髄を通り，特定の筋肉の収縮を促す神経細胞へ辿り着き，筋繊維が張力を発揮する．本節では，筋肉の構造と収縮活動が起こる仕組みについて記述する．

2.1.1 筋肉の種類

筋肉には横紋筋と平滑筋の2つの種類が存在する [5]．横紋筋には横縞模様があり，骨格筋と心筋がその中に分類される．骨格筋は姿勢を保ち，身体を動かす筋肉で一般的に筋肉といわれるものは骨格筋を指す．心筋は心臓を構築している筋肉で，心臓以外の場所には存在しない．平滑筋は内臓や血管の壁に存在し，緊張を保つことや収縮によって内臓や血管の働きの維持を行っている．本研究で取り扱う筋肉は主に骨格筋のことであり，運動神経によって支配され，自身の意思で動かすことができる随意筋とも呼ばれる筋肉である．Fig. 2.1 に筋肉の種類についての概要図を示す．




Fig. 2.1. 筋肉の種類

2.1.2 運動単位

骨格筋は多数の筋繊維から構成されている。脊髓中の前角部にある α 運動ニューロンと呼ばれる神経細胞は、神経軸索を介して末梢にある同じ筋内の複数の筋繊維と接合している。 α 運動ニューロンが電氣的に興奮することによって、その支配下にある筋繊維が同時に筋収縮を起こすような機能単位を構成している。単一筋内にはこのような機能単位が複数組み合わせられており、それぞれが協調的に筋収縮することで張力が発揮される。この機能単位を運動単位 (Motor Unit: MU) と呼ぶ [6]。この概念は、Liddell と Sherrington によって発見され [7]、定義されている。Fig. 2.2 に概念図を示す。Fig. 2.2 では3つの MU があるとすると、それぞれ異なる複数の筋繊維を支配している。




Fig. 2.2. 運動単位 の概念図

出典:中村英夫, “いまさら聞けない生体計測1 (筋電)”, 生体医工学, 57(4・5):pp150

2.1.3 骨格筋収縮

前項で述べたように、ニューロンは刺激を受けて興奮する。この興奮というのは、活動電位を発生することであり、軸索を伝わって終板に達し、筋肉が収縮する。収縮が起こるのは、T管に生じた電気的変化によって電位依存型カルシウムチャンネルが開き、カルシウムイオンが筋小胞体から放出されるためである。より詳しい説明のために、Fig 2.3 に骨格筋収縮までの一連の流れの概念図を示す。




Fig. 2.3. 骨格筋収縮の概念図

出典:山蔭道明 編集, “手術ナーシング 2016 年第 2 号 (Vol.3 No.2)”, pp47

まず運動神経の神経終末から放出された、神経伝達物質の一種であるアセチルコリンが、筋終板にある受容体に結合すると、その構造が変化して陽イオンが筋細胞内に流入してくる。このため、終板に「終板電位」と呼ばれる微弱な電位が発生する。終板の周囲に多数存在するナトリウムチャネルは、この終板電位を感じ取ることで開口し、今度はナトリウムが細胞内に大量に流入してくる。このため、「活動電位」と呼ばれる大きな電位が筋鞘（筋の細胞膜）で発生し、隣り合う筋鞘同士のナトリウムチャネルは次々に活性化していき、活動電位が「T管系」と呼ばれるT字型をした筋層の深部まで伝搬する。T管系には、ジヒドロピリジン受容体と呼ばれるカルシウムチャネルが高密度に存在している。T管系が活動電位を受けて活性化すると、連結しているリアノジン受容体と呼ばれるカルシウムチャネルを介して、筋小胞体からカルシウムが筋漿（筋の細胞質）内に放出され、筋漿内のカルシウム濃度が上昇する。そして、カルシウムが細い筋糸に結合すると筋収縮が発生し、カルシウムポンプの働きによって筋小胞体内に再び回収されると、筋収縮が解除されるといった仕組みになっている [8]。

2.2 筋電計測

筋電計測は主に侵襲か非侵襲で大別される。侵襲的計測法の代表例が針筋電図であり、電極を筋組織に刺し入れすることによって、筋から発生する電気信号を近傍で取得することが可能である。この計測方法は主に神経筋疾患診断に利用され、主に医療機関で使用される。それに対して、非侵襲計測法は、通常、表面筋電図のことを指している。針筋電計測とは異なり、皮膚表面上に電極を貼付して測定するため、比較的簡易に利用できる。本研究では表面筋電計測を行った。

2.2.1 表面筋電図（sEMG）の計測原理

sEMGは筋肉の皮膚上に貼付した電極によって、MUから発生する運動単位活動電位（motor unit action potential: MUAP）が時間的・空間的に重ね合わされたものを観測したものである。MUAPが同一MUから発生する際、ほぼ同じ時刻で支配下の筋繊維上でも観測される。MUAPが発生した後、腱のある方向へと伝導していく。表面EMGで実際に観測されるものは、複数のMUからのMUAP群が重なって伝導してきたものである。観測されたEMGの波形情報から、どのMUから発生したMUAPかを分類する手法をEMGデコンポジションと呼ぶ。この手法は先述のような針電極による侵襲的な測定法にて用いられることが多かった。MUAP波形の特徴が明確で、雑音も少なく測定できるため、EMGデコンポジションに適しているが、感染症対策や測定対象筋に電極を設置するのに技能を要する。それに対して、表面EMGは計測が簡便であり、より多くの人が計測を行なうのに都合が良いとされたいるため、近年では表面EMGでのEMGデコンポジションの研究が進められている。

表面EMG計測は単極導出法と双極導出法とに分けられる。単極導出法とは、2つの電極を用いて1つを関電極として対象とする筋上の

皮膚に設置し、もう1つをその筋以外の位置に不関電極として設置するものである。双極導出法は3つの電極を使用し、2つの関電極を対象とする筋腹上に筋繊維の走行に沿って2～3 cm 離して設置し、他をその筋以外のところに設置する。導出される信号は0.01～10 mV と微弱であり、差動増幅器を用いて60～80 dB に増幅される。またS/N の改善や動きによるアーチファクトの防止のため、通常は5～1000 hz のバンドパスフィルターに通される。先述の通り、表面 EMG は多数の筋繊維の MUAP が時間的・空間的に混在した不規則信号である。生波形から筋の活動様式や運動の制御に関する知見を直接認識するのは容易ではなく、特徴抽出のためのさまざまな処理が必要である。

2.2.2 サンプリングと量子化

EMG を PC で記録するためには離散化する必要がある。連続するアナログ信号を離散化すると信号の劣化が避けられないので、有意な情報を抽出するためにいくつか注意が必要である。Fig 2.4 に信号の離散化に関するイメージ図を示す。信号 $x(t)$ を離散化すると仮定する。時間 t について等間隔に分け、離散化することをサンプリングと呼ぶ。また、縦軸である出力値 $x(t)$ を離散化することを量子化と呼ぶ。各サンプル時間において信号 $x(t)$ に最も近い Fig 2.4 中の点が実際に記録される近似値となる。サンプリング周波数は、サンプリング間隔 Δt の逆数であり、1 秒間あたりのサンプル取得数のことである。これを決定するにあたって、サンプリング定理が基準となる。有効な信号情報を抽出するために、信号の有効周波数帯域の上限周波数を f_e と定義すると、サンプリング周波数 f_s は、 $f_s \geq 2f_e$ を満たす必要があり、この関係のことをサンプリング定理と呼ぶ。一般的には、EMG 信号は最低でも 1 kHz のサンプリング周波数が必要であり、その有効周波数帯域は 5～500 hz 程とされている。 f_e を 500 Hz としたとき、サンプ

リング定理から最低 1 kHz 以上が必要だとわかる。

また、量子化は bit の単位で分解能が表示される。分割数は Fig 2.4 の量子化間隔 Δq の個数を示し、2 のべき乗でその個数を表す。サンプリング周波数も分解能も値が高いほどより精細にデータを表現できるが、その分の記憶容量が増えてしまうので、使用機器、解析条件によって必要な値を見積もる必要がある。




Fig. 2.4. 連続信号の離散化の概念図

出典:中村英夫, “いまさら聞けない生体計測 1 (筋電)”, 生体医工学, 57(4・5):pp151

2.3 信号処理

2.3.1 周波数フィルタリング

EMG 信号を解析する際、雑音を取り除くため周波数フィルタリングによる前処理が必要である。EMG 信号を交流信号とみなし解析を行うため、直流成分近傍の低周波成分を取り除かなければいけない。前述の通り、EMG 信号の有効周波数帯域が 5 Hz から 500 Hz であることから、低域周波数部分をハイパスフィルタを適用し、また、有効周波数帯域の上限の 500 Hz 近傍を遮断周波数とするローパスフィルタも適用する。

2.3.2 振幅情報の解析

sEMG の振幅情報の解析は、通常、交流信号の生データを整流・平滑化の処理を行ってから最大振幅や積分値を評価することが一般的である。その手法としては主に 2 つ挙げられる。1 つは波形 $e(t)$ の絶対値を取ってからある一定の時間窓で移動平均を取る方法、またはローパスフィルタを適用して平滑化する方法である。本研究は 2 つ目の方法で処理を行った。フィルタによる平滑化にも種類が 2 つあり、RMS (Root Mean Square) と ARV (Average Rectified Value) が存在する。RMS は一定時間範囲の EMG 信号を 2 乗し、範囲内の平均を求めた後で平方根をとったものである。式 2.1 に示す。

$$RMS = \sqrt{\frac{1}{2T} \int_{-T}^T e^2(t + \tau)} \quad (2.1)$$

RMS の場合、算出するために一定の時間区間 T もしくはサンプル数 N にデータを区分しなければならない。区間幅の程度は目的によって変わってくる。ARV は整流平滑化とも呼ばれる。振幅の絶対値を求めることを整流と呼び、その後それを一定時間で積分するか、あるいは

ローパスフィルタで平滑したものである．式 2.2 に示す．

$$RMS = \int_{-\infty}^{+\infty} h(\tau) |e(t + \tau)| d\tau \quad (2.2)$$

ローパスフィルタを適用する際のカットオフ周波数を決定する時，EMG の有効周波数帯域がの下限が 5 hz であることから，2 Hz 程度とする場合が多い．本研究ではローパスフィルタで平滑した ARV を適用し，積分筋電図として波形を算出した．

2.3.3 周波数情報の解析

EMG の周波数情報を得るためには離散フーリエ変換 (Discrete Fourier Transform:DFT) によりパワースペクトル密度を絶対自乗化により実数化する必要がある．通常，用いられる指標は中央周波数 (MeDian Frequency:MDF) もしくは，平均周波数 (MeaN Frequency:MNF) が多い．MDF は絶対値自乗パワースペクトル密度 $|S(\omega)|^2$ の中央値となる周波数を求める計算と同義である．式 2.3 に示す．

$$\int_{f_{md}}^{\infty} |S(\omega)|^2 d\omega = \int_0^{f_{md}} |S(\omega)|^2 d\omega \quad (2.3)$$

MNF の場合は絶対値自乗パワースペクトル密度の期待値を求めることと同義である．式 3.1 に示す．

$$f_{mn} = \frac{\int_0^{\infty} \omega |S(\omega)|^2 d\omega}{\int_0^{\infty} |S(\omega)|^2 d\omega} \quad (2.4)$$

MDF，MNF のどちらも絶対値自乗パワースペクトル密度分布の代表値であるが，MNF は統計量における平均値と中央値との関係より，MNF は高周波雑音の影響が顕著に現れる．MDF はそれに対してロバストである特徴を持つ．

第3章 ニューラルネットワークによる 時系列予測

本研究では取得した表面 EMG の時系列予測を NN によって行った。機械学習は、過去の事象からの学習によって自動で校正を行うコンピュータアルゴリズム、もしくは研究領域であり、人工知能の 1 つとみなされている。その中の 1 つに NN というネットワークモデルがある。NN は生物のもつ神経細胞（ニューロン）の働きをモデルにして提唱された。神経細胞同士はシナプスと呼ばれる入力を重み付けして信号を送る部位で結合されており、大量の神経細胞群が連携した電気信号のやり取りによって思考、認識等の処理が行われている。この伝達メカニズムを数理モデルに適用させたものが NN であり、一般的な順伝搬型の NN の概要図を Fig 3.1 に示す。NN における 1 つの関数（図では○）をノードと呼び、並列したノード群を層と呼ぶ。層は入力層、隠れ層、出力層の 3 つに分類される。入力層は単に教師あり学習における入力変数を入力するだけの層である。出力層は直前の層の値を用いて最終的な出力値（教師あり学習におけるターゲット変数の予測値）を出力する。入力・出力層に挟まれたすべての層を隠れ層（中間層）と呼ぶ。よって、NN は層を何層にするか、各層にいくつのノードを配置するか、各ノードに紐づく関数がどのような形か、によって特徴付けられる。




Fig. 3.1. ニューラルネットワークと層構造

3.1 RNN

RNN は、NN のモデルの内部に循環を持つようなネットワークモデルの総称である．このモデルは1986年のデビッド・ラメルハートらの研究に基づく [9]．Fig 3.2 にモデルの概要図を示す．




Fig. 3.2. RNN の概念図

Fig 3.2のようにRNNの中間層は、ある時刻の中間層からの出力を次の時刻の中間層に伝えるためのパスを持つ。そのため時刻 t の中間層は、同じ時刻 t の入力層からのインプットに加え、前の時刻 $t-1$ の中間層からのインプットも受け取る。前の時刻からのインプットが存在することにより、時刻間の影響を考慮したNNを構築することができる。数式で表現すると中間層では、同時刻の入力データ x_t と前時刻の中間層出力 h_{t-1} をそれぞれ重みで線形和したもの $W(in)x_t + Wh_{t-1}$ を受け取り、活性化関数 f で変換した値を層からの出力値としている。 h_{t-1} を時刻 t での入力の一部とすることにより、過去時刻の値を未来時刻に影響させることになる。出力層では一般的なNNと同じように、前段の中間層出力の線形和 $W(out)h_t$ を関数 $f(out)$ で変換した値 $f(out)(W(out)h_t)$ が最終出力となる。関数 $f(out)$ はRNNに入力するデータの種類や、出力する値によって変化する。

3.1.1 RNNの学習方法

RNNでのデータによる学習対象となるのは中間層、出力の重み $W(in)$, W , $W(out)$ である。RNNからの出力値と正解値の誤差 E を計算し、その誤差の値が小さくなるような勾配降下法を使って重み W をチューニングしていく。勾配降下法とは、初めに重み W の初期値をランダムにとりその時の誤差 E を計算する。その後誤差 E の初期値 W での勾配（傾き）を計算、勾配の値が正だと重み W を小さくし、勾配の値が負だと重み W を大きくするといった方法で目標値へのチューニングを行う。Fig 3.3に勾配降下法概念図を示す。




Fig. 3.3. 勾配降下法

一般的なNNの場合、勾配降下法をそのまま適用させられるが、RNNの場合中間層の時間経過を考慮する必要がある、そのままだと誤差逆伝搬法を適用することができない。




Fig. 3.4. 3層ニューラルネットワーク

まず通常のNNでの誤差逆伝搬法について説明する． Fig 3.4 のような3層のNNを考える． あるユニットだけの入力のみを考えると下図のようになり，ここに焦点を当てて考える． net_j , net_k はj層，k層における任意のユニットへの入力であり net_j は3.1のような数式で表せる．

$$net_j = x_1w_{1j} + x_2w_{2j} + x_3w_{3j} + \dots + x_iw_{ij} \quad (3.1)$$

ネットワークの出力の評価関数 J は3.2とする．

$$J = \frac{1}{2} \sum (y_k - E)^2 \quad \left(\frac{\partial J}{\partial y_k} = y_k - E \right) \quad (3.2)$$

この評価関数を用いて各層の重みを以下の更新式により値を変化させ

ながら目標値を探っていく。(ρは学習率というパラメータ)

$$w_{ij} \leftarrow w_{ij} - \rho \frac{\partial J}{\partial w_{ij}} \quad (3.3)$$

$$w_{jk} \leftarrow w_{jk} - \rho \frac{\partial J}{\partial w_{jk}} \quad (3.4)$$

そしてネットワークの後ろの層から計算を行っていく。まず連鎖律 3.5 の法則を示す。

$$\frac{\partial y}{\partial x} = \frac{\partial y}{\partial h} \frac{\partial h}{\partial x} \quad (3.5)$$

それをふまえて w_{jk} の式を展開していく。

$$\frac{\partial J}{\partial w_{jk}} = \frac{\partial J}{\partial netk} \frac{\partial netk}{\partial w_{jk}} \quad (3.6)$$

$$= \frac{\partial J}{\partial netk} h_j \quad (3.7)$$

$netk$ を w_{jk} で微分することで重み w を消去している。次に $\partial J / \partial netk$ を連鎖律を用いて展開する。

$$\frac{\partial J}{\partial netk} = \frac{\partial J}{\partial y} \frac{\partial y}{\partial netk} = (y_k - E) y_k (1 - y_k) \quad (3.8)$$

J の微分は 3.2 で行った表関数の微分であり、 $\partial J / \partial netk$ の微分は、 k 層の活性化関数としてシグモイド関数を使用するためこの微分値となる。更新式 1 つ目の展開が完了した。

$$\frac{\partial J}{\partial w_{jk}} = (y_k - E) y_k (1 - y_k) \quad (3.9)$$

次に、2 つめの更新式 $\partial J / \partial w_{ij}$ を展開していく。1 つ目の流れと同じように w_{ij} を消去し、連鎖律で展開する。

$$\frac{\partial J}{\partial w_{ij}} = \frac{\partial J}{\partial netj} \frac{\partial netj}{\partial w_{ij}} = \frac{\partial J}{\partial netj} x_i \quad (3.10)$$

$$\frac{\partial J}{\partial neti} = \frac{\partial J}{\partial y_k} \frac{\partial y_k}{\partial netk} \frac{\partial netk}{\partial h_j} \frac{\partial h_j}{\partial netj} \quad (3.11)$$

3.11 で左辺に k が残留しているため σ 計算を用いて消去する.

$$\frac{\partial J}{\partial net_j} = \sum_{k=1}^c \left\{ \frac{\partial J}{\partial y_k} \frac{\partial y_k}{\partial net_k} \frac{\partial net_k}{\partial h_j} \right\} \frac{\partial h_j}{\partial net_j} \quad (3.12)$$

$$= \left(\sum_{k=1}^c (y_k - E) y_k (1 - y_k) w_{jk} \right) h_j (1 - h_j) \quad (3.13)$$

ここで Σ の中身が 1 つ目の更新式とほぼ同じ形になっていることが分かる. そして, ij 層の要素, $\partial h_i / \partial net_i$ についても 1 層目と同じ考え方, ここでもシグモイド関数を活性化関数に使用しているため, $s(x)(1-s(x))$ の形を取る. w_{ij} の式展開も完了した.

$$\frac{\partial J}{\partial w_{ij}} = \left(\sum_{k=1}^c (y_k - E) y_k (1 - y_k) w_{jk} \right) h_j (1 - h_j) x_i \quad (3.14)$$

3.9, 3.14 を比較してみると, $(y_k - E) y_k (1 - y_k)$ の式をそのまま流用して計算することができ, この部分を β と置き換えて式を変更すると以下のようになる.

$$\beta_k = (y_k - E) y_k - k(1 - y_k) \quad (3.15)$$

$$\frac{\partial J}{\partial w_{jk}} = \beta_k h_j \quad (3.16)$$

$$\beta_j = \left(\sum_{k=1}^c \beta_k w_{jk} \right) h_j (1 - h_j) \quad (3.17)$$

$$\frac{\partial J}{\partial w_{ij}} = \beta_j x_i \quad (3.18)$$

ij 層, jk 層の更新式はこのように算出される.




Fig. 3.5. 1つ前の時刻を考慮した RNN

RNN の場合，通常の NN の入力に加えて過去の間層の出力を入力として使う．Fig 3.5を見ると，隠れ層 h_t の入力に1つ前の時刻の隠れ層 h_{t-1} の出力を用いている．過去の隠れ層の出力を入力に用いることで，隠れ層の過去状態を保存しているメモリとして利用することになり，過去状態を考慮したネットワークモデルとなる．これにより時系列データの予測が可能になる．Fig 3.5を元にして，RNN の誤差逆伝搬を考える．入力層を x ，隠れ層を h ，出力層を y ，正解値を d ，隠れ層の活性化関数を $f()$ ，出力層の活性化関数を $G()$ とする．また，隠れ層と出力層の任意のユニットに対する入力をそれぞれ p ， q とする．誤差を導入するための評価関数 E を設定する．

$$E = \frac{1}{2} \sum_k \sum_t^{\tau} \|y_{kt} - d_{kt}\|^2 \quad (3.19)$$

この値を用いて，誤差逆伝搬を考える．はじめに，重み V の誤差 $\partial E / \partial V$ を考える．連鎖律によって誤差を分解することで，評価関数 $\times$ 出力層の活性化関数の微分 $\times$ 入力の形を取ることがわかる．純粋な入力 h 以外の評価関数 $\times$ 活性化関数の微分の項は誤差項と呼ばれるもので ε_o

としてまとめる．

$$\frac{\partial E}{\partial V_{jkt}} = \frac{\partial E}{\partial y_{kt}} \frac{\partial y_{kt}}{\partial q_{kt}} \frac{\partial q_{kt}}{\partial V_{jkt}} \quad (3.20)$$

$$= (y_{kt} - d_{kt})g'(q_{kt})h_{jt} \quad (3.21)$$

$$= \varepsilon o_t h_{jt} \quad (3.22)$$

続いてUの誤差を考える．連鎖律を用いて展開すると，評価関数 $times$ 出力層の活性化関数 $times$ 重み V_{times} 隠れ層の活性化関数の微分 $times$ 入力という形を取る．この計算でも $\partial E/\partial V$ と同じように，純粋な入力 x 以外を誤差項 εh とまとめておく．

$$\frac{\partial E}{\partial U_{ijt}} = \frac{\partial E}{\partial y_{kt}} \frac{\partial y_{kt}}{\partial q_{kt}} \frac{\partial q_{kt}}{\partial h_{jt}} \frac{\partial h_{jt}}{\partial p_{jt}} \frac{\partial p_{jt}}{\partial U_{ijt}} \quad (3.23)$$

$$= (y_{kt} - d_{kt})g'(q_{kt})V_{jk}f'(p_{jt})x_{it} \quad (3.24)$$

$$= \sum_k ((y_{kt} - d_{kt})g'(q_{kt})V_{jk})f'(p_{jt})x_{it} \quad (3.25)$$

$$= \sum_k (\varepsilon o_t V_{jk})f'(p_{jt})x_{it} \quad (3.26)$$

$$= \varepsilon h_t x_{it} \quad (3.27)$$

最後に $\partial E/\partial W$ を求める．これは入力が h_{t-1} となる以外は $\partial E/\partial U$ と全く同じである．

$$\frac{\partial E}{\partial W_{ijt}} = \frac{\partial E}{\partial y_{kt}} \frac{\partial y_{kt}}{\partial q_{kt}} \frac{\partial q_{kt}}{\partial h_{jt}} \frac{\partial h_{jt}}{\partial p_{jt}} \frac{\partial p_{jt}}{\partial W_{ijt}} \quad (3.28)$$

$$= \varepsilon h_t h_{i(t-1)} \quad (3.29)$$

3.1.2 RNN の問題点

前節で RNN の誤差逆伝搬法について説明したが，RNN には時系列データを入力とする際に問題点がある．時系列データの数が多くなるほど有効性が消失していく問題である．これは誤差逆伝搬法を用いて学習を進めている際に，その値が徐々に小さくなってしまいうことによって生じる．この問題は「勾配消失問題」と呼ばれている．Fig 3.6 に RNN の一般的な構造を示す．




Fig. 3.6. RNN の構造

$x_1 \sim x_k$ が入力， $h_1 \sim h_r$ が出力， $c_0 \sim c_k - 1$ が次の学習の入力， σ は活性化関数（シグモイド関数）を表す．

$$\sigma = \frac{1}{1 + e^{-x}} \quad (3.30)$$

ある時点の出力 h_t は前時刻の出力 c_{t-1} と現時刻の入力 x_t に重みをかけ，それらを足し合わせ活性化関数に入れたものが 3.31 になる．

$$h_t = \sigma(w_{rec}c_{t-1} + w_{in}x_t) \quad (3.31)$$

時刻 t の時の正解データ t_t と出力 h_t の差の絶対値を E_t とする．誤差逆伝搬はこの大きさを小さくするのが目的であり， w_{rec} の勾配を見てみると，

$$\frac{dE_t}{dw_{rec}} = \sum_{t=0}^k \frac{dE_t}{dw_{rec}} \quad (3.32)$$

と定義される．この場合の誤差逆伝搬は，

$$w_{rec} = w_{rec} - \alpha \frac{dE_t}{dw_{rec}} dw_{rec} \quad (3.33)$$

$$= w_{rec} - \alpha \sum_{t=0}^k \frac{dE_t}{dw_{rec}} \quad (3.34)$$

上式の2項目が働かない，つまり，

$$\lim_{k \rightarrow \infty} \sum_{t=0}^k \frac{dE_t}{dw_{rec}} = 0 \quad (3.35)$$

となってしまう，重みの更新ができないことになる． k 個の時間ステップでの誤差の勾配は次の式で与えられる．

$$\frac{\partial E_k}{\partial W} = \frac{\partial E_k}{\partial h_k} \frac{\partial h_k}{\partial c_k} \cdots \frac{\partial c_2}{\partial c_1} \frac{\partial c_1}{\partial W} \quad (3.36)$$

$$= \frac{\partial E_k}{\partial h_k} \frac{\partial h_k}{\partial c_k} \left(\prod_{t=2}^k \frac{\partial c_t}{\partial c_{t-1}} \right) \frac{\partial c_1}{\partial W} \quad (3.37)$$

$W = [W_{rec}, W_{in}]$ であるため c_t は次のように記述できる．

$$c_t = \sigma(W_{rec} \cdot c_{t-1} + W_{in} \cdot x_t) \quad (3.38)$$

c_t の導関数を計算し，次を取得する．

$$\frac{\partial C_t}{\partial C_{t-1}} = \sigma'(W_{rec} \cdot c_{t-1} + W_{in} \cdot x_t) \cdot \frac{\partial}{\partial C_{t-1}} [W_{rec} \cdot c_{t-1} + W_{in} \cdot x_t] \quad (3.39)$$

$$= \sigma'(W_{rec} \cdot c_{t-1} + W_{in} \cdot x_t) \cdot W_{rec} \quad (3.40)$$

3.40 を 3.37 に接続し，逆伝搬勾配を取得する．

$$\frac{\partial E_k}{\partial W} = \frac{\partial E_k}{\partial h_k} \frac{\partial h_k}{\partial c_k} \left(\prod_{t=2}^k \sigma'(W_{rec} \cdot c_{t-1} + W_{in} \cdot x_t) \cdot W_{rec} \right) \frac{\partial c_1}{\partial W} \quad (3.41)$$

k が大きい場合，1 よりも小さい $\tanh$ 関数と呼ばれる活性化関数によって 3.41 の式は消えてしまう．ここではシグモイド関数 σ をハイパボリックタンジェントの形に変形できる．

$$\sigma = \frac{1}{1 + e^{-x}} = \frac{1}{2} \left(1 + \tanh\left(\frac{1}{2}ax\right) \right) \quad (3.42)$$

それにより σ' の関数は,

$$\sigma' = \frac{1}{2} \left(1 + \tanh\left(\frac{1}{2}ax\right) \right) = \frac{a}{4} \frac{1}{\cosh^2 x} \quad (3.43)$$

となる. $\tanh$ の微分は1以下0以上の値をとり, これに $a/4(<1)$ がかることでより小さくなる. RNNは誤差逆伝搬中に1以下の数字をかけ続けているので, k の値が増えることで勾配消失が起こる.

3.2 LSTM

前項で述べた RNN が持つ勾配問題を解決したネットワークモデル, 長・短期記憶ネットワーク (Long Short Term-Memory:LSTM) が存在する. ゼップ・ホッフライターとユルゲン・シュミットフーバーによって1997年に提唱された. LSTMの内部的な構造はFig 3.7のようになっている.




Fig. 3.7. LSTM の内部構造

LSTMにはタイムステップ t において入力ベクトル h_{t-1} , x_t があり, ネットワークのセル状態は c_t で表され, 連続する時間ステップ t , $t+1$ の間でネットワークを通過する出力ベクトルは h_t で表される. LSTMはセル状態を更新および制御する3つのゲート, 忘却ゲート, 入力ゲート

ト, 出力ゲートが存在する. ゲートでは $\tanh$ 関数, シグモイド関数を使用される.

忘却ゲートはネットワークに前の時刻から入力されたよりも新しい情報が与えられた場合に、セル状態でどの情報を忘却するかを制御する。




Fig. 3.8. 忘却ゲートの働き

忘却ゲートの出力は次のように与えられる。

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t]) \quad (3.44)$$

入力ゲートは新しい入力情報が与えられた際に、どの新しい情報がセル状態にエンコードされるかを制御する。




Fig. 3.9. 入力ゲートの働き

入力ゲートの出力は,

$$\tanh(W_c \cdot [h_{t-1}, x_t]) \times \sigma(W_i \cdot [h_{t-1}, x_t]) \quad (3.45)$$

そして2つの完全に接続された層の出力の要素ごとの積に等しい。

$$\tilde{c}_t = \tanh(W_c \cdot [h_{t-1}, x_t]) \quad (3.46)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t]) \quad (3.47)$$

出力ゲートは、セル状態でエンコードされた情報が次のタイムステップの入力としてネットワークに送信されるかどうかを制御する。




Fig. 3.10. 出力ゲートの働き

出力ゲートの活性化は次のように与えられる。

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t]) \quad (3.48)$$

セルの出力ベクトルは次のように与えられる。

$$h_t = o_t \times \tanh(c_t) \quad (3.49)$$

長期的な依存関係はセル状態にエンコードされ、勾配が消滅することを防ぐことができる。セル状態は、

$$c_t = c_{t-1} \times f_t + \tilde{c}_t \times i_t \quad (3.50)$$

のような形式となる。

第4章 提案手法・実験・結果

4.1 筋電計測

本研究では，EMG のデータセットを UCI Machine Learning Repository と呼ばれる機械学習用データセットを管理・保管しているレポジトリサイトで取得した [11]．使用した筋電センサは Thalmic Labs（現在は North）の「Myo ブレスレット」である．



Fig. 4.1. Thalmic Labs 「Myo ブレスレット」

Myo ブレスレットは8つのセンサch，9軸の慣性計測ユニット，Bluetoothによる送信モジュールを備えたウェアラブルデバイスである．有効周波数帯域が200 Hz と狭く，従来のEMG取得システムよりもジェスチャ認識の平均分類誤差は少し高い数値を出したが，ウェアラブルであるため被験者への負担が少なく簡便に取り扱うことができる．

被験者は前腕の手首付近にデバイスを装着し，表面EMGを取得した．4.2のように，被験者は静止，手を握る，手首の屈曲，手首の伸展，撓屈，尺屈という6つの基本構成からなるハンドジェスチャを行った．



Fig. 4.2. ハンドジェスチャ

動作にはそれぞれラベル付けがされており，一度のタスクでラベル 1, 2, 3, 4, 5, 6 のジェスチャを順番に行い，それを 2 回行った．各ジェスチャはそれぞれ 3 秒間行われ，各動作の間に 3 秒間の休止が設けられた．一回のタスクの時間は約 60 秒ほどとなり，それを txt データとして記録した．サンプリング周波数 1000 Hz で計測が行われ，約 60000 程の大きさの列として記録された．

4.2 信号処理

取得したtxt データは生の表面 EMG でありノイズを多く含んでいるため、予測のために信号処理にかける必要がある。本研究では、整流平滑化を行い積分筋電図化した。遮断周波数を 2.6 Hz とし、1 次 IIR フィルタを Python にて実装した。




Fig. 4.3. 表面 EMG の積分筋電図化

上図：表面 EMG の生波形 下図：積分筋電図

Fig 4.3 のように、整流平滑化の処理をかけることで積分筋電図波形を取得することができ、予測した際の波形の比較観測がしやすくなる。

4.3 筋電位の時系列予測

信号処理された EMG の時系列予測を LSTM ネットワークモデルを用いて行った．今回構築したシステムの全体図を Fig 4.4 に示す．




Fig. 4.4. 時系列予測システムの概要図

初めに，前節で述べた筋電取得部，信号処理部のような予測のための前処理部が設定されている．処理された EMG は学習データと，比較行うテストデータの2つに分けられ，学習データは今回構築した時系列予測のための LSTM ネットワークモデルに入力された．LSTM を実装するにあたり，Tensorflow 内のライブラリの1つである Keras を使用した．モデル内には3つの層が存在し，順々に処理がなされる．最初の層である LSTM では，タイムステップ数30，ユニット数120，エポック数15の設定で処理を行った．次の Dense 層は全結合層のことであり前層と次の層を全結合する．次の model compile 層で最適化アル

ゴリズム、損失関数、評価関数の訓練プロセスの設定を行い、トレーニングにおけるずれを計る指標となる損失関数および、正解に近づける修正方法である最適化を選択した。学習が終了し、予測値として出力されたものと先述のテストデータとの比較して予測の精度を確かめた。以上の流れで時系列予測を行った。

4.4 結果

予測波形とテストデータ波形の比較を行う．Fig 4.5 に比較図を示す．




Fig. 4.5. 予測波形とテストデータ波形比較

緑：テストデータ 赤：予測値

この波形は比較が分かりやすいよう，手首の屈曲の際の時系列に範囲を絞って表示している．また，今回の予測で設定されたエポック数は15であるが，この理由を後述に示す．

1 から 100 までのエポック数ごとの RMSE（二乗平方平均誤差）値をグラフとして算出した Fig 4.5. RMSE は実測値と予測値誤差を表す指標の 1 つであり，4.1 に数式を示す.

$$RMSE = \sqrt{\frac{\sum_{t=1}^T (x_{1,t} - x_{2,t})^2}{T}} \quad (4.1)$$

グラフは差が大きすぎたため縦軸を対数表示にした．グラフを見ると




Fig. 4.6. エポック数ごとの RMSE 値

エポック数15の付近で収束し，大きな差が出てこなくなった．このため LSTM のエポック数を 15 に設定した．その時の RMSE 値は 5.8×10^{-5} となった．

第5章 おわりに

本研究では，ニューラルネットワークの1つである長・短期記憶ネットワークを用いて筋電位の時系列予測を行い，筋活動を行う人間の部位の未来の位置情報の取得を目指した．取得した EMG に整流平滑化を行い積分 EMG とした後，作成した LSTM モデルに入力し，時系列予測を行った．そして，取得したデータの波形をテストデータと比較し，誤差率を計算した．筋電位という複雑な波形推移を見せる時系列データの予測だったが，予測波形は精度よく出力され，RMSE 値も非常に低い値となった．これらの結果は，筋電デバイスが持つ遅延問題解決につながると考えられる．将来の展望として，データセットでの静的なシステムではなく，リアルタイムで計測しながらの時系列予測を行うシステムの構築，学習による処理時間を考慮したシステムの構築を考えている．また，複数チャンネルを要因として入力した場合の予測精度の違い，タイムステップ数，LSTM のユニット数の変化による予測精度の違いも検討したいと考えている．

謝 辞

本研究を進めるにあたり、多忙の身であるにもかかわらず親身になって御指導してくださった五十嵐洋教授に深く御礼申し上げます。また、研究に対する助言、ご教授してくださった研究室の先輩方、同学年の皆様にも深く感謝しております。ありがとうございました。

参考文献

- [1] 櫻井浩史 ほか著, “筋電制御型の義手”, バイオメカニズム誌, Vol. 38, No.1, 2014
- [2] 島田洋一, “機能的電気刺激 (FES) の現状と将来展望”, Akita Med, 36:1-7, 2009
- [3] Robert Tibold and Andrew J Fuglevand, “Prediction of muscle activity during loaded movements of the upper limb”, Journal of NeuroEngineering and Rehabilitation, 2015
- [4] P. R. Cavanagh I and P. V. Komi, “Electromechanical Delay in Human Skeletal Muscle Under Concentric and Eccentric Contractions”, European Journal of Applied Physiology and Occupational Physiology, Vol.42, Number 3, pp.159-163, 1979
- [5] 公益財団法人長寿科学振興財団 健康長寿ネット, “<https://www.tyojyu.or.jp/net/kenkou-tyoju/undou-kiso/kinniku-kinou.html>”, (2022年1月25日アクセス)
- [6] 中村英夫, “いまさら聞けない生体計測 1 (筋電)”, 生体医工学, 57(4・5):149-157, 2009
- [7] Liddell ET, Sherrington CS, “Recruit and some other features of reflex inhibition”, Proc R Soc London, 97: 488-518, 1925
- [8] 山蔭道明 編集, “手術ナーシング 2016 年第 2 号 (Vol.3 No.2)”, pp46-47
- [9] Ronald J Williams, Geoffrey E Hinton, David E Rumelhart, “Learning representations by back-propagating errors”, Nature 323 (6088): 533:536, October 1986

- [10] Sepp Hochreiter, Jurgen Schmidhuber, “Long short-term memory”, Neural Computation 9 (8): 1735-1780, 1997
- [11] “UCI Machine Learning Repository”, <https://archive.ics.uci.edu/ml/datasets/EMG+data+for+gestures>, 2022-1-19