

修 士 論 文

チームワーク評価における協調作業解析手法

A Collaborative Work Analysis Method
for Teamwork Evaluation

東京電機大学大学院工学研究科

電気電子工学専攻電子光情報コース修士課程

20KMH04 小林 航大

研究指導教員 教授 五十嵐 洋

謝 辞

本研究を行うにあたり、五十嵐洋教授（東京電機大学）からは非常に熱心なご指導、ご鞭撻を賜りました。厚く御礼申し上げます。また、和田成夫教授（東京電機大学）には本論文の副査を務めていただき誠にありがとうございました。厚く御礼申し上げます。

協調ロボティクス研究室 OB の皆様には、研究議論を夜を徹して行い、論文の投稿が迫る中で非常に有意義な助言を頂きました。大変感謝しております。また、佐々木元気氏には、関連研究者としてプログラムや実験装置の製作等に関して大変お世話になりました。大変感謝しております。

最後に、度重なる実験にご協力頂き、日々の研究生生活において切磋琢磨した協調ロボティクス研究室の皆様、本研究に有形無形のご援助くださった全ての方々に感謝いたします。

目 次

第 1 章	序論	1
1.1	研究背景	2
1.1.1	従来のチームワーク評価	3
1.1.2	チーム分け	3
1.2	関連研究	4
1.2.1	協調作業の分析	4
1.2.2	協調作業の分類	6
1.3	CFO	8
1.3.1	CFO の定義	9
1.3.2	CFO の推定	11
1.3.3	CFO によるチーム分け	12
1.4	本研究の目的	13
第 2 章	協調作業プラットフォーム	14
2.1	シーソータスク	15
2.2	システム全体像	17
2.3	入力インタフェース	19
2.3.1	ハードウェア	19
2.3.2	制御手法	21
2.4	まとめ	22
第 3 章	モデルの生成	23
3.1	使用フレームワーク	24
3.2	データセットの生成手法	25
3.3	単独作業モデル	27
3.4	協調作業モデル	28
3.5	まとめ	29

第4章 実験1 協調作業モデル生成可能性の検討	30
4.1 実験	31
4.2 単独作業モデルによる単独作業の推定	32
4.3 モデルどうしの作業による協調作業の推定	34
4.3.1 協調作業の推定	34
4.3.2 予測が不可能な原因	35
4.3.3 協調作業全体のモデル化の検討	37
4.3.4 CFO' の推定	38
4.3.5 組み合わせを変えた場合の協調作業推定	41
4.4 まとめ	43
第5章 実験2 協調作業モデルどうしによる 協調作業推定	44
5.1 モデル生成手法の改善	45
5.1.1 Optuna によるハイパーパラメータ最適化	45
5.1.2 DTW による評価値	45
5.2 実験	48
5.2.1 協調作業モデル生成	48
5.2.2 協調作業モデルどうしによる作業予測	49
5.3 結果	50
5.3.1 協調作業モデル生成	50
5.3.2 協調作業モデルどうしによる作業予測	52
5.4 まとめ	54
第6章 実験3 協調作業の解析	55
6.1 CFO の推定	56
6.1.1 単独・協調作業時の力	56
6.1.2 CFO の推定手法	56
6.2 協調作業プラットフォーム	57
6.2.1 ボール操作型	57

6.2.2	直接追従タスク	57
6.2.3	協調作業パフォーマンス	60
6.3	実験	61
6.3.1	単独作業モデル生成	62
6.4	結果	63
6.4.1	力と CFO の解析	64
6.4.2	区間における CFO とパフォーマンスの相関	66
6.5	モデルの評価値と相関	69
6.6	まとめ	71
第 7 章 結論		72
第 8 章 今後の展望		74
本研究に関する発表文献		77

第1章 序論

本研究では、力のインタラクションを考慮した人間モデルを生成し、生成されたモデルどうしの協調作業による協調作業の推定を行う。本章では、以下の項目を述べる。

1.1	研究背景	2
1.1.1	従来のチームワーク評価	3
1.1.2	チーム分け	3
1.2	関連研究	4
1.2.1	協調作業の分析	4
1.2.2	協調作業の分類	6
1.3	CFO	8
1.3.1	CFO の定義	9
1.3.2	CFO の推定	11
1.3.3	CFO によるチーム分け	12
1.4	本研究の目的	13

1.1 研究背景

古来より、チームワークは多くの場面で求められる。特に、大きなものを運ぶなどの力を合わせるといふ協調作業が多く存在していた。今日では、仕事・勉強・スポーツ・芸術等の多くの場面においてチームワークが求められている。ここでのチームワークは2人以上で一つの作業を行うことを指し、集団で作業する際の集団作業効率や相性に影響するため重要なものとなっている。

Google LLC では Project Aristotle によってチームのパフォーマンスを高める要因が研究され、企業にとっても無視できない要因となっている。そこで、集団作業効率や相性の評価のためにチームワーク評価に着目した。

1.1.1 従来のチームワーク評価

チームワーク評価の多くは、アンケートを用いた評価が行われている [1]。しかし、アンケートによる評価は回答者の主観的な意見が含まれる。また、実験終了後に回答するという特性上、リアルタイムに評価することが不可能である。

他にも対話分析による評価も行われている [2]。この方法では、リアルタイムに分析することは不可能ではないが対話中に現れた単語の抽出・分類分けを手動で行い対話分析を行うため、既出ではない単語が出現した場合に評価不能になりリアルタイム性が失われてしまう問題がある。

1.1.2 チーム分け

共同学習におけるチーム分けを行う先行研究もある [3]。二人一組の良いチームを決める方法として評価基準に各個人の点数また、性格検査や職業適性検査を用いる。そして、その結果をもとに NN と局所探索法によりチーム分けを行う。協調作業時の点数ではなく個人作業時の点数を用いているため、点数を平均化したに過ぎない状態になってしまい、チームワーク評価によるチーム分けができているとは言い難い。

1.2 関連研究

1.2.1 協調作業の分析

ヒト-ヒト間やヒト-ロボット間における物理的相互作用に着目し，物理的相互作用の解析を行う関連研究がある．協調作業を行っている時の運動や外乱の対応に関する3つの実験を Fig. 1.1に示すような環境で行い，このとき二人の力がどのように合わさってタスクを完了するかの解析を行う．タスク中の力を分析するため，「合力」と「差力」に変換した．合力 ($F_{net} = F_A + F_B$) はペアの力の合計でありクランクを運動させる力になる．差力 ($F_{diff} = F_A - F_B$) は力の不一致の結果でありクランクの運動に物理的な影響はないが，ペア間の触覚コミュニケーション可能な領域と考えられる．これらをもとに協調作業の解析を行うと，差力が大きく加速，減速を分担するような特殊なペアが生じることがわかった [4]．



Fig. 1.1: Cooperative task for analysis human-human collaboration.

1.2.2 協調作業の分類

触覚を介して仮想環境で相互作用するタスクにおいて、相互作用を記録・分析し、手動でのアノテーションによる分類機的设计を行う。

二人の被験者は Fig. 1.2(b) に示すように仮想環境上で Phantom Premium により触覚を介して相互作用する。仮想環境上の迷路のような場所で長方形のオブジェクトを目標に向けて移動・5 秒間静止するようなタスクを用いる。実験により得られたデータに対して、手動によるアノテーションを行いデータセットの生成を行い、データセットにより分類器を生成した。mRMR（最小冗長性最大関連性）アルゴリズムによる相互作用パターンの認識に最適な特徴セットを選択した結果、576 個の特徴中 243 の特徴が選択された。選択された特徴セットのうち、相互作用力に関する特徴のうち 98 % が使用されていることから、相互作用力に関する特徴の相互作用パターンの認識における重要性がわかる [5]。



(a) Screens of Agent 1 and 2



(b) Agent 1 and 2

Fig. 1.2: Two humans interact through haptic devices in order to jointly move an object, resembling a table with caster wheels, in a virtual environment.

1.3 CFO

先行研究として筆者らは協調作業における「気づかい」(Concern For Others: CFO)に着目し、新たなチームワーク評価を試みている [6]. また、近年の試みとして力のインタラクションを考慮した CFO の推定も行っており非言語コミュニケーションによるチームワーク分析を可能としている [7].

1.3.1 CFO の定義

Concern For Others: CFO を定義するにあたって, Fig. 1.3に示すように単独作業と協調作業の違いについて考える. 単独作業を行う際は作業対象のみ考慮し操作を行う. 一方, 協調作業時には作業対象のみではなく, 他者が介在するため, 単独作業時では現れ得なかった操作量が発生する. この操作量を CFO と定義づける. これは作業に対して良いパフォーマンスをもたらさない場合でも CFO と呼ぶ. 定義より, CFO の推定量 σ_i は,

$$\sigma_i = u_i - f_{NN}(X_i) \quad (1.1)$$

のように算出される. u_i は協調作業時の入力実測値, $f_{NN}(X_i)$ は単独作業時の入力予測値, $X_i \in R^N$ はニューラルネットワーク (Neural Network: NN) の予測に必要な N 個の入力変数, i は作業者の番号である.




Fig. 1.3: Concern For Others.

1.3.2 CFO の推定

CFO の推定は式 (1.1) より協調作業時の入力実測値と、単独作業時の入力予測値が必要である。そのため、協調作業時の単独入力予測を可能にする必要がある。そこで、単独作業時の操作特性を Neural Network: NN によりモデル化し推定する。推定された単独入力予測より CFO が推定されチームワーク評価が可能になる。CFO の推定の例を Fig. 1.4 に示す。




Fig. 1.4: Estimation of CFO.

1.3.3 CFO によるチーム分け

現状のチーム分けの手法ではパフォーマンスを平均化するような分け方になる問題点が存在した。また、考慮されるのは単独作業効率のみであり協調作業効率については考慮されていない。

CFO によるチームワークアシストを行う先行研究が存在する [8]。通常のパフォーマンスによるアシストではなく CFO を用いたアシストであり協調作業効率を考慮してアシストを行う事が可能である。

よって、CFO を用いてチーム分けを行うことにより協調作業を考慮したチーム分けを行うことが可能になる。しかし、先行研究では、1 分から 5 分間の単独作業と協調作業を最低 1 回ずつ各被験者に対して行わなければならない。チームワーク評価としては問題にならないが、「チーム分け」を行う場合、想定される組み合わせ全てに対して協調作業を行う必要があるため、膨大な時間が必要であり現実的でない。

1.4 本研究の目的

本研究では人間の協調作業における操作特性をモデル化し、モデルどうしで協調作業を行うことによるチームワーク評価を目指す。作成されたモデルどうしでの協調作業により、多くの組み合わせでの CFO の推定が可能になる。推定された CFO よりタスクのパフォーマンスによるチーム分けだけでなく、「相性」等を考慮したチーム分けが可能になると考えられる。

モデルどうしによる協調作業が可能か検討するため、実際の協調作業時の相手からの影響を受けた状態の人間をモデル化する。生成されたモデルどうしによる協調作業を行い、実際の協調作業の操作入力と近似することを確認することによりモデルどうしによる協調作業の可能性・CFO 推定の可能性について考察する。

第2章 協調作業プラットフォーム

本章では，協調作業を行う際に用いた協調作業プラットフォームについて以下の項目を述べる．

2.1	シーソータスク	15
2.2	システム全体像	17
2.3	入力インタフェース	19
2.3.1	ハードウェア	19
2.3.2	制御手法	21
2.4	まとめ	22

2.1 シーソータスク

先行研究における協調作業プラットフォームは4人までの協調作業を想定したプレートコントロールタスクを用いていたが、協調作業可能なモデルを生成することを考慮し、Fig. 2.1に示すような単純化されたタスクを用いる。

先行研究で用いていたプレートコントロールタスクは板の上にボールを載せ、板を傾けることでボールを転がしターゲットを追従するタスクであった。また、ボールの移動はダイナミクスを適用することが可能であり難易度が調整可能である。また、前後左右に移動するため二次元のタスクであると言える。

本研究では、単独作業モデルだけではなく協調作業モデルについても生成することによる協調作業の推定を必要としていることからモデル化の難易度が高いことが推測される。そのため、プレートコントロールタスクの次元を二次元から一次元に減らしたシーソータスクを提案し実験・解析を行う。

シーソータスクは仮想空間内にHMDを通して表示され、トラッキングマーカにより現実世界と同じ位置に表示される。操作目標は赤色のターゲットバーとし、被験者は操作棒を操作してプレートを傾けることでボールを動かし、目標を追従する。操作棒は仮想現実内のシーソーと連動して動く。この操作棒を矢印の方向に傾けることによってタスクの操作を行い、ボールを操作する。赤い線で示された目標線は3秒ごとにランダムに移動し、この目標にボールを近づけることをタスクの目的とする。目標は3秒ごとにランダムに移動し、プレートの全長に対し1/2以下1/20以上の移動量になるように制限してある。

ボールの状態は位置 x 、粘性係数 η 、質量 m_b 、重力加速度 g 、プレートの角度 θ としたとき、

$$m\ddot{x} = m_b g \sin \theta - \eta \dot{x} \quad (2.1)$$

で表される。(式(2.1))式を用いてプログラムで計算を行い画面上に表示する。また、プレートに適用されるダイナミクスはプレートの角度 θ 、被験者からのそれぞれの入力トルク τ_1, τ_2 、プレートの操作トルク τ 、質量 m_p 、ダンパの減衰係数 c 、ばね定数 k としたとき、

$$m_p \ddot{\theta} + c \dot{\theta} + k \theta = \tau_1 + \tau_2 \quad (2.2)$$

と表される．式 (2.2) で表されるプレートダイナミクスはインタフェースより被験者に力覚フィードバックされ，それぞれの被験者間で力覚を共有する．

2.2 システム全体像

システム全体像を Fig. 2.2に, 全体のブロックダイアグラムを Fig. 2.3に示す. モータの制御はPCから行われ, マイコン (マイクロコントローラ) はPCとの通信のために用いられる. PC-マイコン間, PC-HMD間通信にはUDP/IP通信を用いる. また, PC-マイコン間は10[kHz], PC-HMD間は100[Hz]で通信を行う.




Fig. 2.1: シーソータスク




Fig. 2.2: 協調作業プラットフォーム




Fig. 2.3: プラットフォームのダイアグラム

2.3 入力インタフェース

2.3.1 ハードウェア

構成した入力インタフェースの全体像を Fig. 2.4に示す. インタフェースは AC サーボモータ, マイクロコントローラ, D/A コンバータ, Head Mount Display: HMD より構成される. 以上の器具に関する詳細を Table 2.1に示す.

モータとコントロールバーは Fig. 2.5に示すようにギアなどを介さず直接接続されており, 後述の制御手法と合わせることでより綿密な制御と高精度な反トルクの推定を可能にする.

Table 2.1: Specifications.

Parts	Ratings
AC Servo Motor	Mitsubishi HF-KP13 100W 0.95N·m MAX
Servo Amplifier	Mitsubishi MR-J3-10A1
Micro controller	ARM, mbed NUCLEO-F767ZI
D/A Converter	Microchip MCP4922 12bit 5V Unipolar
HMD	Oculus VR, Oculus Quest




Fig. 2.4: Input interface.




Fig. 2.5: Motor and control bar.

2.3.2 制御手法

モータに対して、外乱を抑制しより精密な制御を行うために Disturbance Observer: DOB[9] を適用し制御する。また、Reaction Torque Observer: RTOB[10] により反トルクを推定する。

先述の制御手法はモデル式を用いて外乱を抑制しているため、システムに対するシステム同定が必要である。使用するモータはトルク τ 、イナーシャ J 、粘性摩擦係数 B 、角速度 ω 、角加速度 $\dot{\omega}$ としたとき、

$$\tau = J\dot{\omega} + B\omega \quad (2.3)$$

のように、モデル式化できる。 τ 、 ω 、 $\dot{\omega}$ を実測し、擬似逆行列を解くことにより J 、 B を求め、制御に適用した。

以上の制御手法により推定されたトルクを式 (2.2) に入力することによりプレートを操作する。人間どうして協調作業を行う場合、それぞれのモータにかかるトルクの推定値を足し合わせたものを式 (2.2) に入力することにより2つのモータの位置を同期させるとともに、力覚を共有する。

2.4 まとめ

本章では協調作業を行うための協調作業プラットフォームについて述べた．協調作業推定という難易度がより高いと推測される内容に対して操作次元を落とすことでより基礎的な内容から研究を行うことを可能とした．また，ダイレクトドライブモータを使用したインタフェースを用いることで力覚的インタラクションを実現している．

第3章 モデルの生成

本章では，本研究における単独作業・協調作業モデルの生成について，以下の項目より述べる．

3.1	使用フレームワーク	24
3.2	データセットの生成手法	25
3.3	単独作業モデル	27
3.4	協調作業モデル	28
3.5	まとめ	29

3.1 使用フレームワーク

使用したプログラミング言語は C++ 20・Python 3.7.4 であり、機械学習用のフレームワークとして TensorFlow 2.1.0・Keras を使用した。Python は NN・データ処理に関する記述の容易さから主に NN の学習・データの処理に用いた。また、単独作業・協調作業推定は NN にタスクを実行させる事により行う関係上大量の For-Loop 処理が必要である。Python はインタプリタ型言語であるため For-Loop 処理が不得意であり処理速度が遅い。また、Python はすべての変数がオブジェクトで表現されているため、実行メモリの観点でも問題がある。そのため、単独作業・協調作業推定時は C++ を使用し、高速・省メモリ化を図った。

3.2 データセットの生成手法

今回、単独・協調双方において用いている全結合ニューラルネットワークに対して入力するデータセットの生成手法を述べる．Fig. 3.1に示すように遅れ時間，データ間隔，過去ステップ数，入力データ種類数の4つのパラメータにより生成する．遅れ時間とはNNの出力の時間と入力の時間差のことであり，人間の認識の遅れを考慮している．また，時系列データを連続ではなくデータ間隔を過去ステップ数分開けることにより同じ層の数でより長期に渡る情報を入力可能になる．入力データ種類数と過去ステップ数を乗算したものが入力層の数になる．




Fig. 3.1: Example of make datasets.

3.3 単独作業モデル

CFO の推定に必要である単独作業モデルの生成するために NN により単独作業時の操作特性を学習しモデルの生成を行う．NN の基本構成として全結合 NN を用いた．このときの NN の構成の詳細について Table 3.1に示す．また，学習に用いたデータセットの詳細について Table 3.2に示す．

Table 3.1: NNs settings for solo task modeling.

Parameter	Settings
Input & Output layer activation	Liner
Middle layers activation	Sigmoid
Optimizer	Stochastic Gradient Descent lr=0.1
Loss	Mean Squared Error
Layers consisting	40 - 60 - 30 - 1

Table 3.2: Datasets settings for solo task modeling.

Parameter	Settings
Input data	Input Angle $\cdot$ Position Error $\cdot \tau_1 \cdot \tau_2$
Delay time	25 ms
Interval	25 ms
Steps	10
Output data	τ_1

3.4 協調作業モデル

協調作業モデルの生成するために、協調作業時の人間の操作特性を NN により学習し、モデル化を行う。単独作業モデルの生成手法に基づき NN の基本構成として全結合 NN を用いた。このときの NN の構成の詳細について Table 3.3に示す。層の構成以外特に変更はしていない。また、学習に用いたデータセットの詳細について Table 3.4に示す。

Table 3.3: NNs settings for solo task modeling.

Parameter	Settings
Input & Output layer activation	Liner
Middle layers activation	Sigmoid
Optimizer	Stochastic Gradient Descent lr=0.1
Loss	Mean Squared Error
Layers consisting	40 - 30 - 15 - 1

Table 3.4: Datasets settings for solo task modeling.

Parameter	Settings
Input data	Input Angle • Position Error • τ_1 • τ_2
Delay time	25 ms
Interval	25 ms
Steps	10
Output data	τ_1 or τ_2

3.5 まとめ

本章では協調作業モデルの生成手法について述べた。入力データは人間の特性を考慮した形で生成した上でそれぞれ単独作業・協調作業モデルを生成する。また、機械学習でよく用いられる Python だけではなく C++を用いることで作業推定という特殊な使用方法においても高速な推定を実現している。

第4章 実験1 協調作業モデル生成可能性の検討

本章では，本研究で提案するモデルどうしの協調作業による協調作業の推定およびCFO'の推定についての実験と結果について以下の項目を述べる．

4.1	実験	31
4.2	単独作業モデルによる単独作業の推定	32
4.3	モデルどうしの作業による協調作業の推定	34
4.3.1	協調作業の推定	34
4.3.2	予測が不可能な原因	35
4.3.3	協調作業全体のモデル化の検討	37
4.3.4	CFO'の推定	38
4.3.5	組み合わせを変えた場合の協調作業推定	41
4.4	まとめ	43

4.1 実験

20代の男性8人8組の被験者に対して実験を行った。単独作業・協調作業ともに80秒間の作業を行った。なお作業の際は私語を慎むように指示した。人間のモデルは時間によって変化することが考えられるため、当日中にすべての実験を行った。80秒間の作業のうち最初の10秒間を除外し、10-60秒間で学習を行い、60-80秒間で学習結果の確認を行った。

4.2 単独作業モデルによる単独作業の推定

NN を先述の通り 10-60 秒間のデータで学習を行った後、60-80 秒間で予測を行った。このときの 20 秒間の実際の値と予測の値との誤差のヒストグラムを Fig. 4.1 に示す。また、単独作業モデルの操作力によるタスクの操作、単独入力予測が可能か確認するために単独作業時のターゲット情報のみを用いてタスクをモデルに実行させた。このときの 60-80 秒間の実際の値と予測の値との誤差のヒストグラムを Fig. 4.1 に示す。

どちらもともに 0 を中心に分布しており精度良く予測ができていると言える。




Fig. 4.1: Histogram of learning error.




Fig. 4.2: Histogram of solo task by model.

4.3 モデルどうしの作業による協調作業の推定

4.3.1 協調作業の推定

NN の学習は単独作業モデルと同様に問題なく行うことができた． Fig. 4.3にモデルによる協調作業予測と実際の作業の一例を示す． また，モデルどうしによる協調作業を行った際， Fig. 4.3-(a) に示すように協調作業を予測可能な組があった． しかし， Fig. 4.3-(b) に示すように発振してしまう， Fig. 4.3-(c) のように偏りが現れる予測不可能な組が存在し， 予測可能な4組と予測不可能な4組に分類された．




Fig. 4.3: Example of collaborative task prediction.

4.3.2 予測が不可能な原因

予測が不可能であった原因を明らかにするために、単独作業モデルによる同じ目標に対する個人操作予測を行い、個人操作モデルの類似性を比較した。8人全員の作業結果を Fig. 4.4に示す。予測可能な組のそれぞれの予測入力操作量が近似しており個人操作特性が似ているのに対し、予測不可能な組は予測入力操作量が異なっており個人操作特性が異なっていることが判明した。個人操作特性の類似性は CFO の大小に関連するため、2つの組の CFO の平均絶対誤差の平均値を比較したものを Fig. 4.5に示す。すると、モデル化可能な組の CFO が小さいことが確認された ($p < 0.01$)。よって、CFO が小さいことから協調作業時における操作特性は個人操作特性と似ており個人操作特性の学習に使用したものと同等の NN でモデル化が可能であり、モデルどうしによる協調作業が可能であったと考えられる。予測不可能な組は CFO が大きいため、個人操作特性の学習に使用した NN と同等のものでは不十分だった可能性が考えられる。よって、より複雑な操作特性を学習可能な NN を検討する必要があると考えられる。




Fig. 4.4: Histogram of solo task by model.




Fig. 4.5: Mean Absolute Error of two group CFO.

4.3.3 協調作業全体のモデル化の検討

Fig. 4.3-(c) のように偏りが現れ協調作業時の各被験者の操作力の推定が行えない場合であっても、シーソーの角度やボールの位置は精度良く推定できており、協調作業全体の推定は実現していた。そこで、各被験者の操作力の和と予測された力の和を比較した。ここでの各被験者の操作力の和がタスクを操作する実際の力となり、協調作業全体の操作力といえる。Fig. 4.3-(b) の結果は発振してしまっており作業が行えていなかったため除外し、Fig. 4.3-(a), (c) についての結果を Fig. 4.6に示す。

どちらもともに精度良く推定できており、生成された協調作業もでは協調作業全体の推定に関しては実現できていると言える。つまり、現段階では先行研究での Position CFO: PCFO の推定の実現は可能であり、Force CFO: FCFO の推定は困難であるといえる。




Fig. 4.6: Overall model of cooperative task.

4.3.4 CFO' の推定

協調作業を推定可能な組から推定される CFO である CFO' の推定を行った．定義より，CFO' の推定量 σ'_i は，

$$\sigma'_i = f_{NNc}(X_{ci}) - f_{NNs}(X_{si}) \quad (4.1)$$

のように算出される． $f_{NNc}(X_i)$ は協調作業時の入力予測値， $f_{NNs}(X_i)$ は単独作業時の入力予測値， $X_{ci} \in R^N$ ， $X_{si} \in R^N$ はニューラルネットワーク (Neural Network: NN) の予測に必要な N 個の入力変数， i は作業者の番号である．式 (4.1) より推定された CFO' と 協調作業の実測値と式 (1.1) より推定された CFO を Fig. 4.7に示す．また，CFO と CFO' の関係を Fig. 4.8に示す．CFO と CFO' の相関係数は $r = 0.77$ であり CFO' の推定が可能であることが示唆される．




Fig. 4.7: CFO and CFO'.




Fig. 4.8: Compare with Actual CFO and Predict CFO ' .

4.3.5 組み合わせを変えた場合の協調作業推定

A～Dの被験者のうちA・C, B・Dのペアで協調作業モデルを生成しA, Bの協調作業モデルどうして協調作業を行い実際のA・Bのペアの協調作業と比較したものをFig. 4.9に示す.

Fig. 4.9-(a)に示すように力の推定結果は振幅が小さく推定できているとは言い難い. しかしFig. 4.9-(b)に示すように角度の推定結果は良好に推定できているといえる. 協調作業全体のモデル化検討の結論と同様に, 現段階では先行研究でのPCFOの推定の実現は可能であると考えられる. 以上のことから組み合わせを変えた場合における協調作業推定の可能性が示唆される.




Fig. 4.9: Prediction cooperative task of another pair.

4.4 まとめ

本章では、実際に協調作業モデルを生成し、協調作業モデルどうしによる作業推定の実現が可能か検討を行った。その結果、協調作業モデルどうしによる作業推定の実現が可能であることを示唆した。しかしながら、全体の半分の組み合わせにおいてのみの成功に留まり、モデル化手法の改善が必要である。

第5章 実験2 協調作業モデルどうしによる 協調作業推定

ここまでで、協調作業モデルどうしによる作業推定の実現が示唆されたことから、本章では協調作業モデル生成手法を改善し、すべての組み合わせにおけるモデル化を実現する。その上でモデルどうしによる組み合わせ評価の実現可能性について評価する。

本章では、以下の項目を述べる。

5.1	モデル生成手法の改善	45
5.1.1	Optuna によるハイパーパラメータ最適化	45
5.1.2	DTW による評価値	45
5.2	実験	48
5.2.1	協調作業モデル生成	48
5.2.2	協調作業モデルどうしによる作業予測	49
5.3	結果	50
5.3.1	協調作業モデル生成	50
5.3.2	協調作業モデルどうしによる作業予測	52
5.4	まとめ	54

5.1 モデル生成手法の改善

前章でモデルを生成する中でハイパーパラメータによる影響が大きいことがわかっていて、そのため、NN のモデル学習時によく用いられる手法であるハイパーパラメータ最適化を適用する。最適化には様々な手法が存在するが、以下の事柄より Optuna[11] を採用した。

- 最適化精度が高い
- Python のライブラリが存在し、使用が容易
- TensorFlow に対応

5.1.1 Optuna によるハイパーパラメータ最適化

通常 Optuna によるハイパーパラメータの最適化は NN の学習結果の損失値をそのまま用いる場合が多い。しかし、作業モデルによる作業を評価する必要があるため学習により生成されたモデルにより作業を行った結果に対して Fig. 5.1 のように最適化を行う。

Optuna は評価値に対して最適化を行うため、評価関数が重要になる。機械学習における評価関数として、Mean Squared Error: MSE 等が用いられる。作業予測を行う特性上、高い精度で一致することは少なく位相のズレなどが存在する場合がある。そのため、MSE による評価では悪く評価されてしまう場合がある。特に、学習が失敗したときに現れやすい振幅がゼロの波形の場合、学習ができている場合と比較して差がない、もしくは逆転してしまう場合がある。

5.1.2 DTW による評価値

このようなケースに対応するため、Dynamic Time Warping: DTW[12] を用いる。DTW は計算コストが高く計算時間がかかるため、FastDTW[13] を用いて DTW 距離を求めた。学習が問題なく完了している個人操作モデルによる個人作業予測結果と実際の作業結果の RMS_{Real} 、DTW 距離 $DTWD_{Real}$ と学習が失敗した時を想定した $y = 0$ と実際の作業結果の RMS_{Zero} 、DTW 距離 $DTWD_{Zero}$ を

$$DTW_{Eval} = \frac{DTWD_{Real}}{DTWD_{Zero}}, RMS_{Eval} = \frac{RMS_{Real}}{RMS_{Zero}}, \quad (5.1)$$

で比較する. Fig. 5.2より DTW は RMS と比較して有意に評価できていることがわかる ($p < 0.01$). 評価値として, 実際のプレート角度と予測されたプレート角度の DTW 距離を用いる. また, 協調作業が実施できているかの評価も含めるために実際のボール位置と予測されたボール位置の DTW 距離も求めそれぞれの積を評価値として用いる.

Optuna により最適化するパラメータを Table 5.1に示す. それぞれの被験者に対して 400 トライアルすることにより協調作業モデル化を実現する.




Fig. 5.1: Cooperative Tasks between models.

Table 5.1: Optimize Hyper-parameter.

Parameter	Search range	
	LSTM	DNN
n hidden	50 – 400	50 – 400
n layer	1	1 – 7
Activation	sigmoid, tanh, relu	sigmoid, tanh, relu
Recurrent Activation	sigmoid, tanh, relu	N/A
Optimizer	sgd, adam, nadam	sgd, adam, nadam




Fig. 5.2: The comparison of evaluation values DTW and RMS.

5.2 実験

5.2.1 協調作業モデル生成

20 代男女 5 人の被験者に対して単独作業を 80 秒間実施した。また，被験者それぞれの総当り 10 組に対して協調作業を 80 秒間実施した。このときデータは 10kHz で取得し，NN の学習用のデータとして 200Hz に間引き使用する。Table 5.2に示すような設定の DNN・LSTM と Optuna により協調作業モデルを生成した。

入力データとして，人間の認知の遅れを考慮し遅れ時間 (25 ms) を設けた。また，一定間隔 (25 ms) ごとにデータを 10 個サンプリングした。

以上より $8 \times 10 = 80$ を入力要素としている。

Table 5.2: NNs settings for solo or cooperative task modeling.

Parameter	Settings	
	Solo	Cooperative
Input data	Position •	Position •
	Velocity	Velocity
	(Input Angle •	(Input Angle •
	Ball • Target •	Ball • Target •
	Ball-Target Error)	Ball-Target Error)
Delay time	$\tau_1 \cdot \tau_2$	$\tau_1 \cdot \tau_2$
	25 ms	25 ms
Interval	25 ms	25 ms
Steps	10	10
Output data	τ_1	τ_1 or τ_2

5.2.2 協調作業モデルどうしによる作業予測

10 組の協調作業から 20 の協調作業モデルが生成される．重複や同じ人どうしの作業を除く総当り数は 160 組となる．160 組全ての組で協調作業モデルどうしによる協調作業予測を行い，実際の作業と比較する．

5.3 結果

5.3.1 協調作業モデル生成

DNN と LSTM においてそれぞれ Optuna により表 5.1 のようにハイパーパラメータを最適化し，協調作業モデルを生成した．なお，Epochs は 50 とし 10 epoch の間に損失の改善が見られなければ学習を停止するものとした．

それぞれの実際の作業結果と作業予測結果の MSE を図 5.3 に示す．DNN と LSTM の間に有意差は見られず，Optuna によるハイパーパラメータ最適化の影響が大きいことがわかる．

先行研究では 8 組中 4 組のモデル化に成功したのに対し，最適化を用いることで 10 組全ての組に対して DNN と LSTM 双方でモデル化に成功した．ゆえに，最適化を用いることは協調作業モデル化に対して有用であるといえる．

また，全てのペアにおける実際の作業結果と DNN による作業予測結果の誤差のヒストグラムを図 5.4 に示す．すべて組み合わせにおいてヒストグラムがゼロを中心に分布しており，問題なく学習に成功しているといえる．




Fig. 5.3: The comparison of evaluation values LSTM and DNN.




Fig. 5.4: Histogram of cooperative task by model-model.

5.3.2 協調作業モデルどうしによる作業予測

モデル名 A_B のとき作業者 A が B を相手に作業を行ったときのデータから生成された A の協調作業モデルをあらわす。

160 組すべての作業結果を確認した結果、Optuna による最適化に使用した評価値が 10000 を下回る場合作業が可能であると判断し、評価対象とする。モデル名 A_B から E_D すべての協調作業の予測の総当り結果を 10000 を上限値とし 5000 を中央値としたカラーマップにした。DNN によって生成されたモデルどうしによる協調作業の推定結果を図 5.5 に示す。また、LSTM によって生成されたモデルどうしによる協調作業の推定結果を図 5.6 に示す。赤色の部分は作業に失敗し、青色は特に良好に作業を推定できていることを示す。

DNN は LSTM と比較して実際の協調作業とは異なる作業者との作業によって生成されたモデルどうしによる作業においても実際の協調作業と近似することできている。

対して LSTM は A_B と B_A 間の協調作業のように実際の協調作業と等しいペアでは良好に推定ができているが、特に B と D のペアの 16 マスに着目すると実際の協調作業と等しいペア以外では作業が行えていない。B と D 以外の組み合わせにおいても同様の傾向が見られる。原因として考えられるのは、LSTM の長期に記憶することが可能な特性により「協調作業特性」の学習ではなく、「協調作業」の学習をしてしまったと考えられる。つまり、過学習状態であることが考えられ LSTM を使用するためには過学習状態を防ぐ必要がある。

以上より、LSTM は計算資源が必要であることを考慮すると DNN と Optuna によるハイパーパラメータの最適化が協調作業特性のモデル化において有用であると言える。

また、A と C、C と E のように協調作業を良好に推定可能な組み合わせと B と D、A と E のようにそうではない組み合わせが存在する。このことから、提案手法による協調作業の推定は良好に推定可能な組に限られる。

しかしながら、協調作業の推定が不可能な組においても、モデル化のときの協調作業の相手によっては推定が可能になっている。よって、改善のためには推定が可能なモデルが生成されたときの協調作業の相手の解析を行い、協調作業の推定が可能になる要因を特定する必要があると考えられる。




Fig. 5.5: Model-model cooperative task heatmap (DNN).




Fig. 5.6: Model-model cooperative task heatmap (LSTM).

5.4 まとめ

本章では、実験1で課題となった全ての組み合わせにおける協調作業の推定を目指し、協調作業モデルの生成手法を改善した。その結果、全ての組み合わせにおける協調作業モデル生成に成功した。生成されたモデルどうしによる作業推定を試みた結果、実際の作業を行った組み合わせのモデルどうしによる作業推定は良好に行うことができた。しかしながら、実際の作業を行っていない場合を想定した組み合わせにおける作業推定結果は全て良好であるとは言えず、モデルの精度に課題を残す結果となった。

第6章 実験3 協調作業の解析

ここまでで、協調作業モデルどうしによる様々な組み合わせの作業推定の実現を試みたところ、実際の作業により生成されたモデルどうしによる推定は実現可能であった。しかし、チーム分けで必要となる実際に実験を行っていない組み合わせの推定を想定した場合推定ができていない組み合わせが多い結果となった。原因として過学習やタスク自体を学習してしまったことが考えられることから、協調作業自体の解析を行い、協調作業モデル生成手法の改善に務める。

本章では、以下の項目を述べる。

6.1	CFO の推定	56
6.1.1	単独・協調作業時の力	56
6.1.2	CFO の推定手法	56
6.2	協調作業プラットフォーム	57
6.2.1	ボール操作型	57
6.2.2	直接追従タスク	57
6.2.3	協調作業パフォーマンス	60
6.3	実験	61
6.3.1	単独作業モデル生成	62
6.4	結果	63
6.4.1	力と CFO の解析	64
6.4.2	区間における CFO とパフォーマンスの相関	66
6.5	モデルの評価値と相関	69
6.6	まとめ	71

6.1 CFO の推定

6.1.1 単独・協調作業時の力

単独作業時と協調作業時ではそれぞれ同じダイナミクスを持つ操作対象に対して操作を行う。そのため、協調作業時においてそれぞれの被験者からの入力に完全に一致する場合、タスクの操作に必要な力は単独作業時と比較して $1/2$ になる。

それぞれの被験者からの入力量はそれぞれを加算した場合反発する力が相殺し、実際にタスクを駆動した力になる。また、それぞれを減算した場合加算した場合と対比してタスクを操作するためには関係ない力になる。減算した力は、タスクを操作することに関係はないが力覚コミュニケーションが可能な領域であると考えられるため協調作業の解析や協調作業モデルの生成に重要であると考えられる [4]。しかし、CFO を推定する場合単独作業モデルがタスクを操作することのみをモデル化していることから、減算した力はノイズになってしまうことが考えられる。そこで、加算した力に着目し、CFO の推定を行う。

6.1.2 CFO の推定手法

先行研究では各被験者の実際の入力を τ_i 、個人作業モデルにより推定された入力を $\hat{\tau}_i$ とすると各被験者の CFO σ_i は

$$\sigma_i = \tau_i - \hat{\tau}_i \quad (6.1)$$

で表される。本研究では加算した力に着目し、CFO の推定を行うことから提案する CFO $\hat{\sigma}_i$ は

$$\hat{\sigma}_i = \sum \tau_i - \hat{\tau}_i \quad (6.2)$$

で表される。

6.2 協調作業プラットフォーム

6.2.1 ボール操作型

CFO によるチームワークアシストを行う研究に用いていたプレートコントロールタスクや先行研究において協調作業モデルを生成することを目的に単純化し構築した??に示すようなシーソータスクなどのタスクで CFO の推定・解析を行ってきた。これらのタスクはプレートを傾げることでボールを操作するボール操作型協調作業であると言える。解析を行う際、ボール操作型の協調作業では操作入力がボールを操作するための入力であるため直接解釈することができず、解析が困難であるという問題が存在した。

6.2.2 直接追従タスク

先行研究におけるシーソータスクのボールを取り除きコントロールバーで直接ターゲットに追従する Fig. 6.1 に示すような直接追従タスクを構築する。直接追従タスクでは、ターゲットを追従するにあたってボールのように途中に介するものが存在しないため、力の解釈が容易になる。直接追従タスクは Fig. 2.2 に示すように仮想空間内に HMD を通して表示され、トラッキングマーカーにより現実世界と同じ位置に表示される。操作目標は赤色のターゲットバーとし、被験者は操作棒を操作することで仮想空間内のコントロールバーを動作させ目標を追従する。

目標は 3 秒ごとに左右どちらかの方向に一定距離で移動する。また、ターゲットの移動方向がわかりやすいように次のターゲットの位置になめらかに移動させるものとする。また、コントロールバーに適用されるダイナミクスはプレートの角度 θ 、被験者からのそれぞれの入力トルク τ_1, τ_2 、コントロールバーの操作トルク τ 、質量 m_p 、ダンパの減衰係数 c 、ばね定数 k としたとき、

$$\tau = \tau_1 + \tau_2 \quad (6.3)$$

$$m_p \ddot{x} + c \dot{x} + kx = \tau \quad (6.4)$$

と表される。インタフェースとして、操作棒をつけたモータ 2 つを Fig. 6.2 のように設置した。このモータに対して、外乱を抑制するために Disturbance Observer: DOB[9] を適用し制御する。また、Reaction Torque Observer: RTOB[10] により反トルクを推定する。

推定されたトルクを式 (6.3), 式 (2.2) に入力することによりプレート进行操作する. 人間どうして協調作業を行う場合, 式 (6.3) よりそれぞれのモータにかかるトルクの推定値を足し合わせたものを式 (2.2) へ入力することにより 2 つのモータの位置を同期させるとともに, 力覚を共有する.




Fig. 6.1: Direct Follow Task.




Fig. 6.2: Interface for Direct Follow Task platform.

6.2.3 協調作業パフォーマンス

ターゲットとコントロールバーの誤差が 0.15 rad 以内である時間を接触時間と定義し、接触時間をパフォーマンス評価指標として利用する。協調作業時において、パフォーマンスには個人技能が影響する。個人技能の影響を除外するためにそれぞれの個人作業モデルによる作業結果を平均し、実際の作業結果と比較することで個人技能に影響されずパフォーマンス評価を行うことが可能になる。ここでパフォーマンス P は J_H を人間どうしにおける作業時の接触時間、 J_{NN} をモデルによる作業結果を平均したものとすると

$$P = J_H - J_{NN} \quad (6.5)$$

のように表される。 P が正の値であるとき単独作業時と比較して作業効率が向上していることを示し、負の値である時作業効率が低下していることを示す。

6.3 実験

20代の男性3人の被験者に対して単独作業を80秒間実施した。また、被験者それぞれの総当り3組に対して協調作業を80秒間実施した。このときのデータは10 kHzで取得し、NNの学習用のデータとして250 Hzに間引き使用する。

実験後、Table 6.1に示すような設定のLSTMで単独作業モデルを生成した。このとき入力データとして遅れ時間(4ms)を設け、一定間隔(4ms)ごとに過去40のデータをサンプリングした。また、入力要素としてコントロールバーの位置、ターゲットバーの位置、それぞれの位置誤差、入力トルクを使用している。

以上より4の入力要素に対して40の過去ステップを持ったデータを入力要素としている。

Table 6.1: Solo-Model Configuration.

Parameter	Settings
n hidden	80
Activation	relu
Recurrent Activation	sigmoid
Optimizer	adam

6.3.1 単独作業モデル生成

被験者の単独作業結果より，LSTM で学習を行う．学習されたモデルを実際のタスクに適用し，モデルからのトルクでタスクを駆動することにより単独作業の推定を行った．その時の実際の作業時のコントロールバーの角度と推定されたコントロールバーの角度の誤差のヒストグラムを Fig. 6.3に示す．すべての被験者においてヒストグラムがゼロを中心分布しており，問題なく作業を推定できているといえる．




Fig. 6.3: Histogram of errors comparing the results of the Solo-Model with the actual work results.

6.4 結果

先行研究において、協調作業時のそれぞれの CFO の和はパフォーマンスと正の相関があることがわかっている [14]。そのため、本研究においても和の CFO とパフォーマンスとの関連について着目して解析を行う。

本研究では CFO の推定手法を新たに提案しているため、従来手法による和の CFO と提案手法によって推定される和の CFO が存在する。そこで、従来手法と提案手法それぞれの CFO から和の CFO を求め結果の比較を行う。

6.4.1 力と CFO の解析

協調作業時におけるそれぞれの被験者の合力をターゲット移動毎3秒ごとに分割し、移動方向で正規化し 95%信頼区間付きでグラフ化したものを Fig. 6.4に示す。また、提案する CFO により算出された和の CFO を同様にターゲット移動毎3秒ごとに分割し、移動方向で正規化し 95%信頼区間付きでグラフ化したものを Fig. 6.5に示す。

Fig. 6.5に着目すると、0.6 秒付近で正負が逆転する波形になっていることがわかる。そこで、0.12-0.64 sec を区間 1, 0.64-1.16 sec を区間 2 として考える。Fig. 6.4, Fig. 6.5にはそれぞれ区間 1 を黄色、区間 2 を水色で着色してある。

着色した結果から Fig. 6.4に着目すると、区間はそれぞれ実際の作業におけるタスクへの入力の立ち上がり・立ち下がりに対応していることがわかる。このことから、区間 1, 2 の和の CFO はそれぞれパフォーマンスに対して別の影響を与えられ。

Table 6.2: Solo-Model Configuration.

	Section 1	Section 2
Conventional	0.003	-0.052
Proposed	0.226	-0.308




Fig. 6.4: Changes in Net CFO for 3 seconds per target movement (with 95% confidence interval)




Fig. 6.5: Changes in Summation CFO for 3 seconds per target movement (with 95% confidence interval)

6.4.2 区間における CFO とパフォーマンスの相関

従来手法による和の CFO の推定結果とパフォーマンスを Fig. 6.6に示し、提案手法による和の CFO の推定結果とパフォーマンスを Fig. 6.7に示す。また、それぞれの相関係数を Table 6.2に示す。Fig. 6.6, Fig. 6.7の和の CFO 各点はすべての被験者の作業結果をターゲット移動毎 3 秒ごとに分割し、移動方向で正規化した後の平均である。

Table 6.2より、従来手法では区間 1, 2 ともにパフォーマンスとの相関がなかったが、提案手法では僅かではあるが区間 1 におけるパフォーマンスと和の CFO に正の相関が、区間 2 におけるパフォーマンスと和の CFO に負の相関があることがわかる。

このことから、提案手法による和の CFO は直接追従タスクにおける協調作業の解析により適しているといえる。




Fig. 6.6: Summation CFO vs. Performance.




Fig. 6.7: Proposal Summation CFO vs. Performance.

6.5 モデルの評価値と相関

別の角度からの解析として、協調作業モデルどうしによる作業推定精度と各データの相関について確認した。これにより、協調作業推定精度が向上・悪化する原因の一端を推測する。

実験2で行った協調作業モデルどうしによる総当り結果の同じペア 16 データの評価値を平均化し、10 の平均化した評価値を得る。得た評価値と実際の作業を比較することで作業特性の観点から協調作業モデル生成精度との関連を確認する。

関連を確認したところ、それぞれの被験者の力の差をとったものの平均と評価値に負の相関があることがわかった。散布図を Fig. 6.8に示す。評価値は小さいほど精度が向上していると言えることから、差の力が大きいほどモデル化が容易であると言える。このとき、それぞれの被験者の和の力がタスクを駆動する力となるのに対して、差の力はタスク駆動に対して関係ない力となる。そのため、この力はそれぞれの被験者が行った力覚的インタラクションと考えることができ、それぞれのインタラクションが大きいほどモデル化が容易であると言える。




Fig. 6.8: Evaluation Value vs. Subtract Force.

6.6 まとめ

本章では、協調作業モデルの生成精度向上を目指すために、協調作業の解析手法の確立を行った。実際のチームワーク評価で重要となるパフォーマンスに着目し解析を行うことでモデルへの入力要素の厳選や前加工が可能になると考えられる。解析のために単純化したタスクを提案することで、ターゲット追従毎に分割し正規化した解析を実現した。結果、パフォーマンスと提案した CFO に弱い相関が現れるようになることがわかり、解析手法として有用であるといえる。

また、評価値と操作特性という観点から解析を行ったところ、それぞれの被験者のインタラクション量と考えることが可能な差の力と負の相関があることがわかり、インタラクションを増やすことで協調作業モデル生成精度を向上させることが可能であると示唆される。

第7章 結論

先行研究では、Concern For Others: CFO に着目し、定量的でリアルタイムなチームワーク評価を可能にしてきた。しかし、協調作業を組み合わせ毎に行う必要があり、チーム分けや多くの組み合わせのチームワーク評価は困難であった。

そこで、本研究では単純化された協調作業プラットフォームを構築し、人間の協調作業時における操作特性をモデル化、モデルどうしで協調作業を行うことによる協調作業の推定を行い、チームワーク評価を目指した。

本研究では、まず単純化された協調作業プラットフォームを構築し力のインタラクションが可能な協調作業を実現した。また、先行研究で行われていた単独作業モデル生成、CFO の推定を問題なく行うことができた。よって単純化された環境で協調作業モデル生成に関する実験を行うことができる。

次に、実際に協調作業モデルを生成し、協調作業モデルどうしによる作業推定の実現が可能か検討を行った。その結果、協調作業モデルどうしによる作業推定の実現が可能であることを示唆した。しかしながら、全体の半分の組み合わせにおいてのみの成功に留まり、モデル化手法の改善が必要である。

この結果を受けて、実験1で課題となった全ての組み合わせにおける協調作業の推定を目指し、協調作業モデルの生成手法を改善した。その結果、全ての組み合わせにおける協調作業モデル生成に成功した。生成されたモデルどうしによる作業推定を試みた結果、実際の作業を行った組み合わせのモデルどうしによる作業推定は良好に行うことができた。しかしながら、実際の作業を行っていない場合を想定した組み合わせにおける作業推定結果は全て良好であるとは言えず、モデルの精度に課題を残す結果となった。

実験1・2の結果を受けて、協調作業モデルの生成精度向上を目指すために、協調作業の解析手法の確立を行った。実際のチームワーク評価で重要となるパフォーマンスに着目し解析を行うことでモデルへの入力要素の厳選や前加工が可能になると考えられる。解析のために単純化したタスクを提案することで、ターゲット追従毎に分割し正規化した解析を実現した。結果、パフォーマンスと提案した CFO に弱い相関が現れるようにな

ることがわかり，解析手法として有用であるといえる．

以上より，本研究では協調作業時の人間の操作入力から協調作業モデルを生成し，モデルどうしによる作業推定が可能であることを示唆した．しかしながら，実際のチーム分け時必要となる最小限の実験による協調作業推定を実現するためにはモデル化精度が不足している．生成精度を改善するために協調作業解析手法を提案し，有用であることを確認した．

第8章 今後の展望

提案した協調作業解析手法が有用であることが示唆されたことから、提案した解析手法を使用してさらなる解析を行い、協調作業モデル生成の改善を行う。解析手法の充実のみならず、様々な条件における実験を行い、協調作業のより基礎的な解析結果を踏まえたモデルを生成する。

現状のタスクでは最大出力が1 Nm 程度と人間が簡単に抗うことができてしまい、外乱やダイナミクスの設定が困難である。そのため、更に強い力を出力可能である改善した実験タスクを構築し様々な実験条件における協調作業のデータ取得を目指す。

最終的には実際にチーム分け実験を行い本手法の有用性を確認する。また、その際には本実験で用いたタスクのパフォーマンスだけでなく、その他の作業においても有用であるか確認することで、応用性の確認についても確認する。

参考文献

- [1] 三沢 良, 佐相 邦英, 山口 裕幸, “看護師チームのチームワーク測定尺度の作成,” Japanese, 社会心理学研究, vol. 24, no. 3, pp. 219–232, 2009.
- [2] 稲葉 晶子, 大久保 亮二, 池田 満, 溝口 理一郎, “協調学習におけるインタラクション分析支援システム,” Japanese, 情報処理学会論文誌, vol. 44, no. 11, pp. 2617–2627, Nov. 2003.
- [3] 新池 一弘, 中峯 浩, 三宮 信夫, “ニューラルネットワークおよび局所探索法を用いた共同学習におけるペアの組合せ決定法,” Japanese, 計測自動制御学会論文集, vol. 38, no. 5, pp. 477–484, 2002.
- [4] K. B. Reed and M. A. Peshkin, “Physical collaboration of human-human and human-robot teams,” *IEEE Transactions on Haptics*, vol. 1, no. 2, pp. 108–120, Jul. 2008.
- [5] C. E. Madan, A. Kucukyilmaz, T. M. Sezgin, and C. Basdogan, “Recognition of haptic interaction patterns in dyadic joint object manipulation,” *IEEE Transactions on Haptics*, vol. 8, no. 1, pp. 54–66, Jan. 2015.
- [6] H. Igarashi: “Quantification of concern for others to social skill evaluation,” in *2013 IEEE RO-MAN*, Aug. 2013, pp. 559–564.
- [7] G. Sasaki and H. Igarashi, “Analysis of Force Interaction for Teamwork Assistance by Concern For Others,” *Intelligent Human Systems Integration 2019*, vol. 903, W. Karwowski and T. Ahram, Eds., pp. 771–776, 2019.
- [8] G. Sasaki and H. Igarashi: “Teamwork assistance based on concern for others,” in *IECON 2019 - 45th Annual Conference of the IEEE Industrial Electronics Society*, vol. 1, Oct. 2019, pp. 5425–5430.
- [9] K. Ohnishi, M. Shibata, and T. Murakami, “Motion control for advanced mechatronics,” *IEEE/ASME Transactions on Mechatronics*, vol. 1, no. 1, pp. 56–67, Mar. 1996.

- [10] T. Murakami, F. Yu, and K. Ohnishi, “Torque sensorless control in multidegree-of-freedom manipulator,” *IEEE Transactions on Industrial Electronics*, vol. 40, no. 2, pp. 259–265, Apr. 1993.
- [11] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama: “Optuna: A next-generation hyperparameter optimization framework,” in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, ser. KDD ’19, Anchorage, AK, USA: Association for Computing Machinery, 2019, pp. 2623–2631.
- [12] D. J. Berndt and J. Clifford: “Finding patterns in time series: A dynamic programming approach,” in *Advances in Knowledge Discovery and Data Mining*, 1996.
- [13] S. Salvador and P. Chan: “Fastdtw: Toward accurate dynamic time warping in linear time and space,” vol. 11, Jan. 2004, pp. 70–80.
- [14] G. Sasaki and H. Igarashi: “Temporal analysis of cfo in cooperative task for teamwork assist,” in *IECON 2018 - 44th Annual Conference of the IEEE Industrial Electronics Society*, Oct. 2018, pp. 5487–5492.

本研究に関する発表文献

1. 小林 航大, 五十嵐 洋: “力のインタラクションを考慮した人間モデルによる CFO の推定とチームワーク評価 ”, 産業計測制御研究会, IIC-19-010, 2019/11/29.
2. 小林 航大, 五十嵐 洋: “CFO の推定とチームワーク評価における協調作業モデル生成”, 日本機械学会ロボティクス・メカトロニクス講演会’20, 1A1-M09, 2020/5/28.
3. 小林 航大, 五十嵐 洋: “チームワーク評価における協調作業解析手法 ”, 日本機械学会ロボティクス・メカトロニクス講演会’21, 2P3-J11, 2021/6/8.