

2024年度 卒業論文

リアルタイムストレス指標を用いた遠隔操作環境における遅延補完システム

Delay Completion System in Teleoperation
Environment Using Real-time Stress Indicators

東京電機大学工学部 電子システム工学科

指導教員： 教授 五十嵐 洋

研究室名： 協調ロボティクス研究室

21EH060 中嶋 大智

2025年1月31日 提出

研究概要

近年、通信技術の発展に伴い、遠隔操作が様々な場面で活用されている。それに伴い通信遅延の問題が発生しており、それらを補う様々な遅延補完システムの開発や研究が行われている。また、近年提案されているこれらのシステムの多くには操作入力や遅延時間の推定にニューラルネットワークが多く用いられている。

しかし、現在のニューラルネットワークによる非線形予測の精度には限界が存在し、完璧な操作入力の予測は困難となっている。そこで本研究ではニューラルネットワークの精度向上を目指し、ECG(心電図) からリアルタイムで測定可能なストレス指標をニューラルネットワークの入力に用いる遅延補完システムの作成を行った。

追従タスクを用いて遠隔操作の再現を行った環境下で、遅延補完システムによる追従精度の向上や個人差による精度のばらつきの減少は確認された。しかし、ストレス指標を導入したことによる明確な予測精度の向上は見られなかった。また、遅延補完による追従精度の向上に伴い、ストレス指標の値が僅かに低下することが確認された。

目次

第1章	序章	1
1.1	研究背景	2
1.2	関連研究	3
1.2.1	遠隔操作における遅延補完	3
1.2.2	身体の状態推定	4
1.3	研究目的	5
第2章	提案手法	6
2.1	ストレス推定	7
2.2	遠隔操作の再現	9
2.3	遅延補完システム	10
第3章	実験概要	12
3.1	実験目的	13
3.2	実験環境	14
3.3	実験手法	15
3.3.1	予備実験	15
3.3.2	本実験	16
第4章	実験結果と考察	17
4.1	ニューラルネットワークの予測結果	18
4.2	予測誤差の変化	19
4.3	追従誤差の変化	20
4.4	追従とストレスの変化	21
4.5	予測モデルにおける重要度	22
第5章	結論と今後の展望	23

5.1	結論	24
5.2	今後の展望	25

第1章 序章

本研究では，ニューラルネットワークの入力にストレス指標を使用した遅延補完システムを作成を行い，そのシステムの有効性について評価した．本章では以下の項目について述べる．

- 研究背景
- 関連研究
- 研究目的

1.1 研究背景

近年、通信技術の発展に伴い、遠隔操作は医療や宇宙分野などに幅広く用いられている。遠隔操作は多くの場合、通信による遅延を伴うため、入力や映像に遅延が発生するという問題が存在している。操作を行う上で、通信による遅延は操作感、操作精度、信頼性の低下やシステムの不安定化を招くため、遠隔操作における通信遅延は大きな課題となっている [1]。

そこで、遠隔操作の通信遅延を補償するシステムとして、波変数制御、適応信号処理、適応フィルタを用いたシステムなど、様々な遅延補完システムが提案されている [2]。また、近年提案されているこれらのシステムの多くにはニューラルネットワークが使用されている。ニューラルネットワークを用いて、操作入力の予測や通信時に発生する遅延時間の推定、入力情報の補填を行うことが可能であり、遅延の補完やシステムの安定化、自律的な制御を行う手法が存在する [1]。これらの手法により、遅延下におけるパフォーマンスや操作性の改善を行うことができる。

また、これらに用いるニューラルネットワークは、入力と出力が非線形となっている。現在のニューラルネットワークでは、非線形における完璧な予測は困難であり、遅延補完の分野においてニューラルネットワークの精度向上が求められている。

1.2 関連研究

1.2.1 遠隔操作における遅延補完

遠隔操作の遅延補完に関する先行研究では、ニューラルネットワークを用いた予測モデルによって現在の状態と遅延時間を推定し、遅延補完を行う手法が存在する [3]。さらに、固定時間制御に加えて ANN を用いて不安定性の予測を行い、入力遅延による影響を軽減する手法 [1] や、ニューラルネットワークを用いた適応フィルタによって操作入力を安定性を向上させる手法も存在する [2]。これらの手法は、ニューラルネットワークによる様々な予測精度がシステム全体に影響を及ぼすため、予測精度の向上が課題として挙げられている。また、これらの研究ではシステムの状態のみがニューラルネットワークに利用されており、操作者の状態変化については特に言及されておらず、それらの対応については実現できていない。

1.2.2 身体の状態推定

身体の状態推定に関する先行研究では，ニューラルネットワークを用いて筋電図などを解析し，腕の状態を推定する手法が存在する [4]. この手法は，ノイズや変動性が多い環境下においても，PNN を複合的に用いて腕の状態を安定的に推定することが可能である．しかし，PNN の計算コストの重さや異常検知の閾値設定に関しては課題を残している．

また，ニューラルネットワークと自律神経系指標を用いて，テレビコンテンツ視聴時の被験者の興奮や鎮静状態など，多くの状態を推定している手法が存在する [5]. この手法では，心血管系の連続血圧測定から得られた値を自律神経系指標を参考にニューラルネットワークに入力し，被験者の状態を推定している．予測精度は種類によって異なるが，嗜好における予測では 83% の精度で予測可能としている．

1.3 研究目的

既存の手法は操作者の状態の変化を考慮していないため [3], 人間の生体信号をニューラルネットワークの入力に用いることで, 予測精度を向上が期待される.

そこで本研究では, 遅延が発生している遠隔操作環境において, ストレス指標である LF/HF 比をリアルタイムで人間の操作を予測するニューラルネットワークの入力に用いることで, 予測精度を向上させる遅延補完システムの開発を目指す.

第2章 提案手法

本章では，リアルタイムストレス指標をニューラルネットワークの入力に用いた予測遅延補償システムについて，以下の項目について述べる．

- ストレス推定
- 遅延操作の再現
- 遅延補完システム

2.1 ストレス推定

本研究では、ストレスの変化の指標として LF/HF 比を用いた。LF/HF 比とは、ECG(心電図) と RRI(心拍) における LF(低周波成分) と HF(高周波成分) の周波数解析及びパワースペクトル密度の積分値から算出される値であり、交感神経系活動のバランスを示す [6]。また、LF/HF 比はストレスレベルの指標として様々な研究で用いられている [7]。

本研究では、LF/HF 比の解析に用いる ECG の測定に BITalino を用いた。BITalino の画像を図 2.1 に示す。BITalino とは、ECG や脳波、表面筋電図、皮膚電位などの測定が可能なシングルボードコンピュータである。BITalino から出力された ECG を Raspberry Pi 4 で解析をし、UDP 通信を介してニューラルネットワークに入力することで、リアルタイムでストレスの推定を行った。また、ニューラルネットワークの予測モデルにおいて、操作中のストレス指標の変化について学習を行うため、実験タスクの開始時に初期値を 0 とし、LF/HF 比を出力する様に算出を行った。タスク開始時の LF/HF 比を x_0 、その後の LF/HF 値の入力を x_n とすると、ニューラルネットワークへの入力値 s_n は次のようになる。

$$s_n = x_n - x_0 \quad (2.1)$$




図 2.1: BITalino

2.2 遠隔操作の再現

本研究では、遠隔操作の再現において Unity による追従タスクの作成を行った。操作画面を図 2.2 に示す。操作入力にはアナログスティックとして Xbox wireless controller を用いた。赤色の球は被験者が操作をする Agent であり、青色の球がランダムに移動する Target である。被験者は Agent が Target に追従する様に操作を行う。遠隔操作では操作先に対して送信時および受信時の 2 回において遅延時間が発生している。そのため、両方の遅延時間について再現を行う必要がある。操作入力に設定した遅延時間の半分の遅延時間を介して Agent の座標の演算に入力され、演算後の座標および描画情報においてさらに半分の遅延時間を介した後に出力を行う。以上の行程により、遠隔操作の再現を行った。




図 2.2: Tracking task operation screen

2.3 遅延補完システム

本研究で用いた遅延補完システムのブロック図を図 2.3 に示す。操作者のアナログスティックの操作入力 Current Input である。Unity 及び LF/HF 比のデータを用いて FNN(Feedforward Neural Network) によって遅延時間に応じた任意のステップ先の Current Input の値を予測し、その値を Agent の操作へ反映させることで遅延の補完を行う。また、予測値に Assist Gain を乗算することで遅延補完の強さの調節を行う。

次に、ニューラルネットワークの構造を図 2.4 に示す。また、ニューラルネットワークの入力パラメータを表 2.1 に示す。ニューラルネットワークには Self-Attention 機構を導入した FNN を用いる。全ての層が全結合層となっており、入力次元は 16、出力次元は 2 次元としている。また、中間層を 2 層設けており、それぞれのユニット数は 64 個と 32 個である。推論エンジンには Unity Barracuda、学習ライブラリには PyTorch をそれぞれ用いて実装した。また、追従タスクの動作周期およびニューラルネットワークの推論周期は 16.7 ms とした。




図 2.3: Block diagram of delay completion system




图 2.4: Structure of Neural Networks

表 2.1: Neural network input numbers and parameters

Number	Parameter	Number	Parameter
0	AgentPosition.x	8	AgentVelocity.y
1	AgentPosition.y	9	TargetVelocity.x
2	TargetPosition.x	10	TargetVelocity.y
3	TargetPosition.y	11	AgentAcceleration.x
4	DelayTime	12	AgentAcceleration.y
5	CurrentInput.x	13	TargetAcceleration.x
6	CurrentInput.y	14	TargetAcceleration.y
7	AgentVelocity.x	15	LF/HF Ratio

第3章 実験概要

本章では，提案手法の有効性の確認を行う実験について，以下の項目について述べる．

- 実験目的
- 実験環境
- 実験概要

3.1 実験目的

本実験では、ニューラルネットワークの入力に LF/HF 比を用いた際における予測精度への影響の確認を行う。学習時および予測時に LF/HF 比を入力に用いた予測モデルと、用いなかった予測モデルの作成し、それぞれの予測精度や追従精度を測定することで、精度の変化や遅延補完による追従精度に対するストレス指標の値の変化を確認することを目的とする。

3.2 実験環境

本研究における実験の様子を図3.1に示す。実験の被験者は19~22歳の男女8名であった。被験者は実験中に外部からのストレスの影響を軽減する為、楽な姿勢でリラックスするようにした。また、予備実験と実験の環境の変化を抑えるため、予備実験から実験にかけて常に心拍の測定を行い、BITalinoなどの心拍測定デバイスの取り外しは原則として控えるよう指示を行った。

本実験では、遅延補完の効果をより効果的に確認するため、全体の遅延時間を従来の手法よりも長い500 msに設定し、実験を行った [1]。



図 3.1: Subjects during the experiment

3.3 実験手法

3.3.1 予備実験

本研究では，予備実験として本実験と同様の環境下で予測モデルの学習データサンプルの収集およびニューラルネットワークに用いる予測モデルの作成を行った．被験者は，操作遅延を 0 ms とした状態で 180 秒間の追従タスクを 2 回実施し，データサンプルを取得した．提案手法として，取得したデータサンプルを基に，すべてのデータの値を用いて学習を行った予測モデル 1，従来手法として，LF/HF 比の値を 0 に置換した後に学習を行った予測モデル 2 を作成した．作成に使用したニューラルネットワークの設定を表 3.1 に示す．また，予測ステップについては，実験で用いる遅延時間 500 ms と推論周期 16.7 ms に基づいて，30 ステップ (約 500 ms) として設定を行った．

表 3.1: Settings during neural network training

Setting	Value
Learning rate	0.001
Weight decay	0.001
Dropout	0.3
Batch size	128
Epoch	150
Prediction Step	30

3.3.2 本実験

本実験は、予測モデル1を用いた実験1と、予測モデル2を用いた実験2をそれぞれの実験を行った。実験1、実験2では、各termを30秒として、term0~term5の6term、合計180秒の追従タスクを行った。Nterm目における Assist Gain の値 p を式 (3.1) に示す。ただし、本実験では $m = 0.2$ とした。

$$p = mN \quad (3.1)$$

また、追従精度および予測精度の記録を行った。各区間ごとの精度は、追従誤差を e_t 、予測誤差を e_p として式 (3.2) および式 (3.3) に示すように、二乗平均平方根誤差 (RMSE) の平均値を算出する。なお、予測は30ステップ先の値を予測するため、参照する値のステップを遅らせることで時系列を整えて、誤差の算出を行う。

$$e_t = \sqrt{\frac{1}{n} \sum_{i=1}^n ((a^X - t^X)^2 + (a^Y - t^Y)^2)} \quad (3.2)$$

$$e_p = \sqrt{\frac{1}{n} \sum_{i=1}^n ((i_k^X - p_{k+t}^X)^2 + (i_k^Y - p_{k+t}^Y)^2)} \quad (3.3)$$

a^X :Agent の X 座標, a^Y :Agent の Y 座標,

t^X :Target の X 座標, t^Y :Target の Y 座標,

i_k^X :X 軸入力, i_k^Y :Y 軸入力,

p_{k+t}^X :t ステップ後の X 軸予測値,

p_{k+t}^Y :t ステップ後の Y 軸予測値

第4章 実験結果と考察

本章では，実験によって得られた値に関する結果と考察について以下の項目を述べる．

- ニューラルネットワークの予測結果
- 予測精度の変化
- 追従精度の変化
- 追従とストレスの変化
- 予測モデルにおける重要度

4.1 ニューラルネットワークの予測結果

被験者1で用いた予測モデル1の term1 における予測結果を図 4.1 に示す. 図 4.1 の予測結果は, 基本的に操作者の入力値が予測値を追う形となっており, ニューラルネットワークが操作者の操作入力を予測可能であることが確認される.




図 4.1: Predictive results of learning model

4.2 予測誤差の変化

予測誤差の値を図 4.2 に示す。図 4.2 は、各被験者の term 間における平均値を示したグラフであり、近似直線の適合度はそれぞれ LF/HF 比を入力に用いた値は 0.1642、用いなかった値は 0.0392 となった。

全体の平均値において、LF/HF 比を入力に用いた予測誤差が用いなかった結果と比較して僅かに増加したが、区間によっては LF/HF 比を用いた状態の方が精度が良くなる傾向も見られたため、予測精度についてはほぼ変化が無かったと考えられる。また、LF/HF 比を用いた方が近似の適合率が大きく向上していることから、個人差に基づく予測モデルへの影響が軽減され、傾向の一貫性が増していると考えられる。

両方の予測モデルに関して予測誤差が term 毎に増加しているのは、予測モデルは Assist Gain の増加による遅延補完の動作が学習されていないため、予測モデルの予期しない動作が増加するためであると考えられる。




図 4.2: Prediction error results

4.3 追従誤差の変化

追従誤差の変化率を図4.3に示す. これは, 被験者全員における LF/HF 比を入力に用いた場合と用いなかった場合の追従誤差の変化率および近似直線を示したグラフである. また, 近似直線の適合度は, LF/HF 比を用いた値が 0.4792, 用いなかった値が 0.2853 となった.

追従誤差に関しては, 両方の結果において Assist Gain の増加に伴い追従誤差が減少する傾向が見られた. また, LF/HF 比を用いていない場合には, Term4 付近で誤差の減少率が収束していることが確認された. 実験結果より, LF/HF 比を用いたモデルにおいて追従誤差の減少率と近似直線の適合度が高いことが示された. これは遅延補完の効果が増加したことや, 予測モデルにおける遅延補完の一貫性が向上したことにより, 個人差による影響が減少したと考えられる.




図 4.3: Normalized tracking error results

4.4 追従とストレスの変化

追従精度の変化と操作中の LF/HF 比の変化を図 4.4 に示す．図 4.4 は、被験者全員における各 Term の追従誤差の変化率と LF/HF 比の変化をプロットし、それに基づいて導出した近似直線を示したグラフである．

近似直線により、追従誤差が減少すると僅かに LF/HF 比が低下することが確認できる．しかし、グラフからは分散が大きいことがわかり、近似直線の適合率は 0.0219 と非常に低いため、本実験では僅かに LF/HF 比が減少する傾向が見られたが、被験者数の増加などによって傾向が変わる可能性も考えられる．




図 4.4: Tracking accuracy and LF/HF ratio change

4.5 予測モデルにおける重要度

提案手法の予測モデルにおける Attention スコアのヒートマップを図 4.5 に示す. 図 4.5 は, 予測モデルに含まれる Self-Attention 機構における各入力値の重要度を示したグラフであり, 値が高く色が明るいほど出力との関連性が大きく, 重要な値であることを示している. また, x 軸の番号は表 2.1 の入力値にそれぞれ対応している. 左図が被験者 1, 右図が被験者 8 のヒートマップである.

全体として, 速度の値が最も重要であり, 次いで座標の値が重要であることが確認された. 一方, LF/HF 比の値である 15 列目の値は, あまり重要な値として扱われていないことが確認された. 被験者によっては, 右のグラフのように LF/HF 比の一部のスコアが増加する傾向が見られたが, ほとんどの被験者の左のグラフと同様に全体的にスコアが低い結果となった. そのため, 追従操作と LF/HF 比の関連性が低いことが考えられる.




図 4.5: Attention maps for subject 1 and 8 models

第5章 結論と今後の展望

本章では，提案手法によって得られた結果について，以下の項目を述べる．

- 結論
- 今後の展望

5.1 結論

本研究では、遅延補完システムにおけるニューラルネットワークの精度向上を目指して、ニューラルネットワークの入力にリアルタイムで取得可能な LF/HF 比を導入した際の影響について検証を行った。

予測誤差の検証では LF/HF 比を入力に用いたモデルが全区間の平均値で僅かに誤差が増加したものの、分散や各値における近似直線の適合率が向上していることが確認された。そのため、予測モデルにおける個人差の影響が軽減されていることが考察された。

また、追従誤差の検証では、LF/HF 比を入力に用いたモデルが用いていないモデルと比較して、追従誤差の減少率が高く、近似直線の適合率も高いことが確認された。そのため、遅延補完の効果が増加し、個人差による遅延補完のばらつきが減少したことが示唆された。

5.2 今後の展望

LF/HF 比を予測モデルの入力に用いた際、予測誤差における近似の適合率が上昇し、追従誤差における誤差の減少率が向上することが確認された。しかし、予測モデルにおける LF/HF 比の Attention スコアは依然として低い状態であり、ニューラルネットワークへの影響も限定的となってしまった。そのため、LF/HF 比のリアルタイム性や分解能を向上させ、正規化や標準化の計算を見直し、ニューラルネットワークにおける Self-Attention 構造の改善やサンプルデータ数の増加などを行い、さらなる検証する必要がある。

謝 辞

本研究を行うにあたって多くのご指導を賜りました五十嵐洋教授に心より感謝申し上げます。

また，研究に関する貴重な意見や提案，実験方法についての助言をいただき，ご協力いただきました協調ロボティクス研究室の皆様にも深く感謝申し上げます。

最後に，本研究の実験において多くのご協力をいただきました東京電機大学の皆様にも厚く御礼申し上げます。

参考文献

- [1] Shuang Zhang, Shou Yuan, Xinbo Yu, Linghuan Kong, Qing Li , and Guang Li : “Adaptive Neural Network Fixed-Time Control Design for Bilateral Teleoperation With Time Delay”,in IEEE TRANSACTION on Cybernetics, vol. 52, no. 9, pp. 9756-9769, September. 2022
- [2] Kebiria Parham M,Khosravi Abbas, Nahavandi Saeid : “Stable Neural Adaptive Filters for Teleoperations With Uncertain Delays”,in IEEE Robotics and Automation Letters, vol6, no.4, pp. 8863-8670, April.2021
- [3] Haifei Chen, Zhengxiong Liu:“Time-Delay Prediction-Based Smith Predictive Control for Space Teleoperation”, JOURNAL OF GUIDANCE CONTROL, AND DYNAMICS Vol.44,No.4 pp. 872-879, April.2021
- [4] Keisuke Shima , Junichi Imagi , Hideaki Hayashi, Taro Shibasaki , Yuichi Kurita and Toshio Tsuji:“A Probabilistic Neural Network with Anomaly Detection and Related Application to an EMG-controlled Prosthetic Hand”, Journal of the Robotics Society of Japan Vol.33,No.4,pp.275-284,June.2015
- [5] Takuya Watanuki, Akio Nozawa:“Estimation of Mode of Viewing TV and Preference of TV Contents by Autonomic Nervous System Index”, IEEEJ Transactions on Electronics, Information and Systems Vol.134,No.104,pp.1551-1556,October.2014
- [6] Task Force of the European Society of Cardiology the North American Society of Pacing Electrophysiology:“Heart Rate Vari-

ability : Standards of Measurement, Physiological Interpretation, and Clinical Use”, Circulation, Vol.93,No.5,pp.1043-1065,March.1998

- [7] Hye-Geum kim, Eun-ji Cheon, Dai-Seg Bai, Young Hwan Lee, Bon-Hoon koo:“Stress and Heart Rate Variability: A Meta-Analysis and Review of the Literature”, Psychiatry Investig Vol.15,No.3 pp. 235-245,February. 2018