

2024年度 卒業論文

エネルギー効率を考慮したマルチエー ジェントの誘導

Energy-Efficient Multi-Agent Induction.

東京電機大学工学部 電子システム工学科

指導教員： 教授 五十嵐 洋

研究室名： 協調ロボティクス研究室

21EH017 柏木 水輝

2025年1月31日 提出

研究概要

近年，マルチエージェントシステムが注目されている．その手法のひとつとして，牧羊犬の動きから着想を得たシープドッグシステムというアルゴリズムがある．このアルゴリズムの応用例としてロボットによる目標物の誘導，回収や森林火災の燃焼防止などに用いることが期待されている．しかし，実用化するにはロボットのエネルギーを考慮する必要があると考えられる．既存の研究では誘導方法について模索が中心であるため実用化に至らないと考える．そこで本研究ではシープドッグシステムにおいて誘導タスクを行い，追跡エージェントである dog のエネルギーの考慮をすることで，省エネルギーかつ高い誘導効率の両立が可能なアルゴリズムの設計を目的とする．

目次

第1章	序論	1
1.1	背景	2
1.2	先行研究	3
1.2.1	模倣と自立学習による適応型アルゴリズム . . .	3
1.2.2	強化学習を用いた誘導アルゴリズム	4
1.3	研究目的	5
第2章	提案手法	6
2.1	エージェントの動作	7
2.1.1	sheep の動作	8
2.1.2	dog の動作	10
2.2	個性値模倣	13
2.3	ローカル評価	14
2.3.1	算出方法	14
2.3.2	誘導評価	15
2.3.3	エネルギー評価	17
第3章	実験	18
3.1	実験環境	19
3.2	実験方法	21
第4章	結果	22
4.1	各 sheep と目標地点の平均距離の結果	23
4.2	dog のエネルギー評価の推移の結果	24
第5章	考察	25
5.1	sheep の個性値	26

5.2	ローカル評価	29
5.2.1	誘導評価	30
5.2.2	エネルギー評価	31
第 6 章	結論と今後の展望	32
6.1	結論	33
6.2	今後の展望	34

第1章 序論

本研究での背景や意義を捉えて頂くために、本章では以下の項目を述べる.

- 背景
- 先行研究
- 研究目的

1.1 背景

複数のエージェントを同時に利用し協調，競争を通じてタスクを遂行することをマルチエージェントシステム (MAS) という．この MAS をロボットに適用したものをマルチロボットシステムという．複数台のロボットを用いることで単体では困難な作業をすること，人間が作業するには厳しい環境下での作業をすることが期待されている．MAS の手法のひとつとしてシープドッグシステムという羊を誘導する牧羊犬の動作から着想を得た誘導システムが存在する [1]．このシステムを使用することで火災の燃焼防止や人や魚群，ロボットの誘導，海に散らばったごみや重油の収集などに幅広く応用可能であるとされている [2]．しかし，実用化にはロボットのエネルギーを考慮する必要があると考える．既存の研究では誘導方法の模索が中心であり，エネルギーを考慮していないため実用的ではないと考える．

1.2 先行研究

1.2.1 模倣と自立学習による適応型アルゴリズム

小林らは実環境で様々なターゲットを誘導するために、社会認知のアルゴリズムである社会学習理論の基づいて、ロボットの行動の模倣を性格模倣や自立学習として利用している [3]. これにより、事前にモデル化されていない未知のターゲットに対してロボットのパラメータを適応的に調整することで誘導をしている.

1.2.2 強化学習を用いた誘導アルゴリズム

Clark らは強化学習の手法の一つである SARSA を使用した誘導モデルを提案した [4]. 結果として 350 回の学習を行うことで複数のターゲットの誘導を達成している. しかし, 350 回と学習にの回数が多いことから実用化において現実での学習が困難であること, 事前のターゲットモデルを設計しなければならない.

1.3 研究目的

人や犬など生物には体力，ロボットにはバッテリーがありエネルギーが存在する．エネルギー不足で停止をするとシステム全体のパフォーマンスの低下や失敗につながる．よって，エネルギーを考慮することで現実性を高める必要があると考える．そこで本研究では省エネルギーかつ高い誘導効率の両立が可能なアルゴリズムの設計を目的とする．本研究の提案アルゴリズムの実現によってロボットが自律的にエネルギーを考慮した誘導を行うことが期待できる．

第2章 提案手法

本章では使用しているモデル及び提案手法で使用するアルゴリズムの詳細について以下の項目を述べる.

- エージェントの動作
- 個性値模倣
- ローカル評価

2.1 エージェントの動作

本研究では Boids モデル [5] を拡張したものを用いて各ベクトルを算出し、それらの合成ベクトルを入力とすることでエージェントの動作を決定する。また、エージェントは視野を持ち、視野範囲の情報のみで動作を行う。エージェントの種類ごとに動作の詳細を記述する。

- sheep の動作
- dog の動作

2.1.1 sheep の動作

本研究では誘導対象であるエージェントを sheep と呼ぶ. Fig 2.1 に sheep にかかるベクトルを示す. sheep の動作は視野範囲内にいる sheep 同士に対して働く引力, 斥力, 整列力と dog に対する斥力のベクトルから決定する. また, ベクトルを合成するにあたって重みとなる個性値を各ベクトルごとに用意する. i 番目の sheep の司令ベクトルは $\mathbf{u}_i^s$ で表現する. $\mathbf{u}_i^s$ は以下の式で表される.

$$\mathbf{u}_i^s = \mu_c \mathbf{u}_c + \mu_s \mathbf{u}_s + \mu_a \mathbf{u}_a + \mu_d \mathbf{u}_d + \mathbf{u}_r \quad (2.1)$$

ここで μ は各指令ベクトルの個性値である. $\mathbf{u}_c$ は sheep 同士の引力, $\mathbf{u}_s$ は sheep 同士の斥力, $\mathbf{u}_a$ は sheep 同士の整列力である. また, $\mathbf{u}_r$ はランダムウォークである.

各指令ベクトルは以下の式で表される.

$$\mathbf{u}_c = \frac{1}{N_S^s} \sum_{j \in N_S^s} \frac{\mathbf{x}_j^s - \mathbf{x}_i^s}{\|\mathbf{x}_j^s - \mathbf{x}_i^s\|} \quad (2.2)$$

$$\mathbf{u}_s = -\frac{1}{N_S^s} \sum_{j \in N_S^s} \frac{\mathbf{x}_j^s - \mathbf{x}_i^s}{\|\mathbf{x}_j^s - \mathbf{x}_i^s\|^2} \quad (2.3)$$

$$\mathbf{u}_a = \frac{1}{N_S^s} \sum_{j \in N_S^s} \frac{\dot{\mathbf{x}}_j^s - \dot{\mathbf{x}}_i^s}{\|\dot{\mathbf{x}}_j^s - \dot{\mathbf{x}}_i^s\|} \quad (2.4)$$

$$\mathbf{u}_d = -\sum_{j \in N_S^d} \frac{\mathbf{x}_j^s - \mathbf{x}_i^d}{\|\mathbf{x}_j^s - \mathbf{x}_i^d\|} \quad (2.5)$$

ここで N_S^s, N_S^d は視野範囲内にいる sheep と dog の数を表す. $\mathbf{x}^d, \mathbf{x}^s$ はそれぞれ dog と sheep の座標を表す.




图 2.1: Sheep Vectors

2.1.2 dogの動作

本研究では誘導のため追跡を行うエージェントを dog と呼ぶ. Fig 2.2 に dog にかかるベクトルを示す. dog の動作は視野範囲内にいる dog 同士に対して働く斥力と sheep に対する引力, 斥力, 目標誘導地点からの力のベクトルから決定する. また, ベクトルを合成するにあたって重みとなる個性値を各ベクトルごとに用意する. i 番目の dog の司令ベクトルは $\mathbf{u}_i^s$ で表現する. $\mathbf{u}_i^d$ は以下の式で表される.

$$\mathbf{u}_i^d = \mu_t \mathbf{u}_t + \mu_a \mathbf{u}_a + \mu_s \mathbf{u}_s + \mu_g \mathbf{u}_g + \mathbf{u}_r \quad (2.6)$$

ここで μ は各指令ベクトルの個性値である. $\mathbf{u}_t$ は sheep を追跡する引力, $\mathbf{u}_a$ は sheep からの斥力, $\mathbf{u}_s$ は dog 同士の斥力, $\mathbf{u}_g$ は目標座標からの力である. また, $\mathbf{u}_r$ はランダムウォークである.

各指令ベクトルは以下の式で表される.

$$\mathbf{u}_t = \frac{\mathbf{x}_j^s - \mathbf{x}_i^d}{\|\mathbf{x}_j^s - \mathbf{x}_i^d\|} \quad (2.7)$$

$$\mathbf{u}_a = -\frac{\mathbf{x}_j^s - \mathbf{x}_i^d}{\|\mathbf{x}_j^s - \mathbf{x}_i^d\|^2} \quad (2.8)$$


$$\mathbf{u}_s = -\sum_{j \in N_S^d} \frac{\mathbf{x}_j^d - \mathbf{x}_i^d}{\|\mathbf{x}_j^d - \mathbf{x}_i^d\|} \quad (2.9)$$

$$\mathbf{u}_g = R\left(\frac{3}{2}\theta\right) \frac{\mathbf{g} - \mathbf{x}_i^d}{\|\mathbf{g} - \mathbf{x}_i^d\|} \quad (2.10)$$

ここで N_S^d は視界範囲内にいる dog の数を表す. $\mathbf{x}^d, \mathbf{x}^s$ はそれぞれ dog と sheep の座標を表す. $\mathbf{g}$ は目標収集地点の座標を表す. 追跡する sheep は視界範囲内にいる目標地点から最も遠いエージェント, 衝突を回避するため sheep からの斥力は視界範囲内にいる dog から最も近

いエージェントとする． θ はdogからsheep間のベクトルとdogと目標誘導地点間のベクトルのなす角である．

$\boldsymbol{u}_s$ ではdogと目標誘導地点間のベクトルを θ を用いて回転させる．本研究では $\frac{3}{2}\theta$ 回転することで，sheepと目標座標との距離関係によって斥力と引力に適時変更することができる．



⊠ 2.2: Dog Vectors

2.2 個性値模倣

模倣とは社会性認知と呼ばれるものの一種であり、生物が社会を形成するにあたり高いパフォーマンスの維持や向上に必要な能力である[6][7].

本研究では模倣を用いてパフォーマンスの高い dog の個性値を真似て、自身の個性値を更新することでシステム全体のパフォーマンスの向上を目指す. 個性値の初期値は各 dog ごとにランダムに持つ. その後、模倣によって自身の個性値から模倣対象の個性値に徐々に近づけていく. このとき、視野範囲内にいる dog のみを対象とする. また、模倣は自身のパフォーマンスが悪い時に他者を真似ようとすると考えられる. よって、模倣の頻度を自身のパフォーマンスが悪いときのみ模倣をするように、自身の過去10回分のパフォーマンスを参照して最小二乗法より傾きを求める. この傾きが負の場合に模倣を行う. これらの動作は50[step] ごとに行う.

i 番目の dog が j 番目の dog を模倣する場合の式を下記に示す.

$$\mu_i = \mu_i + \text{sgn}(\mu_j - \mu_i) \cdot \exp(a \cdot (E_j - E_i)) \quad (2.11)$$

ここで a は定数, $\text{sgn}()$ は符号のみを返す関数である. 本実験では a は0.05とした. E_i は i 番目の dog のパフォーマンスを表すローカル評価値である. ローカル評価値の詳細は後に記載する.

2.3 ローカル評価

本研究では各 dog ごとに自身の動作のパフォーマンスを評価し，ローカル評価として個別に持たせる．このローカル評価を互いに参照し合うことで模倣を行う．算出方法と評価の種類についての詳細を記述する．

- 算出方法
- 誘導評価
- エネルギー評価

2.3.1 算出方法

評価の項目は誘導とエネルギーの2つを評価とし．2つの評価を合わせたものを個体のローカル評価としている．この動作は50[step] ごとに行う．

ローカル評価値の式を下記に示す．

$$E_i = k_g E_g - k_e E_e \quad (2.12)$$

ここで k は各評価の重みを表す．重みの設定により，誘導とエネルギーの評価の割合を変えることができ，設計の幅を広げることができる． E_g は誘導の評価値， E_e はエネルギーの評価値を表す．

2.3.2 誘導評価

Fig. 2.3 に誘導評価における関係を示す. d_{dj} は dog 同士の距離, d_{ds} は sheep と dog 間の距離, d_{sg} は sheep と目標地点間の距離, d_{dg} は dog と目標地点間の距離を表す. また, θ は d_{dg} と d_{ds} のなす角である. これらの距離から誘導パフォーマンスが高いかを判断し, 自身の誘導評価を決定する. 本研究では d_{dj} は遠いと高評価, d_{ds} は近いと高評価, d_{sg} は近いと高評価, d_{dg} は d_{sg} より遠ければ高評価になるように評価をする.

誘導評価値の式を下記に示す.

$$E_g = \frac{1}{N_S^d} \sum_{j \in N_S^d} (2d_{dj} - \Omega_d) + (d_{sg} - d_{dg}) + \frac{\cos \theta}{d_{sg}} \quad (2.13)$$

ここで N_S^d は視界範囲内にいる dog の数を表す.




图 2.3: Relationships in Guided Evaluation

2.3.3 エネルギー評価

エネルギー評価は各 dog ごとの使用エネルギー量を評価としている．評価の更新間隔である 50[step] あたりのエネルギー量が少ないほど高い評価になる．

エネルギーの評価値の式を下記に示す．

$$E_e = \sum_{k=n-49}^n ||\mathbf{u}_i^d[k]|| \cdot \Delta t \quad (2.14)$$

ここで $u_i^d[k]$ は k [step] 時の dog の指令ベクトル， Δt は 1[step] のサンプリング時間 33[ms] である．

第3章 実験

本章では実験の詳細について以下の項目を述べる.

- 実験環境
- 実験方法

3.1 実験環境

本研究ではシープドッグシステムでの誘導作業をシミュレーションにて行った. Fig 3.1 に実際のシミュレーション画像を示す. フィールドサイズ $400[m] \times 400[m]$ の2次元平面上でシミュレーションを行う. 誘導目標地点は中心座標 $[0, 0]$ とし, 赤色の範囲を誘導の目安とする. エージェントの初期位置はランダムに設定される. 誘導する側の dog エージェントが青色, 誘導される側の sheep エージェントが緑色である. dog と sheep の数はそれぞれ8体と50体である. また, dog と sheep の視野はそれぞれ $20[m]$ と $50[m]$ である.




図 3.1: Simulation Example

3.2 実験方法

本研究ではローカル評価の算出で用いた評価の重みである k を下記のように設定し，これらのパフォーマンスを比較する．シミュレーションの回数を各場合でそれぞれ20回行う．20回分のデータから各sheepと目標地点の平均距離の平均値と標準偏差，dogのエネルギー評価の推移の平均値と標準偏差を算出し検証する．

表 3.1: 評価の重みによるパフォーマンスの比較

	k_g	k_e
模倣なし	0.0	0.0
エネルギー評価のみ	0.0	1.0
誘導評価とエネルギー評価	0.5	0.5
誘導評価のみ	1.0	0.0

第4章 結果

本章ではローカル評価の重みの条件による実験結果の比較を以下の順で述べる.

- 各 sheep と目標地点の平均距離の結果
- dog のエネルギー評価の推移の結果

4.1 各 sheep と目標地点の平均距離の結果

実験より得られたデータより各 sheep と目標地点の平均距離の結果を Fig 4.1 に示す．濃い線が平均値，薄い範囲が標準偏差である．結果として，すべての場合において標準偏差が大きくばらつきがあることが確認できた．このことから安定した誘導ができていないことが分かった．




図 4.1: Average Distance and Standard Deviation between Sheep and Destination

4.2 dog のエネルギー評価の推移の結果

実験より得られたデータより dog のエネルギー評価の推移の結果を Fig 4.2 に示す．濃い線が平均値，薄い範囲が標準偏差である．結果として，誘導評価のみで模倣をした場合は使用エネルギーが多く，エネルギー評価のみで模倣した場合には使用エネルギーが少なくなることが確認できた．




図 4.2: Transition of Energy Evaluation in Tasks

第5章 考察

本章では実験結果から下記の項目ごとに考察を行う.

- sheep の個性値
- ローカル評価
- 誘導評価
- エネルギー評価

5.1 sheepの個性値

Fig 4.1 より誘導とエネルギーの評価を模倣した場合が最も平均距離が大きいことが確認できる．ここで，誘導がうまくいかない理由のひとつに sheep の個性値が関係していると考える．エージェントの個性値はランダムにする関係から，dog が誘導することができない sheep がでてしまう．例として，sheep の個性値が

$(\mu_c, \mu_s, \mu_a, \mu_d) = (1.590, 3.876, 2.105, 3.252)$ の場合のシミュレーションをみると，Fig 5.1 のように sheep が全く集まっていないことが確認できた．そこで，比較対象となるほかの場合でもシミュレーションを行った．模倣をしない，誘導のみの模倣，エネルギーのみの模倣でシミュレーションした様子を Fig 5.2, Fig 5.3, Fig 5.4 に示す．結果からどの場合でも誘導できないことが確認できた．このことから，sheep の個性値をランダム性を持たせつつ，dog で誘導できるように設定する必要があると考える．また，シミュレーションのフィールドサイズを大きくする，sheep の数を減らすといった対策でも解決できると考える．




图 5.1: Simulation of Imitating with Guid and Energy Evaluations




图 5.2: Simulation without Imitation




图 5.3: Simulation of Imitating with Guid Evaluation




图 5.4: Simulation of Imitating with Energy Evaluation

5.2 ローカル評価

本実験では表 3.1 のようにローカル評価の重みを変化させ各場合ごとに結果を算出している．結果からローカル評価の重みを変化させることで dog の動作が変わることが確認できた．よって，このアルゴリズムを使用することで開発者が考えによって柔軟な設計ができることが考えられる．例えば，すぐに補給ができない環境下ではエネルギー評価の重みを大きくすることで省エネルギーに運用することができると考えられる．また，各評価の方法を変更することで誘導対象に合わせた評価を行い，誘導を達成できることが考えられる．

5.2.1 誘導評価

Fig 4.1 より誘導評価を模倣に使用すると、標準偏差が大きく安定した誘導をしていないことが確認できた。模倣しない場合と比較すると模倣しない場合のほうがうまく誘導していると考えられる。これは先述した sheep の個性値だけでなく、誘導評価の算出が適切でないことが考えられる。よって模倣を用いて誘導する場合、評価の方法を適切にしなければパフォーマンスが落ちることが言え、事前に誘導対象に合わせて評価方法を設定する必要があると考える。しかし、実現性を考慮したとき誘導対象を変更するたびに評価方法を変更するのは困難だと考えられるため、広く適応できる評価方法を模索する必要があると考えられる。

5.2.2 エネルギー評価

Fig 4.2 より誘導評価のみで模倣をするとエネルギー評価のみで模倣する場合より使用エネルギーが多くなることが確認できた。また、模倣をしない場合と比較するとエネルギーのみを模倣する場合の方がエネルギー使用は抑えられていることがわかる。このことから使用エネルギーを模倣により考慮することで省エネルギーな誘導を行うことができると考えられる。しかし、本実験では dog は無限のエネルギーを持つものとして評価を行った。現実性を考えるとバッテリーで駆動するロボットにはこの評価は適切でないと考えられる。そのため dog のエネルギーが有限の場合、評価をどのようにするかを考える必要があると考える。

第6章 結論と今後の展望

本章では結果と考察を踏まえた結論と今後の展望について述べる.

- 結論
- 今後の展望

6.1 結論

本研究ではエネルギーを考慮するため，ローカル評価に誘導評価とエネルギー評価を設定し，評価の良いエージェントを模倣するアルゴリズムを考案した．シミュレーションを行い，ローカル評価のゲインを変えることで，模倣しない場合，誘導評価のみで模倣する場合，エネルギー評価のみで模倣する場合，誘導とエネルギー評価で模倣する場合の4通りを比較した．結果としては，誘導評価を考慮することで誘導パフォーマンスを向上することはなかったが，エネルギー評価を考慮することで使用エネルギーを抑えつつ誘導することができた．このことから，ローカル評価のゲインを調整することで省エネルギーかつ高い誘導効率の両立が可能だと考えられる．

6.2 今後の展望

今後の展望として誘導できない sheep がでないよう sheep の個性値の調整を行う．誘導評価を見直すことでどんな誘導対象にも適用できるように調整を行う．実用性を考えるとエネルギーが有限であるのとどのように動作するかを調査する必要がある．dog のエネルギーが有限の場合に省エネルギーかつ高い誘導効率の両立ができるように調査を行う必要がある．

謝 辞

本研究を行うにあたり，五十嵐先生から熱心なご指導を賜りました．また，協調ロボティクス研究室の皆様からは，ミーティングなど交流を通じて技術的なアドバイスを数多く頂きました．本研究にご助力くださったすべての方々に深く感謝致します．

参考文献

- [1] 五十嵐洋, 足達嘉信, 高橋一成: ” マルチエージェントによる協調
追い込み問題牧羊犬シミュレーションプラットフォーム ” ,Robotics
and Mechatronics, No. 10-4, 2010
- [2] S. Zhang and J. Pan, ”Collecting a Flock With Multiple Sub-
Groups by Using Multi-Robot System,” in IEEE Robotics and
Automation Letters, vol. 7, no. 3, pp. 6974-6981, July 2022.
- [3] K. Kobayashi, R. Watanabe and H. Igarashi, ”Adaptive Guid-
ance by Multi-Agent Systems Combining Personality Imitation
and Independent Learning,” 2023 IEEE International Conference
on Robotics and Biomimetics (ROBIO), Koh Samui, Thailand,
2023.
- [4] C. K. Go, B. Lao, J. Yoshimoto and K. Ikeda, “ A reinforcement
learning approach to the shepherding task using SARSA ” , Inter-
national Joint Conference on Neural Networks (IJCNN), Vancou-
ver, BC, Canada, pp. 3833-3836, 2016.
- [5] Craig W. Reynolds, Flocks, Herds, and Schools: A Dis trib-
uted Behavioral Model, Published in Computer Graph ics, 21(4),
pp.25-34 1987.
- [6] 嶋田総太郎: ” 特集「社会性認知のメカニズム」の編集にあたっ
て ” , 認知科学, Vol. 18, No. 1, 2011.
- [7] 田淵一真, 谷口忠大, 榎本哲夫: ” 模倣学習と強化学習の調和によ
る効率的行動獲得 ” , 人工知能学会,3C1-2, 2006.