

2020 年度 卒業論文

口調から言葉の尺度を推定する 会話システム

Verbal Communication System to Estimate
Probability Range in Tone

東京電機大学工学部 電子システム工学科

指導教員： 教授 五十嵐 洋

研究室名： 協調ロボティクス研究室

17EH064 馬場 柚貴

2021 年 1 月 31 日 提出

研究概要

近年，スマートスピーカの普及により会話システムの需要が増加している．従来の会話システムの技術は，音声により話者の意図を推定している．しかし問題点として，人間同士の会話のように非言語の様々な情報から相手の意図を推定することが不可能である．

本研究では，音声により口調から言葉の尺度を分析を行い，話者の意図の推定を行う．結果，精度が悪いが推定できることが確認できた．問題点として，人間とロボットの間での情報の受け渡しを考慮したタスクが必要であることが示唆された．そのため会話の応答において，ロボットの動作の影響を踏まえて予測するシステムを設計する課題が見受けられる．

目次

第1章 序論	1
1.1 背景	2
1.2 先行研究	3
1.2.1 画像認識と音声認識による意図の推定	3
1.2.2 音声感情認識による意図の推定	4
1.3 目的	5
第2章 提案手法	6
2.1 システム概要	7
2.2 音声特徴量	9
2.2.1 取得する音声情報	9
2.2.2 メル対数スペクトル	10
2.3 尺度の定義	11
2.4 ニューラルネットワーク	12
第3章 実験方法	14
3.1 指示バータスク	15
3.1.1 タスクの全体概要	15
3.1.2 人間側の指示	17
3.1.3 ロボット側の操作	18
3.2 尺度の定義	19
3.3 評価方法	20
第4章 実験結果	21
4.1 実験	22
4.2 結果	23
4.3 考察	25

4.3.1	人間の表現の変化	26
4.3.2	音声情報	27
第 5 章	結論と今後の展望	28
5.1	結論	29
5.2	今後の展望	30

第1章 序論

本研究では，人間とロボットの会話において，話者の意図を推定させる．推定する方法として言葉の尺度に注目し，言葉の尺度を音声情報によって得ることを目的とする．本章では以下の項目を述べる．

- 背景
- 先行研究
- 目的

1.1 背景

近年，スマートスピーカが普及している [1]．この普及に伴い，スマートスピーカと連携する家電が増加しており，音声を用いて家電操作する機会が日常的に増えている．そのため，近年音声を用いた会話システムの需要が増加している．

これらの既存製品では会話システムとして，音声から文字情報を認識する音声認識が利用されている．

しかし，言葉の受け答えが重要である人間同士の会話では，短い会話の受け答えにおける様々な会話情報の中で，文字情報以外の情報も取得して意図を推定を行う．そのため，会話システムにも非言語の情報を取得して意図の推定を行うことが重要である．

1.2 先行研究

1.2.1 画像認識と音声認識による意図の推定

話者の伝えたい指示の観点に注目し，その言葉に含まれている尺度の範囲から指示された物体を推定させる岡本らの研究がある [2]．推定する際の取得する会話情報として，音声認識と画像認識を取得している．そのため会話における画像認識を用いた話者の環境から，意図を推定する情報を得ることが可能である．しかし音声情報は音声認識を用いた言語情報からの推定である．そのため，それぞれ話者によって変化する音声情報から得られる情報が少なく，様々な話者による表現の対応できない問題点がある．

1.2.2 音声感情認識による意図の推定

音声情報から文字以外の情報を推定する研究として、感情の推定をする音声感情認識の研究などが挙げられる．Y. Xie, R. Liang らの研究では、音声感情認識を行う際に学習器として Long Short-Term Memory (LSTM) を使用している [3]．この LSTM を用いることで、研究者の学習方法に対する経験則が少なくなった．さらに、2-layer LSTM と Attention Mechanical を用いた Attention-Based LSTM により、感情を精度を高く認識することに成功した．

しかし感情は話者の伝えたい意図が感情でない限り、情報の重要度が高くない．そこで本研究では口調から得られる情報の中で、話者の伝えたい情報として利用される物事の尺度に着目する．

1.3 目的

本研究では、話者の会話における様々な会話情報において、特に音声情報に注目し、話者の伝えたい意図を推定することを行う。また意図の推定方法として、言葉の尺度に注目し、音声情報から尺度を推定することにより、意図を推定するシステムを提案する。

本研究の会話システムにより、既存製品や従来手法による文字情報から意図を推定する音声認識に比べ、人間同士の会話のように、音声情報からより複雑な意図の推定が可能になる。そのため、音声認識だけでなく、会話によりロボットやスマートスピーカなどに指示が行えるようになると考える。

第2章 提案手法

本章では，本研究における口調の特徴から話者の伝えたい言葉の尺度を推定する方法について，以下の項目より述べる．

- システム概要
- 音声情報
- メル対数スペクトル
- 尺度の定義
- ニューラルネットワーク

2.1 システム概要

話者の音声情報から言葉の尺度を推定するために、本研究では、ニューラルネットワークを用いて口調と尺度の関係を学習し推定を行う。

システムの概要を次の図 2.1 に示す。一般的に、音声認識や音声感情認識は、音声情報ではなく、音声情報から特徴量の抽出を行いニューラルネットワークの学習に用いる。本研究においても、音声情報から特徴量を抽出し学習の入力に用いる。対して出力は言葉の尺度とし、これにより、口調と尺度の関係を学習し推定を行う。




图 2.1: Experiment results

2.2 音声特徴量

2.2.1 取得する音声情報

本研究で取得する音声情報としてサンプリング周波数を 16 kHz とする．一般的に人間の可聴域は 22.05 kHz とされているため，サンプリング周波数は 44.1 kHz としている．しかし音声認識は，音声特徴量を取得する際，一般的に 8 kHz に多く音声の情報が含まれる．そのため，本研究においても 16 kHz でサンプリングを行う．

本提案手法では音声認識で一般的な録音方法としてモノラルでの録音を行う．

2.2.2 メル対数スペクトル

メル対数スペクトル (Mel Log Spectrum) は、音声特徴量の一つである。メル対数スペクトルはまず音声情報に対して短時間フーリエ変換 (Short-Time Fourier Transform: STFT) を行う。その後、メル尺度と呼ばれる人間の音の高低を適用した聴覚の尺度を利用する。このメル尺度を利用して、メルフィルタバンク (Mel Filter Bank) を用いる。これはSTFTのビン幅の周波数分解能は必要ないのでこれを削減するためである。近年の研究では、機械学習で扱う音声特徴量としてメル対数スペクトルが使用されている [4]。そのため本研究においてもメル対数スペクトルを用いる。本研究で適用した音声特徴量の詳細を次の表 2.1 で示す。

表 2.1:

Settings	Values
Recode Chanel	monaural
Weighted Window	hanning
Sampling Rate	16 kHz
Mel Filter Bank	40
STFT Frames	32 ms

2.3 尺度の定義

話者の伝えたい意図は、感情、動作、物体の状態など様々な情報がある。本研究では様々な意図の情報の中で、言葉の尺度について注目をする。この言葉の尺度は、“どれくらい何をしたかったのか”といった言葉に含まれる度合いや程度と言い換えることが可能である。そのため言葉の尺度は1次元で表すことが可能であり、本研究では尺度を1次元で表す。

2.4 ニューラルネットワーク

本研究で用いるニューラルネットワークは、再帰型ニューラルネットワーク (Recurrent Neural Network: RNN) の一つである LSTM を用いる。本研究は入力として音声特徴量を用いる音声信号は時間に関係している系列データとなる。そのため系列データの依存関係を学習しやすい RNN を使用する。特に長期の系列データに対して勾配消失問題を解決した LSTM を用いる [5]。これは、音声信号は時系列のデータになるので系列データが多くなるためである。

今回提案するニューラルネットワークの概要を図 2.2 に示す。前述したとおりニューラルネットワークには LSTM を用いる。今回出力は尺度の一次元となる。そのため LSTM の終段の出力のみを取り出す。この LSTM の終段の出力層を 2 層の全結合層を経て 1 次元で出力する。本研究の LSTM の構成の詳細を次の表 2.2 を示す。

表 2.2: LSTM settings Parameters

Parameters	Values
LSTM Input Layer	40
LSTM Middle Layer	60
Output Middle Layer	30
Output Layer	1
Optimizer	Adam
Loss	Mean Squared Error




图 2.2: Overview diagram of LSTM

第3章 実験方法

本章では，前章で提案した手法のパフォーマンスを確認するため，指示バータスクを提案し，その内容を以下の項目より述べる．

- 指示バータスク概要
- ロボットの移動
- 人間の指示
- 尺度の定義
- 評価方法

3.1 指示バータスク

3.1.1 タスクの全体概要

音声情報から口調を抽出し，話者の意図を推定可能か確認するため，指示バータスクを提案する．指示バータスクを図3.1に示す．バータスクとは操作バーを目標バーまで移動させるタスクである．それぞれのバーの初期位置は操作バーを左側，ターゲットバーを右側とする．その上で，それぞれの操作バーの初期位置 x_s と目標バーの初期位置はランダム x_t に決定される．ここで指示タスクとして，このバータスクを指示側と操作側に分ける．それぞれの役割として，操作側をロボットが行い，指示側を人間が行う．



图 3.1: Cue Bar Task

3.1.2 人間側の指示

指示側である人間はロボットに対して、操作バーを移動させる指示を行う。その際の指示内容として本実験では一言のみとする。これは発声する内容を様々な言葉で表現できる場合、実際のパフォーマンスの結果のうち、口調に比べて言葉の意味による要因が大きくなるからである。そのため、今回は口調に注目するために指示内容を一言に限定し、指示をする言葉として“もうちょっと”の一言とする。

3.1.3 ロボット側の操作

操作側であるロボットは人間の指示内容から操作バーを目標バーまで移動量を指定させ移動する．人間の発声する“もうちょっと”は操作バーと目標バーの移動量のみに対して発声しない．一つ前の操作バーの移動量を見て“もうちょっと”と発声する．そのため一つ前の操作バーの移動量を加味させるために，人間が指示を行う前に，移動する前の操作バーの座標 x_s から目標バーの座標 x_t へランダムに移動する．指示バーを移動した状態を人間に提示させる．この移動量はタスク毎に，ランダムに決定している．

3.2 尺度の定義

言葉の尺度は，音の大きさ，明るさや力の大きさ等が挙げられる．本実験の指示タスクでは，言葉の尺度として話者が伝えたい操作バーと目標バーの移動量とする．

3.3 評価方法

前述したように、本実験で使用する単語は移動量だけでなく最初の移動量に関する。そのため尺度である移動量を推定するために評価関数 P を定義する。 P はランダムに移動する前の操作バーの座標 x_s と目標バーの座標 x_t と移動量 x_m を用いて式 (3.1) と定義する。これにより最初の移動量を考慮してタスクの推定の評価が可能となる。

また本実験での移動量を求める際の LSTM の出力にも使用する。これは言葉を推定する際も最初の移動量と実際の移動量の間関係を取得する必要があるからである。

$$P = \frac{|x_m|}{|x_s - x_t|} \quad (3.1)$$

第4章 実験結果

本章では，本研究で提案する話者の口調から尺度を推定する方法のパフォーマンスを確認するために，提案した指示バータスクの実験の結果について以下の項目により述べる．

- 実験
- 結果
- 考察

4.1 実験

実験は、20 第男性 4 名の被験者に対しておこなった。本実験の音声の録音方法として、録音ボタンを被験者に押してもらった後 2.5 sec の間録音を行った。被験者は指示タスクを 10 回を 4 セットの計 40 回行った。また録音時にマイクと顔の位置を 30 cm 程度に一定に保つように指示をした。そのうち 32 回を学習に用いる。その後残りの 8 回でテストを行った。

4.2 結果

本研究では、尺度の評価を行った。提案手法により推定した尺度のパフォーマンス P と実際の尺度のパフォーマンス P との評価関数の差 Evaluation Value Error を箱ひげ図で示した結果を図 4.1 に示す。

推定した尺度と Evaluation Value Error は値が小さいほど誤差がなく予測ができている。全体的に、半分のタスクにおいて P が 0.2 以下と推定することが可能であることが読み取れる。それに比べ残りの半分のタスクの結果は、大きな分散が確認でき、最大では 0.5 ほどの推定と実際の移動量に誤差が生じることが読み取れる。




图 4.1: Experiment results

4.3 考察

本実験の結果から、口調からおおよその移動量を推定が可能であるが、分散があり精度が悪いことが確認できる。精度が悪い原因として、人間の原因と音声処理の原因が挙げられる。この人間側の原因としてあげられるのが人間の表現の変化である。つまり“もうちょっと”の表現の変化がタスク中におこるからだと考える。また他の要因として音声処理の前処理の不足により音声特徴量に雑音成分が含まれてしまった可能性が挙げられる。

4.3.1 人間の表現の変化

人間の表現の変化の原因は、人間の指示をした言葉の表現に対して、実際のロボットに移動量がどのように反映されるのか、予測イメージがタスクを繰り返すなかで変化してしまうからであると考えている。

この予測イメージが変化してしまう原因として、人間が発声した口調に対してロボットが実際に移動する提示がないことが挙げられる。提示がないことで、発声後の操作側の反応から予測イメージをしっかりと作ることがない。

そのため、改善案として操作側の操作後の操作バーの移動量を話者に提示をするタスクを提案する必要がある。

4.3.2 音声情報

音声認識などの従来技術で精度が下がる要因として環境音などの雑音が問題としてあげられる．音声認識等の従来研究では，認識率低下の原因として環境雑音が大きな原因の一つとしてあげられている．本実験でも同様に雑音に対する認識率の低下が問題点として挙げられる．また本実験では，録音ボタンを押した後，録音を行った．録音開始後と人間が発声するタイミングがタスク毎に差が発生することも問題として挙げられる．

改善案として音声区間検出 (Voicer Activity Detection: VAD) 等を用いることが挙げられる．音声部分のみを検出することにより雑音部分の切り取りを行うことができ精度の向上が期待できる [6]．

第5章 結論と今後の展望

本研究では，人間とロボットの会話において，言葉の尺度を音声情報によって話者の意図を推定するシステムを考案した．システムのパフォーマンスを確認するために，指示バータスクを提案しシステムの評価を行った．実験結果と考察を踏まえて，本章では以下の項目を述べる．

- 結論
- 今後の展望

5.1 結論

本研究では、様々な会話情報から、話者の伝えたい尺度を認識することで意図の推定を試みた。話者の様々な会話情報から口調を用いた、そして伝えたい尺度を認識させるためにLSTMを用いて推定させるシステムを提案した。そのシステムのパフォーマンスを確認するために指示バータスクを考案し実際に確認した。結果として、本手法は精度は低いがバータスクにおける操作バーの移動量を推定できることが示唆された。

精度が低い要因として、指示をする人間側が原因だと考えられる。これは人間側は自身の指示がロボットの移動量にどのように反映されるかイメージができなくなるためであると考えた。

5.2 今後の展望

本実験では音声の録音時間が固定の長さになっている．そのため雑音の対策を行うために，VADを用いることで精度を上げたい．

また今回ニューラルネットワークの入力の音声特徴量にはメル対数スペクトルのみを導入した．音声感情認識や音声認識では，基本周波数などのピッチ成分などに加え，メル対数スペクトルのケプストラムの MFCC とその一次差分及び二次差分 (Δ), ($\Delta\Delta$) などの特徴量の導入を行い精度の向上を図っている [7]．そのため本研究においても今後の展望として，精度を向上させるため導入及び比較を行い検討する．

また本実験では，精度の低い原因として指示をしたあとのロボットの移動量を提示がないためだと結論づけた．そのため改善案として，学習し，予測した移動量の結果をタスクに反映させる．その反映させた移動量から指示をさせ，交互に指示と移動を行うようなタスクにすることなどが挙げられる．移動量をタスクに反映させ，人間側に提示すると，指示を行うイメージが指示前と指示後で変化する．この変化の関係を踏まえて移動量の推定を行う必要がある．この問題を解決することで会話の受け答えを踏まえた尺度の推定が可能になると考える．

謝 辞

本研究を行うにあたりご指導，ご伝達を賜りました五十嵐 洋 教授に心より御礼申し上げます．また本研究の実験の参加並びに，研究に関する指摘や議論を頂いた研究室の皆様に深く感謝いたします．

参考文献

- [1] 総務省 | 令和元年版 情報通信白書 | レイヤー別にみる市場動向：
[https://www.soumu.go.jp/johotsusintokei/whitepaper/
ja/r01/html/nd112130.html](https://www.soumu.go.jp/johotsusintokei/whitepaper/ja/r01/html/nd112130.html)
- [2] 岡本 偉吹, 福元 伸也, 鹿嶋 雅之, 渡邊 睦, “ 曖昧な指示を理解するコミュニケーションロボットに関する研究,” in ロボティクス・メカトロニクス講演会講演概要集, Vol. 2020, pp.1P2-E11, Nov. 2020.
- [3] Y.Xie,R.Liang,Z.Liang,C.Huang, C.Zou and B.Schuller,
“ Speech Emotion Classification Using Attention-Based LSTM,”
in IEEE/ACM Transactions on Audio,Speech,and Language Processing, Vol. 27,No. 11,pp.1675-1685,Nov. 2019.
- [4] H.Purwins,B.Li,T.Virtanen,J.Schlüter,
S.Chang and T.Sainath,“ Deep Learning for Audio Signal Processing,” in IEEE Journal of Selected Topics in Signal Processing,vol. 13,No. 2,pp. 206-219, May 2019.
- [5] H. S. Kumbhar and S. U. Bhandari, “ Speech Emotion Recognition using MFCC features and LSTM network,” 2019 5th International Conference On Computing, Communication, Control And Automation (ICCUBE), Pune, India, 2019.
- [6] A. Sehgal and N. Kehtarnavaz, “ A Convolutional Neural Network Smartphone App for Real-Time Voice Activity Detection,” in IEEE Access, vol. 6, pp. 9017-9026, 2018.

- [7] J.Deng,X.Xu,Z.Zhang, S.Frühholz and B.Schuller,
“ Semisupervised Autoencoders for Speech Emotion Recognition,
” in IEEE/ACM Transactions on Audio,Speech,and Language
Processing, Vol. 26,No. 1,pp.31-43,Jan. 2018.