

2022年度 卒業論文

未知ターゲットを適応的に誘導する マルチエージェントの設計

Multi-Agent for Adaptive Guidance of Unknown
Targets

東京電機大学工学部 電子システム工学科

指導教員： 教授 五十嵐 洋

研究室名： 協調ロボティクス研究室

18EH037 小林虎太郎

2022年2月7日 提出

研究概要

近年マルチエージェントの研究が工学や科学、数学など様々な分野で注目を集めている。その中で、羊飼いの犬の動きから着想を得た牧羊犬アルゴリズムという誘導モデルがある。先行研究では避難時の人員誘導や逃走ターゲットの追い込みなどを想定されている。このモデルをロボットに組み込むことで環境問題となっている海洋プラスチックやスペースデブリの回収タスクに応用できると期待される。しかし、実用を考えると環境による外乱などからターゲットのモデル化は困難であると考えられる。既存の牧羊犬モデルではターゲットの性質に依存するため、適切にターゲットをモデル化する必要がある。

そこで本研究では、マルチエージェントを用いてターゲットの事前モデル化が不要な適応的誘導システムの開発を提案する。誘導には牧羊犬アルゴリズムの内部モデルである Boids を使用し、ターゲットに合わせた適応的自律動作をするために個性模倣という模倣アルゴリズムを使用する。結果、個性模倣を持つエージェント群と持たないエージェント群を比較して、模倣によって事前にターゲットの情報を持たないエージェントによる未知ターゲットの適応誘導動作が確認できた。

目次

第1章	序論	1
1.1	背景	2
1.2	関連研究	3
1.2.1	協調追い込み問題	3
1.2.2	視野を考慮したドローンによる牧羊犬グタスク	4
1.2.3	Swarm Robotics のための適応的協調行動の生成 .	5
1.3	研究目的	6
第2章	提案手法	7
2.1	Boids モデル	8
2.1.1	Sheep の制御	8
2.1.2	Dog の制御	11
2.1.3	指令値ベクトル	14
2.2	個性模倣	15
2.3	ローカル評価値	16
第3章	実験	17
3.1	実験環境	18
3.1.1	牧羊犬シミュレーション	18
3.1.2	実験設計	20
3.2	実験方法	21
3.2.1	Sheep と目標地点の平均距離	21
3.2.2	存在確立とエントロピー	22
第4章	結果	24
4.1	Sheep と目標地点の平均距離の結果	25
4.2	エントロピーの結果	26

4.3	追跡条件による結果	27
第5章	考察	30
5.1	平均距離の評価	31
5.2	追跡条件	32
第6章	結論と今後の展望	34
6.1	結論	35
6.2	今後の展望	36

第1章 序論

本研究の背景や意義を捉えて頂くために, 本章では以下の順に述べる.

- 研究背景
- 関連研究
- 研究目的

1.1 背景

自律エージェントの集団協調行動をマルチエージェントシステム (MAS) という。MAS は過去数十年において物理学者や科学者, 様々な分野において注目されている。近年 MAS を利用して, ターゲットを誘導しようとする試みが行われている。これにより, 火災の燃焼防止や人員誘導, 魚群の追い込み漁など, 現実社会の幅広い分野での応用に期待がされている [1]。誘導モデルとして, 羊飼いの犬がヒツジを誘導する動きから着想を得た牧羊犬モデルという誘導システムがある。既存の牧羊犬モデルは, 誘導対象の性質に依存することがわかっており, 現状で実用的とは言えない [2]。

1.2 関連研究

1.2.1 協調追い込み問題

五十嵐らは, 牧羊犬モデルの内部モデルである Boids モデルを用いて対象エージェント群 Sheep を複数の自律エージェント Dog によって任意の地点に誘導する牧羊犬プラットフォームを提案した [2].

結果として, Sheep 群の増加により誘導しやすくなることが示され, さらに Dog の誘導パフォーマンスは Sheep にかかるベクトルの係数や環境によって変化し, 事前設計が現実的ではない点から Dog のリアルタイムなパラメータ更新アルゴリズムの必要性を課題として残した.




Fig. 1.1: Sheepding task simulation[2]

1.2.2 視野を考慮したドローンによる牧羊犬グタスク

Junyan Hu らは前述した牧羊犬モデルを実際に羊の群れを誘導することを見据えてドローンに実装するシミュレーションを行った。また、二輪のロボットによって実機の実験を行い検証をした[3]。結果、シミュレーションと実機実験の両方に成功し、モデルの有効性を示した。しかし、現実環境で実用するために羊群の性質の変化や外乱を考慮する必要性が課題として残った。



Fig. 1.2: Image of shepherding task with UAV[3]

1.2.3 Swarm Roboticsのための適応的協調行動の生成

大倉らはスワームロボットシステムを創発的に制御するためには、十分な適応的振る舞いの自律的獲得機能が必要となり、アドホックアプローチ、すなわちプログラマがほぼ全て行動を記述する方式からの脱却が必要であると指摘している。ここで、自律的振る舞いから連想されるのは機械学習だが、あらかじめ決められた基本行動のうちから適切なものを状況によって選択するにとどまることを指摘している。よって現状を脱却するには、システムの知能化に関する原理的なアプローチ開発が必要である [4]。

そこで大倉らは、進化ロボティクスを発展させたMBEANN(Mutation-Based Evolving Artificial Neural Networks) から、適応的協調行動の生成を試みた。しかし、誘導ターゲットの性質の変化については触れられていない。

1.3 研究目的

実用を見据えた連続したタスクの中で未知のターゲットを適応的に誘導するために、本研究ではターゲットの性質にその場で適応することで事前の詳細なモデル化を不要とする誘導アルゴリズムの作成を目的とする。本研究の提案アルゴリズムの実現により、連続したタスクの中で人間が手を加えずともロボットが自律的に誘導可能となることが期待できる。

第2章 提案手法

本章では使用しているモデル及び提案手法について述べる．また，提案手法で使用するアルゴリズムの詳細を記述する．

- Boids モデル
- 追跡条件
- 個性模倣
- ローカル評価値

2.1 Boids モデル

本研究では、エージェントに加わると思われるベクトルをすべて定義し、それらの合成ベクトルを指令値として2次遅れ系に送り、加速度から位置座標を算出している。エージェントにかかる力を合成して指令値とするモデルを Boids モデルという。

2.1.1 Sheep の制御

本稿では誘導されるターゲットを Sheep と呼ぶ。Sheep の動作は、Sheep の持つ視野範囲 Ω 内の Sheep 同士に対して働く引力 $^c\mathbf{v}_i^{SS}$ 、斥力 $^s\mathbf{v}_i^{SS}$ 、整列力 $^a\mathbf{v}_i^{SS}$ 、Dog に対する引力 $^c\mathbf{v}_i^{SD}$ 、斥力 $^s\mathbf{v}_i^{SD}$ 、整列力 $^a\mathbf{v}_i^{SD}$ の6種類のベクトル合成 $\mathbf{u}_i^S$ から与えられる。Fig. 2.1 に Dog の他 Dog に加わるベクトルを示し、Fig. 2.2 に Dog の Sheep に加わるベクトルを示す。破線の矢印は速度ベクトルを示しており、実線の矢印は力ベクトルを示している。また、これらは全て視野内に存在するオブジェクトにのみ作用し、以下の式によって定義される。




Fig. 2.1: Sheep Vectors to Dog




Fig. 2.2: Sheep Vectors to Sheep

$${}^c\mathbf{v}_i^{SS} = \sum_{j \in \Omega,}^n \frac{\mathbf{x}_j^S - \mathbf{x}_i^S}{|\mathbf{x}_j^S - \mathbf{x}_i^S|} \quad (2.1)$$

$${}^s\mathbf{v}_i^{SS} = - \sum_{j \in \Omega,}^n \frac{\mathbf{x}_j^S - \mathbf{x}_i^S}{|\mathbf{x}_j^S - \mathbf{x}_i^S|^2} \quad (2.2)$$

$${}^a\mathbf{v}_i^{SS} = \sum_{j \in \Omega,}^n \frac{d\mathbf{x}_j^S - d\mathbf{x}_i^S}{|d\mathbf{x}_j^S - d\mathbf{x}_i^S|} \quad (2.3)$$

$${}^c\mathbf{v}_i^{SD} = \sum_{j \in \Omega,}^n \frac{\mathbf{x}_j^D - \mathbf{x}_i^S}{|\mathbf{x}_j^D - \mathbf{x}_i^S|} \quad (2.4)$$

$${}^s\mathbf{v}_i^{SD} = - \sum_{j \in \Omega,}^n \frac{\mathbf{x}_j^S - \mathbf{x}_i^S}{|\mathbf{x}_j^S - \mathbf{x}_i^S|^2} \quad (2.5)$$

$${}^a\mathbf{v}_i^{SD} = \sum_{j \in \Omega,}^n \frac{d\mathbf{x}_j^D - d\mathbf{x}_i^S}{|d\mathbf{x}_j^D - d\mathbf{x}_i^S|} \quad (2.6)$$

ここで, 各項の右上にある添え字はSはSheep, DはDogの位置を表し, ベクトルの向いている方向を示している. 右下の添え字は*i*番目のエージェントを意味している. また, 各ベクトルの重み μ は本稿ではSheepの個性と定義する.

2.1.2 Dog の制御

本稿では誘導する側のエージェントを Dog と呼ぶ. Dog の動作は, Dog の持つ視野範囲 Ω 内の Sheep に対して働く引力 $c\mathbf{v}_i^{DS}$, 斥力 $s\mathbf{v}_i^{DS}$, 整列力 $a\mathbf{v}_i^{DS}$, 視野内の Dog に対して働く引力 $c\mathbf{v}_i^{DD}$, 斥力 $s\mathbf{v}_i^{DD}$, 整列力 $a\mathbf{v}_i^{DD}$, 目標地点に対して働く力 $s\mathbf{v}_i^{DT}$ の 7 種類のベクトル合成 $\mathbf{u}_i^D$ から与えられる. Fig. 2.3 に Dog の他 Dog に加わるベクトルを示し, Fig. 2.4 に Dog の Sheep に加わるベクトルを示し, 2.5 に Dog の目的地点に対して加わるベクトルを示す. 破線の矢印は速度ベクトルを示しており, 実線の矢印は力ベクトルを示している. また, これらは全て視野内に存在するオブジェクトにのみ作用し, 以下の式によって定義される.




Fig. 2.3: Dog Vectors to Dog




Fig. 2.4: Dog Vectors to Sheep




Fig. 2.5: Dog Vectors to Goal

$${}^c\mathbf{v}_i^{DS} = \sum_{j \in \Omega,}^n \cos(\phi + \frac{\pi}{3}) \frac{\mathbf{x}_j^S - \mathbf{x}_i^D}{|\mathbf{x}_j^S - \mathbf{x}_i^D|} \quad (2.7)$$

$${}^s\mathbf{v}_i^{DS} = - \sum_{j \in \Omega,}^n \frac{\mathbf{x}_j^S - \mathbf{x}_i^D}{|\mathbf{x}_j^S - \mathbf{x}_i^D|^2} \quad (2.8)$$

$${}^a\mathbf{v}_i^{DS} = \sum_{j \in \Omega,}^n \frac{d\mathbf{x}_j^S - d\mathbf{x}_i^D}{|d\mathbf{x}_j^S - d\mathbf{x}_i^D|} \quad (2.9)$$

$${}^c\mathbf{v}_i^{DD} = \sum_{j \in \Omega,}^n \frac{\mathbf{x}_j^D - \mathbf{x}_i^D}{|\mathbf{x}_j^D - \mathbf{x}_i^D|} \quad (2.10)$$

$${}^s\mathbf{v}_i^{DD} = - \sum_{j \in \Omega,}^n \frac{\mathbf{x}_j^D - \mathbf{x}_i^D}{|\mathbf{x}_j^D - \mathbf{x}_i^D|^2} \quad (2.11)$$

$${}^a\mathbf{v}_i^{DD} = \sum_{j \in \Omega,}^n \frac{d\mathbf{x}_j^D - d\mathbf{x}_i^D}{|d\mathbf{x}_j^D - d\mathbf{x}_i^D|} \quad (2.12)$$

$${}^s\mathbf{v}_i^{DT} = - \sum_{j \in \Omega,}^n \frac{\mathbf{x}_j^T - \mathbf{x}_i^D}{|\mathbf{x}_j^T - \mathbf{x}_i^D|} \quad (2.13)$$

Sheep と同様に μ を Dog の個性と定義する.

ここで, Sheep に対する引力 ${}^c\mathbf{v}_i^{DS}$ にかかる $\cos(\phi + \frac{\pi}{3})$ について説明する. ϕ は Dog の視野内に存在する Sheep と目標地点の角度を表している. 先行研究では ${}^s\mathbf{v}_i^{DS}$ に $\cos(\phi)$ をかけており, $0 < \phi < \frac{\pi}{2}$ の場合は符号が正となり追跡をはじめ, $\frac{\pi}{2} < \phi < \pi$ の場合は符号が負となり追跡をやめるよう制御されていた. 本研究では, 追跡条件を $0 < \phi < \frac{\pi}{3}$ に制限する事で, よりゴールの直線状に近く位置する Sheep のみを追跡するようにする.

2.1.3 指令値ベクトル

指令値ベクトル $\mathbf{u}_i$ により, 2次遅れ系に適応することで各エージェントの動作を実現する. 誘導するロボットである Dog 実装した制御式を式 (2.14) に, ターゲットとなる Sheep に実装した制御式を式 (2.15) に示す.

$$\begin{aligned} \mathbf{u}_i^D = & {}^c\mu_i^{D,Sc} \mathbf{v}_i^{D,S} + {}^s\mu_i^{D,Sc} \mathbf{v}_i^{D,S} + {}^a\mu_i^{D,Sc} \mathbf{v}_i^{D,S} + {}^c\mu_i^{D,Dc} \mathbf{v}_i^{D,D} + \\ & {}^s\mu_i^{D,Ds} \mathbf{v}_i^{D,D} + {}^a\mu_i^{D,Da} \mathbf{v}_i^{D,D} + \mu_i^{D,T} \mathbf{v}_i^{D,T} \end{aligned} \quad (2.14)$$

$$\begin{aligned} \mathbf{u}_i^S = & {}^s\mu_i^{SSs} \mathbf{v}_i^{SS} + {}^c\mu_i^{SSc} \mathbf{v}_i^{SS} + {}^a\mu_i^{SSa} \mathbf{v}_i^{SS} + {}^s\mu_i^{SDs} \mathbf{v}_i^{SD} \\ & + {}^c\mu_i^{SDc} \mathbf{v}_i^{SD} + {}^a\mu_i^{SDa} \mathbf{v}_i^{SD} \end{aligned} \quad (2.15)$$

2.2 個性模倣

模倣とは、社会性認知の一種であり、個体間の相互作用なしにコミュニケーションを成り立たせる上で欠かせない認知能力である [5]. 人間社会は模倣により、組織内における技能伝搬を実現させ、組織全体で高いパフォーマンスの維持、向上を行う [6].

本研究では、各 Dog エージェントが持つ個性を互いに模倣し合うことで未知の性質の Sheep に対して全体での誘導パフォーマンスを向上させることを目指す. 個性は各 Dog エージェントごとに違う値をランダムに持っており、Sheep の個性に対して一切依存しないものとする. 実装した模倣式を式 (2.16) に示す.

$$\mu_i = \sum_{j \in \Omega, E_i^{local} < E_j^{local}}^n \mu_i + \frac{1}{100}(\mu_i - \mu_j) \quad (2.16)$$

各エージェントが持つローカル評価値 E_i^{local} については後述する. 模倣するエージェントが模倣対象に急速に一致してしまうと模倣の多様性が無くなるため、 $\frac{1}{100}$ を乗算している.

2.3 ローカル評価値

実際に人間など生物が行う模倣には、模倣する価値のある対象を直感的に選び模倣するといった1段メタな学習機構が存在すると考えられている。^[5] しかし、既存の模倣学習では前提として完全な習熟者を被模倣者として行われることが多い。個性模倣では、視野内に存在するDogが持つローカル評価値という定数を比較し、ローカル評価値の高いエージェントを模倣対象として選択する。実装した評価式を式(2.17)に示す。

$$E_i^{locsl} = \cos(\phi) \frac{1}{d} \quad (2.17)$$

ここで d は視野内の Sheep と目標地点との距離であり、式(2.18)のように算出する。

$$d = \sum_{j \in \Omega}^n |\mathbf{x}^T - \mathbf{x}^S| \quad (2.18)$$

$\mathbf{x}_T$ は Dog から見た目標地点の位置ベクトルを表し、 $\mathbf{x}_S$ は視野内の Sheep の位置ベクトルを示す。

ローカル評価値の設定方法は、Dog にさせたい評価を記述する。今回の誘導タスクの場合、Dog にとって良い評価とは ϕ が小さくなり、 d が小さくなった時に高い数値を算出するように設定する。

第3章 実験

本章では実験環境と実験方法について以下の順に述べる.

- 実験環境
- 実験方法

3.1 実験環境

3.1.1 牧羊犬シミュレーション

Boidsモデルの誘導動作をリアルタイムで可視化するためにPyOpenGLにより描画を行った. Boidsモデルにより誘導動作をすることを一般的に牧羊犬システムというため, 本研究では牧羊犬シミュレーションと呼ぶこととした. シミュレーション風景を Fig. 3.1 に示す.




Fig. 3.1: Simulation scenery

このタスクでは誘導する側:Dog を赤丸, 誘導対象:Sheep を緑丸で示し, 緑の集団がゴールである紫丸の地点に誘導されるかを検証する. Sheep と Dog は Boids モデルの動作戦略に従い行動をするが, Dog 側にのみ個性模倣を適応する事により, Sheep 群の誘導変化を観測する.

3.1.2 実験設計

シミュレーションフィールドは $200[m] \times 200[m]$ とし, 目標地点を中心地点 $(x, y) = (0, 0)$ とする. Dog と Sheep の大きさは直径 $1[m]$ とし, 各台数は Dog10 匹, Sheep80 匹とした.

タスクは, Dog が Sheep を目標地点に誘導するシミュレーションを 10 回行う. 10 回分のデータから, 平均距離の平均値とエントロピーの平均値を算出しグラフ化する.

3.2 実験方法

3.2.1 Sheep と目標地点の平均距離

本研究の目的である誘導の評価をするために、各 Sheep と目標地点の距離を平均化した平均距離を測定する。こちらは評価方法なので視野に依存する必要はない。

実装した平均距離の算出方法を式 (3.1) に示す。

$$d = \frac{1}{n} \sum_{i=0}^n |\mathbf{x}^T - \mathbf{x}_i^S| \quad (3.1)$$

n は Sheep の絶対数を表す。

3.2.2 存在確立とエントロピー

群れと目標地点間の距離のみの評価だと群れの分散度合などを正確に評価できないため、ターゲット群のまとまり具合を測定する必要がある。

そこで本研究では、ターゲット群のまとまりを維持しているかを評価するために、エントロピーを算出する。エントロピーの算出方法を式(3.2)に示す。

$$H_i = - \sum P_i \log(P_i) \quad (3.2)$$

ここで P_i は、Fig. 3.2 シミュレーションフィールドを100マスに区切った時の1マスに存在する Sheep の存在確立を示しており、式(3.3)で算出される。

$$P_i = \frac{a_i}{S} \quad (3.3)$$

a_i は i マスに存在する Sheep の数を表し、 S は1マス当たりの面積を表す。今回はシミュレーションフィールドを $200 \times 200[m]$ としたため $S = 400[m^2]$ となる。

エントロピーを算出することにより、あるシーンにおける Sheep の分布度合いを定数として評価することが出来る。本実験でのエントロピーの理論値は最大8.64, 最小0.46 となるが最小値は Sheep 同士の斥力 ${}^s v_i^{SS}$ が大きいほど理論値より大きくなる。




Fig. 3.2: Image of separate field and existence probability

第4章 結果

本章では Dog エージェントの模倣や追跡条件の有無による実験結果の比較を以下の順で述べる.

- Sheep と目標地点の平均距離の結果
- エントロピーの結果
- 追跡条件による結果

4.1 Sheep と目標地点の平均距離の結果

個性模倣を適応した場合と適応しない場合の Sheep と目標地点の平均距離の比較を Fig. 4.1 に示す.




Fig. 4.1: Average distance between sheeps and distination

Fig. 4.1 は個性模倣を適応した場合と未適応の場合で比較したグラフであり, 模倣を適応した場合にのみ誘導に未知の性質を持つ Sheep を目標地点に近づける事が出来ていることが確認できた.

4.2 エントロピーの結果

平均距離の時と同様に模倣を適応した場合としない場合のエントロピーの比較グラフを Fig. 4.2 に示す.




Fig. 4.2: Entropy every 30 seconds

Fig. 4.2 より, 密集度合いを示すエントロピーも模倣のある場合は無い場合と比較して素早く密集させた事が確認できた.

4.3 追跡条件による結果

Dog から Sheep に対しての引力 $c\mathbf{v}_i^{DS}$ にかかる $\cos$ の引数に対して ϕ のみの場合と $\phi + \frac{\pi}{3}$ とした場合の平均距離の比較を Fig. 4.3 に, エントロピーの比較を Fig. 4.4 に示す. なお, 今回は個性模倣を適応した場合における比較である.




Fig. 4.3: Average distance between sheep and destination when tracking conditions are added




Fig. 4.4: Entropy every 30 seconds when tracking conditions are added

Fig. 4.3 と Fig. 4.4 から, 引数によって追跡条件を限定させることにより誘導効率に大きな影響を及ぼすことが確認できた.

第5章 考察

本章では, 実験結果より得た個性模倣と追跡条件の有無について考察を行う.

- 平均距離の評価
- 追跡条件

5.1 平均距離の評価

Fig. 4.1, Fig. 4.2 より, 模倣を適応した場合と未適応の場合で Sheep と目標地点間の平均距離の比較を行った. 模倣を適応した場合は 150[s] 付近で誘導ができていることが確認できたが, 模倣を適応しなかった場合は 300[s] 経過しても誘導することができなかった. 先行研究では Sheep の性質と Dog の性質を一定にし揃えることで誘導を確認できていたが, 本研究では Dog の性質をランダムに生成した影響で Sheep を誘導できなかったと考えられる.

また, 模倣ありの場合でも誘導完了後の sheep の群れを分散させるケースが確認できた. これは, 模倣対象が優れていた個体と模倣対象が十分な習熟をできていない個体の差により, 模倣のため未成熟な個体が誘導後に散らばらせていることが考えられる. 模倣学習の課題として, 模倣対象がビギナーかエキスパートかによる学習の精度差が挙げられている [5]. 対策として強化学習により, 模倣をするだけではなく自らも学習することでより後パフォーマンスを維持できる可能性があると考えられる.

次に, 個性値の収束について考える. 個性模倣を行い続けると最終的に全エージェントが, ある時点のタスクにおいて最良なパラメータに収束すると考えられる. しかし誘導対象が変わった場合, 次のターゲットに適応するために個性模倣をする必要がある. 現状だとその際に個性は収束していて模倣対象と自分が同じ個性であり, 模倣によって適応することができないと考えられる. 対策として, タスクにおける模倣を行う個体数を制限する手法が考えられる. これにより, 一定数の個性の分散を維持することが可能であり, 誘導終了後に全エージェントの個性が収束しなくなると考えられる. しかし, 前述した模倣の未成熟な個体による誘導後の群れの破壊が行われる可能性もあり, 今後は個性の多様性維持に注目する必要があると考えられる.

5.2 追跡条件

Fig. 4.3 , Fig. 4.4 から Dog の Sheep に対する引力 $c\mathbf{v}_i^{DS}$ にかかる $\cos$ の引数に加算する値によって誘導効率に影響があることが確認できた。これは, Sheep の個性によって最適な値が変わると考えられる。例えば Sheep の Dog に対する斥力が大きい場合や Sheep 同士の引力が弱い場合は引数に加算する角度が大きい方が Sheep 全体を密集させることが可能だと推測できる。以上のことからこの引数も個性模倣の対象になりえると考えられる。模倣対象とすることで連続するタスクの中で誘導完了後, 性質の異なる Sheep の誘導効率に大きな影響を与えられとされる。




Fig. 5.1: Tracking sheep when ϕ is between 0 and $\frac{\pi}{2}$




Fig. 5.2: Tracking sheep when ϕ is between 0 and $\frac{\pi}{6}$

第6章 結論と今後の展望

本章では, 結果と考察を踏まえた結論と今後の展望について述べる

- 結論
- 今後の展望

6.1 結論

近年、避難時の人員誘導や海洋プラスチックのゴミの誘導回収などの用途を見据えマルチエージェントの誘導アルゴリズムの研究が行われている。しかし、実用を考えた場合のターゲットの事前のモデル化が難しいという課題がある。

先行研究では、牧羊犬モデルのシミュレーションと同モデルの実用を見据えドローンに組み込んだ研究を紹介した。文献[2]では牧羊犬モデルの誘導効率がターゲットである Sheep の性質に大きく依存することが結論付けられ、文献[3]では実機実験による誘導成功と、自然界で実用するに向けてターゲットの性質の変化や外乱の影響を考慮する必要性が課題として挙げられていた。

そこで本研究では誘導モデルの一種である牧羊犬モデルと社会性認知の一種である模倣をマルチエージェントに適応した個性模倣を使用し、未知のターゲットの誘導アルゴリズムの提案をした。

結果として個性模倣と牧羊犬モデルにより、事前にターゲットの性質の考慮をしていない Dog によって未知の Sheep の誘導に成功した。個性模倣を適応した場合と未適応の場合で比較し、未知のターゲットに対して誘導できたため提案手法の有効性が確認できた。しかし、誘導後に群れを破壊することが確認でき、原因として模倣の対象の熟練度によって Dog エージェント間で誘導の性能に差異が生じていると考察した。また、現状では誘導終了時に個性地が収束している状態であり、連続するタスクを行うためには個性地の多様性の維持が必要であると考察した。

6.2 今後の展望

実環境で実用する場合は人間が逐次介入できないケースが想定されるので、提案したアルゴリズムが連続したタスクの中でターゲットに適応し誘導可能かを検証していく。加えて、追跡条件を模倣対象とすることでSheepの性質変化への適応度を調べる。また実機に実装し、センサや通信精度などシミュレーションと実環境での差異を考慮した検証を行う必要がある。

謝 辞

本研究を進めるにあたり、熱心なご指導をくださいました五十嵐洋教授に心よりお礼申し上げます。また、ミーティングやディスカッションを通してアドバイスをくださいました協調ロボティクスの諸先輩方に深く感謝いたします。

参考文献

- [1] 渡辺春花, 藤岡薫: ”2匹の牧羊犬を用いた群れ誘導における誘導位置の検証”, 情報処理学会第81回全国大会.
- [2] 五十嵐洋, 足達嘉信, 高橋一成: ”マルチエージェントによる協調追い込み問題 牧羊犬シミュレーションプラットフォーム”, Robotics and Mechatronics, No. 10-4, 2010.
- [3] Junyan Hu, Ali Emre Turgut, Tomas Krajník, Barry Lennox, Frashad Arvin: ”Occlusion-Based Coordination Protocol Design for Autonomous Robotic Shepherding Tasks”, IEEE Transaction on Cognitive and Developmental Systems, 10.1109/TCDS.2020.3018549, 2020.
- [4] 大倉和博, 保田俊行, 松村嘉之: ”構造進化型人口神経回路網による Swarm Robotics のための適応的協調行動の生成”, 日本機械学会, 77 巻 775 号, 2011.
- [5] 嶋田総太郎: ”特集「社会性認知のメカニズム」の編集にあたって”, 認知科学, Vol. 18, No. 1, 2011.
- [6] 田渕一真, 谷口忠大, 榎木哲夫: ”模倣学習と強化学習の調和による効率的行動獲得”, 人工知能学会, 3C1-2, 2006.
- [7] 鈴木隆史, 五十嵐洋: ”模倣と多様性の維持による適応型協調アルゴリズム”, ロボティクス・メカトロニクス講演会講演概要集, 1A2-A03, p.1-4, 2013.
- [8] 林咲貴子, 藤岡薫: ”マルチエージェントシステムを利用した効率的な群れ誘導方法の検討”, 情報処理学会, 第78回, 5P-01, 2016.

- [9] 松野文俊: ”群行動の理解と群ロボット研究”, 日本ロボット学会誌, Vol.35, No.6, pp.428-431, 2017.