

2022年度 卒業論文

**マルチロボットシステムによる協調作業
及び人間介入がシステムに及ぼす影響**
Collaborative Work by Multi-Robot System and
Influence of Human Intervention on the System

東京電機大学工学部 電子システム工学科

指導教員： 教授 五十嵐 洋

研究室名： 協調ロボティクス研究室

19EH041 佐藤 航成

2023年2月10日 提出

研究概要

近年、通信技術が発達したことによって複数台のロボットを用いるマルチロボット、そして遠隔操作ロボットが注目を集めている。複数台のロボットを用いたマルチエージェントの対象問題として牧羊犬問題が挙げられる。牧羊犬問題はイヌがヒツジを目的地まで誘導するモデルをシミュレーション上で再現したものであり、協調的要素を有する問題として考えられている。先行研究ではこの問題に対して設計者が自らタスクに必要な制御規則を定める手法がとられている。しかし、人間が制御規則を定める方法ではタスクの環境の変化に対応することは困難である。

本研究では、設計者の介在がより少ない人工知能アプローチによって牧羊犬問題を解く。その際、自律的に働くロボットの制御手法として強化学習を用いるが、この手法は膨大な学習時間を要することが欠点として挙げられる。そこで模倣学習を活用した遠隔操作ロボットを取り入れるによって、より効率的にヒツジの誘導を実現することを目的とする。

結果として、強化学習のみの場合と比べ、行動が不安定であり、誘導に最適であると言えるような行動は獲得できなかった。しかし、タスクを達成し始めるまでの時間は大幅に減少させることができた。従って、効率的な誘導という点を除き、タスクを達成するという事に焦点を当てた際には、遠隔操作ロボットを導入する有効性を確認することができた。

目次

第1章	序論	1
1.1	背景	2
1.1.1	マルチロボットシステム	2
1.1.2	遠隔操作ロボット	3
1.1.3	強化学習	4
1.1.4	模倣学習	5
1.2	関連研究	6
1.2.1	マルチエージェント強化学習	6
1.2.2	五指電動義手の模倣学習	7
1.2.3	牧羊犬問題	8
1.3	研究目的	9
第2章	提案手法	10
2.1	ヒツジモデル	11
2.1.1	凝集力	12
2.1.2	整列力	13
2.2	イヌモデル	14
2.2.1	状態・行動	15
2.2.2	報酬	16
2.2.3	模倣による報酬	17
第3章	実験	18
3.1	実験環境	19
3.1.1	シミュレーション環境	20
3.1.2	パラメータ設定	21
3.2	実験手順	22

3.2.1	強化学習のみによる実験	22
3.2.2	模倣学習を取り入れた実験	24
3.3	評価方法	25
第4章	結果	26
4.1	初期条件におけるエピソード長の結果	27
4.2	条件を変更した場合のエピソード長の結果	28
第5章	考察	29
5.1	強化学習のみを適用した場合	30
5.1.1	初期条件におけるエピソード長	30
5.1.2	条件を変更した場合のエピソード長	31
5.2	模倣学習を取り入れた場合	32
第6章	結論と今後の展望	33
6.1	結論	34
6.2	今後の展望	36

第1章 序論

本研究ではマルチロボットシステムによる協調作業の有効性を調べ、さらに人間介入によってそのシステムを活性化させることを目的とする。本章では以下の順に述べる。

- 研究背景
- 関連研究
- 研究目的

1.1 背景

1.1.1 マルチロボットシステム

マルチエージェントシステムとは複数の自律エージェントを用いることによって、集合的なふるまいを創発するシステムである。そしてこのエージェントにロボットを活用したシステムを本研究ではマルチロボットシステムと呼ぶ。近年は、第5世代移動通信システム(5G)の商用化に向けた広帯域通信や自動運転を可能にするための高速通信など、通信技術の発達が著しい。それに伴ってロボット間での高速な通信が可能となってきており、マルチロボットの研究が盛んに行われている。複数台のロボットを協調させることによる利点はいくつかあるが、まず第1に数台が故障してもシステムとして機能し続けることが挙げられる。また、異なるタスクに同時に対応できることも利点の1つである。そして最も大きな利点はあらかじめ複数台で働くことを前提としているため、ロボットの台数の変化に柔軟に対応できることである[1]。これらの性質から、大規模な工場での作業や故障する可能性が常に隣り合わせにある災害対応などでの活躍が期待されている。

1.1.2 遠隔操作ロボット

通信技術の発達は大規模遠隔操作ロボットの発展にも大きく貢献している。遠隔操作ロボットで懸念されるのは距離の制約、そして遅延の問題である。しかし、通信技術が向上したことによりこれらの問題を解決することが可能となり、従来よりも長距離での利用やリアルタイムでの操作を前提とした研究が数多く行われるようになってきている。また、現地で作業を必要としないことも普及の要因である。過疎地域での労働人口の問題が近年浮き彫りになっているが、遠隔からの作業であれば現地に赴く必要がない。さらに2020年以降はコロナウイルスの影響もあり、人との接触を必要としない作業形態の需要は高まっている。

1.1.3 強化学習

ロボットが試行錯誤の中で自律的に最適な行動を学習する手法を強化学習と呼ぶ。強化学習は目的の状態にたどり着いたときに報酬を与え、その報酬を基に次の行動を決定する。こうして最終的には所望の行動を獲得できる。この手法は設計者の介在、タスクに関する先見の知識量が少なく済むという利点がある。特に近年は複数台のロボット間で協調して作業することも増えてきており、それに伴ってマルチエージェント強化学習の研究[2][3]も数多くなされてきた。しかし、複数台のロボットに対して強化学習を適用する場合、エージェント間共通の報酬を与えても学習できないケースが存在する。これは全体で共通の報酬を設定するだけでは、報酬獲得と無関係な行動が強化されることが要因であると考えられる。また、個体ごとに報酬を付与する方法もあるが、この場合は協調行動自体を獲得することが難しいとされている[4]。




図 1.1: Reinforcement learning.

1.1.4 模倣学習

模倣学習はその現象も機制も複雑で多様な様相を持っており、その定義はきわめて曖昧である [5]. そこで、本研究における模倣学習とは熟練者の動きを観察・模倣し、より良い報酬を得るための動作を推定する技術と定義する. また、正解データである人間の行動と似た行動をとった際に「報酬」を受けとるため、模倣学習を強化学習の特殊型として位置づける考えもある. しかし、本稿では通常の強化学習と区別するため、環境から報酬を得ることで方策を最適化していく学習法を「強化学習」、人間の行動を模倣することで方策を最適化していく学習法を「模倣学習」として考える. そしてこの模倣学習と強化学習を組み合わせることによって、スパースな報酬設計でも学習を進めることが可能となる.

1.2 関連研究

1.2.1 マルチエージェント強化学習

高田らはマルチエージェントシステムの対象問題として缶蹴りを扱っている [6]。ルールは通常の缶蹴りと同様であり，4 体の子のいずれかが 1 体の鬼に見つからずに缶に触れることを目的としたタスクである。このタスクにおける協調行動とは，ある子が他の子と同期的に缶に近づき，自ら鬼に発見される自己犠牲の行動である。この行動を獲得するための制御手法として，強化学習が用いられている。結果として，課題の難易度次第で協調行動を獲得することに成功しており，マルチエージェントに強化学習を適用することの有効性を示している。




図 1.2: Experimental environment.

1.2.2 五指電動義手の模倣学習

築地らは強化学習と模倣学習を用いて柔軟な把持動作の獲得を試みている [7]. 先行研究では強化学習により把持動作を獲得したが、膨大な時間を要した. そこで新たに模倣学習を取り入れた手法を提案し、強化学習のみを適用した場合と比較している. 結果として、最適行動を獲得するまでの時間は変化しなかったが、把持に近い行動を学習するまでの時間は大幅に短縮している. また、模倣学習を取り入れたことによって、より人間の動作に近い持ち方で把持できることも確認されている.




図 1.3: Experimental environment.




図 1.4: Learning environment.

1.2.3 牧羊犬問題

相庭らはイヌがヒツジを誘導するモデルを用いてマルチエージェントシステムの研究を行っている [8]. この研究では2匹のイヌ, 50匹のヒツジをフィールド上に配置し, イヌが協調しながらヒツジをゴールまで誘導するモデルを提案している. まず, イヌに視野範囲を設定し, 視野内にいるすべてのヒツジから重心を求める. イヌの内1匹は視野範囲のもっとも外側にいるヒツジを重心に近づける役割, もう1匹が重心にアプローチすることで目的地へ誘導する役割を担う. そして, 上記のモデルと視野範囲を設定しない同様のモデルを比較検証している. その結果, 視野範囲を設定し, 認識できる数を制限したことでより協調しながら誘導できることが確認された.




図 1.5: Initial condition.




図 1.6: Proposed model.

1.3 研究目的

先に述べた牧羊犬問題に対して、従来は必要な行動を設計者が直接手動で設計する手法がとられてきた。この手法は目的に沿った効率的なタスク達成が期待できる。一方で、マルチロボットの協調戦略という観点から考えると、挙動を細かく指示することはタスクに特化した設計になってしまい、有効性が限られる。そこで本研究では、設計者の介在がより少ない強化学習によって牧羊犬問題を解くこと、さらに模倣学習を取り入れることによって、より効率的にヒツジの誘導を実現することを目的とする。

第2章 提案手法

本章では牧羊犬問題におけるヒツジとイヌのモデルを提案する.

- ヒツジモデル
- イヌモデル

2.1 ヒツジモデル

ヒツジ群はそれぞれ個体ごとが持つ視野範囲のなかで、近くの個体と群れようとするベクトル v_c と近くの個体と同じ方向に移動しようとするベクトル v_a に従って行動する [9]. これを表現した数式モデルを以下に示す.

$$\mathbf{V}^{n+1} = \mu_0 \mathbf{V}^n + \mu_1 \mathbf{v}_c + \mu_2 \mathbf{v}_a \quad (2.1)$$

$\mathbf{V}$ は速度ベクトル, μ_0, μ_1, μ_2 は各ベクトルの重み, n は時間ステップを意味する. そのため, μ_0 が大きいほど, 過去 of 速度ベクトルを優先する. また, μ_1, μ_2 の大きさに応じて, 凝集力, 整列力の力がそれぞれ変化する.

表 2.1: Sheep model.

パラメータ	内容	数値
n	ヒツジの数	9
d	視野範囲	7 m
μ_0	重み	0.3
μ_1	重み	1.2
μ_2	重み	10
V_{max}	最高速度 (イヌがいない時)	2 m/s

2.1.1 凝集力

凝集力とは、近くの個体がなす重心 P_G に集まろうとする力である。視野内 d にいる個体数 n のヒツジの重心を計算し、その重心から自分の位置 P_M を引くことにより求める。

$$P_S = \sum_{i=1}^n P_i \quad (2.2)$$

$$P_G = \frac{P_S}{n} \quad (2.3)$$

$$\boldsymbol{v}_c = P_G - P_M \quad (2.4)$$




図 2.1: Cohesion.

2.1.2 整列力

整列力とは、近くの個体と同じ方向に向かって移動しようとする力である。各個体が持つ移動ベクトルを合計し、その値を視野範囲 d に存在する個体数 n で割ることにより求める。

$$\mathbf{v}_S = \sum_{i=1}^n \mathbf{v}_i \quad (2.5)$$

$$\mathbf{v}_a = \frac{\mathbf{v}_S}{n} \quad (2.6)$$




図 2.2: Alignment.

2.2 イヌモデル

イヌは自律ロボット、遠隔操作ロボット、両方の役割を担う。自律ロボットとして働くイヌには強化学習、遠隔操作ロボットとして働くイヌには模倣学習と呼ばれる計算知能アプローチをそれぞれ用いて牧羊犬に必要な行動を獲得する。

強化学習を適用する際に重要となるのは、観測する状態パターン、選択する行動パターン、与える報酬の3つの設計であるが、本稿では個体ごとに学習環境を用意するのではなく、グループとして学習環境を設ける。このように設定することにより、イヌが協調しながらヒツジを誘導することを促すことができる考える。また、1体のイヌを人間が操縦する遠隔操作ロボットとして導入させ、その行動軌跡と似た動作をした時に与える報酬を別途用意する。つまり、強化学習による報酬と模倣学習による報酬の2つの報酬パターンを設ける。

2.2.1 状態・行動

強化学習を行う上では観測する「状態」、選択する「行動」がうまく設計されない場合、適切なパラメータを使い、長い時間学習をさせてもタスクに必要な行動は獲得できない．本研究では試行錯誤の末、以下のように設定した．選択しうる「行動」のパターンは7通りであり、自律ロボットは自律的に行動を選択し、遠隔操作ロボットの場合はキーボードから入力することで選択する行動を起こす．

表 2.2: State space.

自分（イヌ）の位置
自分（イヌ）の速度
自分（イヌ）の向き
他のイヌの相対位置
ヒツジの相対位置
ヒツジの絶対速度
ゴールの相対位置

表 2.3: Action space.

行動	入力(遠隔操作ロボット対応)
前移動	
後移動	
右移動	
左移動	
右回転	
左回転	
停止	入力なし

2.2.2 報酬

目的状態にたどり着くことが困難なタスクにおいては報酬を目的状態以外の場合にも付与することが望ましいと考えられている。しかし、本研究においてはイヌがヒツジにアプローチしていない場合でさえ、ゴールに行き着くこともあり、このような場合に細かく報酬を設計することは学習に逆効果を及ぼすと考えられる。そのため、ある状態における報酬 $r(t)$ は以下のように設定する。1つ目の条件として、ヒツジがゴールに到着した時に1匹につき + 1.0 の報酬を与える。従って、全てのヒツジを誘導した場合は + 9.0 の報酬を得ることになる。そして2つ目の条件として、経過ステップごとに - 0.001 付与するように設定する。このマイナスの報酬によって、イヌにより短い時間でヒツジの誘導を促す事が可能となる。

表 2.4: Reward.

条件	数値
ヒツジがゴールに到達	+ 1.0
1 ステップ経過	- 0.001
それ以外	0

2.2.3 模倣による報酬

強化学習は設計者の介在，タスクに関する先見的な知識量が少なくて済むという利点の一方で，学習に時間を要するという欠点がある．この問題を解決すべく用いるのが模倣学習である．遠隔操作ロボットを用いて正解データを示し，模倣学習を行うことによって学習の促進を図る．本研究では，模倣学習のアルゴリズムとして敵対的模倣学習 (Generative Adversarial Imitation Learning: GAIL) を用いる．GAIL[10] とは敵対的生成ネットワーク (Generative Adversarial Network) に基づいて提案されたアルゴリズムである．GAN は教師データと似たデータを生成しようとする「Generator」と入力されるデータが教師データであるか，あるいは生成されたデータかを識別する「Discriminator」によって構成されている．そして，GAIL もまた同様の枠組みである．Generator により生成される状態・行動サンプルが，熟練者のサンプルとどの程度似ているのかを Discriminator により判定し，その確率 $D(s,a) \in [0, 1]$ を報酬として出力する．さらにその報酬が Generator の入力となり，強化学習の要領と同じように学習し，生成データをより洗練させていく．このようにして，次第に教師である人間のデータに近づけていく．




図 2.3: GAIL overview.

第3章 実験

本章では行った実験を以下の項ごとに述べる.

- 実験環境
- 実験手順
- 実験方法

3.1 実験環境

牧羊犬問題は動的に動くヒツジに対して、イヌがいかにして効率よく目的地まで誘導するかを検証するタスクである。本実験では、自律ロボットのみで学習する場合と遠隔操作ロボットを導入した場合の2パターンの実験を行い、比較する。

3.1.1 シミュレーション環境

牧羊犬モデルを再現するために、仮想環境としてUnityを用いた。下図はタスク実行中の様子である。40 m × 40 m の大きさから成るフィールド上にヒツジ (9 匹)、イヌ (3 匹) を配置する。イヌは自分の前方 10 m × 10 m を視野範囲とする。さらに、四隅は壁となっており、壁に隣接する形で取り付けられた赤色の範囲を目的地 (14 m × 6 m) とする。当初、ヒツジとイヌは同じ大きさに設定していたが、学習が一向に進まない問題が生じた。そのため、タスクの性質上、イヌのスケールをヒツジの2倍としている。そして、全ての羊が目的地に到着した時をタスク完了とし、1000 step 経過しても誘導できない時はその時点でタスク終了とする。




図 3.1: Initial condition.

3.1.2 パラメータ設定

機械学習には人間が調整する必要のあるパラメータが存在し、これをハイパーパラメータと呼ぶ。このハイパーパラメータの値によって学習の速度や安定度を調整することが可能となる。試行錯誤の結果、本研究では以下のように設定している。「strength」はそれぞれの学習で受け取る報酬に乗算する値である。この値の比によって強化学習、模倣学習どちらを優先するのかが定まる。また、タスクが複雑なため、今回は「buffer_size」を大きな値に設定している。このように方策を更新するために必要な経験(状態, 行動, 報酬)を増やすことで正しく問題を捉えられるようにしている。他のパラメータは既定の範囲内とされる値に設定している。

表 3.1: Reinforcement learning parameter

パラメータ	内容	数値
strength	強化学習の影響度	0.5
gamma	将来の報酬割引率	0.99
hidden_unit	隠れ層のニューロン数	512
num_layers	隠れ層の数	2
learning_rate	強化学習の学習率	0.0003
buffer_size	方策更新前に収集する経験数	20480

表 3.2: Imitation learning parameter

パラメータ	内容	数値
strength	模倣学習の影響度	1.0
gamma	将来の報酬割引率	0.99
hidden_unit	隠れ層のニューロン数	128
num_layers	隠れ層の数	2
learning_rate	模倣学習の学習率	0.0003

3.2 実験手順

3.2.1 強化学習のみによる実験

まず、自律ロボットのみを用いて誘導を図るため、 4.0×10^7 step(unity上で誘導の動きを確認できるまで) 学習させる．次に，以下のように環境を変更させて，学習済みモデルを基にタスクを実行する．環境を変化させて実験を行う事で，マルチエージェントタスクに強化学習を適用する有効性を検証する．

- (1) ゴール地点を中央に変更し，さらにゴールの範囲を縮小
- (2) ヒツジの数を+5 体，犬の数を+2 体ずつ増加
- (3) (1) + (2) + フィールドの大きさを 2 倍に拡大




図 3.2: Situation (1).




图 3.3: Situation (2).




图 3.4: Situation (3).

3.2.2 模倣学習を取り入れた実験

模倣学習を取り入れた実験では、遠隔操作エージェントとして人間がマルチエージェントの中に介入した場合の影響を調べる．まず、学習前に操作主はディスプレイとキーボードを用いて1体のイヌを操作し、ヒツジをゴールまで誘導する．この手順を30回繰り返す．そして、その行動軌跡をイヌの各個体に記憶させ、強化学習のみの時と同様に 4.0×10^7 step 学習させる．

3.3 評価方法

強化学習において、タスク開始からタスク終了までの過程をエピソードと呼び、学習の1サイクルのことをステップと呼ぶ。牧羊犬タスクでは全てのヒツジを目的地に誘導した時、または一定時間(1000 step)経過した時をエピソード完了としている。本研究では評価方法としてエピソード長を考える。タスク開始から終了までの時間を意味するエピソード長は、横軸を学習に費やした総ステップ数、縦軸を1回の試行に要したステップ数とする。そして、自律エージェントのみの場合と人間が介入した場合のエピソード長をそれぞれ評価する。さらに前者の場合はタスクの環境を変化させた時のエピソード長も調べ、状況の変化に対する再学習の必要性を検討する。

第4章 結果

本章では行った実験の結果を以下の項ごとに述べる.

- 初期条件におけるエピソード長の結果
- 条件を変更した場合のエピソード長の結果

4.1 初期条件におけるエピソード長の結果

下図は初期条件において、自律エージェントのみで学習を行った場合と遠隔操作エージェントを介入させ、模倣学習を取り入れた場合のエピソード長である。




図 4.1: Episode length.

まず、自律エージェントのみで学習した場合を見てみると、学習初期は上限時間である 1000 step 経過してもタスクを達成することができず、そこでエピソードが終了されている。しかし、 2.0×10^7 step 付近を過ぎてからは、経過時間に比例するように 1 エピソードにかかる時間が減少していることがグラフから読み取れる。そして最終的に、タスクにかかる時間は約 400 step まで縮まっている。模倣学習を取り入れた場合も同様に学習初期は上限時間である 1000 step 経過してもタスクを達成することができていない。しかし、自律エージェントのみの場合と比較すると、誘導に初めて成功するまでの時間は大幅に減少していることが確認できる。最終的には上昇下降を繰り返しながら、1 エピソードにかかる時間は 4.0×10^7 step で約 550 step となっている。

4.2 条件を変更した場合のエピソード長の結果

自律エージェントのみを用いて学習を行う場合は、タスクの環境を変更させた時のエピソード長についても考える。環境を変化させる時の条件を改めて以下に記す。そして、図 4.2 が初期条件を加えた計 4 つの環境におけるそれぞれの 1 エピソードにかかる時間を示すグラフである。

- (1) ゴール地点を中央に変更し、さらにゴールの範囲を縮小
- (2) ヒツジの数を+5 体、犬の数を+2 体ずつ増加
- (3) (1) + (2) + フィールドの大きさを 2 倍に拡大




図 4.2: Situation change task.

(1) の場合、初期条件よりもかかった時間は増加しているが、依然として 1000 step 以内にタスクを達成できている事が読み取れる。さらに、(2) の場合は初期条件よりも短い時間でタスクを達成している事が読み取れる。一方で、(3) の場合は上限時間である 1000 step 経過してもタスクを達成することができていない。

第5章 考察

本章では行った実験の結果を踏まえ、以下の項ごとに考察を述べる．

- 強化学習のみを適用した場合
- 模倣学習を取り入れた場合

5.1 強化学習のみを適用した場合

5.1.1 初期条件におけるエピソード長

自律エージェントのみで学習を行った場合、学習初期はタスクの達成に長い時間を要したが、学習が進むにつれて誘導に必要な行動を獲得していることが図 4.1 から読み取れた。実際に、Unity 上でも誘導のための協調行動を獲得していることが見てとれた。ヒツジが分散している時には3体のイヌは同じ個体にアプローチしないような動きを示し、1体のイヌで誘導するのが難しいような場合は他のイヌが加勢するような動きも見せた。この要因として、本実験では個体ごとではなく、グループとして報酬を与えた事が影響したと考えられる。一方で、最適行動を獲得するまでには 4.0×10^7 step(約4日)を要するという結果に至った。本研究では、この膨大な学習時間を必要とする問題に対して、模倣学習を取り入れることを提案している。しかし、協調行動を考慮せず、誘導することにのみに焦点を当てた場合、個体ごとに学習環境を与えることもこの問題を解決する上で有効なのではないかと考える。

5.1.2 条件を変更した場合のエピソード長

図 4.2 はタスクの環境を変更させた時の 1 エピソードにかかる時間を表したグラフである。まず、ゴールの条件を変更した場合は初期条件と比べてタスク達成までにより長い時間がかかった。しかし、それでも時間内にタスクを達成できており、Unity 上でも誘導に必要な行動をとっていることが確認された。次にエージェントの台数を変更した場合は、1 体のイヌに対するヒツジの数が少なくなったことが影響し、むしろ初期条件よりもエピソード長は短くなった。一方で、これらの条件にフィールドのサイズを大きくする要素を加えた場合は、時間内にタスクを達成することができなかった。この要因としてイヌの視野は変化していないため、より広い範囲に分散しているヒツジを探索するまでに長い時間がかかってしまったことが挙げられる。そのため、イヌの視野範囲を広げるなど、その性能次第でフィールドの大きさの変化にも対応できると考える。タスクに必要な行動を組み込み式によって解く従来の手法は、マルチエージェントを対象とした問題においても素早く、安定してタスクを解ける等の長所を発揮してきた。しかし、この手法は環境が想定外に変化する際には効率よく対応することが難しい。一方で、強化学習を用いた手法は環境が多少変化した場合でも学習し直す必要はなく、学習済みモデルによって柔軟に対応できる事を本実験によって示唆した。

5.2 模倣学習を取り入れた場合

模倣学習を取り入れた場合は強化学習のみで学習を進めた場合よりも短い時間でグラフが下がり始めていることが図 4.1 から確認できる。これは人間が示した行動軌跡を事前に保有していたため、ヒツジをゴールに誘導するという目的を学習初期から認識できたことが要因であると考えられる。しかし、強化学習のみを適用した場合とは異なり、模倣学習を取り入れた場合はエピソード長の増減が不安定であり、学習速度も低下している。最終的に 4.0×10^7 step 学習させたが、Unity 上では誘導に最適な動きは確認できなかった。特に複数のイヌが同じヒツジにアプローチし、互いに妨害し合う様子が多々見られた。本実験ではハイパーパラメータの1つ「strength」の値を意図的に高く設定したが、この設定が人間の行動軌跡を過度に重要視する結果につながり、学習の停滞を引き起こしたのではないかと考える。また、学習が安定しなかったことは「learning_rate」の値が影響しており、学習の収束を急ぎすぎたと推測する。また、遠隔操作ロボットの操作主は熟練者を想定して実験を行ったが、実際にはその人間の操作は一貫されておらず、不完全なデータが生成されたことも1つの要因として考えられる。

第6章 結論と今後の展望

本章では結論と今後の展望について以下の項ごとに述べる.

- 結論
- 今後の展望

6.1 結論

近年、第5世代移動通信システム (5G) など通信技術の発達が著しい。それに伴ってロボット間での高速な通信が可能となっており、ロボット複数台による協調作業の研究が盛んに行われている。また、通信技術の成達はマルチロボットだけでなく、遠隔操作ロボットの技術向上にも繋がっている。従来と比べ、大容量のデータ通信が可能となったことで遠隔操作ロボットにおける距離の制約や遅延の問題が少なくなっている。

複数台のロボットを用いたマルチエージェントの対象問題として多々扱われる牧羊犬問題は、複数台のヒツジがBoidモデルによって相互に影響しながら動くため、動的に環境が変化する。また、その過程でヒツジはいくつかの異なる群れをつくることもあるため、効率的な誘導には複数のイヌを必要する。これらの理由から牧羊犬タスクはマルチエージェントを対象とするベンチマーク問題となっている。先行研究ではこの問題に対して、設計者が自らタスクに必要な制御規則を定める手法がとられているが、人間が制御規則を定める方法ではタスクの環境の変化に対応することは困難である。マルチロボットは一部のロボットが故障しても働き続けることができる点、そして異なるタスクに同時に対応できる点から災害対応などでの活躍が特に期待されている。しかし、災害現場は常に環境が変化し続け、そういった場面においてはロボット自身が制御規則を見つける手法が有効であると考えられる。そこで提案する手法が強化学習であり、この学習法によってロボットは自律行動を獲得する。しかしながら、自律ロボットは人間と比べると状況把握能力が低いという欠点がある。

従って本研究では、設計者の介在がより少ない強化学習によって牧羊犬問題を解くこと、さらに模倣学習を取り入れることによって、より効率的にヒツジの誘導を実現することを目的とした。

結果として、牧羊犬タスクのような協調的要素を有する問題に対しても強化学習が有効であること、さらに人間がマルチロボットのシステムに介入することの有効性を一部示した。最初に、強化学習を適用した複数の自律ロボットを用いて実験を行った結果、安定しながら学習が進み、最終的に最適行動を獲得することを確認できた。また、学習済みモデルを用いてタスクの環境を変化させて観測した結果、問題なく対応でき、マルチエージェント問題に対する強化学習の有効性を示した。一方で、最適行動を獲得するまでには膨大な時間を要するという課題も残した。そこでこの問題を解決すべく、模倣学習を取り入れて実験を行った。模倣学習を取り入れた場合は人間が示した行動軌跡を事前に保有していたため、エピソード長の下がり始めはより早かった。しかしその後、学習速度は低下していき、最適行動を獲得することは出来なかった。Unity 上でもヒツジにアプローチする様子が学習初期から見られたが、ヒツジの位置によっては誘導に苦戦してるような場面やイヌ同士で妨害し合うような場面も多々見られた。この問題は、人間の行動を重要視しすぎてしまったことが要因であると考察した。それでも、学習初期の時点で時間内にタスクを達成すること自体は出来ており、人間が介入する有効性を示した。

6.2 今後の展望

本研究では、最適行動を獲得するまでに時間がかかるという強化学習の欠点に対して、模倣学習を取り入れることによって改善した。しかし、効率的に誘導を行うという点においてはむしろ悪影響を及ぼしてしまった。この問題は主に模倣学習のハイパーパラメータを大きく設定しすぎた事が影響したのではないかと推測する。今後はハイパーパラメータの値を調整しながらどのような結果に至るのか検証していく。また、当初はフィールドをトロイダル状にして学習を行っていたが、イヌの行動とは無関係に報酬を受け取る問題が発生し、最適な方策を獲得できなかったため、壁を設けることによって改善した。しかし、実環境における問題はフィールドの制限のない環境がほとんどであり、その点を踏まえると、実環境への対応は難しい。したがって今後は報酬設計などを工夫し、フィールドに制限のない環境での学習を考える必要がある。さらに、事前に人間が介入するのではなく、マルチロボットが働く環境にリアルタイムで人間が介入することで、どのような影響をマルチロボットシステムに及ぼすのか調査する必要がある。

謝 辞

本論文の作成にあたり，ご多忙の中，有益な助言や本研究の方向性を示していただいた五十嵐教授に心よりお礼申し上げます．また，研究を進めるにあたり貴重な意見をくださった先輩方，同期の友人達に感謝いたします．

参考文献

- [1] 末岡 裕一郎, 角田 祐輔: “シープドッグシステムから紐解くマルチエージェントシステムの制御”, 計測と制御, 第 59 巻, 第 2 号, pp. 125-130, 2020.
- [2] 岩科享, 森山甲一, 松井藤五郎, 武藤敦子, 大塚信博: “マルチエージェント強化学習への好奇心探索の適用”, 人工知能学会全国大会論文集, 第 35 回, 2021.
- [3] 渡邊俊彦, 和田竜也: “マルチエージェント追跡問題のための相対座標系に基づく階層型モジュラー強化学習”, バイオメディカル・ファジィ・システム学会誌, Vol. 35, No. 3, pp. 39-47, 2022.
- [4] 佐々木薫, 飯間等: “報酬の設定を自動化した集中型高速マルチエージェント強化学習法”, システム制御情報学会, Vol. 12, No. 2, pp. 65-74, 2010.
- [5] 春木 豊, 都築 忠義: “模倣学習に関する研究”, 心理学研究, 第 41 巻, 2 号, pp. 90-106, 1970.
- [6] 高田 亮介, 坂本 孝丈, 竹内 勇剛: “強化学習を用いた缶蹴りエージェントによる協調行動の獲得”, 人工知能学会全国大会, 第 35 回, 2021.
- [7] 築地 貫太, 山口 暢彦, 福田 修, 奥村 浩: “シミュレーション環境を用いた五指電動義手の模倣学習”, 日本知能情報ファジィ学会, 第 37 回, 2021.
- [8] 相庭 千晴, 藤岡 薫: “牧羊犬の視野制限による群れ誘導への影響”, 情報処理学会, 第 83 回, 2021.

- [9] 東 俊一, 田淵 絢子, 杉江 俊治: “牧羊犬制御のモデル化”, 計測自動制御学会, 第 48 巻, 12 号, pp. 882-888, 2012.
- [10] 松原 崇充, 鶴峯 義久: “動的方策計画法を用いた敵対的模倣学習とその応用”, 日本ロボット学会誌, Vol. 38, No. 6, pp. 507-510, 2020.