

修 士 論 文

個人操作特性を考慮した

操作対象ダイナミクス最適化

Optimization of Dynamics Parameters for Machine
Operation using Individual Operation Characteristics

東京電機大学大学院工学研究科

電気電子工学専攻電子光情報コース修士課程

18KM16 孟 子群

研究指導教員 教授 五十嵐 洋

謝 辞

本研究を行うにあたり，五十嵐洋教授（東京電機大学）からは非常に熱心なご指導，ご鞭撻を賜りました．厚く御礼申し上げます．また，和田成夫教授（東京電機大学）には本論文の副査を務めていただき誠にありがとうございました．厚く御礼申し上げます．

加えて，ニューラルネットワーク関連でお世話になりました石川優一郎氏，ならびに多くの助言を下さいました協調ロボティクスメンバーならびに OB の方々に心から感謝いたします．

目 次

第 1 章	緒論	1
1.1	研究背景	2
1.1.1	運転アシストシステムの開発動向	3
1.1.2	個人操作特性	4
1.2	先行研究	5
1.2.1	ドライバ個人操作特性解析	6
1.2.2	人間機械システムにおける操作熟達	8
1.2.3	人間の意図推定技術	10
1.3	研究目的	13
第 2 章	操作対象のダイナミクスの最適化システムの設計	14
2.1	ニューラルネットワーク (Neural Network : NN)	15
2.2	個人操作モデルの作成	16
2.3	ガウシアンフィルタ (Gaussian Filter : GF)	17
第 3 章	移動体操作タスクのモデル化	18
3.1	1次元操作タスク	19
3.1.1	Bar tracking task	20
3.1.2	NN の構成	22
3.2	2次元操作タスク	23
3.2.1	Circle tracking task	24
3.2.2	NN の構成	26
第 4 章	予備実験	27
4.1	実験手法	28
4.1.1	個人操作モデルの作成	29
4.1.2	ダイナミクスの最適化	30
4.1.3	操作評価指標	31
4.2	実験結果	33

4.2.1	個人操作モデルの作成	34
4.2.2	ダイナミクスの最適化	36
第 5 章	Bar tracking task	39
5.1	実験手法	40
5.2	実験結果	42
5.2.1	個人操作モデルの作成	43
5.2.2	ダイナミクスの最適化	44
第 6 章	Circle tracking task	48
6.1	実験手法	49
6.1.1	実験環境	50
6.1.2	個人操作モデルの作成	51
6.1.3	ダイナミクスの最適化	52
6.1.4	操作評価指標	53
6.2	実験結果	54
6.2.1	個人操作モデルの作成	55
6.2.2	ダイナミクスの最適化	57
第 7 章	結論	61
7.1	まとめ	62
7.2	今後の展望	63
	本研究に関する発表文献	66

第1章 緒論

現在，車運転の熟達アシストに関する研究が広く行われてきた．その中で，個人の操作特性に合わせた運転アシストや制御することが非常に重視化されている．そのために，同一の人間に対して，操作特性，身体特性，生活特性といった多角的な操作特性を考慮する必要がある．しかし，従来の研究では，依然として長期のトレーニング時間が問題となっている．本研究では，個人操作モデルを用いたダイナミクスの最適化解析法に着目し，誰でも短時間で思い通りの操作が可能にするシステムの開発を目指す．本章では，これらの背景とともに本研究での目的を述べる．

1.1 研究背景

本節では，従来の運転アシストシステムの導入およびその影響について述べる．また，ドライバ個人操作特性について議論する．

1.1.1 運転アシストシステムの開発動向

安心・安全で環境にやさしいモビリティ社会の実現を目指して、路車間通信を利用した安全運転アシストシステムや自動運転車の開発など、自動車と情報通信との融合による新しい自動車交通システム開発の取り組みが進められている。特に自動運転車はドライバーの認知判断・操作といった運転操作を補助する運転アシストシステムに代わる次世代のシステムとして期待されており、2020年までの実用化を目指して、日、米、欧で技術開発が進められている。

自動運転技術の開発をさかのぼれば、1975年ごろにコンピューター・ビジョン技術による自動運転の研究開発が行われたのを皮切りに、途中で活動が落ち込んでものの現在まで脈々と研究開発が行われてきた。現在までに開発された自動運転車開発の歴史をFig. 1.1に示す。

しかし、自動運転の実用化には技術面以外にも法令面や社会的受容性、国際標準化など解決すべき課題がさまざま残されている [1]。




Fig. 1.1: The history of autonomous vehicle development[1].

1.1.2 個人操作特性

近年、日本国内では、自動車保有台数は増加し、成人一人に車一台という高比率となっており、高齢化や女性ドライバの増加などから、より幅広い層のドライバに自動車が使用されて来ている。このような背景から、自動車の利用目的も日常生活における買い物や通勤などの短距離移動中心に変化しているため、安全性や市街路での運転しやすさが求められている。安全性や利便性の向上を目的とした運転アシストの一つとしては、走行条件や運転状況に応じて、ドライバの運転行動と協調してアシストするシステムが考えられる [2]。このような運転アシストシステムは大別して、ドライバの「認知」をアシストするものと、「操作」をアシストするものがあり、「操作」に関するものの一つとして操舵操作が挙げられ、操舵に関するアシストシステム [3] としては、可変ギヤ比システムやステアバイワイヤ技術が挙げられる。

しかしながら、これらの高度化された運転アシスト技術には、人と機械の意図の対立、機械への不信や過信、オートメーションサプライズなど、高度化に伴う問題が存在する [4]。これは、システムがドライバ各個人の操作特性に合わせたアシストをしていないことが要因の一つである。このため、各ドライバの運転に関する特性やシステムの変化に伴う運転行動の特性の変化を定量的に把握することが必要になる [5]。

また、人間にとって安全性を向上させることだけではなく、操作の容易さや快適性などを高めるための運転アシストシステムの導入が進んでいる。これらのシステムは、運転行動に対してアシストを行うため、車両単体だけではなく人間・自動車系としての設計が必要になる。

自動車を運転する人間はそのスキル、嗜好、体調などさまざまな特性を持っているため、個々の操作特性に合った運転アシストや制御をすることが重要になる。しかし、アシストや制御のタイミングなどがその人間の操作特性に合っていないことが問題となっている。これは、一般にアシストや制御タイミングなどを標準的な人間に合わせて、一律に設定していることが原因とされている [6]。

これらの問題を克服するためには、個人ごとに適合できる新たな運転アシストシステムを構築することが必要となっている。今後、より高度な先進安全技術による事故低減についても期待されている [7]。

1.2 先行研究

昨今，人間機械システムにおいて，個人操作パフォーマンスの向上を目的として数多くの研究が行われている．特に，運転アシストに注目が集まっております．それらの研究の多くは，機械の自律的な動作によって設計者が想定する特定のタスクにおいて高いパフォーマンスを示している．しかし，想定外のタスクにおいて人間の学習能力を阻害することが危惧されている．

本節では，個人の操作特性を重視した運転アシストシステムについて議論を行う．

1.2.1 ドライバ個人操作特性解析

本項では、ドライバ個人操作特性解析に関する先行研究を例示し、検討を行う。

近年、自動運転の研究開発が加速している。自動運転によりもたらされる価値は、事故の削減、運転負担の軽減、移動困難な人々への移動支援など、多大なものがあり、技術開発に対する期待も大きい。一方で、自動運転に不安を感じているドライバも少なからず存在し [8]、技術の普及にはドライバの安心感、受容性の醸成が必要であることが示唆される。そこで、運転するドライバにとって、運転の是非の基準は個人の運転方法であるため、自動運転においても、個人の運転スタイルに合わせることで、安心感、受容性の面で重要と考えられた。

竹原らの研究では、ドライバの操舵行動より、操舵に関する車両特性や走行環境と人間との関係に着目し、個々のドライバ特性を把握するための基礎検討として、技能差に着目した分類を行うことを目的とした。一般的な市街地での運転状況で多く見られる低速での右左折操舵として、クランクコースにおける検討を行った。ドライビングシミュレータを用いた走行実験においてステアリングギヤ比や、コースの道幅の変更などを行い、車両の特性と環境の特性の変化に対する適応力を考慮したドライバの分類方法を提案した [9]。結果として、ドライバ操舵行動特性について、操舵角に着目し、実車両を用いたクランクコースでの走行実験を行い、分類のため、操舵角標準偏差、運転荒さ、総操舵量の三指標を適応し、ドライバの分類が可能であることを確認した。また、提案した手法により、車両特性や走行環境の変化への適応力を考慮し、運転技量の差に則した分類も可能となった。

平松らの研究では、手動運転中にシステムが個人の運転スタイルを学習し、個人に合わせた自動運転を提供することを最終目標とし、ドライバの運転スタイルをモデル化した [10]。運転スタイルとは、運転行動の主要な走行パラメータの個人特性と定義した。運転スタイルの異なるドライバの一般道路の走行データを収集し、追従走行中のデータを分析した結果、停止中と減速中の車間距離は、個人の運転スタイルを反映し、目標車間距離の基準を決めるのにデータを用いて、車間距離のモデル化を提案した。また、モデル化手法の妥当性を検証するため、テストコースで、自動追従車両による評価実験を行った。結果として、個人モデルを反映した自動追従は、個人の感覚に一致することがわかった。また、車間距離の一致度が高いと、安心感と受容性も高くなったことがわかつ

た．今後の課題として，平松らは提案したモデルをよりさまざまな走行状態を含む走行環境において自動走行車両で評価し，各走行環境，走行状態で一致度を確認することである．しかし，提案した手法を他の個人特性に拡張すること，変動要因の検出方法，精度向上について検討することが示唆された．

青柳ら [11] の研究では，走行環境の安全性と運転負担を考慮し車室内の情報呈示を制御するシステムの開発に向け，個人差を考慮した負担推定手法を提案し，実験によりその手法の妥当性を検証した．結果として，運転負担だけではなく情報視認負担も変化させた実験により，提案手法の有効性を示した．しかし，提案手法には個人差補正時の基準の設定や，情報視認の負担の感度の個人差補正などの課題が存在している．今後はこれらの課題に取り組み，よりドライバーの個人操作特性に配慮した情報制御システムを構築し，車室内での価値，利便性の向上につなげていった．


1.2.2 人間機械システムにおける操作熟達

本項では、機械操作早期熟達に関する先行研究を例示し、検討を行う。


昨今、人間機械システムの操作パフォーマンスの向上を目的として数多くの研究が行われている。特に、運転アシストに注目が集まっており、それらの多くは機械の自律的な動作により、設計者が想定する特定のタスクにおいて高いパフォーマンスを示している。しかし、想定外のタスクにおいて人間の学習能力を阻害することが危惧されている。

この問題を解決するためには、五十嵐ら [12][13][14] の先行研究では、初心者が短時間で思い通りに操作できる機械システムの実現を目指し、操作者に気づかれないように機械特性を修正するサブリミナルキャリブレーションを提案した。この手法は、人間の有する無意識で学習過程を考慮し、操作者の熟達促進効果が期待され、操作パフォーマンスを小さくするように操作対象のダイナミクスの修正をすることを目的とした。Fig. 1.2に操作者の内部モデルを考慮した熟達過程の概略図を示す。それぞれ、横軸を時刻、縦軸を操作者内部モデルおよび操作対象のダイナミクスとした。しかし、操作対象ダイナミクスの急激な変化は、人間が有する学習適応能力を妨げ、違和感や暴走している感覚を与える。そこで、認知科学分野で論じられる人間知覚閾指標である JND (Just Noticeable Difference) を導入することにより、操作者が知覚できない範囲で操作対象のダイナミクス修正を試みた。

また、サブリミナルキャリブレーションを途中で打ち切ったとしても、操作者の学習能力により、最終的にはスキル獲得を達成する。つまり、サブリミナルキャリブレーションの終了条件は、内部モデルと厳密に一致するまでシビアに求める必要はない。結果としては、操作者の学習能力を妨げることなく、操作対象のダイナミクスを内部モデルに近づけることが可能となる。結果として、操作者は思い通りに機械を操れる状態(熟達)までの時間を短縮することを達成した。被験者を対象とした実験後のアンケート結果により、操作対象のダイナミクスの変化が操作の違和感や操作対象が暴走している感覚を与えている可能性が示唆された。しかし、人間の内部操作モデルの予測には操作者が長時間の操作が必要という問題がある。したがって、人間操作の予測時間を短縮する必要があると考えられる。



(a) Natural learning process by human learning ability.



(b) Subliminal calibration without human awareness.

Fig. 1.2: Comparison between human internal model and operated machine dynamics.

1.2.3 人間の意図推定技術

本項では、人間の意図推定技術に関する先行研究を例示し、検討を行う。

近年、知能ロボットの研究は盛んに行われ [15]，社会に普及している．こうした知能ロボットは労働力の減少や作業負担の増加を解決するため，人間が行うことを目的としている．すでに掃除や接客などの今まで人間が行っていた作業の一部を行うロボットが開発され，今後活躍の場を広げながら様々な形で普及していくと予想される．そのため，人間とロボットの活動範囲を共有することが増加することから，両者による協調作業や情報交換が増加していくと考えられる．ロボットが人間と協調作業を行う場合，人間に対して余計な負荷やストレスをかけないために人間の行動や意図を予測する必要があると考えられる．

現在，人間の行動や意図の予測について広く研究が行われている．人間の意図推定技術には様々なものが存在するが，代表的な例として身体的特徴を用いた手法，ニューラルネットワークモデル (Neural Network : NN) を用いた手法，隠れマルコフモデルを用いた手法の3つについて紹介する．

身体的特徴を用いた手法は主に人間とのすれ違いに注目した手法であり，人間の回避意図やコミュニケーション意図，ストレスなどの精神的負担を予測し，対応するためのものである．

人間は行動を起こす時，周囲の環境の影響を受ける．その時，特に重要となるのが対象物との距離である．人間は距離によって対象物に感じる感情が変化する．これは，一般的にパーソナルスペースと呼ぶ．Photchara Ratsamee らはパーソナルスペースの影響を応用したソーシャルフォースモデルと呼ばれるアルゴリズムを開発し，顔の向きとともに利用することで人間の回避とコミュニケーションの2つの行動について分類を行った [16]．結果として，およそ90%程度の確率で回避やパーソナルスペースを考慮したコミュニケーションを行うことができた．また，複数の人間に対しても検証を行い，成功確率が75%と低下したものの適切な行動が行えることを示した．

このような身体的特徴を用いた手法の特徴として，比較的導入が容易である点があり，様々なロボットに応用できるという利点がある．しかし，大人数に対してや，周囲の環境に対しての適応力が低い点や身体的特徴の表れない動きでは利用することが困難である．

NN は人間の脳の仕組みを模した学習アルゴリズムであり、人間の行動予測によく用いられる手法である。人間の動きに関する様々な要素について学習と呼ばれる最適化作業を行うことで行動と要素の間に計算式を成り立たせることで要素から行動を求めることができる。

Yanan Li らはロボットが人間と協調作業を行う際に、人間の行動意図を NN によって学習することで最適なインピーダンスモデルを作成し、人間と円滑な作業が行えるようなインピーダンス制御モデルの作成を目指し、実験によって検証を行った [17]。Yanan Li らの研究では、ロボットの動きを所定の軌道に追従させるだけではなく、力の入力加減などを学習することで人間とロボットが協調作業を行うことを目指した。結果として、動きと力加減に関して学習を行うことで、人間の初動から力加減と目的の位置、すなわち人間の入力を予測した。人間の入力を予測することふあできれば、人間の移動にかかるエネルギーを軽減させることが可能となった。

NN を用いた手法の特徴として、一度動きに関して学習してしまえば、リアルタイムに動きを予測することができるため、適応力が高いことが挙げられる。しかし、欠点として NN の性質上、人間の動作意図を知る要素がわからなければ学習が行えない点が挙げられる。そのため、様々な動きを同時に行うような動きは学習することが難しい。今回の研究で行われているような物体を運ぶだけでなく、把持の力加減や何かにぶつからないように避けることなどを同時に行う場合、非常に高度な学習やセンサが必要となる。

マルコフモデルとは、直前の状況からのみ次の結果の確率が決定されるというマルコフ性を仮定し、事象をモデル化する手法である。隠れマルコフモデルとは、マルコフモデルの中でも、過去の状況の遷移などが不明である状態から結果を用いて事象をモデル化する手法である。

Yihuan Zhang らはこの隠れマルコフモデルとガウス混合モデルという近似手法を用いて人間が車を操作した際の車線変更や車線維持の挙動のモデル化を行った [18]。結果として、目標車両の挙動を 85%以上の確率で予測することができ、車線変更の 4 秒前に車線変更挙動の予測が可能であった。

隠れマルコフモデルを用いた手法の特徴として、高い精度で予測を行うことができることである。先行研究 [18] の結果からもわかるように、車線変更という任意に行われる行動に対して、早いタイミングで検知が行える手法は少なく、非常に利点がある。しか

し、この手法における欠点としては、非常に限定された範囲でしか利用できないという点である。行動の種類やその要因となりうるものの種類が厳密に把握できていない場合、このモデルを用いて予測を行うことは困難である。また、予測を行うためには決定するだけの膨大な量の情報が必要である点も実装する際には、大きな欠点になると考えられる。

本項では、人間の意図推定技術の手法とその利用結果について検討した。それぞれ簡易的に実装できるものから、膨大なデータを用いて確率的に意図を求める方法まで様々なものが存在し、未だ手法の確立はなされていないことがわかった。そのため、使用用途や実装される環境を考慮し、適切な手法を選択し、発展させていく必要があると示唆された。

1.3 研究目的

本研究では、操作不良や空間認識が苦手などによって引き起こされる事故を未然に防ぐために、個人操作モデルを用いた操作インタフェースのオフライン解析法を提案する。また、初心者や高齢者を含めてより幅広い年齢層のドライバが短時間で思い通りに操作できるシステムの実現を目指す。

NNによる個人操作モデルを作成した後、シミュレーション上でデータ解析を行う。そして、個人操作特性に合わせたダイナミクスのパラメータを最適化することで操作パフォーマンスを向上させる。

第2章 操作対象のダイナミクスの最適化システムの設計

本研究では，個人操作特性を考慮し，操作対象ダイナミクスの最適化の設計を行う．本章では，ダイナミクスの最適化手法の概要および提案した手法について説明を行う．

2.1 ニューラルネットワーク (Neural Network : NN)

ニューラルネットワーク (NN) とは，入力層 (input layer)，隠れ層 (Hidden layer)，出力層 (Output layer) から構成される Fig. 2.1. 層と層の間は強度を変化することが可能な重み情報によって繋がっている．入力に対する出力結果を教師情報と照らし合わせ，重みを変化させることによって，その差異を小さくすることで学習を行う．




Fig. 2.1: Image of Neural Network : NN.

2.2 個人操作モデルの作成

本研究では，入力デバイスとして Saitek Cyborg Evo 社のジョイスティック (Joystick : JS) を採用した．採用した JS を Fig. 2.2 に示す．JS からの入力値を用い，NN による個人操作モデルを作成する．個人操作モデルを作成する時に，NN を用いることで個人操作をモデル化する．被験者は操作しながらモデルが生成できる．その後，作成した個人操作モデルを用い，シミュレーション上で個人操作特性に合わせたダイナミクスのパラメータを推定する．



Fig. 2.2: Image of Joystick.

2.3 ガウシアンフィルタ (Gaussian Filter : GF)

GF は一般的にガウスぼかし (Gaussian Blur) などとも呼ばれ、ガウス関数を用いて画像をぼかす技術を指す。ある画素の周辺にガウス分布に基づいた重みを掛け、畳み込み処理を行うことでフィルタリングされる。カーネルの重み $f(x, y)$ は次式に示すガウス関数によって決定される。

$$f(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right), \quad (2.1)$$

ここで、 x および y はカーネルにおける要素の位置、 σ は分散を表している。本研究では追従誤差値を1つの画素とみなして GF の処理を行うため、カーネルサイズは最小の 3×3 を使用する。式 (2.1) によって要素を構成し、全ての合計が1となるようにカーネルを用意する。このとき、 σ は最も一般的である 1.0 とした。用意したカーネルを Fig. 2.3 に示す。

0.075	0.125	0.075
0.125	0.200	0.125
0.075	0.125	0.075

Fig. 2.3: Kernel used for Gaussian filter.

第3章 移動体操作タスクのモデル化

本章では，提案した1次元操作タスクおよび2次元操作タスクの構成について説明を行う．

3.1 1次元操作タスク

本節では，1次元操作タスクの構成およびNNの構成について説明を行う．

3.1.1 Bar tracking task

本研究では，1次元バー追従操作タスクである Bar tracking task を作成する．

Bar tracking task は，1名で完遂できる作業である．Bar tracking task の仮想的な作業環境は，Fig. 3.1のように赤色のバーおよび青色の操作対象バーによって構成されている．被験者が操作する場合において，一定距離で3[sec]ごとで移動するターゲットを目標し，操作対象バーを入力インタフェースの操作によって傾け，目標バーを追従させることが目標である．また，実験の様子を Fig. 3.2 に示す．




Fig. 3.1: Bar tracking task.




Fig. 3.2: Experiment situation of Bar tracking task.

3.1.2 NN の構成

Bar tracking task において，学習を行う NN には，3 層 NN を採用し，入力層を 12 要素，中間層を 18 要素，出力層を 1 要素，学習係数を 0.005 としてバックプロパゲーション法にて 60[sec] 間の学習させた．3 層 NN において，入力信号は，被験者の左右の操作履歴 4 ステップおよび目標バーと操作対象バーの座標追従誤差 4 ステップとし，教示信号は被験者の左右の操作としている．また，学習を行う時間は 45[sec] 間として設定し，予測を行う時間は 15[sec] 間とした．そして，推定されたダイナミクスのパラメータから各解析を行う．

3.2 2次元操作タスク

本節では，2次元操作タスクの構成およびNNの構成について説明を行う．

3.2.1 Circle tracking task

本研究では、2次元円軌道追従操作タスクである Circle tracking task を作成する。

Circle tracking task は、1 名で完遂できる作業である。Circle tracking task の仮想的な作業環境は、Fig. 3.3 のように赤色の目標マーカおよび青色の操作対象マーカによって構成されている。被験者が操作する場合において、一定距離で円軌道方向に 3[sec] ごとで移動するターゲットを目標し、操作対象マーカを入力インタフェースの操作によって傾け、目標マーカを追従させることが目標である。

また、Circle tracking task における目標マーカの動作は操作対象が十分に追従可能な速度であり、常に等速で円軌道を描くように設定する。実験の様子を Fig. 3.4 に示す。




Fig. 3.3: Circle tracking task.




Fig. 3.4: Experiment situation of Circle tracking task.

3.2.2 NN の構成

Circle tracking task において，学習を行う NN には，3 層 NN を採用し，入力層を 24 要素，中間層を 36 要素，出力層を 2 要素，学習係数を 0.005 としてバックプロパゲーション法にて 60[sec] 間の学習させた．3 層 NN において，入力信号は，被験者の左右の操作履歴 4 ステップおよび目標マーカと操作対象マーカの座標追従誤差 4 ステップとし，教示信号は被験者の左右の操作としている．また，学習を行う時間は 45[sec] 間として設定し，予測を行う時間は 15[sec] 間とした．そして，推定されたダイナミクスのパラメータから各解析を行う．

第4章 予備実験

第4章において，Bar tracking task を用いて予備実験を行い，実験手法および実験結果について述べる．

4.1 実験手法

本節では，個人操作モデルの作成実験およびダイナミクスの作成実験について述べる．

4.1.1 個人操作モデルの作成

本実験では、被験者は20代男女23名であり、それぞれ市販のJSによるBar tracking taskを用いて実験を行う。被験者にはJSの操作により、ランダムに動作するように設定し、操作対象バーを操縦するように指示を行う。Bar tracking taskにおいて、学習モード (Learning mode) と予測モード (Prediction mode) の2つのモードを作成する。学習モードにおいて、被験者によるJSの入力を入力値とし、NNを用いることで個人操作モデルを作成する。学習モードでは、被験者の操作時間は60[sec]とする。予測モードでは、シミュレーション時間は30[sec]とする。

NNによる個人操作をモデル化する。この時、被験者全員は同一のダイナミクスのパラメータを用いて実験を行う。被験者の操作時間は60[sec]があり、0秒から45秒までをNNによって学習し、45秒から60秒は予測のみを行っている。その後、追従を確認し、作成した個人操作モデルによる操作の予測を行う。

4.1.2 ダイナミクス最適化

本実験では、シミュレーション上で被験者の操作を予測する。被験者によりジョイスティックの操作を行い、そのときのバーの位置を x ，JS による操作入力量を u として、以下の運動方程式 (4.1) となる。

$$M\ddot{x} + D\dot{x} = u. \quad (4.1)$$

ここで、 M ， D ， $\dot{x}$ ， $\ddot{x}$ は、それぞれ可変の慣性係数，粘性係数，目標バーの速度，そして目標バーの加速度である。本実験では、 M ， D ， $\dot{x}$ ， $\ddot{x}$ の係数を総称して、被験者の“ダイナミクスのパラメータ”と呼ぶこととする。前節に示したように学習した個人操作モデルにおいて被験者の最適のダイナミクスをそれぞれ推定する。

4.1.3 操作評価指標

本実験では、被験者が JS によって操作する移動体をランダムに動作するバーに精度良く追従することである。サンプリング時刻 k におけるバーの位置およびバーの速度をそれぞれ $x_r[k]$ とし、現在の移動体との差から、追従位置誤差を算出し、式 (4.2) より求められる。

$$e[k] = x_r[k] - x[k], \quad (4.2)$$


また、追従位置誤差の総和を $\tilde{e}$ とし、式 (4.3) より算出する。

$$\tilde{e} = \sum_{k=0}^N e[k]. \quad (4.3)$$


ここで、 N は 1 試行あたりの総ステップ数とする。

これより、参照点追従を指示された被験者は、操作誤差を最小化するように個人操作モデルの修正を行ったと考えられる。もし被験者が思い通りに操作対象を操ることができる (E が十分小さい) ならば、個人操作モデルが操作対象のダイナミクスに十分近づけているといえる。そこで、本論文では個人操作モデルと操作対象のダイナミクスの誤差と操作パフォーマンス指標に正の相関性を仮定する。すなわち、操作パフォーマンス指標 E を小さくするように、操作対象のダイナミクスのパラメータを修正することにより、結果として操作対象の挙動を被験者のイメージに近づけることができると考えられる。

また、追従位置誤差および追従速度誤差をそれぞれに Fig. 4.1(a) および Fig. 4.1(b) の 3D マップに示す。3D マップの x 軸, y 軸, z 軸はそれぞれは慣性係数, 粘性係数, 追従誤差の大きさを表す。Fig. 4.1 に示したようにより濃い色の箇所は誤差が少ない。



(a) Tracking position error.



(b) Tracking velocity error.


Fig. 4.1: 3D map of tracking error in mass · damper system.

4.2 実験結果


本節では，Bar tracking task において，個人操作モデルの作成実験およびダイナミクスの最適化実験の結果について述べる．

4.2.1 個人操作モデルの作成

全被験者 23 名の個人操作モデルを作成し，Fig. 4.2(a) に示したように被験者の実際の操作とターゲットの動きに差が存在することを確認した．さらに，Fig. 4.2(b) に示すように NN による人間操作の学習および予測にも成功した．



(a) Comparison between operation input and target movement.



(b) Comparison between operator's input and input of individual operation model.

Fig. 4.2: Evaluation experiment of individual operation model.

4.2.2 ダイナミクス最適化

本実験において、 M の領域範囲は 1.0~10.0 となり、 D の領域範囲は 0.1~2.0 という結果となった。そして、個人操作特性に合わせたダイナミクスのパラメータを推定するため、個人操作モデルを用いシミュレーション上で M 、 D を 460 パターンの組み合わせで変化させる。

23 名の被験者に対してそれぞれの最適なダイナミクスのパラメータを Fig. 4.3 に示す。被験者の大部分の M 値は最小値になる場合が多かったため、ダイナミクスのパラメータが最適ではない可能性があると考えられる。そのため、今後の実験では新たな領域範囲での実験を行う必要があると考えられる。




Fig. 4.3: Dynamics optimization.

さらに、個人に合ったダイナミクスのパラメータを用いて再度実験を行い、被験者のアシストなしとアシストありの2回実験に対して、追従位置誤差の検証を行った。Fig. 4.4に示すように被験者23名中17名は最適なダイナミクスのパラメータを導入することにより位置誤差の減少が確認された。予測できなかった原因として、6名の被験者は二回目の実験が別日で行われたためであると推測される。




Fig. 4.4: Validation of tracking position error.

次に、予測できなかった6名の被験者に対して再度同日での実験を行った。Fig. 4.5 に示すように被験者6名の被験者は同日に行った実験において、最適なダイナミクスのパラメータを導入することにより追従位置誤差の減少も確認された。さらに、被験者に対して同日で予測した最適なダイナミクスのパラメータは別日で予測した最適なダイナミクスのパラメータより予測精度が高いことも確認した。

加えて、リアルタイムで被験者に対しての操作を学習および予測をすることにも考慮必要がある。このことより、時間により人間の操作が変化することが判明した。




Fig. 4.5: Time lapse comparison of tracking position error.


第5章 Bar tracking task

第5章において，Bar tracking task を用いて実験を行い，実験手法および実験結果について述べる．


5.1 実験手法

本実験では、被験者は20代男女10名であり、それぞれ市販のJSによる Bar tracking task を用いて実験を行う。NN を用いることで個人の操作をモデル化する。この時、被験者は同一のダイナミクスのパラメータで実験を行う。

予備実験の結果より、推定したダイナミクスのパラメータは最適ではない可能性があること示唆された。そこで本実験では、GF を用いることで、算出された追従位置誤差、追従速度誤差を平滑化し、各被験者の最適なダイナミクスのパラメータの推定精度の向上を図る。GF を用いて、Fig. 5.1(a) および Fig. 5.1(b) の3D マップに被験者の追従位置誤差、追従速度誤差の一例として示す。



(a) Tracking position error.



(b) Tracking velocity error.

Fig. 5.1: 3D map of tracking error in mass · damper system.

5.2 実験結果

本節では，Bar tracking task において，個人操作モデルの作成実験およびダイナミクスの最適化実験の結果について述べる．

5.2.1 個人操作モデルの作成

まず、アシストなしのときの全被験者 10 名の個人操作モデルを作成し、Fig. 5.2 に示す。図に示すように、45 秒間の学習により得られた個人操作モデルが被験者の入力と近似していることを確認した。以上の結果から、NN による人間操作の学習および予測が可能にした。




Fig. 5.2: Comparison between operator's input and input of individual operation model.


5.2.2 ダイナミクスの最適化

本実験において、 M の領域範囲は $0.1 \sim 2.5$ となり、 D の領域範囲は $0.1 \sim 2.5$ に設定した。そして、個人に合った最適なダイナミクスパラメータを検出するため、個人操作モデルを用いシミュレーション上で M および D を 23×23 パターンの組み合わせで変化させた。本論文では、被験者の追従位置、速度誤差が最小となった際のパラメータを最適なダイナミクスのパラメータと定義する。ここで、Fig. 5.3(a) および Fig. 5.3(b) に 10 名の被験者の追従位置、速度誤差が最小となった際のそれぞれのダイナミクスのパラメータを示す。


また、個人に合わせたダイナミクスのパラメータを用いて再度実験を行い、被験者のアシストなしとアシストありの 2 回実験の追従位置誤差、追従速度誤差についての検証を行った。Fig. 5.4(a) および Fig. 5.4(b) に 2 回実験における追従誤差の比較を示す。各被験者個人が最適なダイナミクスのパラメータを導入することにより追従位置誤差、追従速度誤差の減少を確認した。

10 名の被験者の追従位置誤差、追従速度誤差の大きさについて t 検定を行った結果を Fig. 5.5(a) および Fig. 5.5(b) に示す。各被験者個人に最適なダイナミクスのパラメータの導入を可能とした。

以上の結果から、GF を用いた最適なダイナミクスのパラメータの検出精度の向上を確認した。この結果から、最適なダイナミクスのパラメータの導入による各被験者個人の操作パフォーマンスの向上が可能であることを示した。




(a) Plots of position error.




(b) Plots of velocity error.

Fig. 5.3: Dynamics of minimum tracking error.




(a) Tracking position error.




(b) Tracking velocity error.

Fig. 5.4: Validation of tracking error.



(a) Tracking position error.



(b) Tracking velocity error.

Fig. 5.5: Comparison between tracking error.

第6章 Circle tracking task

第6章において，Circle tracking task を用いて実験を行い，実験手法および実験結果について述べる．

6.1 実験手法

先述のよう Bar tracking task では，単純な 1 軸方向の操縦実験を行った．しかし，ダイナミクス最適化実験により，数名の被験者の最適なダイナミクスのパラメータは同じ慣性係数 M となった．そこで，本節では，より複雑な操作タスクとして円軌道追従タスクである Circle tracking task を作成する．実験環境および評価手法について述べる．

6.1.1 実験環境

個人操作特性に合わせたダイナミクスの最適化の有効性を検証するため、2 軸方向に動作する目標マーカの操縦実験を行った。被験者は 20 代男女 12 名とし、それぞれ JS による 2 次元の Circle tracking task を用いて実験を行った。そして、被験者には JS の操作により、目標マーカがランダムに動作するように設定し、操作対象マーカを操縦するよう指示を行う。また、実験前に各被験者には目標マーカが円軌道を描くことを説明する。被験者の操作は常に目標マーカの円軌道の中に操作対象が収まるように指示する。

Circle tracking task において、学習モード (Learning mode) および予測モード (Prediction mode) の 2 つのモードを作成する。学習モードにおいて、被験者による JS の入力を入力値とし、NN を用いることで被験者の操作モデルを作成する。さらに、学習モードにおける操作時間は 60[sec] とした。検証として、予測モードを 20[sec] と設定した。ここで、被験者の操作はすべて不要で、オフライン状態で被験者データの解析を行い、個人操作特性に合わせた最適なダイナミクスのパラメータを推定する。

6.1.2 個人操作モデルの作成

本実験では、個人操作モデルを作成する際に、NN を用いることで個人の操作をモデル化した。このとき、被験者は同一のダイナミクスのパラメータで実験を行った。また、学習時間は 45[sec] に設定し、予測は 15[sec] とする。

6.1.3 ダイナミクスの最適化

本実験では、シミュレーション上で被験者の操作を予測する。被験者は JS の操作を行い、そのときの目標マーカの座標位置を x 軸, y 軸, JS の操作入力量を $\mathbf{u}$ とすると、以下の運動方程式 (6.1) および (6.2) となる。

$$\mathbf{x} = \begin{bmatrix} x \\ y \end{bmatrix}, \quad (6.1)$$

$$\mathbf{u} = \ddot{\mathbf{x}} \begin{bmatrix} M_x & 0 \\ 0 & M_y \end{bmatrix} + \dot{\mathbf{x}} \begin{bmatrix} D_x & 0 \\ 0 & D_y \end{bmatrix}. \quad (6.2)$$

ここで, M_x , D_x , $\dot{x}$, $\ddot{x}$ は, それぞれ可変の x 軸の慣性係数, 粘性係数, 目標マーカの速度, そして目標マーカの加速度である。 M_y , D_y , $\dot{y}$, $\ddot{y}$ は, それぞれ可変の y 軸の慣性係数, 粘性係数, 目標マーカの速度, そして目標マーカの加速度である。

本実験では, M_x , M_y , D_x , D_y の係数を総称して, 被験者の “ダイナミクスのパラメータ” と呼ぶこととする。 前節に示したように学習した個人操作モデルにおいて各被験者個人の最適なダイナミクスのパラメータをそれぞれ推定する。

6.1.4 操作評価指標

本節では、熟達アシスト効果検証用のタスク評価指標について述べる．本実験の目的は、被験者が操作する移動体をランダムに動作する目標マーカに精度良く追従することである．サンプリング時刻 k における目標マーカの座標位置は $X_r[k]$, $Y_r[k]$ とし、現在の移動体との差から、追従位置誤差を算出し、式 (6.3) および式 (6.4) より求めた．同様に、追従速度誤差、追従加速度誤差も算出可能である．

$$e_x[k] = X_r[k] - X_x[k], \quad (6.3)$$

$$e_y[k] = Y_r[k] - Y_y[k]. \quad (6.4)$$

また、 x 軸追従位置誤差の平均、 y 軸追従位置誤差の平均をそれぞれ $\tilde{e}_x$, $\tilde{e}_y$ とし、式 (6.5) および式 (6.6) で算出した．同様に、追従速度誤差の平均、追従加速度誤差の平均も算出可能である．

$$\tilde{e}_x = \frac{1}{k} \sum_{k=0}^N e_x[k], \quad (6.5)$$

$$\tilde{e}_y = \frac{1}{k} \sum_{k=0}^N e_y[k]. \quad (6.6)$$

ここで、 N は1試行あたりの総ステップ数とする．

また、目標マーカ追従を指示された被験者は、操作誤差を最小化するように個人操作モデルの修正を行ったと考えられる．もし被験者が思い通りに操作対象を操ることができる (e が十分小さい) ならば、個人操作モデルにおいて操作対象適切なダイナミクスに十分近づいたといえる．


そこで、本j実験では、個人操作モデルと操作対象のダイナミクスの誤差と操作パフォーマンス指標に正の相関性を仮定する．すなわち、操作パフォーマンス指標を小さくするように、操作対象のダイナミクスのパラメータを修正することにより、結果として操作対象の挙動を被験者のイメージに近づけることができると考えられる．

6.2 実験結果


本節では，Circle tracking task において，個人操作モデルの作成実験およびダイナミクスの最適化実験の結果について述べる．

6.2.1 個人操作モデルの作成

はじめに，アシストなしのときの被験者全員の個人操作モデルを作成した．個人操作モデルの作成の一例として，NNによる学習した被験者の x 軸， y 軸の入力量をそれぞれ Fig. 6.1(a) および Fig. 6.1(b) に示す．0秒から40秒までをNNによって学習し，45秒から60秒は予測のみを行っている．Fig. 6.1に示すように，45秒間の学習により得られた個人操作モデルが被験者の入力と近似していることを確認した．結果より，個人操作モデルを生成できることがわかり，NNによる各被験者の操作を学習および予測が可能であるといえる．



(a) x-axis.



(b) y-axis.

Fig. 6.1: Comparison between operator's input and input of individual operation model.

6.2.2 ダイナミクスの最適化

本実験において M_x , M_y , D_x , D_y は 0.1~2.5 に設定した. 個人の最適なダイナミクスのパラメータは, 個人操作モデルを用いてシミュレーション上で M_x , M_y , D_x , D_y を 0.1~2.5 の範囲で推定した. 被験者の追従位置, 速度誤差が最小となった際のパラメータを最適なダイナミクスのパラメータと定義する. ここで, Fig. 6.2(a) および Fig. 6.2(b) に 12 名の被験者の x 軸, y 軸追従位置誤差および x 軸, y 軸追従速度誤差が最小となった際それぞれのダイナミクスのパラメータを示す.

また, 個人に合わせたダイナミクスのパラメータを用いて再度実験を行った. 被験者のアシストなしおよびアシストあり実験における追従位置誤差, 追従速度誤差を検証し, 二回目実験における各誤差の比較を行った結果を Fig. 6.3(a) および Fig. 6.3(b) に示す. Fig. 6.3 に示したように, 各被験者全員は最適なダイナミクスのパラメータを導入することによる追従位置誤差, 追従速度誤差の減少を確認した.

そして, 12 名の被験者の追従位置誤差値, 追従速度誤差値の大きさについて t 検定を行った結果を Fig. 6.4 に示す. Table. 6.1 に示すように, ダイナミクスの最適化手法によって追従位置誤差の減少を確認した ($p < 0.05$). 同様に, Table. 6.2 に示すように, ダイナミクスの最適化手法によって追従速度誤差の減少を確認した ($p < 0.005$). 各被験者の個人操作特性に合わせた最適なダイナミクスのパラメータの導入を可能にした.


以上より, 本研究で提案したダイナミクスの最適化手法の有効性を検証し, 操作アシストは個人操作パフォーマンスに影響を与えることを確認した.

Table 6.1: Comparison between tracking position error.


	w/o Assist	w/ Assist
Average value	1.722	1.141
SD	1.001	0.539

Table 6.2: Comparison between tracking velocity error.

	w/o Assist	w/ Assist
Average value	2.652	0.794
SD	1.450	0.540




(a) x-axis.




(b) y-axis.

Fig. 6.2: Dynamics parameters of minimum tracking error.




(a) Tracking position error.




(b) Tracking velocity error.

Fig. 6.3: Validation of tracking error.



(a) Tracking position error.



(b) Tracking velocity error.

Fig. 6.4: Comparison between tracking error.

第7章 結論

本稿では，シミュレーション上で個人操作特性にあわせたダイナミクスのパラメータを最適化する手法の提案を行った．これらについてまとめ，本研究における今後の展望について述べる．

7.1 まとめ

本稿では、Bar tracking task および Circle tracking task を作成し、推定されたダイナミクスのパラメータを用いて各被験者の追従誤差に対して検証を行った。また、初心者や高齢者など機械操作や空間認識などが苦手な人の操作熟達効率の向上を目指した。個人操作特性を考慮したアシストをするために、ダイナミクスの最適化手法を提案した。

予備実験では、NN による人間の操作の学習と予測を可能にした。また、人間の操作は時間によって変化していることが判明した。

Bar tracking task において、GF を用いたダイナミクスのパラメータの検出精度の向上を確認した。

Circle tracking task において、被験者の操作熟達による追従軌跡の変化は、はじめに目標マーカの移動軌跡をとらえ、その軌道上に操作対象を乗せたうえで追従をする傾向が見られた。個人ごとに適合できる新たな運転アシストシステムの開発に向け、個人差を考慮したダイナミクスの最適化手法を提案し、実験により提案手法の有効性を示した。実験結果として、NN による個人操作の学習および予測を可能にした。また、Circle tracking task 上で個人操作特性に合わせた最適なダイナミクスのパラメータの検出も可能にした。

以上により、ダイナミクスを最適化することによって熟達アシスト効果があることを示唆された。しかし、ダイナミクスのパラメータを推定する時間は長期になり、今後は処理時間の短縮する必要性が示された。

7.2 今後の展望

今後の展望として、被験者の追従位置誤差、追従速度誤差の両方を考慮し、新たな評価方法での検証実験を行い、被験者の操作量の決定に用いている時系列情報をする必要がある。今後もよりリアルタイム性の高い操作タスクを構築することが判明した。さらに、被験者の人数や年齢層などを拡大し、結果の推移を検証する必要性が明らかとなった。

加えて、操作対象のダイナミクスの変化によって、フォースフィードバックによるアシストのアルゴリズムを作成する必要があると考えられる。短時間で個人のダイナミクスを最適化をすることで、今後の熟達アシストの効率化を目指す。

より幅広い年齢層の人間に操作しやすく、人間と機械の意図対立、機械への不信や過信など自動運転技術の高度化に伴う問題を解決し、自動車のみならず、電動車いす、航空機などにも搭載可能な操作アシストシステムは、さらに幅広い分野での応用が可能であると確信している。

参考文献

- [1] 須田ほか： “自動運転技術の開発動向と技術課題”，情報管理, Vol. 57, No. 11, pp. 809-817, 2015.
- [2] 景山一郎： “ドライバ特性をふまえた車両システムづくりをめざして”，自動車技術会シンポジウムテキスト, No. 06-05, pp. 1-6, 2006.
- [3] 相馬仁： “自動車運転支援システムに関するヒューマンファクタ”，自動車技術会, Vol. 60, No. 10, pp. 10-14, 2006.
- [4] 稲垣敏之： “ヒューマン・マシンシステム -高信頼性が損なう安全性，システム/制御/情報”，41(10), pp. 403-409, 1997.
- [5] 高田裕史ほか： “メンタルモデルに基づく障害物回避時の操舵行動の考察”，自動車技術会学術講演会前刷集, No. 92-03, pp. 11-14, 2003.
- [6] 天野也寸志ほか： “運転行動予測による運転支援システムの構築”，日本機械学会論文集（C 編），70 巻 698 号，2004.
- [7] 面田雄一ほか： “運転技量差に着目した自転車追い抜き時における自動車運転者の走行方法分析”，自動車技術会論文集, Vol. 50, No. 2, pp. 455-460, 2019.
- [8] 三井住友海上火災保険，あいおいニッセイ同和損害保険，インターリスク総研： “自動運転車および公道実証実験に関する消費者の意識調査”，
<http://www.ms-ins.com/news/fy2016/pdf>, 2017/08/01 アクセス.
- [9] 竹原ほか： “操舵行動におけるドライバ個人特性解析に関する研究”，自動車技術会論文集, Vol. 40, No. 3, pp. 899-904, 2009.
- [10] 平松ほか： “自動走行における運転スタイル個人適合手法の提案”，自動車技術会論文集, Vol. 49, No. 4, pp. 818-824, 2018.
- [11] 青柳宗一郎ほか： “個人差を考慮した運転負担推定に基づくドライバーへの情報制御手法”，自動車技術会論文集, Vol. 49, No. 1, pp. 74-81, 2018.

- [12] Hiroshi Igarashi : “Subliminal Calibration for Machine Operation, Journal of Advanced Computational Intelligence and Intelligent Informatics”, Vol. 16, No. 1, pp. 108-116, 2012.
- [13] 五十嵐洋 : “機械操作早期熟達のためのサブリミナルキャリブレーション”, 日本シミュレーション学会 -人と機械をつなぐ視座-, 第 33 巻, 第 2 号, pp. 42-48, 2014.
- [14] Hiroshi Igarashi : “Skill evaluation on tracking task with subliminal calibration and subliminal input filtering”, IECON 2016-42nd Annual Conference of the IEEE Industrial Electronics Society, 2016.
- [15] Deng Zhi-Hui, Zhu Yun-hang : “The Design and Implement of Household Robot Based on Android Platform”, IEEE Workshop on Advanced Research and Technology in Industry Applications (WARTIA) , pp. 449-452, 2014.
- [16] Photchara Ratsamee, Yasushi Mae, Kazuto Kamiyama, Mitsuhiro Horade, Masaru Kojima, and Tatsuo Arai : “Social interactive robot navigation based on human intention analysis from face orientation and human path prediction”, ROBOMECH Journal, 2015.
- [17] Yanan Li, Shuzhi Ge : “Human-Robot Collaboration Based on Motion Intention Estimation”, IEEE/ASME TRANSACTION ON MECHATRONICS, Vol. 19, no. 3, pp. 1007-1014, June 2014.
- [18] Yihuan Zhang, Qin Lin, Jun Wang, Sicco Verwer, and John M. Dolan : “Lane Change Intention Estimation for Car-Following Control in Autonomous Driving”, IEEE TRANSACTION ON INTELLIGENT VEHICLES, Vol. 3, no. 3, pp. 276-286, SEPTEMBER 2018.

本研究に関する発表文献

- [I] 孟子群, 五十嵐 洋: “人間操作モデルを用いたインタフェースのオフライン設計”, 電気学会産業応用部門産業計測制御研究会, IIC-18-021, pp. 19-22, 2018/11/30.
- [II] 孟子群, 五十嵐 洋: “個人操作モデルを用いた操作対象のダイナミクスのオフライン設計 -個人操作特性に合わせたダイナミクスの最適化-”, 日本機械学会ロボティクス・メカトロニクス講演会 '19 (Robomech 2019), 2A2-M04, 2019/06/08.
- [III] 孟子群, 五十嵐 洋: “個人操作特性を考慮した操作対象ダイナミクスの最適化”, 第20回計測自動制御学会システムインテグレーション部門講演会 (SICE SI 2019), 3C2-01, 2019/12/14.