

修 士 論 文

サブリミナルキャリブレーションによる内部モデル
修正支援

Subliminal Calibration for Modifying Operator's Personal
Model

東京電機大学大学院工学研究科

電気電子工学専攻電子光情報コース修士課程

19KMH19 山崎 友輔

研究指導教員 教授 五十嵐 洋

謝 辞

本研究を行うにあたり、五十嵐洋教授（東京電機大学）からは非常に熱心なご指導、ご鞭撻を賜りました。厚く御礼申し上げます。また、和田成夫教授（東京電機大学）には本論文の副査を務めていただき誠にありがとうございました。厚く御礼申し上げます。

加えて、本研究に対して多くの意見やご指導を頂きました協調ロボティクス研究室の皆様に深く感謝いたします。

目 次

第 1 章	緒論	1
1.1	背景	2
1.2	先行研究	3
1.2.1	内部モデル	3
1.2.2	サブリミナルキャリブレーション	4
1.3	本研究の目的	6
第 2 章	任意の機械特性への熟達可能性の検証	7
2.1	実験タスク	8
2.2	操作デバイス	9
2.2.1	仮想モデル追従制御	11
2.2.2	反力推定オブザーバ (RFOB)	12
2.2.3	外乱オブザーバ (DOB)	14
2.3	提案手法	16
2.4	実験内容	17
2.5	実験結果	19
第 3 章	サブリミナルキャリブレーションによる内部モデル制御	22
3.1	実験タスク	23
3.2	操作デバイス	25
3.3	提案手法	27
3.4	実験内容	30
3.5	実験結果	31
第 4 章	機械操作支援に向けたキャリブレーション	33
4.1	提案手法	34
4.2	実験内容	37
4.3	実験結果	38
4.3.1	提案手法を用いなかった場合	38

4.3.2	ソフトウェアダイナミクスを変化させた場合	40
4.3.3	ハードウェアダイナミクスを変化させた場合	42
第 5 章	結論	44
5.1	まとめ	45
5.2	今後の展望	46
	本研究に関する発表文献	48

第1章 緒論

近年，機械操作の自動化やアシスト技術が普及し，操作パフォーマンスの向上や作業の効率化が期待されている．本研究では，人間の操作を熟達させることで効率化，高パフォーマンス化を目指す熟達支援の手法を提案する．本章では，これらの背景とともに本研究の目的を述べる．

1.1 背景

人間の運動はスポーツをはじめ、書字、機械の操作など多岐にわたる。これらを一括すると、運搬や単純作業等の機械が代行可能なものと、娯楽や芸術等の機械で代行できないものに分けられる。前者は自動化、後者はアシストや熟達支援を用いた高効率化、高パフォーマンス化が提案されている。

機械操作支援の分野では様々な自動化や操作アシストの手法が提案されている。中でもカメラを用いた周辺情報の視覚的フィードバックは自動車をはじめとした多くの機械操作に実用化され、パフォーマンスの向上が確認されている。しかし、視覚的フィードバックは人間に与える情報量の増加することによる認知負荷の増大が問題とされており、結果として操作者の集中力の低下が報告されている [1]。

そこで、人間が機械操作の際に無意識的に利用している感覚の一つである力覚の利用が研究されており [2]、作対象に与えられた反力の提示や、目標操作を提示するシステム等の様々なアルゴリズムが提案されている [3]。力覚を利用した操作支援システムでは、システムと人間の操作が競合することによるパフォーマンスの低下や事故の発生が問題とされており、人間の操作を考慮した支援が必要とされている。

この問題に対し、熟達支援の研究は操作する人間自身を熟達させることによってシステムのアシストを必要とせず思い通りの操作を可能とすることを目指している。本研究では五十嵐らの提唱するサブリミナルキャリブレーションに着目し、早期の熟達を可能にする手法を提案する。サブリミナルキャリブレーションでは、人間の認知特性を考慮した気づかれない機械特性の変化を利用することで違和感のないキャリブレーションを実現し、人間の熟達を促進する [4]。

1.2 先行研究

1.2.1 内部モデル

人間は機械操作を行う際、自身の操作に対する機械の応答を予測しながら操作を行う [6]。そして、自身の操作に対する実際の応答を確認し、予測モデルを修正する。この過程を繰り返すことで予測モデルの精度を向上していく。人間はこの予測モデルをもとに操作を行うため、予測モデルの精度が向上することでパフォーマンスも同時に向上する。つまり、人間の機械操作の熟達とは機械の応答を予測するモデルの精度が向上することであるといえる。この予測モデルを内部モデルと呼ぶ。

内部モデルが存在している根拠として、動物の眼球運動の制御においてフィードバック誤差学習が行われていることがニューロンの発火状態の観察によって明らかにされている。また、フィードバック誤差学習モデルを利用したシミュレーションにより同様の制御学習の過程を再現できることが確認されている [7]。

内部モデルを考慮すると、人間の機械操作は Fig. 1.1 のモデルで表される。

本研究では内部モデルの変化に着目した熟達支援を提案する。




Fig. 1.1: Human machine control model .

1.2.2 サブリミナルキャリブレーション


サブリミナルキャリブレーションは五十嵐らの提唱する人間に気づかれないキャリブレーションによって操作者の早期熟達を促進する熟達支援の手法である。サブリミナルキャリブレーションの内部モデルと操作デバイスの変化イメージを Fig. 1.2 に示す。

人間の熟達過程で内部モデルの修正目標である操作デバイスの応答が変化した場合、内部モデルの修正に混乱が生じ、熟達が阻害されてしまう。そこで、サブリミナルキャリブレーションは人間の知覚指標としてウェーバーの法則を利用した人間に気づかないキャリブレーションを行う。ウェーバーの法則では、人間の気づくことのできない刺激変化の大きさ ΔI はもともと与えられている刺激の大きさ I に対して一定の値 σ をとるとされており、以下の式で表される。


$$\sigma = \frac{\Delta I}{I}. \quad (1.1)$$

一般に σ の値は一定とされており、 ΔI を JND(Just Noticeable Difference) と呼ぶ。刺激変化が JND と比較して小さい場合、人間はその変化に気づくことができない。サブリミナルキャリブレーションでは機械特性の変化の大きさが JND よりも小さくなるように制御することで人間に気づかれないキャリブレーションを実現する。

サブリミナルキャリブレーションでは、操作から内部モデルを推定し、最急降下法によって機械特性を内部モデルに修正する。ここで問題となるのが、修正目標とする内部モデルには個人差が大きく、タスクによって人間の熟達過程も異なるため、熟達する機械特性を一意に決定することができない点である。これにより、内部モデルがタスクやデバイスに専用化されてしまう恐れがある [5]。本研究ではこの問題を解決するため、熟達目標とする機械特性を設定した熟達支援手法を提案する。



(a) Natural learning process by human learning ability.



(b) Subliminal calibration without human awareness.

Fig. 1.2: Image Diagram of Subliminal Calibration.

1.3 本研究の目的

本研究では、人間の思い通りの操作を可能とするアシスト手法として熟達支援に着目し、サブリミナルキャリブレーションによる任意の機械特性に対する熟達可能性の検証を目的とする。

また、機械特性の変化に対する人間の内部モデルの応答を確認することで内部モデルをキャリブレーションによって制御し、任意の機械特性に対する早期の熟達を可能とするキャリブレーション手法を提案する。

第2章 任意の機械特性への熟達可能性の検証

本研究ではサブリミナルキャリブレーションによる内部モデルの制御を提案し、任意の機械特性に対する早期な熟達を目指す。本章では、サブリミナルキャリブレーションによる特定機械特性に対する熟達可能性を検証することを目的とした実験の構成、実験結果を述べる。

2.1 実験タスク

本実験では操作パフォーマンスを計測するためのタスクとしてバー追従タスクを構成した。タスク中の画面を Fig. 2.1 に示す。

被験者はランダムに移動する追従目標を操作対象を操作することで追従し、位置および速度の誤差を0にすることを目標とする。操作バーの位置 x は操作デバイスを介した操作入力 u を用いて次式で表される。

$$\dot{x} = A\mathbf{x} + Bu,$$

$$\mathbf{x} = \begin{bmatrix} \dot{x} \\ x \end{bmatrix}, A = \begin{bmatrix} -d_s/m_s & 0 \\ 1 & 0 \end{bmatrix}, B = \begin{bmatrix} g_s/m_s \\ 0 \end{bmatrix}. \quad (2.1)$$

ここで、 m_s , d_s , g_s はそれぞれ慣性係数、粘性係数、操作入力ゲインを示しており、ランダムに移動する追従目標を十分に追従できる値とした。

パフォーマンス評価指標 E は操作対象と追従目標の位置誤差 e および速度誤差 $\dot{e}$ を用いて以下の式で評価を行った。

$$E = e + \dot{e}. \quad (2.2)$$




Fig. 2.1: Bar Tracking Task.

2.2 操作デバイス

本実験の操作デバイスとしてサブリミナルキャリブレーションによって機械特性を変更可能な可変インピーダンスジョイスティックを構成した。本デバイスは日本パルスモーター社製リニアサーボモータ (ghr 15 300 s m3 a3) によって構成されており，サブリミナルキャリブレーションによってインピーダンス制御のパラメータを変更することで熟達を目指す。

リニアサーボモータの制御ブロック図を Fig. 2.2 に示す。

本システムはインピーダンス制御を実現させるための仮想モデル追従制御，被験者の操作入力を推定し，仮想モデルに入力する反力推定オブザーバ (RFOB)，外乱を除去し，制御及び RFOB の精度を向上する外乱オブザーバ (DOB) からなる。




Fig. 2.2: Control Block of Variable Impedance Joystick.

2.2.1 仮想モデル追従制御

仮想モデルは二次系の運動方程式であり，以下の式で表される．

$$\hat{F}^{ext} = J_M \ddot{u}_M + D_M \dot{u}_M + K_M u_M. \quad (2.3)$$

本研究で用いる可変インピーダンスジョイスティックはジョイスティックの動作を模倣しており，操作に対して中心点(入力ゼロ点)に戻す力，摩擦力が仮想的に与えられる．この式を変形すると

$$\ddot{u}_M = J_M^{-1}(F^{ext} - B_M \dot{u}_M - K_M u_M). \quad (2.4)$$

と表すことができ，RFOBを用いて推定した被験者の入力 $\hat{F}^{ext}$ を用いることで仮想モデルの加速度 $\ddot{u}_M$ を計算することが可能となる．得られた加速度をサンプリング時間で二階積分することで仮想モデルの位置 u_M を得ることができる．なお，加速度の計算に用いる位置及び速度は1サンプル前のものを用いる．

仮想モデルの J_M ， D_M ， K_M はそれぞれ質量項，粘性項，ばね項を示しており，これらを総称してダイナミクスと呼ぶ．本実験ではダイナミクスをキャリブレーションすることで操作熟達を検証する．

仮想モデルの追従にはPD制御を用い，モータへの出力指令推力 F^{com} を決定する．PD制御には制御対象と目標値の位置誤差 Δu_{PD} と速度誤差 $\Delta \dot{u}_{PD}$ を用いる．これを式に表すと，

$$F^{com} = K_P \Delta u_{PD} + K_D \Delta \dot{u}_{PD}. \quad (2.5)$$

となる．ここで， K_P ， K_D はそれぞれ比例ゲイン，速度ゲインである．ここでの目標値は仮想モデルであり，制御対象はリニアサーボモータであるため， Δu_{PD} ， $\Delta \dot{u}_{PD}$ はそれぞれ

$$\begin{aligned} \Delta u_{PD} &= u_M - u, \\ \Delta \dot{u}_{PD} &= \dot{u}_M - \dot{u}. \end{aligned} \quad (2.6)$$

と表される．以上により仮想モデル追従制御が行われ，リニアサーボモータの位置 u が追従タスクの操作入力として扱われる．

2.2.2 反力推定オブザーバ (RFOB)

本研究にて用いた反力推定オブザーバ (RFOB) は村上らの提唱するセンサレスでモータにかかる反力を推定するオブザーバである [8]. RFOB のブロック図を Fig. 2.3 に示す.

RFOB および DOB はモータの推定モデルを用いてモータに加わる外力の推定を行う. モータのモデルは以下の式で表される.

$$F^{model} = J_N \ddot{u} + B_N \dot{u}. \quad (2.7)$$

F^{model} はモデルによって推定されたモータの推力を表しており, この値には指令推力 F^{com} と外力 F^{ext} が含まれている.

$$F^{model} = F^{com} + F^{ext}. \quad (2.8)$$

F^{com} は指令推力であり, 既知の値であることから, 上式を変形させることで外力の推定が可能である.

$$\hat{F}^{ext} = F^{com} - F^{model}. \quad (2.9)$$

以上より得た外力を仮想モデルに入力することで仮想モデルの位置を計算する.

ここで問題となるのが, 算出した外力は純粋な人間の加えた入力だけでなく, 外乱やモータモデルの構築の際の誤差が含まれている点である. このため, DOB を導入することでこれらの影響の低減を図る.




Fig. 2.3: RFOB Block.

2.2.3 外乱オブザーバ (DOB)

外乱オブザーバ (DOB) は大西らの提唱する外乱を低減するオブザーバである [9]. 外乱オブザーバのブロック図を Fig. 2.4 に示す. DOB ではモータモデルによって推定された推力と指令推力の差を指令推力に加えることで外力の影響を考慮した入力推力を算出する. 入力推力 F^{DOB} は以下の式で表される.

$$F^{DOB} = F^{com} + (F^{model} - F^{com}). \quad (2.10)$$

DOB を導入することでモータモデルの誤差が RFOB の外力推定に与える悪影響を低減することが可能となり, 高い推定精度を発揮することが可能となる.




Fig. 2.4: DOB Block.

2.3 提案手法

従来のサブリミナルキャリブレーションでは、追従目標と操作対象の追従誤差を内部モデルと機械特性の誤差であると定義し、タスク中の追従誤差が最小化されるように最急降下法によってキャリブレーションする．本実験においてはタスクのパフォーマンス評価指標 E を最小化するようにキャリブレーションを行う．キャリブレーションの式を以下に示す．

$$D_o[t+1] = D_o[t] - \mu \frac{\partial E}{\partial D_o},$$
$$\sigma > \frac{\Delta D_o}{D_o}. \quad (2.11)$$

ここで、 D_o はキャリブレーション対象となる仮想モデルのダイナミクスであり、 μ は重み係数を示している． σ は人間の JND であり、本研究では先行研究より $\sigma = 0.05$ とした．

本実験ではサブリミナルキャリブレーションによってダイナミクス変化を行う前のダイナミクスの初期値を熟達目標の機械特性として熟達可能性を検証する．サブリミナルキャリブレーションによってパフォーマンス評価指標 E が十分に小さくなった後に JND より小さい変化でダイナミクスを初期値にキャリブレーションする．キャリブレーションの式を以下に示す．

$$D_o[t+1] = D_o[t] + \mu \frac{(D_{ref} - D_o[t])}{D_{ref}}. \quad (2.12)$$

ここで、 D_{ref} は熟達目標の機械特性である初期ダイナミクス、 μ は重み係数を表している．本手法でも式 (2.11) と同様に人間の JND によってキャリブレーションの大きさを制限している．

2.4 実験内容

本実験では、サブリミナルキャリブレーションによる特定機械特性に対する熟達可能性を検証することを目的とし、可変インピーダンスジョイスティックを操作デバイスとしたバー追従タスクを構成した。可変インピーダンスジョイスティックの仮想モデルのダイナミクスをサブリミナルキャリブレーションによって変化させることで、目標とする初期ダイナミクスに対する熟達支援を実現する。実験の様子を Fig. 2.5 に示す。

被験者は20代の男性10名とし、キャリブレーションを行わない場合(条件a)、サブリミナルキャリブレーションのみを行い目標ダイナミクスへのキャリブレーションを行わない場合(条件b)、サブリミナルキャリブレーションを用いて目標ダイナミクスへのキャリブレーションに対する熟達支援を行う場合(条件c)の3つの条件についてパフォーマンスの推移を比較した。実験時間を70秒間とし、10秒間を1Termとしてパフォーマンス評価指標 E の累積値をパフォーマンス変化として評価を行う。タスクの最初の10秒間をTerm0とし、キャリブレーションを行わない評価基準時間とした。

Term1 から Term4 の間をサブリミナルキャリブレーションによってダイナミクスを内部モデルに近づける時間とし、条件b、条件cにおいてキャリブレーションを行った。Term5では条件cのみダイナミクスを目標ダイナミクスへキャリブレーションを行い、条件Aおよび条件Bではダイナミクスを操作しなかった。Term6ではすべての条件でキャリブレーションを行わず、熟達効果を評価するためのパフォーマンス計測時間とした。この時、条件cではすべての被験者においてダイナミクスが初期値となっていることが確認された。




Fig. 2.5: Experiment of Bar Tracking Task.

2.5 実験結果

各条件での Term0 における初期パフォーマンスと Term6 における熟達評価パフォーマンスの比較を Fig. 2.6 に示す．図中 w/o は条件 a を示しており，subliminal は条件 b，w が条件 c を示している．3つのグラフについて比較すると条件 b および条件 c におけるパフォーマンス指標の累積値が低下しており，熟達が確認できる．条件 a と条件 c は同じダイナミクス下でのパフォーマンス評価であることから，提案手法によって目標ダイナミクスにおける操作の早期熟達が可能であるといえる．

次に，条件 b と条件 c について term ごとのパフォーマンスの推移を比較した．それぞれのパフォーマンスの推移を Fig. 2.7 に示す．2つの条件について比較すると同じ条件下でキャリブレーションが行われる Term1 から Term4 の区間条件 b においてはキャリブレーションを行わず，条件 c では目標ダイナミクスにキャリブレーションを行う Term5，キャリブレーションを行わないがダイナミクスの異なる環境となる Term6 のいずれにおいてもパフォーマンスの推移に大きな差異は認められなかった．このことから，ダイナミクスを目標ダイナミクスへキャリブレーションすることはパフォーマンスに悪影響を与えていないことが確認できる．内部モデルとダイナミクスのずれがパフォーマンスと等しいと考えると，内部モデルはキャリブレーションによるダイナミクス変化を追従していると言い換えられる．このことから，本実験によって任意の機械特性に対する熟達可能性が示され，内部モデルの制御可能性が示唆された．




Fig. 2.6: Comparison of Proficiency Effects.




Fig. 2.7: Changes in Subject Performance.

第3章 サブリミナルキャリブレーションによる 内部モデル制御

前章の実験にて，サブリミナルキャリブレーションによって任意の機械特性に対する熟達が可能であることが示された．本章では，サブリミナルキャリブレーションを用いた任意の機械特性に対する熟達を早期化する手法を提案する．

3.1 実験タスク

本実験ではタスクに対する熟達を排除し、操作デバイスの機械特性と内部モデルのずれを純粹に評価することを目的として円軌道追従タスクを構築した。タスク画面を Fig. 3.1 に示す。本タスクは前章で構築したバー追従タスクを二次元タスクに拡張したものであり、操作対象の位置 $\mathbf{X}$ を次の式で決定する。

$$\dot{\mathbf{X}} = \mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{u},$$
$$\mathbf{X} = \begin{bmatrix} \dot{x} & \dot{y} \\ x & y \end{bmatrix}, \mathbf{A} = \begin{bmatrix} -b_s/m_s & 0 \\ 1 & 0 \end{bmatrix}, \mathbf{B} = \begin{bmatrix} g_s/m_s \\ 0 \end{bmatrix}. \quad (3.1)$$

被験者は等速で円軌道を描くように移動する追従目標を二軸の可変インピーダンスジョイスティックによる入力で操作対象を操作し、追従する。本タスクでは追従目標が等速で円駆動場を運動するため、目標の動作を予測しやすく、急激な入力の変化も起こらないため、タスクに対する慣熟を原因とする熟達の影響を小さくすることが可能である。これにより内部モデルとダイナミクスの誤差がパフォーマンスに充てる影響が大きくなる考えた。パフォーマンス評価指標 E は追従目標と操作対象の中心座標誤差 e および速度誤差 $\dot{e}$ を用いて以下の式で表される。

$$E = \mu_e \cdot e^2 + \mu_d \cdot \dot{e}^2. \quad (3.2)$$




Fig. 3.1: Circle Tracking Task.

3.2 操作デバイス

操作デバイスには前章で構築した可変インピーダンスジョイスティックを二軸に拡張した可変インピーダンスジョイスティックを使用する．二軸可変インピーダンスジョイスティックを Fig. 3.2 に示す．

二軸可変インピーダンスジョイスティックは前章にて構築した可変インピーダンスジョイスティックの可動子に同様の可変インピーダンスジョイスティックを直交するように配し，シャフトによって上方のリニアサーボモータを支持するように構築した．

上方と下方のリニアサーボモータはそれぞれ独立して制御されており，制御システムは前章にて説明した可変インピーダンスジョイスティックと同様のシステムを持つ．人間の入力を $\hat{\mathbf{F}}^{ext}$ とすると，仮想モデルの位置 $\mathbf{u}_M$ は以下の式で表される．

$$\hat{\mathbf{F}}^{ext} = J_M \ddot{\mathbf{u}}_M + D_M \dot{\mathbf{u}}_M + K_M \mathbf{u}_M. \quad (3.3)$$

これらの仮想モデルが持つダイナミクスは同一の値としており，縦方向と横方向で操作感の差異のない制御を行っている．




Fig. 3.2: Two Axis Variable Impedance Joystick.

3.3 提案手法

本実験ではサブリミナルキャリブレーションによる内部モデル誘導可能性を検証するため、順方向キャリブレーション、逆方向キャリブレーションの二種のキャリブレーションアルゴリズムを提案し、内部モデル変化を比較する。

キャリブレーションする機械特性は前章と同様に仮想モデルのダイナミクスとした。順方向キャリブレーションは評価指標 E を最小化するようダイナミクス D_o をサンプリング時間 t において以下のようにキャリブレーションする。

$$D_o[t+1] = D_o[t] - \mu \frac{\partial E}{\partial D_o}. \quad (3.4)$$

順方向キャリブレーションでは十分な熟達の後、目標とする初期ダイナミクス D_{ref} への熟達を行うため、以下の式でキャリブレーションを行う。

$$D_o[t+1] = D_o[t] + \mu \frac{(D_{ref} - D_o[t])}{D_{ref}}. \quad (3.5)$$

順方向キャリブレーションの内部モデルとダイナミクス変化のイメージを Fig. 3.3 に示す。

本研究では内部モデルとデバイスの機械特性の一致後、人間の内部モデルが機械特性を追従するように変化することを確認している。順方向キャリブレーションではそれを利用して一度ダイナミクスを内部モデルに一致させた後に目標ダイナミクスに誘導する手法をとる。

逆方向キャリブレーションではパフォーマンスを一定にする キャリブレーションを行った。キャリブレーションは以下の式で表される。

$$D_o[t+1] = D_o[t] + (-\mu_r \frac{\partial \dot{E}}{\partial D} + \mu_{ref} \frac{(D_{ref} - D[t])}{D_{ref}}). \quad (3.6)$$

逆方向キャリブレーションでは気づきを防ぐため、重み μ_r と μ_{ref} を用いて緩やかにキャリブレーションの切り替えを行った。本手法でのダイナミクスと内部モデルの変化イメージを Fig. 3.4 に示す。人間は内部モデルと自身の操作から予測されたダイナミクスを比較し、内部モデルの修正を行っているため、内部モデルとダイナミクスの誤差が大きいほど修正も大きくなると推測できる。評価指標 E を操作の誤差とし、内部モデル修正に対する E の減少を阻害することでより大きな内部モデル修正を促す。




Fig. 3.3: Fowared Direction Calibration.




Fig. 3.4: Reverse Direction Calibration.

3.4 実験内容

被験者は20代の男女10名として、実験タスクを50秒間行い、目標との位置誤差 e および速度誤差 $\dot{e}$ の変化を測定した。被験者は順方向キャリブレーションを用いた場合、逆方向キャリブレーションを用いた場合、キャリブレーションを行わない場合の3つの条件のタスクを各1度ずつ、ランダムな順番で行った。

50秒間のタスクを開始から10秒間のsection1、その後の20秒間のsection2、その後の10秒間のsection3、最後の10秒間のsection4に分割し、制御内容を変化させた。順方向キャリブレーション、逆方向キャリブレーションともにsection1およびsection4をパフォーマンス計測時間とし、熟達効果の測定を行う区間とした。順方向キャリブレーションはsection2において(2)式に表されるキャリブレーションを行った後、section3にて(3)式に表される目標ダイナミクスへのキャリブレーションを行った。逆方向キャリブレーションはsection2, section3ともに(4)式によるキャリブレーションを行った。このとき、パフォーマンスが向上しない方向にキャリブレーションを行う重み μ_r はタスク時間に比例して減少し、目標ダイナミクスにキャリブレーションする重み μ_{ref} はタスク時間に比例して大きくなるように制御した。

3.5 実験結果

各手法ごとの section1(initial) と section4(trained) における e , $\dot{e}$ の累積値を Fig. 3.5 に示す. 図中 R_e , $R_{\dot{e}}$ はそれぞれ逆方向キャリブレーションにおける追従位置誤差 e の累積, 追従速度誤差 $\dot{e}$ の累積を示しており, F_e , $F_{\dot{e}}$ はそれぞれ順方向キャリブレーションにおける追従位置誤差 e の累積, 追従速度誤差 $\dot{e}$ の累積を示している. 順方向キャリブレーションと逆方向キャリブレーションを比較すると, 位置誤差については逆方向キャリブレーションが有意に減少しており, 速度誤差については順方向, 逆方向キャリブレーション共に有意な減少を確認した. これらの結果から, サブリミナルキャリブレーションを用いる際, 逆方向キャリブレーションは順方向キャリブレーションと比較して内部モデルの修正量を大きくすることが考えられる.

Fig. 3.6 は逆方向キャリブレーションを行った際の操作を目標ダイナミクス下で行った際のパフォーマンスの推移予測と実際のタスク中のダイナミクス下でのパフォーマンス推移およびキャリブレーションを行わなかった場合のパフォーマンス推移の比較を示している. キャリブレーションを行わなかった場合と目標ダイナミクス下での推移予測は仮想的に同じダイナミクス条件下でのパフォーマンスを示しており, 逆方向キャリブレーションによってパフォーマンスが大きく向上している.

これらをまとめると, 内部モデルと実際のダイナミクスの差が大きいほど人間の内部モデル修正量は大きくなる傾向が見られ, 逆方向キャリブレーションによって内部モデルの変化を誘発することができると考えられる. また, 逆方向キャリブレーションをサブリミナル化することで, 人間の内部モデル修正量がキャリブレーションによるダイナミクス修正量より大きくなり, 結果としてタスク中のパフォーマンスも高めることに成功した.

これらの結果から, 内部モデルと機械特性の誤差が大きいほど内部モデル修正量が大きくなる傾向およびダイナミクス変化を追従するよう内部モデルが変化する傾向が確認できた. このことから, 内部モデルと機械特性の誤差を制御することで内部モデル修正を制御可能であることが示唆された.




Fig. 3.5: Performance Changes.




Fig. 3.6: Performance Changes in Target Dynamics.

第4章 機械操作支援に向けたキャリブレーション

サブリミナルキャリブレーションは変化させる機械特性によって様々なデバイス、タスクに対する熟達支援が可能である。本章では本研究の目的である操作デバイスに対する熟達支援に向けたキャリブレーションを検討する。

4.1 提案手法

本実験では機械操作のアシストを行う際に用いられる視覚的フィードバック、力覚フィードバックに着目し、機械操作支援に向けた熟達支援に有用な機械特性を明らかにする。実験には前章と同様の実験タスクおよび操作デバイスを用いる。

一般的に、機械操作の熟達支援では力覚フィードバックによる操作支援が有効であるとされており、本研究でもキャリブレーション対象として扱ってきたダイナミクスは可変インピーダンスジョイスティックの力覚フィードバックを決定する係数であるといえる。可変インピーダンスジョイスティックのダイナミクスを本実験ではハードウェアダイナミクスと呼称し、次に述べるソフトウェアダイナミクスと区別する。

これに対し、視覚的フィードバックは実装が容易であり、自動車のカメラを用いた周辺情報の提示等の実用事例が多く挙げられる。本実験においてはタスク画面が視覚的フィードバックにあたる。視覚的フィードバックは操作対象の位置 $\mathbf{X}$ を計算する以下の式で決定される。

$$\begin{aligned}\dot{\mathbf{X}} &= \mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{u}, \\ \mathbf{X} &= \begin{bmatrix} \dot{x} & \dot{y} \\ x & y \end{bmatrix}, \mathbf{A} = \begin{bmatrix} -b_s/m_s & 0 \\ 1 & 0 \end{bmatrix}, \mathbf{B} = \begin{bmatrix} g_s/m_s \\ 0 \end{bmatrix}. \end{aligned} \quad (4.1)$$

上式より被験者の操作入力に対する操作対象の応答は m_s , b_s , g_s の3つの係数によって決定されることがわかる。本実験ではこれらの係数をソフトウェアダイナミクスと呼称する。追従目標は円軌道を等速で移動しており、本実験では絶対位置の誤差のみでなく軌跡の追従性度を考慮した評価を行うためにタスク中の操作対象の位置座標を直交座標系から極座標系に変換して評価を行った。パフォーマンス評価指標 E は以下のように定義した。

$$\begin{aligned}E &= \mu_r \Delta r + \mu_t \Delta \theta, \\ \Delta r &= r_o - r_{ref}, \Delta \theta = \theta_o - \theta_{ref}. \end{aligned} \quad (4.2)$$

ここで、 μ_r , μ_t は重み係数であり、追従目標の極座標を (r_{ref}, θ_{ref}) 、操作対象の極座標を (r_o, θ_o) とする。

本実験ではハードウェアダイナミクスおよびソフトウェアダイナミクスを制御することでそれぞれ力覚フィードバック、視覚的フィードバックを用いた熟達支援を可能とする。

ダイナミクス変化には前章で提案した順方向キャリブレーションを利用し，力覚フィードバック時と視覚的フィードバック時の被験者のパフォーマンス推移を比較することでキャリブレーション対象とするパラメータが熟達に与える影響を検証する．本実験におけるタスクのイメージを Fig. 4.1 に示す．




Fig. 4.1: Circular trajectory tracking task.

4.2 実験内容

被験者を 20 代の男女 18 名とし、キャリブレーションを行わない場合、ハードウェアダイナミクスを変化させた場合、ソフトウェアダイナミクスを変化させた場合の 3 条件について実験を行った。

実験時間は 50 秒とし、4 つの section で構成される。section1 はタスクの最初の 10 秒間であり、キャリブレーションを行わず、評価基準とするパフォーマンスの測定を行う。section2 は section1 の後の 20 秒間であり、この間にサブリミナルキャリブレーションによってパフォーマンス評価指標 E 最小化する。section3 は section2 の後の 10 秒間であり、この間にダイナミクスを目標ダイナミクスにキャリブレーションする。section4 は section3 の後の 10 秒間であり、キャリブレーションを行わず、section1 と比較するためのパフォーマンス測定時間とする。section1 および section4 において、ソフトウェアダイナミクスおよびハードウェアダイナミクスは目標機械特性である各ダイナミクスの初期値となっていることが確認された。これにより、各実験条件において同じ環境下でのパフォーマンス測定が可能であり、キャリブレーションするパラメータごとの影響を評価することが可能である。

4.3 実験結果

本実験はパフォーマンスの個人差が大きいタスクであるため、被験者を評価基準におけるパフォーマンスによって高パフォーマンスグループと低パフォーマンスグループの2グループに分割して評価を行った。

4.3.1 提案手法を用いなかった場合

提案手法を用いなかった場合のパフォーマンス測定時の誤差累積の変化を Fig. 4.2 に示す。 H_r , H_θ , L_r , L_θ はそれぞれ高パフォーマンスグループの Δr , $\Delta\theta$ 低パフォーマンスグループの Δr , $\Delta\theta$ の累積値を平均したものである。

高パフォーマンスグループの誤差は r , θ 共に訓練後に増加する傾向が見られた。この傾向は以前に次元バー追従タスクで検証した際にも同じような結果であった。原因として等速で同じ軌道を描くタスクであるために集中力が低下してしまったことが考えられる。

低パフォーマンスグループの誤差は r , θ 共にパフォーマンスの向上が見られた。さらに、 r では誤差が30%ほど減少し、 $p = 0.0585$ の有意傾向が見られた。また、 θ では誤差が60%ほど減少し、 $p = 0.0457$ の有意な差を確認した。

アシストを行わない場合には低パフォーマンスグループでは明確な操作パフォーマンス向上が見られるが、高パフォーマンスグループでは有意な差はみられなかったが、長時間の操作がパフォーマンス低下を引き起こしてしまう可能性が示唆された。




Fig. 4.2: Total error without proposed method.

4.3.2 ソフトウェアダイナミクスを変化させた場合

ソフトウェアダイナミクスに対してサブリミナルキャリブレーションを用いた場合のパフォーマンス測定時の誤差累積の変化を Fig. 4.3 に示す.

高パフォーマンスグループの誤差は r では 20%ほど減少し, $p=0.0642$ の有意傾向が見られた. θ 訓練後に誤差が増加する傾向が見られたが有意な差は確認されなかった. 低パフォーマンスグループの誤差は r , θ 共にパフォーマンスの向上が見られた. r では誤差が 40%ほど減少し, $p = 0.0310$ の有意差が確認された. θ では誤差が 20 %ほど減少し, $p = 0.0622$ の有意傾向が見られた.

提案手法によってソフトウェアダイナミクスを変化させた場合, 高パフォーマンスグループ低パフォーマンスグループ共に r の誤差が小さくなる効果が示された. これはソフトウェアダイナミクスの変化を用いることで操作者が目標軌道を遅れてなぞるような操作の熟達を促進可能であるといえる.




Fig. 4.3: Total error with software dynamics.

4.3.3 ハードウェアダイナミクスを変化させた場合

ハードウェアダイナミクスに対してサブリミナルキャリブレーションを用いた場合のパフォーマンス測定時の誤差累積の変化を Fig. 4.4 に示す.

高パフォーマンスグループ, 低パフォーマンスグループそれぞれの r , θ すべての場合で誤差の減少が確認されたが, 最も大きく誤差が減少した低パフォーマンスグループの θ においても $p = 0.162$ と有意な差は得られなかった.

また, 低パフォーマンスグループ, 高パフォーマンスグループ共に訓練前後の誤差減少率はダイナミクス変化を行わない場合およびソフトウェアダイナミクスを変化させた場合と比較して小さな変化で会った.

しかしながら, アシストを行わなかった場合, ハードウェアダイナミクスを変化させた場合, ソフトウェアダイナミクスを変化させた場合の 3 つの手法で唯一高パフォーマンスグループの θ のパフォーマンスを向上させ, 全てのパフォーマンスにおいて誤差の減少が確認された.




Fig. 4.4: Total error with hardware dynamics.

第5章 結論

本研究では，人間の思い通りの操作を目指し，サブリミナルキャリブレーションに着目した任意の機械特性に対する熟達支援手法を提案した．本章ではこれらについてまとめ，本研究における今後の展望を述べる．

5.1 まとめ

本研究では、任意の機械特性に対する熟達支援を可能とするサブリミナルキャリブレーションの手法の提案を行った。今回はサブリミナルキャリブレーションによる任意の機械特性に対する熟達可能性の検証、任意の機械特性に対する早期熟達を目指した内部モデル誘導の提案、機械操作熟達に向けたキャリブレーション手法の検証を行った。

本研究では最急降下法によって機械特性を内部モデルに近づける手法の問題点として、熟達する機械特性を定めることができず、タスクの専用化が起こることを問題とした。そこで、サブリミナルキャリブレーションによる熟達後に目標機械特性にキャリブレーションを行うことで目標の機械特性に対する熟達が可能であることを確認した。また、機械特性を目標機械特性にキャリブレーションする際、人間の内部モデルが機械特性の変化を追従する様子を確認した。

そこで、任意なダイナミクスに対する熟達をより早期化するため、内部モデルの誘導を提案した。結果として内部モデルと実際のダイナミクスの差が大きいほど人間の内部モデル修正量は大きくなる傾向が見られ、逆方向キャリブレーションの早期熟達に対する有用性が示唆された。

機械操作熟達に向けたキャリブレーションする機械特性の比較では、一般的に機械操作熟達に有用とされる力覚フィードバックの利用は視覚的フィードバックと比較して熟達の効果は小さかった。視覚的フィードバックは初期パフォーマンスの低いグループに対しては特に有効であり、目標軌跡を追従する操作の熟達に有効であることが確認された。

結論として、本研究ではサブリミナルキャリブレーションによる機械特性の変化に起因する操作者の内部モデル変化を確認した。これにより、内部モデル誘導による任意機械特性に対する熟達の早期かが期待できる。

5.2 今後の展望

本研究では、任意の機械特性への早期の熟達を支援する手法として内部モデル誘導を提案した。本研究では人間の内部モデルと実際の機械特性の誤差をタスクにおける追従誤差とみなして内部モデル誘導を行ったが、近年、ニューラルネットワーク (NN) を用いた人間の操作モデルの生成が盛んに研究されており、この技術を用いることで内部モデルをより正確に推定し、キャリブレーションの効果を高めることが可能であると考ええる。

次に、本研究の応用先について述べる。本研究で目的とした任意な機械特性に対する熟達は訓練用デバイスに対して非常に有用であると考ええる。訓練用デバイス上で実際のデバイスの機械特性を目標機械特性として提案手法を用いることで、実際のデバイスを使用する前に内部モデルを構築することができ、操作ミスの問題の減少や、自動化やアシストとい行ったシステムを必要としない思い通りの操作を可能となる。応用先は機械操作のみでなく、機械特性がシステムによって可変のものであれば楽器の演奏、書字など人間のさまざまな運動に対する熟達支援が可能である。これらの応用先についても、提案手法を利用した際の熟達支援効果の検証を今後行う必要がある。

参考文献

- [1] Marcus Tonniss : “Visual Longitudinal and Lateral Driving Assistance in the Head Up Display of Cars”, 6th IEEE and ACM International Symposium on Mixed and Augmented Reality, 2007.
- [2] “Effects of Grip-Force, Contact, and Acceleration Feedback on a Teleoperated Pick-and-Place Task”, Rebecca P. Khurshid, Naomi T. Fitter, Elizabeth A. Fedalei, Katherine J. Kuchenbecker, IEEE TRANSACTIONS ON HAPTICS, Vol. 10, No. 1, p.40-p.53, January-March 2017
- [3] Xi Chen, Sunil K. Agrawal : “Assisting Versus Repelling Force-Feedback for Learning of a Line Following Task in a Wheelchair ”, IEEE TRANSACTIONS ON NEURAL SYSTEMS AND REHABILITATION ENGINEERING, VOL. 21, NO. 6, NOVEMBER 2013.
- [4] 五十嵐洋 : “械操作早期熟達のためのサブリミナルキャリブレーション ”, シミュレーション学会誌, 第 33 巻, 第 2 号, pp. 120-126, 2014.
- [5] 佐藤知正 : “協働ロボット (コボット) が拓く生産と生活の革新”, 横幹, Vol. 9, No. 2, pp. 79-85 2015.
- [6] 川人光男 : “脳の計算理論”, 産業図書, 1996.
- [7] 川人光男 : “脳の運動学習”, 日本ロボット学会誌, Vol. 13, No. 1, pp.11-19 , 1995.
- [8] 村上俊之, 中村亮, 郁方銘, 大西公平 : “反作用推定オブザーバに基づいた多自由度ロボットの力センサレスコンプライアンス制御”, 日本ロボット学会誌, Vol. 11, No. 5, pp. 765-768, 1993
- [9] 大西公平 : “外乱オブザーバによるロバスト・モーションコントロール”, 日本ロボット学会誌, Vol. 11, No. 4, pp. 486-493, 1993

本研究に関する発表文献

- [a] 山崎 友輔, 五十嵐 洋: “サブリミナルキャリブレーションによる汎用デバイス操作”, 日本機械学会ロボティクス・メカトロニクス講演会 2019, 2P1-L02, 2019/6/07.
- [b] 山崎 友輔, 五十嵐 洋: “サブリミナルキャリブレーションによる力覚提示を用いた熟達支援”, ヒューマンインターフェースシンポジウム 2019, 5C3-3, pp. 784-789, 2019/9/5.
- [c] 山崎 友輔, 五十嵐 洋: “人間が持つ機会挙動予測モデルの修正による熟達支援”, IIP2020 情報・知能・精密機器部門 (IIP 部門) 講演会, No. 20-8, 2020/03/26-27.
- [d] 山崎 友輔, 五十嵐 洋: “サブリミナルキャリブレーションによる内部モデル修正支援”, 日本機械学会ロボティクス・メカトロニクス講演会 2020, 2A1-C12, 2020/05/27-29.