

修 士 論 文

「空気を読める」アーキテクチャに基づく可変アドミッタンスによる操作支援

Proposal of STA Architecture to Assist Human Manipulation
using Variable Admittance Control

東京電機大学大学院工学研究科
電子システム工学専攻修士課程
21KMH01 井上 温
研究指導教員 教授 五十嵐 洋

謝 辞

本研究を行うにあたり,五十嵐洋教授(東京電機大学)からは非常に熱心なご指導,ご鞭撻を賜りました.厚く御礼申し上げます.また,和田成夫教授(東京電機大学)には本論文の副査を務めていただき誠にありがとうございました.厚く御礼申し上げます.協調ロボティクス研究室 OB の皆様には,研究議論を夜を徹して行い,論文の投稿が迫る中で非常に有意義な助言を頂きました.大変感謝しております.最後に,度重なる実験にご協力頂き,日々の研究生活において切磋琢磨した協調ロボティクス研究室の皆様,本研究に有形無形のご援助くださった全ての方々に感謝いたします.

目次

第1章 緒論	1
1.1 背景	2
1.2 関連研究	3
1.2.1 インピーダンス制御	3
1.2.2 可変アドミッタンス制御を用いた操作支援	4
1.2.3 Human Adaptive Mechatronics	6
1.3 「空気を読む」システムアーキテクチャ	8
1.3.1 ヒューマンセンシング	9
1.3.2 ヒューマンモデリング	10
1.3.3 動作生成	11
1.4 本研究の目的	12
第2章 実験プラットフォーム	13
2.1 入力インタフェース	14
2.2 コントローラ	16
2.3 HMD	18
2.4 実験タスク	19
第3章 制御手法	20
3.1 DOB and RFOB	21
3.2 加速度制御による仮想機械インピーダンス制御	22
3.3 可変アドミッタンス制御	23
第4章 実験1 可変アドミッタンス制御時のリアルタイム学習における人間モデル パラメータの検討	24
4.1 使用フレームワークおよびネットワーク	25
4.2 データセット生成	26
4.3 人間モデル生成に向けたハイパーパラメータ最適化	27
4.4 人間モデル生成に向けたハイパーパラメータ最適化結果	30
第5章 実験2 インピーダンスパラメータに対する操作特性の調査	34
5.1 実験目的と実験条件	35

5.2	実験結果	36
第 6 章	実験 3 STA アーキテクチャによる可変アドミッタンス制御	39
6.1	STA アーキテクチャによる可変アドミッタンス制御に向けた条件設定 . .	40
6.1.1	実験内容	42
6.1.2	実験結果	43
6.2	固有振動数に対する人間モデルの妥当性	45
6.3	学習済み人間モデルによる制御検証	46
第 7 章	結論	47
第 8 章	今後の展望	49
	本研究に関する発表文献	52
	その他の発表文献	53

第1章 緒論

本研究では，人間機械間の協調について，人間モデルを用いた機械からヒトへの協調操作支援を行う．本章では，以下の項目を述べる．

1.1	背景	2
1.2	関連研究	3
1.2.1	インピーダンス制御	3
1.2.2	可変アドミッタンス制御を用いた操作支援	4
1.2.3	Human Adaptive Mechatronics	6
1.3	「空気を読める」システムアーキテクチャ	8
1.3.1	ヒューマンセンシング	9
1.3.2	ヒューマンモデリング	10
1.3.3	動作生成	11
1.4	本研究の目的	12

1.1 背景

近年、日本における高齢者の割合は少子高齢化の影響により増加傾向であり、2060年には65歳以上の高齢者人口割合が約40%まで増加すると言われている[1]。加えて、若手作業員の減少によって作業員の平均年齢が高齢化していることが問題視されている。このため、システムの自動化やヒトの操作をアシストすることが求められている。機械の自動化として、ヒトの代替を目指し、ティーチングによる作業の自動化などが行われている。例えば、工場では工作機械の自動化からはじまり、産業用ロボットを用いた自動化が進んでいる。プロセスを自動化することで、規範動作においてヒトの代替が可能となる。しかしながら、ヒトの持つ柔軟で繊細な動作や熟練者による勘所を再現することは困難である。

そのため、ヒューマンインタフェースを利用した人間機械間協調が研究されている。例えば、Medicaroid社のHitonoriなどの手術支援機器[2]や、協働ロボットなどが用いられている。これらの機器は、機械の持つ特性とヒトの持つ特性との融合を目指している。ヒトと機械の協調において、決まったタスクにフォーカスした操作支援システムでは、フォースフィードバック制御を用いた操作支援が有効である。一方、人間の持つスキルや直感、適応力などが必要とされるタスクにおいては、ヒトの意図の変化や環境の変化に適応可能な操作支援システムが必要となる。

1.2 関連研究

人間の持つスキルや直感，適応力などが必要とされるタスクでは，ヒトの意図の変化や環境の変化に適応可能な操作支援システムが必要となる．本節ではヒトと機械の協働に向けた制御技術について議論を行う．

1.2.1 インピーダンス制御

ヒトと機械との協働には，ヒトの操作に適したインピーダンスパラメータを決定することが重要であるといわれている．インピーダンスモデルは，

$$\boldsymbol{f} = \boldsymbol{m}\ddot{\boldsymbol{x}} + \boldsymbol{d}\dot{\boldsymbol{x}} + \boldsymbol{k}\boldsymbol{x} \quad (1.1)$$

で表される．ただし， $\boldsymbol{f}$ は力ベクトル， $\boldsymbol{x}$ は位置ベクトル， $\boldsymbol{m}$ は質量係数， $\boldsymbol{d}$ はダンピング係数， $\boldsymbol{k}$ はバネ係数である．池浦らは，ヒト-ヒト間協調におけるヒトの特性をインピーダンスパラメータを近似し，このパラメータを機械に適用して協調実験を行うことで，人間機械間協調においてダンピング項が最も重要になると示した [3]．これによって，機械に人間の反応を模倣させることが可能であると示唆されている．孟らは，個人操作特性を考慮したインピーダンスパラメータ最適化のために，個人操作モデルをニューラルネットワーク（Neural Network: NN）を用いて生成し，そのモデルを用いてシミュレーションによるインピーダンスパラメータ最適化を行った [4]．しかしながら，個人操作モデルの生成に用いるタスク環境のインピーダンスパラメータは一定値であり，初期インピーダンスパラメータに対する依存性は考慮していない．適切なダンピング係数は実行するタスクや機械と協調するヒトによって異なるため，状況に応じてインピーダンスパラメータを最適化することが必要となる．

1.2.2 可変アドミッタンス制御を用いた操作支援

ヒトと機械との協働には，ヒトの操作に適したインピーダンスパラメータを決定することが重要であるといわれている．そこで，Fig.1.1 に示すように，インピーダンスパラメータをタスクの状況などに応じて変化させる，可変アドミッタンス制御を用いた操作支援が数多く研究されてきた．

可変アドミッタンス制御では，仮想ダンピング係数，仮想質量係数，もしくはその両方を調整する．これらのインピーダンスパラメータを調整するために，ヒトの意図を定義する必要がある．

Duchaine らは，仮想ダンパの調整を主とし，ヒトの直感的な操作を改善した [5]．この研究では，Fig.1.2 に示すように力の微分と速度を用いて意図を定義し，インピーダンスパラメータとの関連付けを行った．

一方，Wang らは，軌道と移動方向を Long Short-Term Memory: LSTM を用いて学習し，人間の動きを予測した [6]．予測した軌跡をもとに，進行方向へのダンピング係数を減少する可変アドミッタンス制御を実現している．しかしながら，モデルはオフラインで事前にオフラインで学習する必要がある，短期的な予測は可能であるもののヒトの熟達による変化に対応することはできない．




Fig. 1.1: Block diagram of basic variable admittance control.






Fig. 1.2: Interpretation of the time derivative of the force[5].

1.2.3 Human Adaptive Mechatronics

前述の通り、ヒトが必要となるシステムは数多くある。ここで、機械操作に対して行われるヒトの熟達に着目した研究が行われている。ヒトの操作パフォーマンスは操作スキルの熟達や好みによって左右される。これは時系列的に変化し、静的ではない。そのため、Human Adaptive Mechatronics: HAM が提唱された [7]–[9]。Fig.1.3(a) に示す従来のシステムでは、ヒトが機械の動特性を学習し、内部モデル [10] を更新することで制御を行う。これに対し、Fig.1.3(b) に示す HAM ではヒトのスキルを常に機械側が同定し、スキルに合わせて機械特性を変化することでヒトの操作を支援する。機械側がヒトのスキルに寄り添うことで、人間機械系システムの操作パフォーマンスを引き上げることが可能となる。ここで、ヒトのスキルを評価するコントローラが必要となる。コントローラの設計は数多くの研究が行われ、スキル適応制御 [11] やサブリミナルキャリブレーション [12] などがある。



(a) Previous Human-Machine system




(b) HAM system


Fig. 1.3: Comparison of previous human-machine system and HAM system[8].

1.3 「空気を読める」システムアーキテクチャ

人間機械間協調において、ヒューマンセンシング (Human-Machine System: HMS) による操作意図の推定やスキル評価を取り入れたシステム設計が数多く提案されている。しかしながら、これらの多くはシステムによるアシストに対するヒトの反応について考慮されていない。そのため、タスクに対してパフォーマンスを向上するアシストであれ、機械とヒトとの間で齟齬が生じ、機械側が空気を読めない状態が発生する。五十嵐は「空気を読む」を工学的に扱うため、「空気を読める」システムアーキテクチャ (Sensing The Atmosphere: STA) を提案した [13]。本節では、「空気を読める」システムアーキテクチャの構成について述べる。STA アーキテクチャでは、Fig.1.4 ヒューマンセンシングによる従来の HMS に加え、リアルタイムなヒューマンモデルの生成、モデル予測値に基づく動作生成によって構成される。



(a) Architecture of conventional human-machine systems.



(b) Architecture of proposed system with STA.

Fig. 1.4: Architecture to Sense The Atmosphere: STA.

1.3.1 ヒューマンセンシング

ヒトの状態を観測するために、生体信号計測や力センシング、画像処理などが行われている。ここで、観測対象となる時変な要因は主にフィジカル要因とメンタル要因に大別される。フィジカル要因を用いた観測として、ヒトの身体的な動作である眼球運動を用いた注意視野推定 [14] や筋電、力情報を用いた意図推定 [5] が挙げられる。メンタル要因として、脳波を用いた感性推定 [15] や心拍を用いたストレス計測 [16] が挙げられる。

これらの一部を用いたヒューマンセンシングによって、従来の操作支援が設計されてきた。しかし、これらの操作支援はそのセンシングした現在時間の状態を用いており、その状態に対して行う操作支援に対してヒトがどのような影響を与えるかは考慮されていない。

さらに、ヒトの状態は時時刻刻と変化するため、機械とヒトとの間で齟齬が生じ、機械側が空気を読めない状態が発生する可能性がある。

1.3.2 ヒューマンモデリング

ヒューマンセンシングで計測したヒトの状態を用いてヒューマンモデルを構築することで、ヒトの未来の状態を予測する．これにより、操作支援などの機械からのアプローチによるヒトに対する影響を観測することが可能となる．モデルはFig.1.5に示すようにデータを取得して生成する．ヒューマンモデルの入力には、ヒューマンセンシングにて計測した人間の様子 $u_h[k-T]$ 、ヒトへのフィードバック情報 $u_b[k-T]$ 、システムの動作指令値 $u_m[k-T]$ を用いる．教示には現在の人間の様子 $u_h[k]$ を用いる．ただし、 k は予測対象ステップ、 T は過去サンプリングステップである．これをリアルタイムに学習することで、疲労などヒトの特性の変化に適応したヒューマンモデルの生成を行う．




Fig. 1.5: Block diagrams of the human model.

1.3.3 動作生成

ヒトの様子 $\mathbf{u}_h$ が出力できるヒューマンモデルは、そのヒトのコピーと捉えることができるため、システムによるアシストを与えた際に、そのアシストにヒトがどのように反応するかを予測することができる。予測したヒトの様子 $\hat{\mathbf{u}}_h$ に対する評価関数 $\mathbf{J}$ を、

$$\mathbf{J} = f^{STA}(\hat{\mathbf{u}}_h[k]) \quad (1.2)$$

と定義する。そして、最急降下法を用いてこの評価関数 $\mathbf{J}$ を最小化するフィードバック指令値 $\mathbf{u}_b$, $\mathbf{u}_m$ を決定する。

$$\mathbf{u}_b[k] = \mathbf{u}_b[k-1] - \mu_b \frac{\partial J[k]}{\partial \mathbf{u}_b[k]} \quad (1.3)$$

$$\mathbf{u}_m[k] = \mathbf{u}_m[k-1] - \mu_m \frac{\partial J[k]}{\partial \mathbf{u}_m[k]} \quad (1.4)$$

ただし、 μ_b , μ_m はタスクに応じた正の重み係数である。

これをリアルタイムに行うことにより、ヒトの応答を用いた「空気を読んだ」動作生成を可能とする。

1.4 本研究の目的

本研究では、人間機械協調における機械からのアプローチによるヒトに対する影響に着目し、「空気の読める」システムアーキテクチャによる機械操作支援を提案し、その応用可能性の検証を目的とする。また、機械インピーダンスが変化する環境における人間モデルの生成可能性について検証し、操作特性のモデル化が可能か検討を行う。

第2章 実験プラットフォーム

本章では，本研究で用いた実験環境について詳細に述べる．

2.1	入力インターフェース	14
2.2	コントローラ	16
2.3	HMD	18
2.4	実験タスク	19

2.1 入力インタフェース

ヒトが操作する入力インタフェースの外観を Fig.2.1 に示す．インタフェースは Table 2.1 に示す2つのリニアアクチュエータとマイクロコントローラ（マイコン）、D/A ボード、ヘッドマウントディスプレイ (Head-Mount Display: HMD)、コンピュータによって構成される．コンピュータ-マイコン間、コンピュータ-HMD 間は UDP/IP 通信によって接続される．操作者は立位姿勢にて上段に拘束された把持対象を握ることで操作を行う．

入力インタフェースに用いたリニアアクチュエータの仕様を Table 2.1 に示す．2つのリニアアクチュエータは交差するように設置し、リニアシャフトを用いて支持した．これによって、ヒトにフォースフィードバックを行う．本モータが駆動可能な瞬間最大推力は 90 N であり、瞬時最大電流は 2.7 A である．ただし、本研究では最大出力は 66 N、最大電流は 2.0 A に制限した．

また、M 系列信号を用いたシステム同定 [17] により、使用したモータのノミナル値は Table 2.3 に示す通りになった．




Fig. 2.1: 2-DoF Variable impedance actuator.

Table 2.1: Specifications.

Parts	Specification
Motor	GHR GHR-15-300-S-M3-A3
Motor driver	Panasonic MINAS A5L MADHT1105L01
Micro controller	STMicroelectronics NUCLEO-F767ZI
A/D Converter	Analog Devices AD5754R 16bit

Table 2.2: Linear actuator specifications.

Parameters	Specifications
Stroke length	300 mm
Rated thrust	17 N
Instantaneous maximum thrust	90 N
Stroke length	300 mm
Rated current	0.51 Arms
Instantaneous maximum current	2.7 Arms
Encoder resolution	1 μ m

Table 2.3: Nominal parameters.

Motor	Nominal mass	Nominal damping
lower	5.4915 kg	2.5102 N/(m/s)
upper	1.1387 kg	8.8656 N/(m/s)

2.2 コントローラ

コントローラは、制御を行うコンピュータ、モータドライバへの指令やエンコーダからの出力から位置を計算するマイクロコントローラ、モータを駆動するモータドライバによって構成した。

マイクロコントローラには Fig.2.2 に示す STMicroelectronics NUCLEO-F767ZI を用いた。これに加え、Fig.2.3 に示す Analog Devices 社の AD5754 D/A コンバータを搭載した DAC-HAT を用いることで、高精度なエンコータ値の読み込みを行った。

コンピュータは、機械学習を用いた演算に加え、高速な処理が可能な制御マシンとして Table 2.4 に示す構成とした。制御フレームワークとして Advanced Robot Control System V6(ARCS6) を使用した。

モータドライバは、Fig.2.4 に示す Panasonic 社の MINAS A5L を用いた。これは最大出力が 10 A であり、リニアアクチュエータを十分に駆動できる。また、本モータドライバはトルク制御が可能であるため、後述する制御手法を実装することができる。




Fig. 2.2: NUCLEO-F767ZI




Fig. 2.3: DAC-HAT



Fig. 2.4: Panasonic MINAS A5L motor driver

Table 2.4: Computer specifications.	
Parts	Specification
CPU	Intel i9-12900K 16 Core 24 Thread 5.2 GHz
Memory	128GB DDR4 3200 MHz
GPU	NVidia RTX3090 GDDR6X 24 GB

2.3 HMD

被験者は Fig.2.5 に示す HMD を装着し，仮想空間内で作業を行う．本研究では Meta 社 Meta Quest 2 を用いた．これは 1832×1080 /eye の解像度を持ち，リフレッシュレートは 90 Hz である．内蔵されたカメラを用いたハンドトラッキング機能を用い，被験者の手を仮想空間上に表示することで作業上の違和感を減らした．



(a) Front view.



(b) Top view.

Fig. 2.5: Meta Quest 2.

2.4 実験タスク

Fig.2.6 に実験タスクを示す．目標位置 $\mathbf{x}_{disp}^{ref} = [x_{disp}^{ref}, y_{disp}^{ref}]^T$ は円軌道，もしくは正葉曲線軌道を描く．円軌道の時，

$$\mathbf{x}_{disp}^{ref} = g_{disp} \begin{bmatrix} \cos(2\pi t/T_{disp}) \\ \sin(2\pi t/T_{disp}) \end{bmatrix} \quad (2.1)$$

でサンプリング時間ごとに移動する．また，正葉曲線軌道の時，

$$\mathbf{x}_{disp}^{ref} = g_{disp} \sin(4\pi t/T_{disp}) \begin{bmatrix} \cos(2\pi t/T_{disp}) \\ \sin(2\pi t/T_{disp}) \end{bmatrix} \quad (2.2)$$

でサンプリング時間ごとに移動する．ただし， g_{disp} はリニアアクチュエータの可動範囲に調整する正のゲイン， T_{disp} は目標軌道 1 周にかかる時間であり，本研究では円軌道の時 $g_{disp} = 0.1, T_{disp} = 3\text{ s}$ ，正葉曲線の時 $g_{disp} = 0.15, T_{disp} = 7\text{ s}$ とした．




Fig. 2.6: Task Overview.

第3章 制御手法

本章では，本研究で用いた制御手法について詳細に述べる．

3.1	DOB and RFOB	21
3.2	加速度制御による仮想機械インピーダンス制御	22
3.3	可変アドミッタンス制御	23

3.1 DOB and RFOB

本研究では、ヒトの操作する力を測定するために反力推定オブザーバ（Reaction Force OBServer: RFOB）[18] により反力を推定する．モータに入力される反力にはヒトの操作入力に加え，環境外乱などの多くの外乱が含まれる．そのため，外乱オブザーバ（Disturbance OBServer: DOB）[19] を用いることで外乱を推定することで制御ループ内から外乱を除去し，RFOBを用いてヒトの反力 F^h を推定する．

DOBとRFOBのブロック図をFig.3.1に示す．外乱 F_{dis} を推定することで $\hat{F}^{dis}$ を算出し，フィードバックループを構成することでロバストな制御を構築する．DOBによって外乱を除去した制御ループ内において，外乱から更に摩擦力 $\hat{F}^{frc}$ を差し引くことで，反力 $\hat{F}^{est}$ のみを推定することが可能となる．ここで， x は位置， I は電流， F は力， M_* は質量項， K_F は推力定数， g_* は遮断周波数， I^{cmp} は補償電流， $*_n$ はノミナル値， $*_{DOB}$ はDOBに用いる変数 $*_{RFOB}$ はRFOBに用いる変数を示す．




Fig. 3.1: Block diagram of DOB and RFOB

3.2 加速度制御による仮想機械インピーダンス制御

仮想的なモータを見立てたとき、力 $\hat{F}^{ext}$ に対してモータが取るべき位置 x^{ref} 、速度 $\dot{x}^{ref}$ 、加速度 $\ddot{x}^{ref}$ は、

$$\hat{F}^{ext}(s) = M_v \ddot{x}_v^{ref}(s) + D_v \dot{x}_v^{ref}(s) + K_v x_v^{ref}(s), \quad (3.1)$$

よりそれぞれ、

$$x_v^{ref}(s) = \frac{\hat{F}^{ext}(s) - (D_v/s + K_v/s^2)x_v^{ref}(s)}{M_v} \times \frac{1}{s^2}, \quad (3.2)$$

$$\dot{x}_v^{ref}(s) = \frac{\hat{F}^{ext}(s) - (D_v/s + K_v/s^2)x_v^{ref}(s)}{M_v} \times \frac{1}{s}, \quad (3.3)$$

$$\ddot{x}_v^{ref}(s) = \frac{\hat{F}^{ext}(s) - (D_v/s + K_v/s^2)x_v^{ref}(s)}{M_v}, \quad (3.4)$$

で求まる．ただし、 M_v は仮想的な質量、 D_v は仮想的な粘性係数、 K_v は仮想的なバネ定数である．この指令に対し追従するように軌道追従させることによって、仮想機械インピーダンス制御を達成する．

加速度制御による仮想機械インピーダンス制御のブロック図を Fig.3.2 に示す．ここで、 K_1 、 K_2 は加速度制御に用いる位置ゲイン、速度ゲインである．




Fig. 3.2: Acceleration control based virtual impedance control

3.3 可変アドミッタンス制御

前述した仮想機械インピーダンスを制御することにより、任意のダイナミクスを持つモータを構成することができる。本研究では、STA アーキテクチャを用いた可変アドミッタンス制御を行い、 M_v , D_v , K_v を制御する。STA アーキテクチャを用いた可変アドミッタンス制御のブロック図を Fig.3.3 に示す。ここで、各アドミッタンスパラメータはバネ定数 K_v を一定としたとき、固有振動数 ω_n によって一意に決定することができる。

$$M_v = \frac{K_v}{\omega_n^2} \quad (3.5)$$

$$D_v = 2\sqrt{M_v K_v} \quad (3.6)$$

$$D_v = D_v^c \quad (3.7)$$

ただし、 D_v^c は臨界減衰率であり、減衰比 $\zeta = 1$ とする。本研究の STA アーキテクチャを用いた可変アドミッタンス制御では、この固有振動数 ω_n を制御する。




Fig. 3.3: Variable admittance control w/ STA.

第4章 実験1 可変アドミッタンス制御時のリアルタイム学習における人間モデルパラメータの検討

本章では，本研究における人間モデルの生成について，以下の項目を述べる．

4.1	使用フレームワークおよびネットワーク	25
4.2	データセット生成	26
4.3	人間モデル生成に向けたハイパーパラメータ最適化	27
4.4	人間モデル生成に向けたハイパーパラメータ最適化結果	30

4.1 使用フレームワークおよびネットワーク

本研究で使用したプログラミング言語はC++17であり、機械学習フレームワークとして Libtorch を使用した。Libtorch は Pytorch が提供する C++ API であり、リアルタイムな学習に高速な処理速度を必要とするため採用した。

また、ヒトの操作特性は時系列的に表現され则认为、人間モデルには時系列ネットワークである Gated Recurrent Unit(GRU)[20] を使用した。GRU のネットワーク構成を Fig.4.1 に示す。GRU はリセットゲート，更新ゲートで構成される。

更新ゲートでは，新たな記憶割合を調整し，長期記憶の更新割合の重み z_t を生成する。

$$z_t = \sigma(W_z[x_t, h_{t-1}]) \quad (4.1)$$

リセットゲートでは忘却割合を調整し，その重み r_t を生成する。

$$r_t = \sigma(W_r[x_t, h_{t-1}]) \quad (4.2)$$

重み r_t を用いて，長期記憶の更新を行う $\tilde{h}_t$ を生成し， $(1 - z_t) : z$ の比率で h_{t-1} と $\tilde{h}_t$ をそれぞれ重み付けし，長期記憶 h_t を更新する。

$$\tilde{h}_t = \tanh(W_h[x_t, r_t \circ h_{t-1}]) \quad (4.3)$$

$$h_t = (1 - z_t) \circ \tilde{h}_{t-1} + z_t \circ h_t \quad (4.4)$$

ただし， W はパラメータ行列， x_t は入力ベクトルである。

本章では，活性化関数を Relu，最適化関数を adam[21] に設定した。




Fig. 4.1: Gated Recurrent Unit

4.2 データセット生成

モデル生成に必要なパラメータを決定するため、被験者2人に対して実験を行った。実験は円軌道を描くターゲットに対する追従実験とし、72秒間の操作を行った。ダイナミクスは仮想ダンパ D_v のみを5–15 N/m/sの範囲で3秒ごとにランダムに変化させ、その時のデータを取得した。実験データ取得時のブロック図を Fig.4.2 に示す。取得したデータの内12–60 sのデータを学習用とし、60–72 sのデータを検証用とした。ただし、サンプリング周期は1 msである。




Fig. 4.2: Block diagram for collecting experimental data.

4.3 人間モデル生成に向けたハイパーパラメータ最適化

取得したデータを用いて、人間モデルの生成を試みる。人間モデルの生成に用いた NN の構成を Table 4.1 に示す。

エポック数とバッチサイズは、リアルタイムに人間モデルを生成することを考慮し、どちらも 1 とした。Table 4.1 のパラメータは固定とし、人間モデル生成に必要なハイパーパラメータを探索した。設定したハイパーパラメータを Table 4.2 に示す。ここで、遅れステップ T_{del} は NN の出力するステップと最新の入力の間隔の時間差のことを示し、間隔ステップ T_{int} はサンプリングステップに対する間引き量を表す。概要図を Fig.4.3 に示す。また、各ゲインは、各入力に 0-1 の範囲になる範囲の内、最適なゲインを決定するパラメータである。また、本研究では x 軸と y 軸の 2 軸を扱う。これらを 1 つのモデルとして生成できるか、もしくは各軸ごとにモデルを生成する必要があるか検討するため、Table 4.1 の入出力層に 1 軸のみ、もしくは 2 軸を扱うかを含め探索した。

ハイパーパラメータの探索および最適化ツールとして Optuna[22] を用いた。また、最適化アルゴリズムには NSGA-II[23] を用いた。これは進化型多目的最適化アルゴリズムであり、2 つ以上の目的関数のパレート最適解を探索する。目的関数は x 軸の位置のコサイン類似度の最大化、 y 軸の位置のコサイン類似度の最大化の 2 つを設定した。ここで、コサイン類似度を計算する際の位置は、学習した人間モデルの出力 $\hat{F}_h$ によりバーチャルモデルを駆動した結果となる。すなわち、人間モデルが仮想的なモータに対して実際の被験者に使用したターゲットの動きに対してどのような力入力を行ったかを表す。実際の被験者の力入力による位置軌跡と人間モデルの予測した力入力による位置軌跡が近いほど、被験者の操作特性を学習した人間モデルであると解釈した。人間モデル評価時のブロック図を Fig.4.4 に示す。

また、トライアル数は 2000 回以上とした。ただし、コサイン類似度が 0.999 以上となった場合は早期終了するものとした。

Table 4.1: NN settings.

Parameters	Value
Inputs	Position error, Velocity error, Acceleration error, Force, Virtual mass, Virtual damping, Virtual spring
Output	Force
Optimizer	Adam
Activation function	Relu
Epoch	1
Batch size	1

Table 4.2: Optimization parameters.

Parameters	Optimization range
NNs	Single or Double
Hidden dim	1 to 50
Sequence	1 to 20
Delay steps T_{del}	1 to 300 or 200
Interval steps T_{int}	1 to 100
Learning rate	0.0001 to 0.003
Gain of Position error	50 to 80
Gain of Velocity error	1 to 15
Gain of Acceleration error	0.001 to 0.2
Gain of Force error	0.01 to 0.1




Fig. 4.3: Example of dataset parameters.





Fig. 4.4: Block diagram of evaluation for trained human models.

4.4 人間モデル生成に向けたハイパーパラメータ最適化結果


人間モデル生成に向けたハイパーパラメータ最適化を行い、最適化した人間モデルによるバーチャルモデル操作の結果を Fig.4.5 に示す。ただし、(1)–(4) は次の条件時である。

- (1) Two NNs to output x-axis and y-axis (Delay steps = 200)
- (2) Output x-axis and y-axis in a single NN (Delay steps = 200)
- (3) Two NNs to output x-axis and y-axis (Delay steps = Interval steps)
- (4) Output x-axis and y-axis in a single NN (Delay steps = Interval steps)

また、各条件時に最適化した各人間モデルのコサイン類似度を Table 4.3 に示す。また、条件 (4) 時の時系列予測結果を Fig.4.4 に、最適化したパラメータを Table 4.4 に示す。これらの結果から、時系列データの遅れステップ T_{del} と間隔ステップ T_{int} は同一パラメータとして扱い、更に 10 Steps, すなわち 10 ms 程度が良好な予測精度を得ることができることがわかる。遅れステップ T_{del} をヒトの認知の遅れと同一な値として設計する場合においては、間隔ステップ T_{int} を異なる値として任意に決定することは困難であり、人間モデルの生成において依存パラメータとして考察する。また、条件 (4) 時において、良好な予測精度を得ていることから、ダイナミクス変化を含む人間モデルの生成可能性を示唆した。



(a) x axis




(b) y axis


Fig. 4.5: Histogram of positional error(best parameters).

Table 4.3: Tuning results.

Pattern	Cosine Similarity	
	x-axis	y-axis
(1)	0.997	0.992
(2)	0.690	0.833
(3)	0.998	0.996
(4)	0.999	0.999



(a) x axis



(b) y axis

Fig. 4.6: Prediction result between operated by model and by human.

Table 4.4: Best parameters (pattern 4).

Parameters	Optimized values
NNs	Single
Hidden dim	22
Sequence	2
Delay steps T_{del}	10
Interval steps T_{int}	10
Learning rate	0.0005
Gain of Position error	[65, 78]
Gain of Velocity error	[15, 8]
Gain of Acceleration error	[0.1013, 0.0309]
Gain of Force error	[0.1, 0.01]

第5章 実験2 インピーダンスパラメータに対する操作特性の調査

本章では，本研究で使用したインタフェースにおけるインピーダンスパラメータに対する操作特性の調査について，以下の項目を述べる．

5.1	実験目的と実験条件	35
5.2	実験結果	36

5.1 実験目的と実験条件

ヒトの持つ操作特性には個人差がある．本研究では，可変アドミッタンス制御により固有振動数 ω_n を制御するが，ヒトにより最も操作しやすい ω_n は異なる．ここでは，固有振動数 ω_n に対する追従誤差により比較を行う．ここで，追従誤差 e_x は，

$$e_x = \boldsymbol{x}_{disp}^{ref} - \boldsymbol{x} \quad (5.1)$$

で表される．ただし， $\boldsymbol{x} = [x_x, x_y]$ はそれぞれ操作オブジェクトの x 軸の位置，y 軸の位置である．実験タスクは円軌道追従，正葉曲線追従の 2 つを行い，1 周ごとの位置追従誤差 $\tilde{e}_x$ を二乗平均平方根誤差 (Root mean-squared error: RMSE) により，

$$\tilde{e}_x = \sqrt{\frac{1}{N} \sum_{k=0}^N e_x^2[k]} \quad (5.2)$$

で算出した．ここで， N は 1 周あたりのサンプリング数であり，円軌道追従の時 3000，正葉曲線追従の時 7000 である．また，速度 $\dot{\boldsymbol{x}}$ についても同様に算出した．

実験は円軌道追従の時 90 s 間，正葉曲線追従の時 192 s 間行い，それぞれ 26 週の軌道を描かせた．また，固有振動数 ω_n は 4 rad/s から 10 rad/s まで 1 rad/s 刻みで 7 回実験を行った．

5.2 実験結果

20代男子4名に対する円軌道追従時の実験結果を Fig.5.1 に、正葉曲線追従時の結果を Fig.5.2 に示す。実験結果より、被験者毎に個人差があり、最適なインピーダンスパラメータが異なることがわかる。また、正葉曲線追従時において、被験者2の $\omega_n = 7 \text{ rad/s}$ 時における1周毎の位置追従誤差を Fig.5.3 に示す。結果より、1周毎にRMSE値は異なり、タスク終了間際の操作能力の低下は疲労などの要因によると考えられる。

次に、速度追従誤差について検討する。円軌道追従時の実験結果を Fig.5.4 に、正葉曲線追従時の結果を Fig.5.5 に示す。速度追従誤差については位置追従誤差と異なり、 ω_n が小さい、すなわちより重い操作感の状態になるほど誤差が小さくなることがわかる。

これらの結果より、STA アーキテクチャにおいて、位置誤差と速度誤差を用いた評価関数の作成には、目標となる ω_n が異なるため、本研究では位置誤差のみを評価関数に使用することとした。




Fig. 5.1: Comparison of the root mean-square error of the cumulative position tracking at each impedance parameter (Circle tracking task).




Fig. 5.2: Comparison of the root mean-square error of the cumulative position tracking at each impedance parameter(Rose curve tracking task).






Fig. 5.3: Root mean-square error of the cumulative position tracking for each cycle of the task(Subject 2).




(a) x axis




(b) y axis

Fig. 5.4: Comparison of the root mean-square error of the cumulative velocity tracking at each impedance parameter (Circle tracking task).



(a) x axis



(b) y axis

Fig. 5.5: Comparison of the root mean-square error of the cumulative velocity tracking at each impedance parameter (Rose curve tracking task).

第6章 実験3 STA アーキテクチャによる可変アドミッタンス制御

本章では，本研究の提案する STA アーキテクチャによる可変アドミッタンス制御について，以下の項目を述べる．

6.1	STA アーキテクチャによる可変アドミッタンス制御に向けた条件設定	40
6.1.1	実験内容	42
6.1.2	実験結果	43
6.2	固有振動数に対する人間モデルの妥当性	45
6.3	学習済み人間モデルによる制御検証	46

6.1 STA アーキテクチャによる可変アドミッタンス制御に向けた条件設定

本研究では、先行研究である STA アーキテクチャを基に、個人に最適なインピーダンスパラメータに制御する可変アドミッタンス制御を行う。ここで、STA アーキテクチャにおける各パラメータを決定する。

本研究では、ヒューマンセンシングの対象は力 $\mathbf{F}^h$ とする。力には疲労や慣れなど、時刻刻々と変化する要因が含まれる。これをヒトの様子 $\mathbf{u}_h$ とすることで制御を行う。

次に、ヒューマンモデルを考える。ヒューマンモデルには実験 1 と同様に GRU を使用し、活性化関数を Relu, 最適化関数を adam に設定した。ヒューマンモデルはリアルタイムに学習される。タイミング図を Fig.6.1 に示す。インタフェースの制御周期は 1 kHz であり、人間モデルの学習は 500 Hz で実行する。そして、50 Hz で学習したモデルの重みをコピーし、動作生成に用いる予測を行う。

最後に動作生成を考える。リアルタイムに学習を行う人間モデルの入力に対して変化量 $\Delta\omega_n$ を与えることで、 $\Delta\omega_n$ によるヒトの操作特性の変化を予測する。ここで、人間モデルの入力要素となる固有振動数 $\omega_n^\pm$ は $\Delta\omega_n$ により、

$$\omega_n^\pm[k] = \omega_n[k] \pm \Delta\omega_n, \quad (6.1)$$

となる。この変化量を与えた時の $\mathbf{F}_x$ をそれぞれ予測し、仮想インピーダンスモデルを駆動することで、位置の軌道 $\hat{\mathbf{x}}^\pm$ を算出する。予測するサンプリングステップ数を N とした時、予測した $\hat{\mathbf{F}}^h$ に対する評価値 $\mathbf{J}^\pm$ は、

$$\begin{aligned} \mathbf{J}^\pm &= f^{STA}(\hat{\mathbf{u}}_h[k]) \\ &= \frac{1}{N} \sum_{l=k}^N \left(\mathbf{x}_{disp}^{ref}[l] - \hat{\mathbf{x}}^\pm[l] \right)^2, \end{aligned} \quad (6.2)$$

と定義する。そして、最急降下法を用いてこの評価関数 $\mathbf{J}$ を最小化するフィードバック指令値 $\mathbf{u}_m$ を ω_n とし、

$$\omega_n[k] = \omega_n[k-1] - \mu_m \frac{\partial J[k]}{\partial \omega_n[k]} \quad (6.3)$$

$$= \omega_n[k-1] - \mu_m \frac{\mathbf{J}^+[k-1] - \mathbf{J}^-[k-1]}{2\Delta\omega_n}, \quad (6.4)$$

で更新する。




Fig. 6.1: Timing diagram of human model transfer between control threads.

6.1.1 実験内容

提案手法の制御可能性の検証のため、215 秒間の正葉曲線追従作業を行った。はじめの 12 秒間はイニシャライズ、12–75 秒の間は ω_n をランダムに変化することで人間モデルの事前学習を行い、その後 STA を適用した。 ω_n は 3.5–10.5 rad/s で制限した。提案手法における各パラメータは $\Delta\omega = 0.05$ rad, $N = 20$ step, $\mu_m = 30$ とした。人間モデルに用いたパラメータを Table 6.1 に示す。

Table 6.1: NN Settings.

Parameters	values
Hidden dim	22
Sequence	2
Delay steps T_{del}	10
Interval steps T_{int}	10
Learning rate	0.0005
Gain of Position error	[65, 78]
Gain of Velocity error	[15, 8]
Gain of Acceleration error	[0.1013, 0.0309]
Gain of Force error	[0.1, 0.01]
Gain of Natural frequency	[0.1, 0.1]

6.1.2 実験結果

20代男性4名の被験者に対し、実験2にて各 ω_n における位置追従誤差 $\tilde{e}_x$ の中で最良であった時と提案手法による位置追従誤差 $\tilde{e}_x^{STA}$ との比較をFig.6.2に示す。また、被験者1名に対する、提案手法による ω_n のヒストグラムと実験2による各 ω_n に対する操作パフォーマンスをFig.6.3に示す。結果より、提案手法による有効性は見られず、事前実験にて観測した最適な ω_n に対して収束していないことがわかった。




Fig. 6.2: Comparison of the averaged RMSE of the position error with fixed natural frequencies and with STA.




Fig. 6.3: Comparison of histograms of natural frequencies adjusted by the STA and each RMSE when fixed (Subject 2).

6.2 固有振動数に対する人間モデルの妥当性

実験結果より、本実験で構築した人間モデルでは ω_n に対するヒトの変化を予測できていないと考えられる。そこで、実験2にて収集した各 ω_n におけるデータを基に、実験にて使用したパラメータを用いて学習し、人間モデルによる仮想インピーダンスモデルの駆動を行うことで、実データと同様の位置追従誤差 $\tilde{e}_x$ が得られるか確認した。各入力に対するゲインは実験時と同様とし、Epoch 数を100、バッチサイズを8196、学習係数を 1×10^{-5} 、Early stopping の patience は7とした。

学習結果を Fig.6.4 に示す。結果より、十分に学習したモデルにおいても被験者と同様のパフォーマンスを示すことができず、人間モデルの生成に問題があることがわかった。本稿では入力に F_x と ω_n を含めることで、 ω_n の変化によるヒトの操作特性の変化を予測できると仮定したが、入力パラメータやモデルの選択に問題があったといえる。




Fig. 6.4: Compare of normalized position error.

6.3 学習済み人間モデルによる制御検証

静的な固有振動数 ω_n に対するヒトの操作特性と、動的に変化する時の操作特性は異なる可能性がある。そこで、学習した人間モデルに対してリアルタイムに転移学習 (transfer learning: TL) を行うことで操作特性の獲得が可能となると仮定し、実験を行った。比較のため、リアルタイムに転移学習を行わない場合も行った。実験条件は 6.1.1 と同様とした。

実験 2 にて各 ω_n における位置追従誤差 $\bar{e}_x$ の中で最良であった時と提案手法による位置追従誤差 $\bar{e}_x^{STA}$ 、転移学習時、学習済みモデルの読込のみとの比較を Fig.6.5 に示す。結果より、十分な事前学習を行なったモデルを用いた場合に対しても提案手法の有効性を確認できなかった。




Fig. 6.5: Comparison of the averaged RMSE of the position error with fixed natural frequencies, with STA, with STA and TL, and with STA and only loaded trained model.

第7章 結論

先行研究では、ヒューマンセンシングにより計測したヒトの様子をロボットシステムへの行動司令値やフィードバック生成の評価に加えることができれば、「空気を読める」システムが実現できると考え、STA アーキテクチャが提案された。しかし、アーキテクチャの提案に留まっており、実際に制御として適用できるかは確認されていなかった。

そこで本研究では、STA アーキテクチャに基づき、操作インタフェースのインピーダンスパラメータをヒトの力操作を用いて個人に最適なインピーダンスパラメータに制御する可変アドミッタンス制御の実現を目指した。

まず、実験に用いる入力インタフェースを構築し、加速度制御による仮想機械インピーダンス制御を実装した。仮想環境内に入力インタフェースを再現することで、表示される操作オブジェクトと入力インタフェースとの位置を一致した。

次に、リアルタイムな人間モデル生成に向けて実験データを収集し、エポック数1、バッチ数1の時を想定してハイパーパラメータの探索を行った。その結果、予測可能なパラメータを求め、可変インピーダンス環境における人間モデル生成の可能性を示唆した。

そして、インピーダンスパラメータに対する力操作特性の調査を行った。連続する目標軌道に追従する操作を行った結果より、被験者毎の操作特性により、最適なインピーダンスパラメータが異なることが確認された。また、位置追従と速度追従では特性が異なり、速度追従では重い操作感を提示するパラメータほど誤差が小さくなることがわかった。これらより、位置誤差と速度誤差を組み合わせた評価関数の作成を行うと最適なインピーダンスパラメータに収束できない可能性があることを示唆した。

これらの結果から、STA アーキテクチャによる可変アドミッタンス制御の検証を行った。位置追従誤差を用いた評価関数を定義し、リアルタイムに人間モデルの生成を行いつつ実験を行った。その結果、最適なインピーダンスパラメータに向けて制御できない結果を得た。この結果から人間モデルに問題があると考え、インピーダンスパラメータに対する人間モデルの妥当性を検証した。各インピーダンスパラメータにおける実験データを基に、実験にて使用したパラメータを用いて学習し、人間モデルによる仮想インピーダンスモデルの駆動を行うことで、実データと同様の操作パフォーマンスが得られるか確認した。結果より、十分に学習したモデルにおいても被験者と同様の操作パフォーマ

ンスを示すことができず、人間モデルの生成に問題があることがわかった。

以上より、STA アーキテクチャによる可変アドミッタンス制御において、インピーダンスパラメータに対応する人間モデルの精度が十分に満たされていないことがわかった。また、評価関数に位置追従誤差と速度追従誤差のどちらも含めたインピーダンスパラメータ最適化手法には十分に個人操作特性の解析を行う前処理が必要となると結論付ける。

第8章 今後の展望

本研究で提案した手法にはインピーダンスパラメータに対応する人間モデルの精度が不足していることから、モデルパラメータの最適化を行う。また、人間モデルは全結合型 NN による生成も報告されており、GRU のみではなく、時系列 Transformer など他のモデルも検討を行う。リアルタイムな人間モデル生成を必要とする制御手法の制約により、深層学習を行うことが困難であることから、10 ms 程度の学習周期を確保するモデルとパラメータの選択を行う。

本研究では評価値として位置追従誤差と速度追従誤差に着目したが、力情報に含まれる操作意図や他のメンタル要因など、ヒトから取得できる要素は多くある。そのため、ヒトの操作意図の考慮を含めた評価関数を定義することで最適なインピーダンスパラメータレンジ内で操作意図を考慮した可変アドミッタンス制御を目指す。

更には、STA アーキテクチャに基づき、フォースフィードバックなどのアクティブな操作支援を設計することで STA アーキテクチャの応用可能性を確認する。

参考文献

- [1] “Annual health, labour and welfare report,” *General Welfare and Labour*, Ministry of health, labour and welfare in japan, 2015, pp. 4–19.
- [2] 手術支援ロボット *hinotori*, ja, <https://www.medicaroid.com/product/hinotori/>, Accessed: 2023-1-3.
- [3] R. Ikeura, H. Monden, and H. Inooka: “Cooperative motion control of a robot and a human,” *Proceedings of 1994 3rd IEEE International Workshop on Robot and Human Communication*, Jul. 1994, pp. 112–117.
- [4] 孟子群 and 五十嵐洋, “個人操作特性を考慮した操作対象ダイナミクスの最適化,” 第 20 回システムインテグレーション部門講演会, pp. 2506–2511, 2019.
- [5] V. Duchaine and C. M. Gosselin: “General model of Human-Robot cooperation using a novel velocity based variable impedance control,” *Second Joint EuroHaptics Conference and Symposium on Haptic Interfaces for Virtual Environment and Teleoperator Systems (WHC’07)*, Mar. 2007, pp. 446–451.
- [6] Y. Wang, Y. Yang, B. Zhao, *et al.*, “Variable admittance control based on trajectory prediction of human hand motion for physical Human-Robot interaction,” *NATO Adv. Sci. Inst. Ser. E Appl. Sci.*, vol. 11, no. 12, p. 5651, Jun. 2021.
- [7] K. Furuta, “Control of pendulum: From super Mechano-System to human adaptive mechatronics,” vol. 2, 1498–1507 Vol.2, Dec. 2003.
- [8] S. Suzuki, K. Kurihara, K. Furuta, F. Harashima, and Y. Pan: “Variable dynamic assist control on haptic system for human adaptive mechatronics,” *Proceedings of the 44th IEEE Conference on Decision and Control*, Dec. 2005, pp. 4596–4601.
- [9] S. Suzuki, K. Kurihara, K. Furuta, F. Harashima, and Y. Pan: “Variable dynamic assist control on haptic system for human adaptive mechatronics,” *Proceedings of the 44th IEEE Conference on Decision and Control*, Dec. 2005, pp. 4596–4601.
- [10] M. Kawato, K. Furukawa, and R. Suzuki, “A hierarchical neural-network model for control and learning of voluntary movement,” *Biol. Cybern.*, vol. 57, no. 3, pp. 169–185, 1987.

- [11] K. Tervo and H. N. Koivo, “Adaptation of the Human-Machine interface to the human skill and dynamic characteristics,” *IFAC Proceedings Volumes*, vol. 47, no. 3, pp. 3539–3544, Jan. 2014.
- [12] H. Igarashi: “Subliminal calibration for machine operation,” *2009 35th Annual Conference of IEEE Industrial Electronics*, Nov. 2009, pp. 4268–4273.
- [13] 五十嵐洋: “「空気を読める」システムアーキテクチャ,” 【D】平成 29 年電気学会産業応用部門大会講演論文集, 2017, pp. 47–50.
- [14] 石原義大 and 五十嵐洋, “さりげないアシストのための attention map による人間の注意推定,” 電気学会論文誌 C (電子・情報・システム部門誌), vol. 137, no. 9, pp. 1185–1191, 2017.
- [15] 満倉靖恵, “脳波解析による感性アナライジング,” 電気学会誌, vol. 136, no. 10, pp. 687–690, 2016.
- [16] Electrophysiology, Task Force of the European Society of Cardiology the North American Society of Pacing, “Heart rate variability,” *Circulation*, vol. 93, no. 5, pp. 1043–1065, Mar. 1996.
- [17] 足立修一: システム同定の基礎. 東京電機大学出版局, 2009.
- [18] T. Murakami, F. Yu, and K. Ohnishi, “Torque sensorless control in multidegree-of-freedom manipulator,” *IEEE Trans. Ind. Electron.*, vol. 40, no. 2, pp. 259–265, Apr. 1993.
- [19] K. Ohnishi, M. Shibata, and T. Murakami, “Motion control for advanced mechatronics,” *IEEE/ASME Trans. Mechatron.*, vol. 1, no. 1, pp. 56–67, Mar. 1996.
- [20] J. Chung, C. Gulcehre, K. Cho, and Y. Bengio, “Empirical evaluation of gated recurrent neural networks on sequence modeling,” Dec. 2014. arXiv: [1412.3555 \[cs.NE\]](#).
- [21] D. P. Kingma and J. L. Ba: “Adam: A method for stochastic optimization,” *3rd International Conference on Learning Representations, ICLR 2015 - Conference Track Proceedings*, International Conference on Learning Representations, ICLR, Dec. 2015.
- [22] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, “Optuna: A next-generation hyperparameter optimization framework,” Jul. 2019. arXiv: [1907.10902 \[cs.LG\]](#).
- [23] K. Deb, A. Pratap, S. Agarwal, and T. Meyarivan, “A fast and elitist multiobjective genetic algorithm: NSGA-II,” *IEEE Trans. Evol. Comput.*, vol. 6, no. 2, pp. 182–197, Apr. 2002.

本研究に関する発表文献

1. Yutaka Inoue, Ryo Watanabe and Hiroshi Igarashi: “ On-Line Optimization of Virtual Dynamics to Maximize Machine Operation Performance and Minimize Stress Levels ”, 2022 JSME-IIP/ASME-ISPS Joint International Conference on Micromechatronics for Information and Precision Equipment (MIPE2022), A3-3-04, Nagoya, Japan, August 28-31, 2022.
2. 井上温, 五十嵐洋: “ 「空気を読める」アーキテクチャに基づく可変アドミッタンスによる操作支援 ”, 日本機械学会情報知能精密機器部門講演会 IIP2023, 2023/3/3.

その他の発表文献

1. 井上温, 五十嵐洋: “STA アーキテクチャによるシングルコプタ UAV の姿勢制御”, 日本機械学会情報知能精密機器部門講演会 IIP2020, P12, 2020/03/26.
2. 井上温, 五十嵐洋: “運搬アシスト用 UAV の開発 -STA アーキテクチャによる姿勢制御-”, 日本機械学会ロボティクス・メカトロニクス講演会'20, 2A1-B03, 2020/5/29.
3. 井上温, 五十嵐洋: ”複数の Coaxial-UAV による協調搬送に向けた姿勢制御”, 日本機械学会ロボティクス・メカトロニクス講演会'21, 1P3-B09, 2021/6/9.
4. 井上温, 渡辺亮, 五十嵐洋: ”相互位置関係が未知の複数の Coaxial-UAV による協調搬送のための姿勢制御-2DoF 姿勢制御に向けた設置位置推定-”, 日本機械学会ロボティクス・メカトロニクス講演会'22, 1P1-G02, 2022/6/2.