

修 士 論 文

機械学習を用いた追従操作における
サプライズの推定

Estimating Surprises in Tracking Operations
Using Machine Learning

東京電機大学大学院工学研究科
電子システム工学専攻修士課程
23KMH08 加藤 一沙
研究指導教員 教授 五十嵐 洋

謝 辞

本研究を行うにあたり，五十嵐洋教授（東京電機大学）からは非常に熱心なご指導，ご鞭撻を賜りました．厚く御礼申し上げます．また，和田成夫教授（東京電機大学）には本論文の副査を務めていただき誠にありがとうございました．厚く御礼申し上げます．

協調ロボティクス研究室の皆様には技術的なアドバイスを数多く頂きました．本研究にご助力下さった全ての方々に感謝致します．

目 次

第 1 章	緒論	1
1.1	研究背景	2
1.1.1	機械操作における熟達の統括的議論	3
1.2	自由エネルギー原理 (FEP : Free Energy Principle)	5
1.2.1	FEP の概要	6
1.2.2	用語解説	7
1.2.3	研究動向と定量化に向けた課題	9
1.3	本研究の目的	10
第 2 章	提案手法	11
2.1	サプライズの定式化	12
2.2	操作情報を利用した脳内モデルの構築	14
第 3 章	提案手法の有効性調査と予測モデルの精度検証	17
3.1	実験タスク	18
3.2	入力インタフェース	19
3.3	実験条件	20
3.4	実験結果, 及び考察	21
3.5	統括的議論	33
第 4 章	結論	35
4.1	まとめ	36
4.2	今後の展望	37
	本研究に関する発表文献	41

第1章 緒論

今日では少子高齢化の進行により日本の生産年齢人口が減少しており，労働力不足や経済規模の縮小といった課題が懸念されている．一方で，AI 技術の普及により，人間の操作支援や労働力不足の改善が期待されており，人間-機械協調の場が増加している．人間と機械の協調的な操作にあたり操作者の個人特性を考慮した支援システムが課題となる．本研究では，個人差を考慮した支援システムの構築を目指す．

本章では，これらの背景とともに本研究の位置づけ，及び目的を述べる．

本章では以下の項目について述べる．

- 研究背景
- 研究目的

1.1 研究背景

近年、少子高齢化の進行に伴い日本の生産年齢人口(15～64歳)は1995年をピークに減少しており、2050年には5,275万人(2021年から29.2減)に減少すると見込まれている。生産年齢人口の減少により、労働力の不足、国内需要の減少による経済規模の縮小など様々な社会的・経済的課題の深刻化が懸念されている [1]。

一方で、コンピュータ、及び機械学習の発展によりAI技術が普及し始めている。これらの技術を活用することで機械による人間の操作支援を可能とし、労働者不足の改善に期待できる。また、AI技術をはじめとしたアシストシステムは労働者不足の改善だけに限らず、自動運転といった日常生活にまで普及しており、アシストシステムは人間の補助的な役割を果たしている。

ここで課題となるのが人間は熟達することである。アシストシステムは人間の熟達を考慮しなければならず、常に更新される人間の意図との競合により操作パフォーマンスの低下が示唆されている [2]。上記より、人間-機械協調の場が増加する現代では常に熟達する人間の意図の考慮、操作技能、熟達過程等の個人差という課題に対して早急に解決すべきと言える。

1.1.1 機械操作における熟達の統括的議論

熟達理論は多岐にわたり、心理学、教育学、認知科学、神経科学等の異なる視点から理論や概念が展開されている。本項では機械操作に焦点を当てた人間の熟達に関する議論を行い、前述した常に熟達する人間の意図、及び個人差の解消の手掛かりについてまとめる。

Fitts と Posner による運動学習の理論 [3] では認知、連合、自動化の 3 つの段階で表現されている。認知段階では、新しいタスクを学び始める段階で、手順やルールを理解することに集中する。この段階ではエラーが多く、試行錯誤が繰り返される。連合段階では基本的なスキルが身につく、エラーが減少し、動作がスムーズになる。この段階ではフィードバックを活用して調整が行われる。自動化段階では、スキルが完全に習得され、ほとんど無意識にタスクを実行することが可能である。

Schmidt の運動スキーマ理論 [4][5] では前述した Fitts と Posner による運動学習の連合段階から自動化段階への過程について述べたものと言える。スキーマとは過去の経験からなる記憶により、構造化されたものである。人間は新しいタスクを始める際 0 から理解するのではなく既存知識に当てはめて理解しようとする。自動車を例にした場合、自家用車ではなく初めて乗るレンタカーでもある程度運転可能であり、0 から操作方法を理解しているわけではない。これはハンドルやアクセル、ブレーキ等の操作方法は既知でありその型が潜在的に脳内に保有されているからと考えられる。

筋力制御は熟達に関係があると示されている。谷貝氏らはドラム打叩課題を熟練者、未経験者に課し、熟練者の方が演奏安定性である打叩間隔 (ITI: Inter-Tap Interval)・打叩強度が高くなることを定量的に検証した [6]。ITI・打叩強度の結果、熟練者は未経験者と比較して演奏のばらつきが小さく、出力が大きいことが示された。付随して、ドラム熟練者が局所的な筋制御ではなく、様々な筋を協働させていることが明らかとなった。機械操作とは異なるが手首の回旋運動、屈曲伸展筋といった共通点から本研究の議論において有用的であると言える。

さらに、熟達が筋力制御に関連すると分かったところで神経と筋力制御の関連性について説明する。運動が習熟すると神経回路に一定の経路や近道ができ、動作命令が早く伝わるようになり、複雑な動作が反射的に調整され自動化される。学習時の脳活動についての研究では、学習初期と比べて習熟度が向上するに連れて大脳基底核と小脳が中心

に活動すると報告されている。そして最終的に運動記憶は、運動野、運動前野、補足運動野にプログラムされ、長期的に安定した動作になると考えられている [7]。

統括すると、機械操作の熟達は、スキルの段階的進展に伴う筋力制御の精密化と、それを支える神経回路の再編成によるものである。脳内ではスキーマ化された知識が活用され、熟達が進むほど動作が効率化し、プロセスが自動化される。

1.2 自由エネルギー原理 (FEP : Free Energy Principle)

前項 1.1.1 より，本研究では脳機能と機械操作の熟達に着目し，その観点から脳情報理論の数理モデルである自由エネルギー原理 (以下，FEP) について取り上げる．

本節では FEP の概要と研究動向，及び定量化に向けた課題について述べる．

1.2.1 FEP の概要

FEP は Helmholtz が唱えた無意識的推論 [8] を元に Karl Friston らが提唱している脳の情報理論であり、知覚、学習、行動といった脳機能を統一的に表すものである。そして環境との相互作用を通して、予測誤差を最小化するような行動プロセスである能動的推論 [9][10] が提唱された。FEP は知覚機能と直接関係する KL ダイバージェンス項と知覚とは直接には関係しないサプライズ項と呼ばれる 2 つの項の和として表せる。つまり、自由エネルギーの最小化はダイバージェンス項だけでなくサプライズ項を減少させることで達成できる [11]。能動的推論は行動することも推論として扱うことが可能であり、知覚と行動を FEP という 1 つの評価指標として扱うことが可能となった。

FEP は脳の目的を真の事後分布 $p(x|s)$ を知ること、つまり感覚入力 s と呼ばれる神経活動のもとで隠れ状態 x を推論している。隠れ状態 x についての確率分布 $q(x)$ 、感覚入力 s についての確率分布 $p(s)$ 、隠れ状態 x のもとで感覚入力 s が生じる確率 $p(s|x)$ とし、KL ダイバージェンス (以下、 D_{KL}) と変分ベイズを用いて算出可能である。以下の式 (1.1) のように定義される。次項 1.2.2 に式 (1.1) の各変数、及び項について詳細に述べていく。

$$D_{KL}(q(x)||p(x|s)) = \int q(x) \log \left(\frac{q(x)}{p(s, x)} \right) dx - \log(p(s)) \quad (1.1)$$

1.2.2 用語解説

- 生成モデル

生成モデル $p(s, x)$ とは隠れ状態 x と感覚入力 s の同時確率分布で表現され、人間の知識とされている。

- 隠れ状態

隠れ状態 x とは人間が直接観測することはできず感覚信号を通して脳が推論した結果であるため、個人ごとに同じ環境を見たとしても「見え方」が異なる。

隠れ状態 x についての確率分布 $q(x)$ は人間の推測である。

- D_{KL}

D_{KL} とは式 (1.2) に示すように2つの分布の類似度を測る指標である。FEP では真の事後分布 $p(x|s)$ と人間の推測 $q(x)$ を変分ベイズ推定を用いて近似することで定量が可能となる。しかし、式 (1.2) から分かる通り直接は計算不可である。そこで、右辺をベイズの定理を用いて展開していくと式 (1.1) で示したようになり、第1項を「自由エネルギー」、第2項を「サプライズ」と呼ぶ。

自由エネルギーの概要図を Fig. 1.1 に示す。

$$D_{KL}(q(x)||p(x|s)) = \int q(x) \log \left(\frac{q(x)}{p(x|s)} \right) dx \quad (1.2)$$

- サプライズ

サプライズ $-\log(p(s))$ とは人間の驚きである。自己情報量であるサプライズは感覚入力の負の対数を取ったものである。0以上1以下の値を取り、確率 s の値が小さいほど大きくなる。これは確率が高い(頻繁に起きる)事象が生じたことを伝える情報よりも確率が低い(めったに起きない)事象が生じたことを伝える情報の方が情報量は大きいという考え方に基づく [11]。




Fig. 1.1: Composition of free energy.

1.2.3 研究動向と定量化に向けた課題

FEP を用いた機械操作における熟達支援の研究は調査したか限りでは見受けられなかった。その背景として神経活動を指し、脳内のセンサ値である感覚入力 s のサンプリングが困難であると推察している。神経活動を測定する方法はいくつかある。脳波 (EEG : Electroencephalography) では頭皮に電極を配置し、脳の電氣的活動をリアルタイムで記録する方法である。これにより、脳の異なる部位での活動の変化が測定可能である [12]。また筋電図 (EMG : Electromyography) では、神経から筋肉への信号を測定する技術で、神経活動を間接的に評価する方法である [13]。機能的磁気共鳴画像法 (fMRI : Functional Magnetic Resonance Imaging) では、脳の血流の変化を測定することで神経活動を間接的に可視化する [14]。上記のように神経活動を測定する方法はあるものの動作が限定的である。また、リアルタイムに神経活動が取得可能であってもその神経活動が何を示しているかを明白にするには FEP の観点から、環境とのインタラクションから解析する必要があるためリアルタイム性が担保できない。

1.3 本研究の目的

熟達と脳機能の密接な関係性から FEP に着目した。しかし、既存の手法では感覚入力 s のサンプリングが機械操作において不向きであることから、本研究では FEP の概念に帰着した。

本研究では FEP を用いて、人間の熟達過程を考慮したアシストシステムを構築することを大目的とし、サプライズを工学的に定式化、推定、及び熟達の指標として妥当性の検証を目的とする。

第2章 提案手法

本章ではサプライズの定式化を行い，操作情報とニューラルネットワーク (以下，NN) を用いた定量評価を試みる．

本章では以下の項目について述べる．

- サプライズの定式化
- 操作情報を利用した脳内モデルの構築

2.1 サプライズの定式化

前章で述べたように機械操作を行う環境において感覚入力 s の算出は困難である．故に FEP の既存の式をそのまま使用することはできない．そこで本研究では，FEP のサプライズ部分に着目し，その概念から定量化につながる着想を得た．

本研究では機械操作環境を用意しており，入力インタフェースを用いて操作対象を駆動させ追従対象を追うタスクを行ってもらう．その際のサプライズ S を以下の式 (2.1)(2.2) のように定式化した．

人間は予測誤差を最小化するために，常に未来を予測している．NN を用いて人間の脳内つまり，人間が予測する未来の誤差を定量化し，その未来の誤差と実際の誤差の差分をサプライズ S とする．

Fig. 2.1 にシステム概要を示したブロック線図を示す．位置誤差に関するサプライズ $S_{pos}(t)$ は，操作対象と追従対象の距離を位置誤差 $e(t)$ と人間が予測する未来の位置誤差 $\hat{e}(t)$ の絶対値の差分である．

$$S_{pos}(t) = |\hat{e}(t) - e(t)| \quad (2.1)$$

速度誤差に関するサプライズ $S_{vel}(t)$ は，位置誤差 $e(t)$ の微分値である速度誤差 $\dot{e}(t)$ と人間が予測する未来の速度誤差 $\hat{\dot{e}}(t)$ の差分である．

$$S_{vel}(t) = \hat{\dot{e}}(t) - \dot{e}(t) \quad (2.2)$$




Fig. 2.1: Input-output relationship of the model during training.

2.2 操作情報を利用した脳内モデルの構築

本研究で使用する NN モデルは 3 層の全結合型ニューラルネットワークを使用した。Fig. 2.2, Fig. 2.3 に示すように学習時と予測時で入力データ, 教師データのステップをずらす事により τ 秒先の誤差を予測する人間の脳内モデルを構築した。また, 学習, 及び予測はリアルタイムで行っている。これは人間の脳が常に学習, 予測を行っていることに基づくためである。以下の Table. 2.1 に学習時と予測時のモデルの入出力関係を示す。

Table 2.1: NN Setting

Parameter	Setting
Input data during training	$u(t - \tau), e(t - \tau), \dot{e}(t - \tau)$
Output data during training	$e(t), \dot{e}(t)$
Input data during prediction	$u(t), e(t), \dot{e}(t)$
Output data during prediction	$\hat{e}(t + \tau), \hat{\dot{e}}(t + \tau)$
Activation	Hyperbolic tangent function
Learning rate	0.01

人間の操作情報を操作量 u として, 前節で述べたように, モデルを用いて予測した誤差が位置誤差 $\hat{e}(t)$, 速度誤差 $\hat{\dot{e}}(t)$ となり, 実際に得られる位置誤差 $e(t)$, 速度誤差 $\dot{e}(t)$ の差分をサプライズ S として定量評価する。




Fig. 2.2: Input-output relationship of the model during training.




Fig. 2.3: Input-output relationship of the model during prediction.

第3章 提案手法の有効性調査と予測モデルの精度検証

本章では自身が提案したサプライズ S が熟達の指標として有効であるか，予測モデルの精度について検証を行った．

本章では以下の項目について述べる．

- 実験タスク
- 入力インターフェース
- 実験条件
- 実験結果，及び考察
- 統括的議論

3.1 実験タスク

機械操作として被験者には Fig. 3.1 に示すような 2 次元の円追従タスクを行わせた。座標空間内にある赤色オブジェクトが「操作対象」、灰色オブジェクトが「追従対象」である。リサーチ軌道を描く追従対象に操作対象を留めるように指示した。




Fig. 3.1: Follow-up tasks in machine operation.

3.2 入力インタフェース

入力インタフェースには, Fig. 3.2 に示す MadCatz 社のジョイスティックコントローラ (Cyborg V.1 Flight Stick) を使用した.

操作対象の動作は式 (3.1) に示す仮想的なダイナミクス制御が反映されている. M_v は慣性係数として操作対象の仮想的な質量となり, D_v は粘性係数として操作対象の滑りやすさを, k_v は弾性係数として位置の変位に比例した力を発生させる. ジョイスティックの傾斜度を操作入力量 u として, その入力量に応じて操作対象の位置 x, y が決定する.

$$M_v \begin{bmatrix} \ddot{x} \\ \ddot{y} \end{bmatrix} + D_v \begin{bmatrix} \dot{x} \\ \dot{y} \end{bmatrix} + k_v \begin{bmatrix} x \\ y \end{bmatrix} = u \quad (3.1)$$



Fig. 3.2: Input Interface.

3.3 実験条件

実験条件を以下にまとめる．リサージュ軌道を描く追従対象が1周にかかる時間が約20[s]であるため，実験時間を約100[s]にすることで追従対象の周回数を5周分に設定した．また， τ 秒先の誤差を予測する人間の脳内モデルを構築した．本実験では τ 秒先を予測時間 $\tau 0.1[s]$ として設定した．

本実験はアシストシステム構築の前段階であるため，アシスト，もしくは被験者の熟達のどちらかによってパフォーマンスが向上したかについて議論する必要がない．よって被験者にはあらかじめタスクやジョイスティックに慣れる必要はなく，むしろ熟達過程を見るうえでは初見の方が良いと考えた．

- 被験者：20代男女6名
- 実験時間：約100[s]
- 予測時間：0.1[s]

3.4 実験結果，及び考察

- 予測モデルの有効性
 - ヒストグラム解析

1名の被験者を代表として結果を報告する．モデルに入力するデータのヒストグラム解析を行った結果を Fig. 3.3 に示す．本解析では，被験者による操作量，位置誤差，および速度誤差の3つのデータについて，その分布特性を評価した．まず，Fig. 3.3(a) および (b) に示されているように，被験者の操作量は不均一であることが確認された．この不均一性は，操作量の大部分が特定の範囲に偏る一方で，一部のデータが大きく異なる値を示すため，分布全体が偏った形状をしていることによるものである．このようなデータ特性は，予測モデルが統計的に意味のある特徴を抽出しにくくし，モデルの精度や汎化性能に悪影響を与える可能性がある．

一方で，Fig. 3.3(c) および (d) に示される位置誤差と速度誤差については，全体的に正規分布に近い形状を示していることが確認された．これらの分布は中心値を軸に左右対称で，外れ値も比較的少ないため，予測モデルがデータの傾向を捉えやすい特性を持っていると考えられる．このような特性は，モデルがより安定的かつ正確な予測を行う上で重要な要因となる．

操作量のヒストグラムでは不均一性が顕著であった一方で，位置誤差および速度誤差のヒストグラムでは，全体的に均一性が認められた．この結果を踏まえ，位置誤差と速度誤差に基づいた予測結果のヒストグラムについても検討を行った．その結果を Fig. 3.3(e) および (f) に示す．

Fig. 3.3(e) は位置誤差の予測に基づくヒストグラムを示しており，Fig. 3.3(c) の位置誤差データのヒストグラムと非常に近い形状を持つことが確認された．同様に，Fig. 3.3(f) に示される速度誤差の予測ヒストグラムも，Fig. 3.3(d) の速度誤差データのヒストグラムと概ね類似した形状を示すものの，予測ヒストグラムでは山の形状が若干大きくなっている点が観察された．分布の中心軸はどちらもおおよそ0を基準としているが，予測結果の方が分布のピークがより強調され，元データに完全には忠実でないことが示唆される．

この差異は，速度誤差データの分布に含まれる微細な特徴をモデルが正確に再現する

ことが難しかった可能性を示している。また、予測モデルが速度誤差の変動に対して過剰適合する傾向や、分布の再現性における制約が影響を及ぼしている可能性も考えられる。さらに人間の操作特性に着目すると、ジョイスティックなどの操作では、人間の反応速度が追従性に影響する。目標の動きに対して位置的には適切に操作できても、速度の変化を予測・補正するのが難しいことが考えられる。このことから、人間は速度の変化よりも位置のずれに対して敏感な場合があり、そのため、操作時に速度誤差よりも位置誤差を小さくするよう無意識に調整している可能性が示唆された。

それでもなお、Fig. 3.3(f) の予測結果は、元データの主要な特徴を概ね再現しており、予測モデルの性能として一定の妥当性が認められる。今後の改善点としては、速度誤差における分布形状の再現性を向上させるためのデータ前処理やモデル構造の最適化が挙げられる。

これらの結果を総合すると、位置誤差の予測は元データに非常に忠実であり、速度誤差の予測においても全体的な傾向を捉えている一方で、分布の微細な違いを修正することで、モデルのさらなる精度向上が期待される。




Fig. 3.3: histogram.(a)Operation X-Axis. (b)Operation Y-Axis. (c)Position Error. (d)Velocity Error. (e)Predicted Position Error. (f))Predicted Velocity Error.

○ 位置誤差および速度誤差の時系列予測評価

位置誤差、速度誤差とその予測値を時系列で解析した結果を Fig. 3.4 および 3.5 に示す。これらの図は、モデルが各時点における誤差をどの程度正確に予測できているかを視覚的に評価するものである。時系列解析においては、予測モデルが時間経過に伴ってどのように誤差を推定し、その精度がどの段階で改善されたかを把握することが重要である。特に、位置誤差や速度誤差といった時間依存の変数に対する予測精度は、モデルの学習過程やデータの特徴を反映するため、これらの図は予測の信頼性を評価するための有力な手段となる。また、時系列データの中で誤差が時間と共にどのように変動し、その変動をモデルがどれほど正確に捉えているかを確認することで、モデルがデータの傾向をどのように学習しているのかについても洞察を得ることができる。

まず、Fig. 3.4 に示す位置誤差の予測結果について考察する。位置誤差は緩やかな変動を伴い、視覚的なフィードバックや感覚に基づいて人間が比較的容易に認識・調整できる情報であると考え、連続的で速度誤差より比較的予測可能なパターンを示せる。このような安定した変動は、モデルが過去のデータに基づいて未来の値を予測する際に予測が容易であると考えた。

時系列の開始 $0[s]$ ~ $10[s]$ の間では、予測値が元データと乖離しており、予測精度が著しく低いことが確認された。この期間では、予測モデルが入力データから有効なパターンを十分に抽出できておらず、適切な学習が行われていない可能性が高い。しかし、 $10[s]$ 以降になると、予測値が元データに非常に近い形となり、モデルが位置誤差の傾向を精度良く捉え始めていることが分かる。これは、データが十分に蓄積され、モデルが時系列データの累積的な学習を進めた結果である。

次に、Fig. 3.5 に示す速度誤差の予測結果について考察する。速度誤差は位置誤差に比べて急激な変動を伴うことが多く、微細な動きや急激な変化を捉えるのが難しく、予測が複雑になる。そのため、速度誤差の予測には予測モデルがピーク部分や急激な変動に過剰に反応することが多く、結果としても、予測値が実際の値を上回るオーバーシュートの傾向を示している。これは、モデルが急激な変化を学習する際に生じやすい現象であり、特に速度誤差のような高頻度で変動するデータには顕著である。

これらの結果を総合すると、速度誤差の予測精度には課題が存在するものの、全体としてモデルは時系列データの主要な傾向を適切に捉えることができていると評価できる。

特に位置誤差に関しては、人間の運動制御が位置情報を基に行われるため、予測モデルが位置誤差を比較的容易に予測できるのに対し、速度誤差では急激な変動に対応するためのモデルの適切な設計が重要であることが示唆される。また、初期の学習段階でのデータ不足や急激な変動への対応能力を改善するために、データの前処理やモデルアーキテクチャの改良を検討することが有効であると考えられる。




Fig. 3.4: Predicted fitness of position error.




Fig. 3.5: Predicted fitness of velocity error.

。平均平方二乗誤差による予測モデルの評価

定量的に予測モデルを評価するために、平均平方二乗誤差（RMSE: Root Mean Squared Error. 以下、RMSE）を用いて評価を行った。RMSE は、予測値と実測値の間の誤差の大きさを定量的に示す指標であり、値が小さいほど予測精度が高いことを意味する。今回の解析では、被験者合計 6 名（A から F）の個人ごとの予測モデルについてそれぞれ RMSE を算出した。被験者間の特性の違いを考慮せずに単純に RMSE を平均してしまうと、各被験者ごとのデータ特性や行動のばらつきを適切に反映できない恐れがあるため、本研究では被験者ごとの個別の RMSE を評価対象とした。

位置誤差の予測において、RMSE は比較的小さな値となり、モデルが位置誤差を比較的精度良く予測できていることを示唆している。この値は、モデルが実際の位置誤差と平均的にどれだけ乖離しているかを表しており、誤差の範囲が許容範囲内であれば、モデルのパフォーマンスは適切であると評価できる。特に、位置誤差は視覚的フィードバックや感覚によって比較的容易に調整されるため、モデルは予測しやすい特徴を捉えていると考えられる。

一方で、速度誤差の予測では、RMSE が位置誤差よりも大きな値となっており、モデルが速度誤差を予測する際の精度がやや低いことを示している。速度誤差は位置誤差と比較して急激な変動や動的な特徴を含む場合が多く、これが予測精度の低下に影響を与えている可能性がある。例えば、急激な速度の変化に対するモデルの過剰な反応（オーバーシュート）や、急変動に対する予測誤差の影響が挙げられる。このような急激な変動は、モデルが適切に学習できていない部分や、速度誤差特有の特性を捉えるための改善の余地があることを示唆している。

Table 3.1: RMSE for the subject's personal model

Player	RMSE of Position Error	RMSE of velocity Error
A	0.091	0.148
B	0.067	0.222
C	0.081	0.236
D	0.103	0.213
E	0.107	0.241
F	0.099	0.156

- サプライズ S とパフォーマンスの相関関係

予測モデルの精度が概ね確保されたことを前提に、次のステップとして位置誤差 $e(t)$ および速度誤差 $\dot{e}(t)$ に基づく各サプライズ S と、パフォーマンスとの関係性を明らかにすることを試みた。このステップでは、サプライズが人間の操作における熟達度や適応能力をどのように反映しているかを評価することを目的としている。具体的には、サプライズ概念である「予測と実際の結果の乖離」が、操作の練習や慣れに伴ってどの程度減少し、それに付随してパフォーマンス（位置誤差や速度誤差）が向上するかを検証した。

本研究では、位置誤差 $e(t)$ と速度誤差 $\dot{e}(t)$ を追従誤差およびパフォーマンスの指標として扱い、これらを式 (3.2) および式 (3.3) に示す。

$$e = \sqrt{(|x_{tgt} - x_{ope}|)^2 + (|y_{tgt} - y_{ope}|)^2} \quad (3.2)$$

$$\dot{e} = \dot{x}_{tgt} - \dot{x}_{ope} \quad (3.3)$$

各被験者のサプライズ S とパフォーマンスの相関係数を Table. 3.2 に、被験者代表 1 名の各サプライズ S とパフォーマンスの推移を Fig. 3.7 および 3.8 に示す。まず、位置誤差のサプライズ S_{pos} と位置誤差のパフォーマンス e についての結果を詳述する。Table. 3.2 から、位置誤差のサプライズ S_{pos} と位置誤差のパフォーマンス e との間には弱い正の相関があることが確認された。このことは、サプライズが大きいほどパフォーマンスがやや悪化する傾向を示しているが、相関の強さは限定的であることを示唆している。

さらに、Fig. 3.6 では、位置誤差のサプライズ S_{pos} が 0 に収束している一方で、位置誤差のパフォーマンス e は発散している様子が見て取れる。この結果は、被験者がタスクを通じて熟達することを前提として進めた実験において、熟達の傾向が確認できなかったことを意味している。特に、サプライズ S_{pos} が収束していく様子は、予測モデルが高精度であるために予測誤差の振りが減少したことが原因と考えられる。この点から、位置誤差のサプライズ S_{pos} を熟達の指標として用いることは、少なくとも本実験の条件下では妥当性が示されなかったと考えられる。

次に、速度誤差のサプライズ S_{vel} と速度誤差のパフォーマンス $\dot{e}$ について考察する。

Table. 3.2およびFig. 3.7の結果から、速度誤差のサプライズ S_{vel} と速度誤差のパフォーマンス $\dot{e}$ の間には明確な負の相関があることが分かった。具体的には、速度誤差のサプライズ S_{vel} が小さくなるほど速度誤差 $\dot{e}$ も小さくなり、すなわちパフォーマンスが向上する傾向が確認された。この強い負の相関は、速度誤差のサプライズが熟達度の指標として適切である可能性を示している。

また、Fig. 3.7では、速度誤差のサプライズ S_{vel} が減少するのに伴い、速度誤差 $\dot{e}$ も同時に減少する動的な傾向が視覚的に確認できる。この結果は、被験者がタスクを遂行する中で速度誤差の予測がよりの確になり、その結果として操作精度が向上していることを示唆している。速度誤差は位置誤差と比較して急激な変動を含むことが多く、予測が難しい側面を持つが、その分予測が上手くいった際にパフォーマンスへの影響が顕著に現れる可能性がある。この点から、速度誤差のサプライズ S_{vel} は熟達度やパフォーマンスの評価において有効な指標となり得ると考えられる。

以上の結果から、位置誤差に関するサプライズ S_{pos} は熟達の指標としての有効性を示すことが難しい一方で、速度誤差に関するサプライズ S_{vel} は明確にパフォーマンスと関連しており、熟達の評価においてより適切な指標である可能性が示唆された。

Table 3.2: Correlation coefficient between subject surprise and performance

Player	CC of position	CC of velocity
A	0.38	-0.81
B	0.22	-0.68
C	0.24	-0.77
D	0.34	-0.68
E	0.38	-0.73
F	0.5	-0.41




Fig. 3.6: Predicted fitness of position error.




Fig. 3.7: Predicted fitness of velocity error.

3.5 統括的議論

本節では、本実験で得た結果を基に、提案したサプライズについて考察を行う。

学習に用いる入力データのヒストグラム解析では人間の操作量 u が不均一なデータに対して、位置誤差、速度誤差については正規分布に近い形状をしていた。よって、予測モデルがデータの傾向を捉えやすい入力データであると示唆できた。また、位置誤差および速度誤差の時系列予測を評価したところ、位置誤差の予測精度に関しては10[s]以降を境に正確に予測できていた。一方で、速度誤差の予測に関しては傾向を掴めていたものの、各ピークでオーバーシュートしてすることが視認できたが、概ね予測できている結果となった。

予測モデルを定量的に評価するために用いた RMSE の結果によれば、位置誤差の予測モデルは非常に高い精度を持つモデルであり、速度誤差の予測モデルも十分に良好な精度を示した。これらの結果を総合すると、提案した予測モデルは被験者が引き起こす未来の誤差を適切に予測できていることが明らかになった。このことは、「人間の脳が常に未来の出来事を予測している」という FEP の観点からも、人間の脳内モデルをある程度再現できていると評価できる。

次に、サプライズ S とパフォーマンスの相関関係について考察を深める。位置誤差のサプライズ S_{pos} とパフォーマンス e については、相関は弱い正の値を示した。一方、速度誤差のサプライズ S_{vel} とパフォーマンス $\dot{e}$ については強い負の相関が確認された。この結果を踏まえ、各ケースについて詳細に議論を行う。

まず、位置誤差のサプライズ S_{pos} とパフォーマンス e の関係についてである。サプライズとは、「予測の難しさ」を定量化する試みとして提案されたが、Fig. 3.6 に示すように、位置誤差のサプライズ S_{pos} は実験の初期段階で0付近に収束している。しかし、その一方でパフォーマンス e は一貫して発散している様子が確認された。理論的には、サプライズ S_{pos} が収束するに伴い位置誤差 e も減少し、パフォーマンスが向上することが期待されるが、この結果はそれに反するものである。この乖離は、位置誤差の予測精度が非常に高いがゆえにサプライズがほとんど発生せず、パフォーマンスとの関連性を捉えるには不十分であった可能性を示している。このため、位置誤差のサプライズ S_{pos} を熟達の指標とすることには限界があると結論付けられる。

次に、速度誤差のサプライズ S_{vel} とパフォーマンス $\dot{e}$ の関係についてである。Fig. 3.7

に示される結果からも明らかなように、速度誤差のサプライズ S_{vel} が小さいほどパフォーマンス $\dot{e}$ が向上する（速度誤差が小さくなる）ことが確認された。これは、速度誤差におけるサプライズ S_{vel} が熟達の指標として機能する可能性を示唆している。予測モデルの精度は位置誤差のモデルと比較してやや劣るものの、サプライズ S_{vel} が予測の難しさを反映し、それが被験者の操作パフォーマンスに直接影響を及ぼしていることが明確に示された。

最後に、位置誤差のサプライズ S_{pos} と速度誤差のサプライズ S_{vel} が熟達の指標として異なる結果を示した背景について議論する必要がある。特に、速度誤差のサプライズ S_{vel} とパフォーマンス $\dot{e}$ の関係において、被験者6名中5名が負の相関を示したことは注目すべき点である。この結果は、速度制御が位置制御と比較してより動的で難易度が高いため、サプライズの影響が顕著に現れる可能性を示唆している。また、速度誤差のサプライズは操作のスムーズさやタイミングの調整といった動作スキルに密接に関連していると考えられる。

これらの結果を踏まえ、位置誤差および速度誤差のサプライズを熟達度の指標としてさらに有効に活用するためには、サプライズの定義や計算方法を改良し、予測モデルの性能や被験者間の個人差を考慮した解析を行う必要がある。さらに、被験者ごとの操作特性や戦略の違いを詳細に解析することで、より包括的な結論を導き出せると考えられる。

第4章 結論

アシストシステムの構築を大目的として本研究では，サプライズ S の定量評価に試みた．本章では本研究のまとめ，今後の展望について述べる．

4.1 まとめ

今日では少子高齢化の進行により日本の生産年齢人口が減少しており，労働力不足や経済規模の縮小といった課題が懸念されている．一方で，AI技術の普及により，人間の操作支援や労働力不足の改善が期待されており，人間-機械協調の場が増加している．人間と機械の協調的な操作にあたり操作者の個人特性を考慮した支援システムが課題となる．本研究では，個人差を考慮した支援システムの構築を目指した．

個人差を考慮した支援システムを構築するうえで，操作者の熟達過程を考慮しなければならない．そのため熟達と脳の密接な関係性からFEPに着目した．しかしFEPの定量化非現実的であるためFEPのサプライズの理論，及び概念に着目し「予測の難しさ」を定量化することに試みた．結果，位置誤差のサプライズ S_{pos} とパフォーマンス e に強い相関は見られなかったものの，速度誤差のサプライズ S_{vel} とパフォーマンス $\dot{e}$ に関しては負の相関を確認した．このことから速度誤差のサプライズ S_{vel} は操作者の熟達を示す指標であると示唆された．

4.2 今後の展望

本研究で提案したサプライズ概念は、人間の脳内モデルの一部を模倣し、未来の操作や誤差を予測する試みとして一定の成果を得ることができた。しかしながら、位置誤差と速度誤差におけるサプライズが熟達の指標として異なる結果を示した点や、サプライズとパフォーマンスの相関が必ずしも強くない場合があったことから、さらなる改善と発展が必要である。以下に、今後の展望を示す。

まず、サプライズ指標の改良が挙げられる。現在のサプライズ指標は予測の難しさを反映するものとして設計されたが、実験結果から位置誤差のサプライズが熟達の指標として機能しない可能性が示唆された。この課題に対して位置の認識が熟達と無関係であるか、多角的に調査すべきと考えた。

次に、予測モデルのさらなる向上が必要である。位置誤差と速度誤差の予測精度には違いがあり、この差異がサプライズとパフォーマンスの相関に影響を及ぼしている可能性がある。より精度の高い予測モデルを構築するためには、速度誤差の急峻な変化やノイズを的確に捉える高次特徴量の抽出が重要である。また、位置誤差や速度誤差に加え、操作環境や被験者の行動パターンといった多様な要因を統合的に解析する多変量解析の導入も検討すべきである。

さらに、被験者の個人差を考慮した解析も重要である。被験者間のサプライズとパフォーマンスの関係には個人差が存在する可能性がある。そのため、クラスタリング手法を用いて被験者の操作特性を分類し、各グループに適した解析を行うことが望ましい。加えて、被験者の操作傾向に応じて予測モデルを適応的に更新する仕組みを構築することで、個別最適化を図ることができる。

熟達度の総合的な評価指標の構築も課題である。サプライズだけでなく、パフォーマンスや行動特性を総合的に組み合わせた評価指標を考案する必要がある。例えば、サプライズの減少率や収束速度、誤差の分散や標準偏差の推移、さらには操作効率や応答時間といった指標を組み合わせることで、より包括的な熟達度の評価が可能になると考えられる。

以上を踏まえ、本研究の成果は予測モデルを用いた熟達評価の新たな可能性を示したものの、その実用化や汎用性を高めるためにはさらなる研究が必要である。これらの課題を克服することで、より多くの分野での応用が期待できるだろう。

また，今回の実験では人間がどのくらい先の未来を予測しているかを考慮せず，予測モデルの予測時間を 0.1[s] と決めていた．しかし，運動に関する脳波の 1 に運動準備電位 (RP: Readiness Potential 以下, RP) がある．ECG での測定が可能であり，運動を行う 1～1.5[s] 前に発生する電位である [15]．事前に動かそうとした場合 1000[ms]～800[ms] 前に，無意識化の場合では 550[ms] 前に生じる．このことから人間がなにか動作をする際，既に何かを想定していることが考えられる．これは，人間がどのくらい先の未来を予測しているかについて関係があると捉え，今後検証する必要がある．

参考文献

- [1] 総務省, “情報通信白書 ICT 白書令和4年版情報通信白書刊行から50年～ICTとデジタル経済の変遷～”, 日経印刷, 2022.
- [2] H. Igarashi, A. Takeya, E. Harashima and M. kakikura, “Human Adaptive Assist Planning for Teleoperation”, The 32nd Annual Conference of the IEEE Industrial Electronics Society, 4522/4527, 2006.
- [3] Fitts, P. M. and Posner, M. I.: Human Performance, 1-162, Belmont: Brooks/Cole, 1967.
- [4] Schmidt, R. A.: A schema theory of discrete motor skill learning, Psychological Review, Vol. 82, pp. 225-260, 1975.
- [5] Schmidt, R. A.: Motor schema theory after 27 years: Reflections and implications for a new theory, Research Quarterly for Exercise and Sport, Vol. 74, No. 4, pp. 366-375, 2003.
- [6] 谷貝祐介, 古山宣洋: “ドラム打叩動作における身体の協応と熟達に関する研究: 表面筋電図を用いた演奏安定性の検討”, Cognitive Studies 24(1), 136-140, 2017.
- [7] Nudo, R. J., et al. “Neural substrates for the effects of rehabilitative training on motor recovery after ischemic infarct”, Science, 272, 1791-1794, 1996.
- [8] von Helmholtz, H. “Treatise on physiological optics”, Vol.3, The Optical Society of America, 1925.
- [9] Friston, K., Kilner, J. and Harrison, L., “A free energy principle for the brain” J. of Physiology - Paris, Vol.100, pp.70-87, 2006.
- [10] Friston, K., Daunizeau, J. and Kiebel, S.J., “Reinforcement learning or active inference?” PLoS ONE, Vol.4, No.7, e6421 2009.
- [11] 乾 敏郎, 坂口 豊, “自由エネルギー入門”, 岩波書店, p149, 2021.

- [12] Niedermeyer, E., & da Silva, F. L., “ Electroencephalography: Basic Principles, Clinical Applications, and Related Fields ” . Journal of Clinical Neurophysiology, 21(1), 50-63, 2004.
- [13] Farina, D., Merletti, R., & Enoka, R. M., “ The extraction of neural strategies from the surface EMG. ” Journal of Applied Physiology, 96(4), 1486-1495, 2004.
- [14] Ogawa, S., & Lee, T. M, “ Magnetic Resonance Imaging of Brain Activity during Memory Tasks: Toward an Integration of Brain Function and Structure. ” Science, 247(4932), 23-28, 1990.
- [15] Hans H. Kornhuber, Luder Deecke, “ Pflugers Archfur die gesamte Pysiologie des Menschen und der Tiere ” , June 1965.

本研究に関する発表文献

- [1] 加藤 一沙, 五十嵐 洋: “機械学習を用いた追従操作におけるサプライズの推定”, 日本バーチャルリアリティ学会, 2024.